分类号：_____ 单位代码：10335

密　级：无 学　　号：_____

浙江大学

# 硕士学位论文

中文论文题目 ：基于强化学习的无人帆船控制模型研究

英文论文题目 ：**The Research on Unmanned Sailboat Control Model Based on Reinforcement Learning**

申请人姓名：_____

指导教师：_____

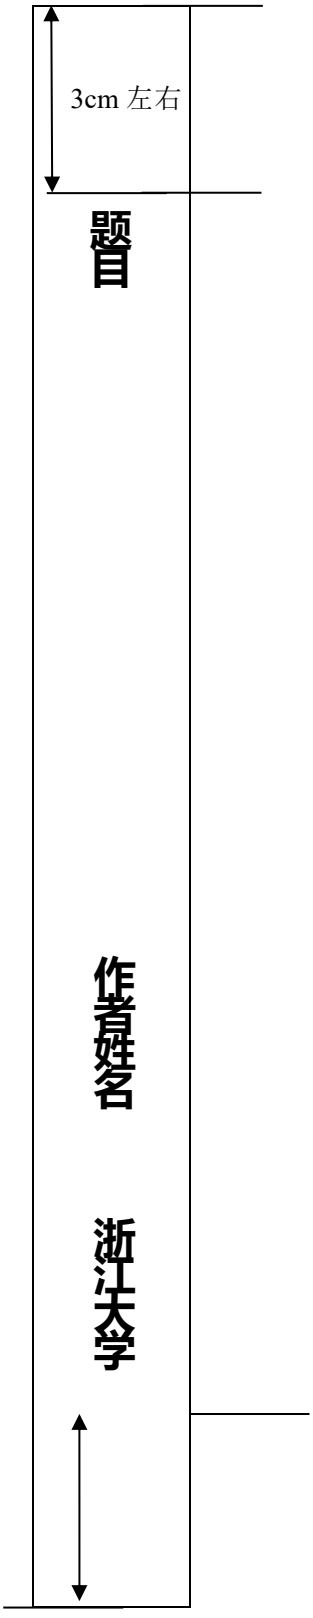
合作导师：_____

专业名称：_____

研究方向：_____

所在学院：_____

**论文提交日期：　二〇二六年六月**


3cm 左右
题目
作者姓名
浙江大学

# 基于强化学习的无人帆船控制模型研究

**论文作者签名:**_____

**指导教师签名:**_____

论文评阅人 1：(姓名\职称\单位,下同)

评阅人 2：盲审

评阅人 3：盲审

评阅人 4：

评阅人 5：

答辩委员会主席：(姓名\职称\单位)

委员 1：

委员 2：

委员 3：

委员 4：

委员 5：

答辩日期：

# The Research on Unmanned Sailboat Control Model Based on Reinforcement Learning

**Author's signature:_____**

**Supervisor' s signature:_____**

External Reviewers:_____(姓名\职称\单位,下同)_____

_____盲审_____

Examining Committee Chairperson:

_____(姓名\职称\单位)_____

Examining Committee Members:

_____

Date of oral defence：

# 浙江大学研究生学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得**浙江大学**或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：　　签字日期：　年　月　日

# 学位论文版权使用授权书

本学位论文作者完全了解**浙江大学**有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权**浙江大学**可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后适用本授权书）

学位论文作者签名：　　导师签名：

签字日期：年　月　日　　签字日期：年　月　日

# 致谢

××××××

# 摘要

无人帆船依托风能驱动，具有能耗低、续航时间长及适应海洋长期观测任务等优势，已逐渐成为海气界面观测与海洋数据采集的重要平台。在实际应用中，其自主航行能力直接关系到任务执行效率与运行安全。海洋环境中风场具有显著的时空变化特性，尽管现有方法通常依赖风速与风向信息实现有效控制，但在实际航行过程中，相关观测数据仍可能受到测量误差、时延及局部扰动等因素影响，从而对控制性能产生一定制约。因此，探索在有限或不完全环境信息条件下的自主航行方法，具有重要的研究意义。

围绕无人帆船自主航行问题，现有研究多基于环境信息可获取的前提，通过路径规划、制导与控制等分层策略实现稳定航行，并在常规场景中取得了良好效果。然而，这类方法主要面向信息条件较为充分的应用情形，对于环境信息受限条件下的控制问题关注相对较少。在此背景下，强化学习作为一种数据驱动方法，能够通过与环境交互直接学习控制策略，为在不完全信息条件下实现自主决策提供了一种新的技术路径。

基于此，本文以部分可观测条件下的无人帆船自主航行为研究对象，聚焦于航迹点之间的局部航行决策这一基础问题，提出一种无需显式风场信息的端到端强化学习控制方法。为支撑模型训练与验证，首先构建了融合无人帆船动力学特性的仿真交互环境，并在环境中引入动态风场、传感器噪声及执行器误差，使其能够更真实地刻画实际航行过程中面临的复杂扰动。在控制模型设计方面，基于 Soft Actor-Critic 算法构建端到端控制框架，实现由状态到控制量的直接映射，从而将控制策略的设计问题转化为数据驱动的策略学习问题。通过引入长短期记忆网络对历史状态序列进行建模，使模型能够从状态演化过程中捕捉环境变化的潜在规律，实现在无风场信息输入的条件下的稳定控制效果。在此基础上，为提升模型对复杂航行任务的适应能力，引入注意力机制对历史信息进行动态加权，从而实现对关键时序特征的自适应提取，增强决策过程的针对性。本文以静态障碍物场景为代表，对上述方法在典型复杂任务中的表现进行了验证。

通过多组对比实验，系统验证了所提出方法的有效性。结果表明，该方法在任务成功率、控制平滑性及复杂环境适应能力方面均表现出良好性能，并能

够在复杂风场环境、高噪声环境及障碍物场景下保持稳定表现。结合注意力权重分布的分析可以发现，模型在不同航行阶段能够动态调整对历史信息的关注重点，从而反映出其对关键决策信息的有效利用。这一现象说明，在部分可观测控制问题中，历史信息的选择性利用对于提升决策性能具有重要作用。

综上，本文研究表明，通过端到端强化学习框架结合时序建模与信息筛选机制，可以在不依赖显式环境信息的条件下实现有效的无人帆船自主航行控制。相关研究为复杂海洋环境下无人帆船智能航行方法的设计提供了一种具有潜力的技术路径，并为后续多阶段或全局航行任务的拓展奠定了基础。

**关键词**：无人帆船；强化学习；端到端控制；部分可观测环境；自主航行

# Abstract

Unmanned sailboats, powered by wind energy, offer advantages such as low energy consumption, long endurance, and suitability for long-term ocean observation missions, and have gradually become important platforms for air–sea interface observation and marine data collection. In practical applications, their autonomous navigation capability is crucial to both mission efficiency and operational safety. However, the marine wind field exhibits significant spatiotemporal variability. Although existing methods typically rely on wind speed and direction information to achieve effective control, such observations may be affected by measurement noise, time delays, and local disturbances in real-world scenarios, thereby imposing constraints on control performance. Therefore, exploring autonomous navigation methods under limited or incomplete environmental information is of considerable importance.

With regard to autonomous navigation of unmanned sailboats, existing studies are generally developed under the assumption that environmental information is available, and achieve stable navigation through hierarchical strategies involving path planning, guidance, and control. These approaches are physically interpretable and have been well validated in conventional scenarios. However, they are primarily designed for conditions with relatively sufficient environmental information, while studies addressing control under information-limited conditions remain comparatively limited. In this context, reinforcement learning, as a data-driven approach, provides a new paradigm for control design by enabling agents to learn control policies directly through interaction with the environment, thereby offering a promising solution for decision-making under incomplete information.

Motivated by the above considerations, this paper investigates autonomous navigation of unmanned sailboats under partially observable conditions, with a focus on the fundamental problem of local decision-making between waypoints. An end-to-end reinforcement learning control method that does not rely on explicit wind field information is proposed. To support model training and evaluation, a simulation environment incorporating the sailboat dynamics is constructed, in which dynamic wind fields, sensor noise, and actuator errors are introduced to realistically represent environmental disturbances encountered in practice. In terms of control design, a Soft Actor-Critic-based end-to-end framework is developed to establish a direct mapping

from system states to sail and rudder control commands, thereby reformulating the control problem as a data-driven policy learning task. Furthermore, a Long Short-Term Memory network is employed to model historical state sequences, enabling the agent to capture latent environmental dynamics from state evolution and achieve stable control without explicit wind information. To further enhance performance in complex navigation scenarios, an attention mechanism is introduced to dynamically weight historical information, allowing adaptive extraction of critical temporal features. Static obstacle scenarios are adopted as representative cases to evaluate the proposed method in typical complex tasks.

Extensive comparative experiments are conducted to validate the effectiveness of the proposed approach. The results demonstrate that the method achieves favorable performance in terms of task success rate, control smoothness, and adaptability to complex environments, while maintaining robustness under varying wind conditions, high noise levels, and obstacle scenarios. Analysis of attention weight distributions further reveals that the model dynamically adjusts its focus on historical information at different navigation stages, indicating effective utilization of key decision-relevant features. This observation highlights the importance of selective use of temporal information in partially observable control problems.

In conclusion, the proposed framework, which integrates end-to-end reinforcement learning with temporal modeling and information selection mechanisms, enables effective autonomous navigation of unmanned sailboats without relying on explicit environmental information. The results provide a promising direction for intelligent navigation in complex marine environments and lay a foundation for future extensions to multi-stage or global navigation tasks.

**Keywords:** Unmanned Sailboats; Reinforcement Learning; End-to-End Control; Partially Observable Environments; Autonomous Navigation

# 目 录

致谢 ..... I
摘要 ..... II
ABSTRACT ..... IV
目 录 ..... VI
1 绪论 ..... 1
1.1 研究背景与意义 ..... 1
1.2 国内外研究现状 ..... 4
1.2.1 无人帆船建模 ..... 4
1.2.2 无人帆船运动控制 ..... 6
1.3 研究内容与章节安排 ..... 9
2 相关原理知识 ..... 12
2.1 深度学习知识 ..... 12
2.2 强化学习知识 ..... 15
2.3 无人帆船动力学模型 ..... 21
2.4 本章小结 ..... 28
3 训练交互环境 ..... 29
3.1 引言 ..... 29
3.2 基础环境框架 ..... 29
3.3 实验任务设定 ..... 33
3.4 性能优化 ..... 35
3.5 本章小结 ..... 37
4 基于强化学习的无人帆船控制模型 ..... 38
4.1 引言 ..... 38
4.2 网络模型与算法 ..... 38
4.3 奖励函数 ..... 44
4.4 实验结果与分析 ..... 48
4.4.1 基线对比实验 ..... 48
4.4.2 模型鲁棒性测试 ..... 56

**4.4.3 敏感性分析 ..... 60**
**4.5 本章小结 ..... 62**
**5 面向静态障碍物环境的控制模型优化 ..... 63**
**5.1 引言 ..... 63**
**5.2 避障问题的优化方案 ..... 63**
**5.2.1 网络结构优化 ..... 63**
**5.2.2 避障环境 ..... 65**
**5.3 实验结果与分析 ..... 67**
**5.3.1 注意力机制对比实验 ..... 67**
**5.3.2 注意力滑动窗口长度对比实验 ..... 71**
**5.3.3 注意力权重分析 ..... 73**
**5.4 本章小结 ..... 78**
**6 结论与展望 ..... 79**
**6.1 主要结论 ..... 79**
**6.2 本文创新点 ..... 80**
**6.3 未来展望 ..... 80**
**参考文献 ..... 82**
**作者简历 ..... 89**

# 1 绪论

## 1.1 研究背景与意义

海洋科学是一门以观测为基础的数据密集型学科[1]。观测对于海洋科学研究至关重要,观测资料缺乏是制约海洋科学发展的瓶颈[2]。根据资料显示，海洋覆盖了地球表面约70%的面积,但仅有其中一小部分得到了探索(大约5%或更少)[3]。海洋多圈层相互作用是当今海洋科学的研究热点,其中之一是海气相互作用研究。海洋观测技术中的天基观测技术、海基观测技术、水下观测技术虽各有优点，但却无法满足海气界面长航时、大范围观测数据连续获取需求[4]。

近年来，随着海洋机器人技术与传感器技术的不断进步，海洋机器人现场采集数据逐渐取代传统的船基采样方式[5]，极大地提高了数据获取效率和数据质量[6]，促进了海洋科学的发展。目前，用于科学观测任务的海洋机器人主要包括水下滑翔机、AUV、无人帆船和波浪滑翔机等。与其他传统海洋移动观测平台相比，无人帆船与波浪滑翔机都是以海洋环境能源为驱动,可以实现海气界面环境要素低成本、长航时、大范围、高时空分辨率的自主连续观测的平台。而无人帆船在航速、适用水域方面相比较于波浪滑翔机具备更优秀的性能，在海表气象要素和浅水水文信息获取等方面显示出了较大的潜力，可以为海洋立体综合观测、海洋环境安全保障提供观测技术方法与先进平台支持[7]。

国外从20世纪90年代开始开展无人帆船的研究工作[8]，理论和实践发展较为迅速,无人帆船已进入业务化观测应用阶段。相关观测任务例如：1、由Saildrone公司开发的一艘配备科学传感器的自动驾驶帆船于2019年完成了环绕南大洋的航行,此次任务持续了196天，航行距离达11879海里,在南大洋获得了原位碳通量数据[9]。2、2021年美国国家海洋和大气管理局（NOAA）和Saildrone公司进行合作，使用帆船对飓风“山姆”进行监测，实现了风暴中心画面的实时传输，并获取了空气温度、气压、大气湿度、波高和洋流的数据，为飓风预测模型提供了依据[10]。3、2022年，两艘名为“TRITON”的自主航行船被部署在红海的苏沙哈岛附近，以收集和提供水深数据、视频和水化学采样数据，对于后续开展珊瑚礁景观的研究起到了至关重要的帮助[错误!未找到引用源。]。如图1.1所示包含了国外著名的无人帆船。

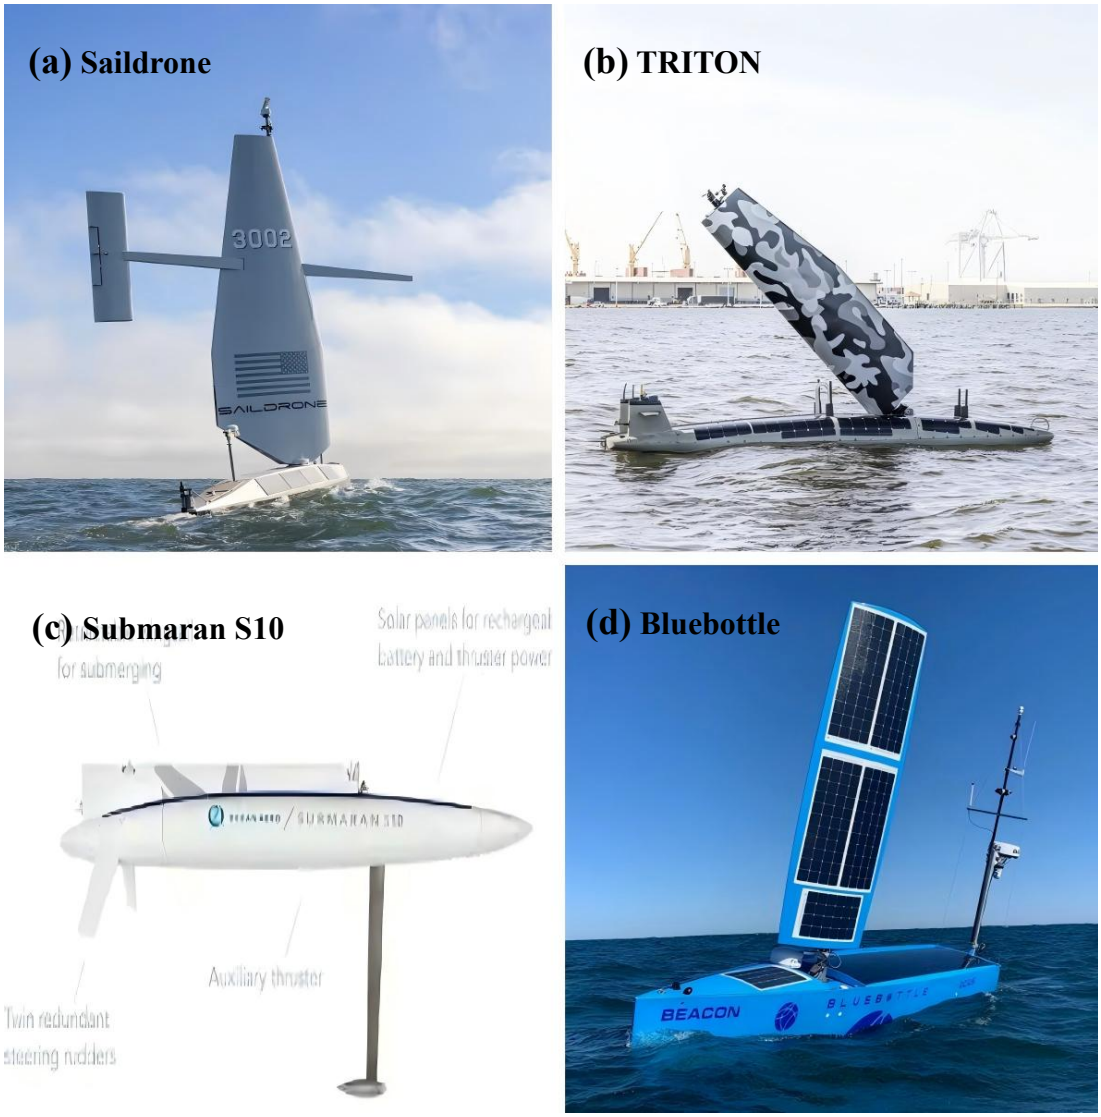



图 1.1 国外著名无人帆船。

Fig.1.1 Famous foreign unmanned sailboats.

国内无人帆船尚处于起步阶段，上海交通大学、香港中文大学、哈尔滨工程大学、浙江大学、大连海事大学、青岛大学等单位开展了相关研究工作，为推动我国无人帆船的发展做出了积极贡献[2]。中国科学院沈阳自动化研究所自 2018 年开始进行“海鸥号”无人帆船的研制工作[12]，至今已经开展了多次海试任务[13]并在技术领域取得了一定的成果[14][15]。浙江大学海洋学院的“信天翁”号无人帆船在 2025 年成功穿越“蝴蝶”、“韦帕”台风核心区域，掌握了台风运动时完整的气象、海浪等“一手资料”，意味着我国在海洋气象监测领域迈出了历史性一步[16]。如图 1.2 所示包含了国内开展研究及应用的无人帆船。




图 1.2 国内无人帆船。

Fig.1.2 Domestic unmanned sailboats.

目前无人帆船的关键技术主要聚焦于高海况适应性技术、风能高效利用技术和智能航行控制技术等[2]。其中智能航行控制技术是无人帆船从近海观测走向深蓝的关键一环。不同于常规螺旋桨驱动 USV，无人帆船的推进力完全来源于风场。风速与风向不仅决定推进效率，更直接影响航向稳定性、横倾角以及侧滑误差。风场既是驱动力来源，也是主要扰动源。

在典型的无人帆船控制框架中（GNC 体系），导航子系统往往假设可以获得相对风速或真风信息，并根据此完成帆角与舵角的精确追踪。然而，在执行海上长航时任务的过程中，风速风向传感器受到高盐雾、高湿度以及持续海浪冲击等恶劣海洋环境的影响，容易出现测量漂移、信号失真甚至设备失效等问题，从而导致获取的风场信息存在一定的不确定性。此外，在远海区域，由于缺乏稳定的

气象观测基础设施以及实时通信链路，外部风场数据的获取往往存在空间分辨率不足或更新延迟的问题。这些因素都会在一定程度上削弱依赖风场信息进行控制与决策方法的可靠性与鲁棒性。相比之下，基于无人帆船自身状态信息（如速度、航向、姿态以及历史控制输入等）进行决策与控制的方法，可以在不依赖外部风场测量的情况下，通过系统动态响应间接反映当前风场环境的影响，从而实现对未知或不完全可观测风场条件下的自主航行控制。这类方法能够作为现有基于风场信息控制策略的重要补充，提高无人帆船在复杂海洋环境中的自主性与任务可靠性。

## 1.2 国内外研究现状

本文主要的研究内容是无人帆船在部分可观测条件（无风场信息）下的控制策略，在本质上与常规控制策略相同，最终目标同样是追求高效可靠的风帆和船舵调节策略。因此下面将从完全可观测条件下的常规控制策略研究现状展开论述，具体可以分为帆船的建模以及运动控制两个部分。

### 1.2.1 无人帆船建模

无人帆船的数学建模问题是开展航行控制、路径规划与自主决策等研究的理论基础。精确而合理的动力学模型不仅关系到控制算法的设计效果，也直接影响仿真平台的可信度与工程应用的可行性。由于无人帆船在航行过程中同时受到气动力、水动力以及环境扰动等多重耦合作用，其动力学行为呈现出显著的非线性、强耦合与不确定性特征。因此，围绕动力学建模方法的研究一直是无人帆船领域的核心问题之一。

在现有研究中，基于分离式思想构建的 MMG（Maneuvering Modeling Group）模型被广泛应用于帆船及常规船舶的操纵运动分析，该模型最初由日本拖曳水池委员会船舶操纵运动数学模型研讨小组提出，其基本思想是将船舶所受的总体水动力与气动力进行分解建模，将复杂耦合的受力问题拆分为若干相对独立的子系统[17]。针对帆船而言，通常将受力分解为船体、龙骨、风帆与舵四个部分，并分别建立经验或半经验表达式，最终通过力与力矩的叠加获得整船的运动方程。该方法以操纵运动为研究核心，强调工程实用性与参数辨识的可操作性，能够较好地结合水池试验或实船试验数据进行模型修正。在自由度选取方面，针对无人帆船的运动特性，不同研究对动力学模型进行了不同程度的简化与扩展。Jaulin 等

人提出了一种三自由度模型[18]，主要考虑纵荡、横荡与艏摇运动，忽略横摇运动的影响。该模型假设帆船在常规航行状态下横摇幅度较小，对整体操纵性能影响有限，从而在保证计算效率的同时，保留对航向控制与路径跟踪具有主要影响的动力学分量。该类模型结构相对简洁，便于与控制算法结合，尤其适用于早期自主控制研究以及嵌入式系统资源受限的应用场景。后续研究表明，船体横摇会改变帆面的气动力分布，并影响龙骨产生的侧向水动力，从而对帆船航行性能产生重要影响[19]。因此，Xiao 等人在统一海洋航行器非线性动力学框架的基础上构建了四自由度模型[20]。该框架源于 Fossen 提出的海洋航行器六自由度非线性动力学理论[21-23]，其模型结构具有严格的数学性质，包括惯性矩阵对称正定、科氏与离心矩阵满足反对称条件等，有利于稳定性分析与控制律设计。Xiao 等人通过合理裁剪自由度，保留纵荡、横荡、横摇与艏摇四个自由度，并针对帆船的气动特性引入风帆气动力模型与侧向水动力模型，形成适用于帆船的动力学表达。

上述帆船动力学模型往往不能够直观的表现帆船在不同风向、风速条件下的航行性能特征。因此，在航海工程领域通常引入速度极线图（polar diagram）进行性能表征，例如图 1.3 所示。速度极线图通常由速度预测程序（Velocity Prediction Program, VPP）计算得到，也可以通过水池试验或实船航行试验数据进行标定，为后续的路径规划与控制策略提供依据。最早的速度预测程序由 MIT 的 Kerwin 在上世纪 70 年代开发[24]，近年来结合其他领域的计算方法突破，速度预测程序的精度和速度也逐渐得到提升[25-27]。

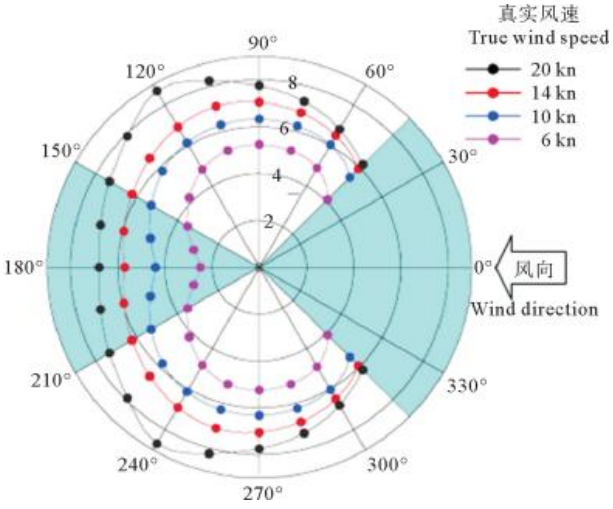



图 1.3 速度极线图[28]。

Fig.1.3 Velocity Polar diagram.

基于以上的数学模型，研究人员搭建了一些通用性的数值模拟平台，例如

Robotx[29]、USVSim[30]等。其中 USVSim 主要面向复杂条件下的控制验证，所包含的环境因素以及船体自由度最丰富，几乎涵盖了水面航行中的各类要素。

总体来看，国内外在帆船建模方法与建模工具方面已较为成熟，相关模型的计算结果也得到了广泛认可，当前研究重点逐渐转向风帆与船体结构设计以及关键性能参数的测量与优化[14]。

### 1.2.2 无人帆船运动控制

无人帆船的运动控制系统通常采用 GNC（Guidance，Navigation and Control）体系结构。这一体系广泛应用于各类航行器领域，其核心思想是通过分层结构实现从任务决策到执行控制的运行：制导（Guidance）模块负责基于指定任务生成期望航行和路径；导航（Navigation）模块负责状态估计与环境感知；控制（Control）模块根据参考指令产生舵角与帆角控制，实现具体的运动响应[31]。自主无人帆船的 GNC 系统如图 1.4 所示。

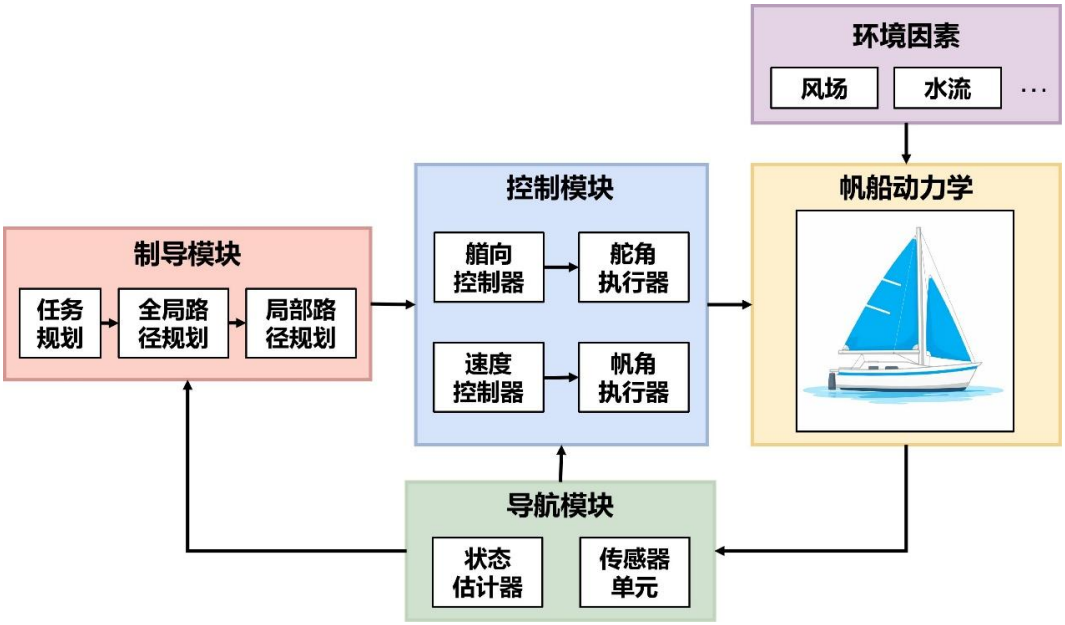



图 1.4 无人帆船 GNC 系统。

Fig.1.4 Unmanned sailboat GNC system.

(1)导航模块

导航模块的核心任务是对帆船自身状态（位置、速度、航向角等）及外部环境（风速、风向等）进行估计和融合，为制导模块和控制模块提供可靠的输入。对于仿真环境，导航模块可以等效看做 1.2.1 节中的动力学模型，通过模型迭代提供相应数据。在实际平台应用中，导航模块通常采用多传感器融合的结构，通过集成全球定位系统（GPS）、风速仪和惯性测量单元（IMU）实现状态估计，并

通过滤波算法实现多源信息融合以提高姿态与速度估计精度[32]。

(2)制导模块

制导模块包含任务规划器和全局/局部路径规划器，其中包括帆船到达目的地的轨迹，同时还会考虑各种限制条件，例如：障碍物、帆船动力学以及环境因素。在出现特殊情况时，制导模块必须能够实时重新规划并更新路径，使其保持所期望的轨迹。然后，制导会将所期望的轨迹发送给控制模块。全局路径规划主要负责将设定好的具体任务进行拆解，在已知风场地图和障碍物分布信息的条件下，生成航迹点序列。局部路径规划则侧重于相邻航迹点之间结合实时的环境感知结果进行轨迹修正和动态避障。

在全局路径规划方面，研究人员多采用经典的 A*算法和 Dijkstra 算法并针对海上环境进行相应优化。ASV Roboat 系统采用基于 A*的路径规划器，并引入天气预报信息进行代价函数修正，以实现对风场变化的适应性规划[33]。Yuan 等人通过构建 24 邻域搜索结构，并结合速度极线图对 A*算法进行改进，在保证可行性的同时增强了对风向变化与操纵约束的鲁棒性[34]。Saoud 等人则将 Dijkstra 算法与概率路线图（PRM）以及速度预测程序（VPP）相结合，将优化目标由传统的最短路径长度转变为最短航行时间，使规划结果更符合帆船动力学特性与风能利用效率[35]。除传统图搜索算法外，生物启发式与群体智能方法也被广泛引入全局路径规划问题。蚁群优化（Ant Colony Optimization, ACO）及其改进形式在处理非凸搜索空间与多约束优化问题中展现出优势。改进蚁群算法（IACO）[36]与滚动窗口蚁群算法（RIACO）[37]通过在信息素更新与路径评价机制中嵌入风场信息与环境约束，使规划结果更加符合实际海况需求。此外，部分研究将遗传算子融入粒子群算法（PSO）以增强全局搜索能力[38]，或引入 Q-learning 与高斯过程 Q-learning 以提升策略泛化能力[39][40]。针对帆船在逆风条件下的性能退化问题，还有研究构建了基于强化学习的全局规划器，通过与风场交互学习最优策略，实现对禁航区与不可达风向区域的自适应规避[41]。总体而言，上述方法逐步实现了由“几何最优”向“动力学可行且时间最优”的规划范式转变。

在局部路径规划层面，研究重点主要集中于航迹跟踪与动态环境适应。视线法（Line-of-Sight, LOS）因结构简洁、实现方便而成为航迹跟踪中的经典方法。Plumet 等人提出了一种基于 LOS 的吸引势函数构造方式，并在此基础上叠加与

航行速度相关的排斥项，使得帆船在接近障碍物或受限区域时能够平滑调整航向[42]。势场法（Potential Field, PF）同样被广泛应用于局部路径规划，其核心思想在于构建目标点的吸引势与障碍物的排斥势，实现实时航向修正。Saoud 等人和 Yuan 等人在势场框架下结合实时 VPP 优化，将风能利用效率与航行速度信息嵌入势函数设计中，从而提升了算法对动态海洋环境与风场扰动的适应能力[34][35]。项天远针对可变风场环境，利用海洋风场的季节性变化规律，建立了空间概率势场，并将概率势场作为寻求最优路径时启发函数的组成因子，使其倾向于选择使风向概率势场变大的解，结果表明该方法可以使无人帆船航行时间变短[43]。康梦萁等人针对无人帆船短途最优路径问题提出了速度最优法，并在逆风工况和风场变化频繁情况下对其进行验证，结果表明该方法可以达到无人帆船短途航行要求[44]。

（3）控制模块

控制模块利用来自制导模块的规划轨迹以及包括导航模块传感器信息在内的估计状态，确定具体的航行方向以及期望速度。帆船的动力学表现为多输入多输出（Multiple-Input Multiple-Output，MIMO）系统，其中舵角用于控制航向角，而帆角则用于控制帆船速度。尽管在理论研究中帆角和舵角的控制存在着一定耦合性，但在实际应用中通常会通过如上图 1.4 所示的独立执行器来实现简化处理[31]。

艏向控制通常视为闭环控制，现有研究大体可归纳为三类：（1）基于航向误差最小化的控制方法；（2）基于优化框架的控制方法；（3）基于智能或人工智能的控制策略。第一类方法以经典反馈控制为代表，包括比例控制器（P 控制）、比例–积分–微分（PID）控制器、线跟踪算法[45]以及自动转向机制[46]等。这类方法结构清晰、实现简单，对模型依赖程度较低，在中低速或风况相对稳定的场景下具有良好的鲁棒性和工程可实现性。针对帆船动力学强非线性的特点，研究者进一步引入非线性控制理论。反馈线性化方法[47][48]通过对系统非线性项进行补偿，使闭环系统近似转化为线性系统，从而在一定程度上提升了控制精度。反步法（Backstepping）[49][50]则基于李雅普诺夫稳定性理论逐级构造虚拟控制量，能够在存在模型不确定性与外界扰动的条件下保证系统渐近稳定。然而，反步法在递推设计过程中易产生所谓的“项数爆炸”问题，为此，动态面控制（Dynamic Surface

Control）等改进方法被提出，用以引入低通滤波器替代高阶导数计算，从而缓解复杂度急剧增加的问题[51]。在传统反馈控制方法之外，近年来研究者逐渐将优化理论引入无人帆船的艏向控制问题，形成了第二类基于优化框架的控制方法，例如：LQR（Linear Quadratic Regulator）、MPC（Model Predictive Control）等。Aeolus项目采用了 LQR 方法来设计一种无约束的最优转向控制器，其转向速度比非线性比例控制器更快，且在最终时刻，偏航角和航向误差均为零，且没有出现超调现象[52]。Dong 等人的研究中考虑了高斯模型，并结合了模型预测控制（MPC），将其称为高斯过程模型预测控制（GPMPC），以提高存在噪声情况下的跟踪精度[53]。Liu 等人的研究提出了一种协同的模型预测控制方法，该方法能够同时控制舵和帆以实现路径跟踪，并且还能保持横摇角度[54]。第三类基于智能或人工智能的控制策略则聚焦于通过状态机（SM）、模糊控制、机器学习等方式来形成控制律。Sun 等人将帆船换舷（tacking）过程划分为初始、左转、右转、无风和加速五种状态，并依据帆船在场地中的位置及航向在这些状态之间切换，同时通过设定最大舵角或零舵角实现相应的转向策略[55]。Chen 等人使用强化学习方式实现了航行过程中帆和舵的协同控制[56]。

在速度控制方面，传统方法通常依据帆船速度极线图构建查找表，通过当前相对风向与风速确定最优帆角[57][58]。该类方法计算量小、实时性强，但对风场变化的适应能力有限。另一类方法则采用模糊逻辑规则[59][60]，通过专家经验构建风向-风速-帆角之间的映射关系，在一定程度上增强了对不确定性的适应性。近年来，为提升在复杂环境中的鲁棒性，有学者将反馈线性化或反步法等自适应非线性控制器与在线参数更新机制相结合，实现帆角的实时优化调节[61]。

综上所述，无人帆船控制模块的研究已由早期的经典线性控制方法，逐步发展至融合非线性控制理论与数据驱动方法的多层次框架。未来的发展趋势将更加侧重于舵帆协同、模型与数据融合以及在复杂海况下的鲁棒自适应能力提升，为实现长期自主航行与远海复杂任务执行提供坚实的理论与技术支撑。

## 1.3 研究内容与章节安排

本文主要研究基于强化学习的无人帆船控制模型，将局部航行的路径规划和路径追踪问题转化为马尔科夫决策过程，最终以一种端到端的方式为帆舵执行器提供角度参考值，实现航迹点之间的局部航行任务，并通过仿真分析来验证模型

的有效性。本文的章节安排如下：

第一章为绪论介绍无人帆船的研究背景以及本课题的研究意义、国内外发展现状和论文的主要内容与结构。

第二章主要介绍后续章节中所涉及到的一些原理基础，包括深度学习和强化学习的基础知识，无人帆船的动力学模型。

第三章主要对所构建的仿真交互环境进行系统性介绍。首先，在整体框架设计方面，基于 OpenAI Gym 构建仿真平台，完成无人帆船动力学模型的搭建，并给出相应的数值迭代求解方法。在外部环境建模方面，引入基于 Dryden 模型的动态风场，以模拟真实海洋环境中的风场扰动特性；同时，在交互过程中考虑传感器噪声与执行器误差，以增强仿真环境的真实性与复杂性。在此基础上，进一步明确后续研究所针对的典型实验任务，为强化学习模型的训练与评估提供统一场景设定。最后，针对强化学习训练过程中环境交互效率问题，对环境-模型交互速度提出可行的优化思路，从而提升整体训练效率。

第四章围绕部分可观测环境下无人帆船的局部航行控制问题展开研究。首先，从马尔可夫决策过程的角度分析部分可观测环境与完全可观测环境之间的本质差异，并综述强化学习在机器人领域中应对部分可观测问题的典型方法。在此基础上，针对本研究任务特点，对控制模型的网络结构进行优化设计，并构建能够适应不同风向条件的奖励函数。在实验验证方面，选取基于模型预测控制（MPC）的端到端控制方法作为对照基线，对所提出方法的有效性进行系统评估。同时，在不进行后训练微调的条件下开展鲁棒性测试，以检验模型在环境扰动下的泛化能力。最后，通过敏感性分析量化各输入特征对决策结果的影响，模型的可解释性进行讨论。

第五章主要围绕无人帆船局部航行中的避障问题展开研究。在第四章路径规划与跟踪控制研究的基础上，进一步分析无人帆船在局部动态环境中可能面临的典型避障场景。针对避障任务需求，对仿真交互环境及奖励函数进行针对性改进，从而实现避障策略的有效学习。同时，引入注意力机制以增强模型对时序信息的选择性利用能力，提升复杂环境下的决策性能。通过构建对比实验，验证了注意力机制在避障任务中的有效性；并进一步通过不同注意力滑动窗口长度的对比实验，以及典型航行过程中的注意力权重分布分析，揭示了模型对历史信息的利用

特性及其对避障决策的影响机制。

第六章对本研究的主要工作和创新点进行总结，并客观指出当前研究中存在的不足，并对未来进一步的研究方向提出展望。

本文的研究框架如图 1.5 所示：

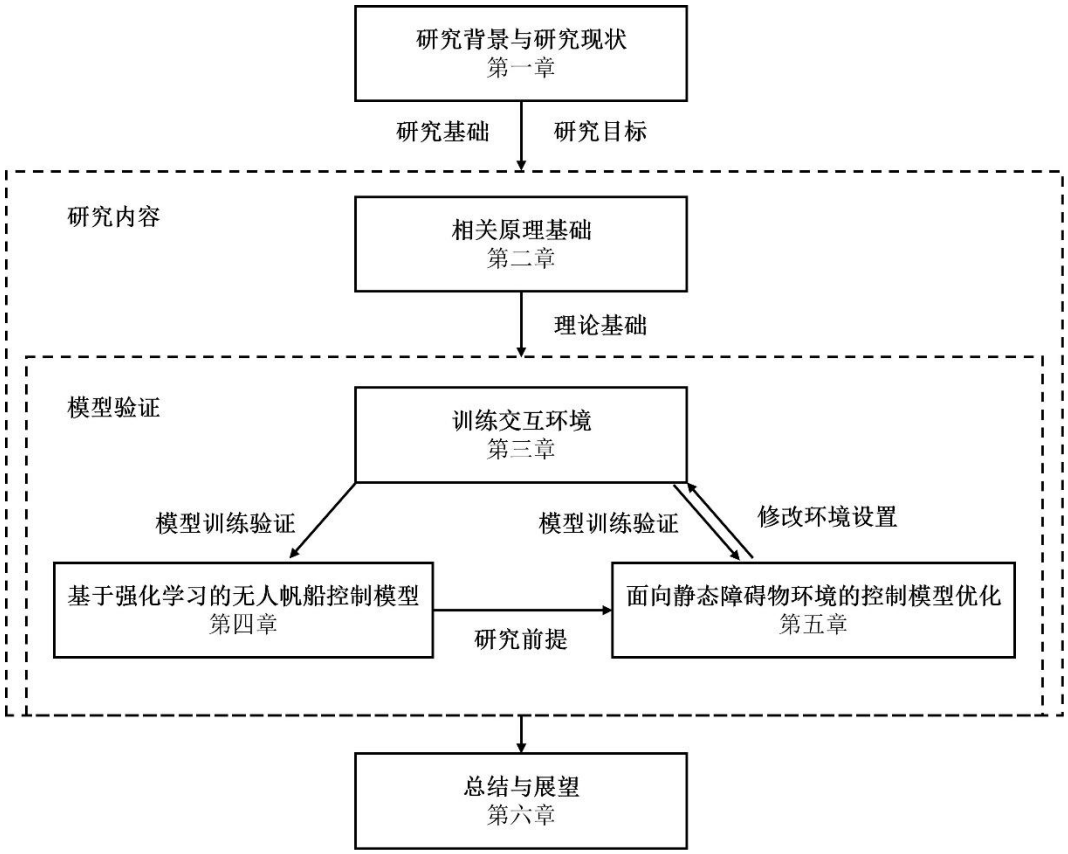



图 1.5 论文研究框架。

Fig.1.5 Research framework of the thesis.

# 2 相关原理知识

## 2.1 深度学习知识

深度学习是机器学习的一个分支,主要基于神经网络模型,通过多个层次(深度)进行特征的自动学习。传统的机器学习算法一般要求手动提取特征，而深度学习模型则能够从数据中自动学习特征，使其在图像识别、自然语言处理、语音识别等复杂任务中表现优异。

（1）神经网络的基础结构

深度神经网络（DNN）是一种前馈神经网络，通常由输入层、隐含层和输出层组成，如图 2.1 所示。每个神经元（节点）通过加权输入连接到上一层或上一层的神经元。神经网络的目的是学习输入与输出之间的映射关系。

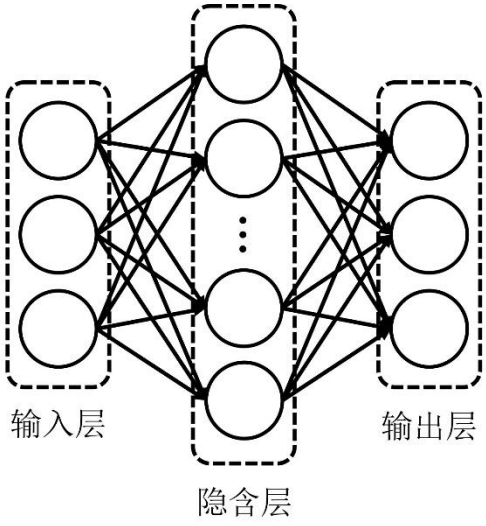



图 2.1 深度神经网络。

Fig.2.1 Deep Neural Network.

每一层的神经元通过公式（2. 1-1）的计算将信号传递给下一层,：

$$a_i^{(l)} = f\left(\sum_{j=1}^{n_{l-1}} w_{ij}^{(l)} a_j^{(l-1)} + b_i^{(l)}\right) \tag{2. 1-1}$$

其中：$a_i^{(l)}$是层$l$中第$i$个神经元的输出;$w_{ij}^{(l)}$是层$l$中第$i$个神经元与层$l-1$中第$j$个神经元的连接权重;$a_j^{(l-1)}$是层$l-1$中第$j$个神经元的输出;$b_i^{(l)}$是层$l$中第$i$个神经元的偏置。通过激活函数$f$进行非线性变换。

常见的激活函数包括 ReLU、Sigmoid（$\sigma$）、tanh 等，激活函数的非线性特性使得神经网络能够表示复杂的非线性映射关系。具体计算如公式（2.1-2）、（2.1-

3）、（2.1-4）所示：

$$ReLU(x) = max(0, x) \tag{2.1-2}$$

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{2.1-3}$$

$$tanh\ (x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}} \tag{2.1-4}$$

在后续的章节中会讨论到全连接层网络，全连接层网络是深度神经网络的一种基本实现形式，其特点是相邻两层之间的神经元均通过权重进行完全连接。通过堆叠多个全连接层，可以构建具有较强非线性表达能力的深度神经网络模型。本文在后续模型设计中也将采用全连接层网络作为基础的网络结构。

（2）反向传播与梯度下降

神经网络的训练通常通过反向传播算法实现，其目标是通过调整网络参数，使模型输出逐渐逼近期望目标。反向传播算法的核心思想是利用链式法则计算损失函数相对于网络参数的梯度，并将误差信息从输出层逐层向前传播至各隐含层。设损失函数为$L$，网络中的权重参数为$w_{ij}$，则可以通过链式法则计算损失函数关于该权重的梯度$\frac{\partial L}{\partial w_{ij}}$。该梯度反映了参数变化对损失函数的影响程度。通过计算各层参数的梯度，可以获得网络参数的更新方向，从而对权重进行迭代优化。通常采用基于梯度下降的优化方法对参数进行更新，其基本形式表示为公式（2.1-5）：

$$w_{ij} = w_{ij} - \eta \frac{\partial L}{\partial w_{ij}} \tag{2.1-5}$$

其中，$\eta$为学习率，用于控制参数更新的步长。通过不断重复前向传播与反向传播的过程，神经网络能够逐步调整参数，使得模型输出不断逼近目标函数，从而实现对复杂输入输出关系的有效建模。

（3）长短期记忆网络（LSTM）

本文将在第四章中对涉及到的部分可观测环境问题进行详细说明，并且引入LSTM 网络以应对这一问题，因此在本节中对 LSTM 的基础原理进行介绍。

LSTM 是一种特殊的循环神经网络（RNN），通过引入门控机制，能够控制信息的记忆和遗忘，能够有效地解决标准 RNN 在处理长序列时的梯度消失或爆炸问题[62]。

LSTM 的关键在于它的单元状态和门控结构。LSTM 的每一个时间步长都有四个主要组件：遗忘门、输入门、单元状态和输出门，具体结构表现如图 2.2 所示。

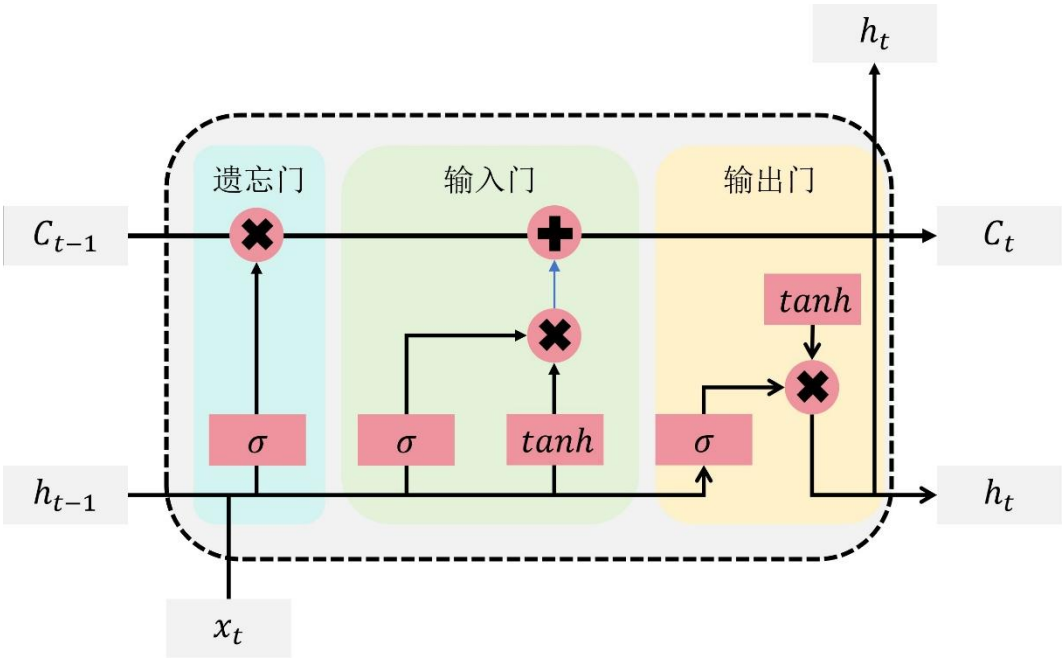



图 2.2 长短期记忆网络结构。

Fig.2.2 Long Short-Term Memory Network Structure.

四个组件的具体计算过程如下：

1.遗忘门

遗忘门决定了当前单元状态中哪些信息将被丢弃。遗忘门的输出是一个介于 0 和 1 之间的值，表示保留的信息的比例，如公式（2.1-6）：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \tag{2.1-6}$$

其中：$f_t$是遗忘门的输出，$\sigma$是 Sigmoid 激活函数。$W_f$是遗忘门的权重矩阵，$h_{t-1}$是前一时刻的隐含状态，$x_t$是当前时刻的输入，$b_f$是偏置项。

遗忘门通过 Sigmoid 函数输出的值决定了上一时刻的单元状态$C_{t-1}$中每个元素的遗忘程度。例如，若某个元素的遗忘门输出接近 0，则该信息将在当前单元状态中被丢弃。

2.输入门

输入门决定了哪些新的信息将写入单元状态。输入门由两部分组成：一部分是通过 Sigmoid 函数控制多少新信息可以写入，另一部分是通过 tanh 函数生成候选值，这些候选值将被加到单元状态中,如公式（2.1-7）（2.1-8）：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.1\text{-}7)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2.1\text{-}8)$$

其中：$i_t$是输入门的输出，$\tilde{C}_t$是当前时刻的候选单元状态。$W_i$和$W_C$是相应的权重矩阵，$b_i$和$b_C$是偏置项。

3.单元状态

LSTM 通过单元状态来维护长时记忆。当前时刻的单元状态$C_t$是上一时刻单元状态与遗忘门输出的加权和，再加上输入门输出的新信息，如公式（2.1-9）：

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (2.1\text{-}9)$$

其中：$C_t$是当前时刻的单元状态。$C_{t-1}$是上一时刻的单元状态。$f_t$和$i_t$分别是遗忘门和输入门的输出。

4.输出门

输出门决定了当前时刻的隐含状态（即当前时间步的输出）。隐含状态的计算是通过当前单元状态的 tanh 值与输出门的 Sigmoid 值进行加权,如公式为：

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.1\text{-}10)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (2.1\text{-}11)$$

其中：$o_t$是输出门的输出，$h_t$是当前时刻的隐含状态。$C_t$是当前时刻的单元状态，$\tanh(C_t)$是对单元状态进行非线性变换后的结果。

## 2.2 强化学习知识

强化学习（Reinforcement Learning, RL）是一种使智能体能够通过与环境的交互来学习策略的机器学习方法。与传统的监督学习和无监督学习不同，强化学习关注的是如何通过试错方式优化决策过程。在强化学习中，智能体通过执行一系列动作与环境互动，并根据环境反馈的奖励来调整自己的策略，使得自身策略能够在未来的决策中获得最大化的累积奖励。

强化学习的核心元素包括智能体、环境、状态、动作、奖励和策略。智能体（Agent）：智能体是决策者，它通过在环境中执行动作来影响环境的状态。环境（Environment）：环境是智能体所处的世界，它会根据智能体的动作反馈状态和奖励。状态（State,$s_t$）：状态是环境在某一时刻的描述，反映了环境的当前条件。动作（Action,$a_t$）：智能体在某一状态下执行的行为。奖励（Reward,$r_t$）：智能体执行动作后从环境中获得的反馈信号，用于指导策略的优化。策略（Policy, $\pi$）：

策略是智能体选择动作的概率分布，它决定了智能体在每个状态下应该选择哪个动作。各要素关系如图 2.3 所示。

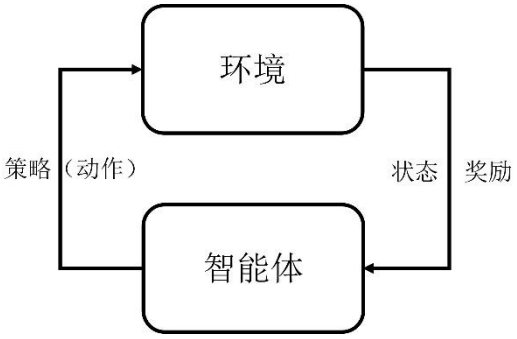



图 2.3 强化学习交互过程。

Fig.2.3 The interaction process of reinforcement learning.

上述元素通过强化学习的数学基础和建模工具——马尔科夫决策过程（Markov decision Process，MDP）构建起逻辑关联。一个 MDP 通常由状态空间、运动空间、奖励函数、状态转移函数、折扣率等构成。可以表示为如公式（2.2-1）的五元组：

$$\mathcal{M} = (S, A, P, R, \gamma) \tag{2.2-1}$$

其中$S$表示状态空间；$A$表示动作空间；$P(s' \mid s, a)$是状态转移概率，表示从状态$s$执行动作$a$后转移到状态$s'$的概率；$R(s, a)$是奖励函数，表示在状态$s$执行动作$a$后获得的奖励；$\gamma$是折扣因子（数值范围在 0 到 1 之间），决定了未来奖励的价值。

马尔科夫性假设未来的状态仅依赖当前状态与动作，如公式（2.2-2）：

$$P(s_{t+1}|s_t, a_t, \dots) = P(s_{t+1}|s_t, a_t) \tag{2.2-2}$$

在此框架下，策略$\pi(a \mid s)$描述在状态$s$下选择动作$a$的概率分布。策略一旦确定，智能体与环境的交互过程中将生成一条随机轨迹，如公式（2.2-3）：

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots) \tag{2.2-3}$$

正如前文所述，强化学习的核心问题可以表述为在未知转移概率的条件下，如何通过交互学习最优策略，其核心目标在于最大化累积回报。

在某一具体交互过程中，定义从时刻$t$开始的折扣回报如公式（2.2-4）：

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k} \tag{2.2-4}$$

其中$r_{t+k}$表示从当前时刻开始，相对应状态和动作在奖励函数计算下的奖励值。

则核心问题的目标函数可以定义为公式（2.2-5）：

$$J(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^t r_t\right] \tag{2.2-5}$$

该表达式反应了策略在长期运行下的期望收益，获取最优策略可以等效看做最大化目标函数的值，具体表示为：

$$\max_{\pi} J(\pi) \tag{2.2-6}$$

这一目标函数$J$是强化学习所有算法设计的理论核心。无论是基于值函数的方法，还是基于策略梯度的方法，本质上都是在不同层面逼近该优化目标。直接对$J(\pi)$进行优化通常较为困难，因此引入价值函数以分解长期收益结构。定义状态价值函数以及动作价值函数，如公式（2.2-7）（2.2-8）：

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s] \tag{2.2-7}$$

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi}[G_t \mid s_t = s, a_t = a] \tag{2.2-8}$$

前者刻画在给定状态下遵循策略所能获得的期望回报，后者则进一步区分具体动作的影响。二者之间满足：

$$V^{\pi}(s) = \mathbb{E}_{a\sim\pi}[Q^{\pi}(s,a)] \tag{2.2-9}$$

由于 MDP 具有时间递归特性，价值函数满足贝尔曼期望方程，如公式（2.2-10）（2.2-11）：

$$V^{\pi}(s) = \mathbb{E}_{a\sim\pi}[R(s,a) + \gamma\mathbb{E}_{s'}V^{\pi}(s')] \tag{2.2-10}$$

$$Q^{\pi}(s,a) = R(s,a) + \gamma\mathbb{E}_{s'}\mathbb{E}_{a'\sim\pi}Q^{\pi}(s',a') \tag{2.2-11}$$

上述方程揭示了长期价值可以表示为即时奖励与未来价值的加权和，这一本质递归结构使得动态规划成为可能。当目标转向最优策略时，可得到贝尔曼最优方程,如下：

$$Q^{*}(s,a) = R(s,a) + \gamma\mathbb{E}_{s'}\max_{a'} Q^{*}(s',a') \tag{2.2-12}$$

其解对应最优动作价值函数。理论上，一旦$Q^{*}(s,a)$被精确求解，即可通过贪婪策略获得最优控制策略，如公式（2.2-13）：

$$\pi^{*}(s) = \arg\max_{a} Q^{*}(s,a) \tag{2.2-13}$$

早期强化学习研究主要围绕值函数的逼近与求解展开。在离散且规模有限的状态–动作空间中，基于值函数的方法取得了显著成功。例如，Q-learning 通过对

贝尔曼最优方程进行随机逼近，实现了无模型条件下的最优价值迭代[63]；SARSA则在策略评估与改进过程中采用在策略更新机制，提升了学习稳定性[64]。随着深度神经网络的发展，深度 Q 网络（DQN）进一步利用函数逼近器刻画高维状态下的动作价值函数，并通过经验回放与目标网络机制缓解训练不稳定问题，使值函数方法在高维离散决策问题中取得突破性进展[65]。

然而在连续高维空间中，精确求解该方程往往不可行，尤其当动作空间为连续变量时，$\max_{a'} Q(s',a')$难以解析计算。为突破这一瓶颈，研究重心逐渐转向直接对策略进行参数化与优化的方法。随着深度神经网络在高维非线性函数逼近中的成功应用，策略不再局限于线性或低维参数化形式，而是通过深度网络实现复杂映射结构的表达能力，由此形成了以神经网络为核心的深度策略梯度框架。

在此框架下，我们可以设参数化策略为$\pi_\theta(a \mid s)$，其中$\theta$表示网络权重参数，则强化学习的优化目标可以表述为在该策略诱导的轨迹分布$\tau \sim \pi_\theta$下最大化期望累积回报，如公式（2.2-14）：

$$J(\theta) = \mathbb{E}_{\tau\sim\pi_\theta}[\sum_t \gamma^t r_t] \tag{2.2-14}$$

根据策略梯度定理，其梯度形式表示为公式（2.2-15）：

$$\nabla_\theta J(\theta) = \mathbb{E}[\nabla_\theta \log \pi_\theta(a \mid s)\, Q^{\pi_\theta}(s,a)] \tag{2.2-15}$$

这一表达式的重要意义在于：策略参数的更新无需对环境动力学建模，只需利用轨迹采样即可获得无偏梯度估计，从而实现端到端的策略优化。然而，直接使用动作价值函数作为权重会导致梯度估计方差较大。为提高训练稳定性，通常引入基线函数$b(s)$，在不改变期望的前提下降低方差。当基线选取为状态价值函数$V(s)$时，可得到优势函数以及更稳定的更新形式，如公式（2.2-16）（2.2-17）：

$$A(s,a) = Q(s,a) - V(s) \tag{2.2-16}$$

$$\nabla_\theta J(\theta) = \mathbb{E}[\nabla_\theta \log \pi_\theta(a \mid s)\, A(s,a)] \tag{2.2-17}$$

Actor-Critic 结构的提出就是在保持策略梯度更新形式不变的前提下，引入一个价值函数估计网络来近似$V(s)$或$Q(s,a)$，以构造低方差、可实时更新的优势估计；同时，由策略网络负责参数化并更新$\pi_\theta(a \mid s)$。因此，AC 结构本质上是对策略梯度方法在网络结构层面的升级，通过双网络协同学习实现策略优化与价值评估的统一[66]。

针对无人帆船控制这一典型的连续高维控制问题，本研究在后续实验中所使用的算法均为目前主流的基于策略梯度的方法，包括 PPO、SAC、TD3。下面将对这三种算法的核心优化点进行说明并进行整体的对比。

PPO（Proximal Policy Optimization）是一种基于策略梯度的近端更新方法，其核心在于通过限制策略更新步长来保证训练过程的稳定性[67]。传统策略梯度在更新过程中若步长过大，容易导致策略性能骤降。PPO 通过构造带裁剪的目标函数，将策略更新限制在“信赖域”附近，从而在不显式计算 KL 散度约束的情况下，实现对策略变化幅度的控制。其优势在于结构简洁、实现稳定、对超参数敏感度较低，适用于中等复杂度的连续控制问题。然而，由于 PPO 属于 on-policy 方法，样本利用率相对较低，在需要大量交互数据的复杂环境中，训练效率受到限制。

与 PPO 不同的是，TD3 和 SAC 均属于 off-policy 方法，通过反复使用经验回放池中的历史数据进行网络参数迭代，大大提升了样本利用率。

TD3（Twin Delayed Deep Deterministic Policy Gradient）属于确定性策略梯度框架下的改进型 Actor–Critic 算法，其核心目标是缓解值函数过估计问题[68]。TD3 通过构建双 Q 网络结构，采用“取最小值”策略抑制过估计偏差，同时引入目标策略平滑和延迟更新机制，减少策略网络过快跟随不稳定 Q 函数更新的问题。

SAC（Soft Actor-Critic）在 TD3 等基于确定性策略梯度的方法基础上，引入最大熵强化学习思想，将策略优化目标从单一的期望回报最大化扩展为回报与策略熵的联合优化。在此框架下，策略由确定性函数转变为随机策略分布，通过对动作的不确定性建模增强探索能力，并在一定程度上避免了确定性策略在复杂环境中易陷入局部最优的问题，从而提升了学习过程的稳定性与泛化性能。其优化后的策略目标函数如公式（2.2-18）：

$$J(\pi) = \mathbb{E}\left[\sum_{t} r\left(s_t, a_t\right) + \alpha \mathcal{H}\left(\pi(\cdot|\, s_t)\right)\right] \tag{2.2-18}$$

其中：$\alpha$代表温度系数，是控制熵项与奖励项之间权衡的超参数。通过调节$\alpha$的值，SAC 控制探索与利用之间的平衡：较大的$\alpha$使得策略更倾向于探索（即更高的随机性），较小的 $\alpha$则会使策略更集中于利用已知的高回报行为。在 SAC 中，$\alpha$是一个可调的超参数，通常通过自动调整来实现最优的探索利用平衡。$\mathcal{H}(\pi(\cdot|$

$s_t))$代表策略的熵（Entropy），用于度量策略的随机性，$\pi(\cdot|\ s_t)$定义了状态$s_t$下选择不同动作的概率分布（在 SAC 中通常是连续的正态分布）。

对于上述三类算法，在实际应用过程中通常会使用到以下几类技术：

1、双 Q 网络

双 Q 网络是为了解决传统 Q 学习方法中的过估计偏差问题而提出的[70]。在 Q 学习中，由于使用同一套 Q 值来选择动作并进行更新，这会导致 Q 值的过度估计，进而影响策略的学习效果。为了克服这一问题，双 Q 学习引入了两套独立的 Q 函数。具体来说，分别使用两个 Q 网络进行动作选择和更新，这样可以减少 Q 值的过度估计。在策略梯度方法中，双 Q 网络可以看做是双 Critic 网络，通过使用两个独立的 Critic 网络来评估动作的价值，并在结果中选择较小值或者平均值，从而减小过高估计的风险。

2、延迟更新、目标网络和软更新

在强化学习算法中，尤其是深度强化学习中的 Actor-Critic 结构，由于算法依赖于复杂的神经网络模型进行估计和更新，网络的更新频率和方式对训练的稳定性有着重要影响。为了解决网络更新过程中可能出现的震荡和不稳定性，延迟更新、目标网络和软更新被广泛应用。

（a）目标网络

目标网络是指在强化学习中采用的一种技术，通过使用与主网络结构相同但参数更新较慢的副本来提供稳定的目标值[65]。在传统的 Q 学习算法中，Q 值的更新直接依赖于当前网络的输出，这容易导致高方差和不稳定的学习过程。为此，引入了目标网络的概念，目标网络的作用是生成稳定的目标值，避免直接使用当前网络的输出进行更新。目标网络并不直接参与动作选择，而是通过间接影响训练目标，提升整个系统的学习稳定性。

（b）软更新

软更新技术是指目标网络在每次更新时，并不是一次性复制主网络的全部参数，而是采用一个较小的步长进行渐进式更新[71]。具体来说，软更新的公式如（2.2-19）所示：

$$\theta'_{target} = \tau \cdot \theta_{main} + (1-\tau) \cdot \theta'_{target} \tag{2.2-19}$$

其中，$\theta'_{target}$是目标网络的当前参数，$\theta_{main}$是主网络的参数，$\tau$为软更新步长，

通常取一个小值（如 0.005）。通过软更新，目标网络的参数仅略微受到主网络参数的影响，从而避免了目标网络的剧烈变化，这种方式可以显著减少训练过程中的不稳定性和过度估计问题。

（c）延迟更新

延迟更新是指在某些强化学习算法中，目标网络的更新频率低于主网络的更新频率[68]。该技术被广泛应用于 TD3 等算法中，目的是减少目标网络的频繁变化，从而避免目标网络过快地贴近主网络，保持目标网络的稳定性。TD3 中还存在着另一种延迟更新策略，在 Critic 网络的目标网络进行多次软更新之后，再更新一次 Actor 网络，使得 Actor 网络在进行参数迭代时使用更加准确的价值估计，从而提升模型整体的稳定性。

3、经验回放机制

在强化学习过程中，智能体通过与环境交互获得训练样本，但连续采集的数据往往具有较强的时间相关性，同时大量交互经验在训练中仅被使用一次，导致样本利用率较低，并可能影响学习稳定性。针对这一问题，经验回放机制被提出[72]，该方法通过将历史交互数据（即状态、动作、奖励和下一个状态的四元组）存储于经验池中，并在训练过程中随机采样小批量数据进行更新，从而打破样本之间的时间相关性，并在 off-policy 学习框架下提高数据利用效率和训练稳定性。

常见的经验回放机制有简单经验回放（所有的经验都存储在缓冲区中，随机采样）以及优先经验回放（优先选择那些学习误差较大的经验进行训练，从而提高样本的利用率，加速收敛）。

## 2.3 无人帆船动力学模型

由于强化学习本身需要与环境进行高频率的交互进行数据收集，在本研究中环境的核心构成就是无人帆船的动力学模型。无人帆船作为典型的风力驱动欠驱动水面航行器，其运动过程受到风力、水动力及控制输入（舵角与帆角）的共同作用。由于完整的六自由度模型结构复杂、参数辨识困难，同时考虑到实际控制任务主要关注平面运动与横摇耦合效应，在多数自主航行研究中通常采用简化模型。对于大部分帆船模型而言，其控制逻辑是近似且通用的，因此本研究所采用的动力学模型直接来自于 Xiao 等人所提出的四自由度模型[20]，并且相关固定参数同样可以在 Xiao 等人分享的 Simulink 仿真模型中获取。

完整的六自由度帆船模型与坐标系设定如图 2.4 所示,在惯性坐标系中$o_n x_n$轴指向正北，$o_n y_n$轴指向正东，$o_n z_n$轴指向水平面的正下方。在船体坐标系中，以帆船重心为坐标系中心$o_b$，$o_b x_b$轴为船体纵轴，由船尾指向船头；$o_b y_b$轴为船体横轴，指向船体右侧；$o_b z_b$为船体纵轴，指向船体正下方。在$o_b x_b$、$o_b y_b$和$o_b z_b$三个方向的速度分别用$u, v, w$表示，产生的角速度分别用$p, q, r$表示。

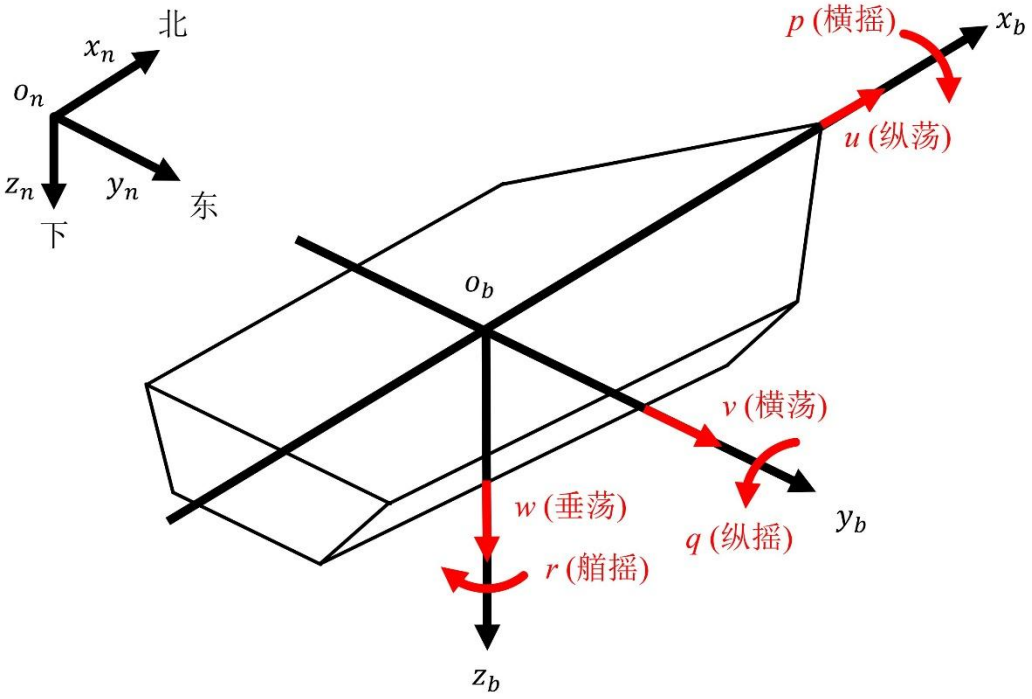



图 2.4 惯性坐标系与船体坐标系。

Fig.2.4 Inertial coordinate system and hull coordinate system.

本研究的四自由度模型的构建基于以下假设：1、将帆船视为刚体。在船体运动过程中不考虑结构形变，因此船体质心在船体坐标系中的位置保持不变。2、忽略纵摇与垂荡运动。3、假设环境水域为平静水域。4、附加质量系数（水动力导数）被视为常数。5、气动力作用点固定。6、船体关于纵向对称面$x_b z_b$对称[20]。

基于上述设定，本文的动力学模型最终简化为四自由度模型。其中，向量$\boldsymbol{v} = [u, v, p, r]^T$表示在船体坐标系下的广义速度向量，分别对应纵向速度$u$、横向速度$v$、横摇角速度$p$以及偏航角速度$r$。另一方面，向量$\boldsymbol{\eta} = [x, y, \phi, \psi]^T$表示在惯性坐标系下描述的船舶状态，其中$x$与$y$为无人帆船在平面内的位置坐标，$\phi$表示横摇角，$\psi$表示偏航角/艏向。

在简化模型中，向量$\boldsymbol{v}$与向量$\boldsymbol{\eta}$的计算如公式（2.3-1）（2.3-2）所示，在后续内容中对公式中涉及的矩阵计算进行进一步说明：

$$M\dot{v} + C_{RB}(v)v + C_A(v)v + D(v)v + g(\eta) = \tau_s + \tau_r \tag{2.3-1}$$

$$\dot{\eta} = J(\psi,\phi)v, J = \begin{bmatrix} \cos\psi & -\sin\psi\cos\phi & 0 & 0 \\ \sin\psi & \cos\psi\cos\phi & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & \cos\phi \end{bmatrix} \tag{2.3-2}$$

其中：$M \in R^{4\times4}$为质量矩阵，$C_{RB} \in R^{4\times4}$为刚体科氏力矩阵，$C_A \in R^{4\times4}$为附加质量科氏矩阵，$D(v) \in R^{4\times4}$为水动力阻尼矩阵，$g(\eta)$为重力与浮力恢复力矩阵，$\tau_s, \tau_r \in R^4$分别为风帆和舵的力矩向量，$J$为变换矩阵。

质量矩阵$M$由刚体质量矩阵$M_{RB}$与附加质量矩阵$M_A$构成，刚体质量矩阵$M_{RB}$如公式（2.3-3）：

$$M_{RB} = \begin{bmatrix} m & 0 & 0 & 0 \\ 0 & m & 0 & 0 \\ 0 & 0 & I_{xx} & -I_{xz} \\ 0 & 0 & -I_{xz} & I_{zz} \end{bmatrix} \tag{2.3-3}$$

其中$m$代表船体质量，$I_{xx}$代表绕$x$轴的转动惯量，$I_{zz}$代表绕$z$轴的转动惯量，$I_{xz}$代表惯量耦合项。

附加质量矩阵如公式（2.3-4）：

$$M_A = \begin{bmatrix} a_{11} & 0 & 0 & 0 \\ 0 & a_{22} & a_{24} & a_{26} \\ 0 & a_{24} & a_{44} & a_{46} \\ 0 & a_{26} & a_{46} & a_{66} \end{bmatrix} \tag{2.3-4}$$

其中$a_{11}$代表纵荡附加质量系数；$a_{22}$代表横荡附加质量系数；$a_{24}$代表横荡－横摇附加质量耦合系数；$a_{26}$代表横荡－艏摇附加质量耦合系数；$a_{44}$代表横摇附加转动惯量；$a_{46}$代表横摇－艏摇附加惯量耦合项；$a_{66}$代表艏摇附加转动惯量。

刚体科氏矩阵如公式（2.3-5）：

$$C_{RB}(v) = \begin{bmatrix} 0 & -mr & 0 & 0 \\ mr & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \tag{2.3-5}$$

附加质量科氏矩阵如公式（2.3-6）：

$$C_A(v) = \begin{bmatrix} 0 & 0 & 0 & -(a_{22}v + a_{24}p + a_{26}r) \\ 0 & 0 & 0 & a_{11}u \\ 0 & 0 & 0 & 0 \\ a_{22}v + a_{24}p + a_{26}r & -a_{11}u & 0 & 0 \end{bmatrix} \tag{2.3-6}$$

水动力阻尼矩阵$D$由龙骨阻尼$D_{keel}$、船体阻力$D_{hull}$以及横摇与艏摇阻尼

$D_{heel,yaw}$组成。龙骨阻尼$D_{keel}$的计算流程如下：

首先计算龙骨相对来流角，如公式（2.3-7）：

$$\alpha_{ak} = tan^{-1}\left(\frac{v_{akv}}{-v_{aku}}\right) \tag{2.3-7}$$

其中$v_{aku}$代表龙骨处相对水流的纵向速度分量；$v_{akv}$代表龙骨处相对水流的横向速度分量。

通过对照升力和阻力系数表，可以计算龙骨升力$L_k$，龙骨阻力$D_k$，如如公式（2.3-8）（2.3-9）：

$$L_k = \frac{1}{2}\rho_w A_k(v_{aku}^2 + v_{akv}^2)C_{lk} \tag{2.3-8}$$

$$D_k = \frac{1}{2}\rho_w A_k(v_{aku}^2 + v_{akv}^2)C_{dk} \tag{2.3-9}$$

其中$\rho_w$代表水密度；$A_k$代表龙骨面积；$C_{lk}$代表龙骨升力系数；$C_{dk}$代表龙骨阻力系数。

最终可得龙骨阻尼向量，计算公式如（2.3-10）：

$$D_{keel} = \begin{bmatrix} -L_k sin\ \alpha_{ak} + D_k cos\ \alpha_{ak} \\ -L_k cos\ \alpha_{ak} - D_k sin\ \alpha_{ak} \\ (L_k cos\ \alpha_{ak} + D_k sin\ \alpha_{ak})z_k \\ -(L_k cos\ \alpha_{ak} + D_k sin\ \alpha_{ak})x_k \end{bmatrix} \tag{2.3-10}$$

其中$x_k$代表骨相对于质心的纵向位置$z_k$代表龙骨相对于质心的垂向位置。

船体阻尼向量计算如公式（2.3-11）：

$$D_{hull} = \begin{bmatrix} F_{rh} cos\ \alpha_{ah} \\ -F_{rh} sin\ \alpha_{ah} cos\ \phi \\ F_{rh} sin\ \alpha_{ah} cos\ \phi z_h \\ -F_{rh} sin\ \alpha_{ah} cos\ \phi x_h \end{bmatrix} \tag{2.3-11}$$

其中$\alpha_{ah}$代表船体来流角；$x_h$代表船体阻力作用点纵向位置；$z_h$代表船体阻力作用点垂向位置；$F_{rh}$代表船体阻力。

横摇与艏摇阻尼计算如公式（2.3-12）：

$$D_{heel,yaw} = \begin{bmatrix} 0 \\ 0 \\ c\dot{\phi}\,|\dot{\phi}| \\ d\dot{\psi}\,|\dot{\psi}|\,cos\ \phi \end{bmatrix} \tag{2.3-12}$$

其中$c$代表横摇阻尼系数；$d$代表艏摇阻尼系数；$\dot{\phi}$代表横摇角速度；$\dot{\psi}$代表艏摇角速度。

重力与浮力恢复力矩阵，涉及到横摇恢复力矩$M_{xw}$与艏摇配重力矩$M_{zw}$计算

如下：

$$G = \begin{bmatrix} 0 \\ 0 \\ a\phi_{deg}^2 + b\phi_{deg} + M_{xw} \\ M_{zw} \end{bmatrix} \tag{2.3-13}$$

$$M_{xw} = -y_w\, w_c\, y_{bm}\cos\ \phi \tag{2.3-14}$$

$$M_{zw} = -y_w\, w_c\, x_c \sin\ |\phi| \tag{2.3-15}$$

其中$a, b$代表横摇恢复力矩拟合系数；$\phi_{deg}$代表横摇角的角度量；$y_w$：内部横向移动配重的位置；$w_c$代表配重质量；$y_{bm}$代表浮心到质心的横向距离；$x_c$代表配重相对于质心的纵向位置。

在该无人帆船动力学模型中，帆力与舵力均由流体动力学升力–阻力模型得到，其中帆角和舵角定义为$\delta_s, \delta_r$。对风帆进行力矩计算时，需要将真实风转换到作用在风帆上的视风。

环境风速在惯性坐标系中可以表示公式（2.3-16）的矩阵形式：

$$v_t = \begin{bmatrix} v_t cos\ \alpha_w \\ v_t sin\ \alpha_w \\ 0 \end{bmatrix} \tag{2.3-16}$$

其中$v_t$代表环境风速；$\alpha_w$代表真实风向角。

考虑风速随高度变化的对数风速剖面模型,风帆处风速计算公式如(2.3-17)所示：

$$v_{tw} = \frac{ln\left(\frac{|\ z_s\ |\ cos\ \phi}{h_0}\right)}{ln\left(\frac{h_1}{h_0}\right)} v_t \tag{2.3-17}$$

其中$z_s$代表帆作用点高度；$h_0$代表参考高度；$h_1$代表风速测量高度。

进而通过艏摇角旋转矩阵与横摇角旋转矩阵可以得到船体坐标系中的风速，具体计算如下：

$$\mathrm{v}_{tb} = R_2 R_1 \mathrm{v}_{tw} \tag{2.3-18}$$

$$R_1 = \begin{bmatrix} \cos(-\psi) & -\sin(-\psi) & 0 \\ \sin(-\psi) & \cos(-\psi) & 0 \\ 0 & 0 & 1 \end{bmatrix} \tag{2.3-19}$$

$$R_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos\,(-\phi) & -\sin\,(-\phi) \\ 0 & \sin\,(-\phi) & \cos\,(-\phi) \end{bmatrix} \tag{2.3-20}$$

在风帆处的视风向量计算如公式（2.3-21）：

$$v_{awb} = \begin{bmatrix} v_{awu} \\ v_{awv} \\ 0 \end{bmatrix} = v_{twb} - \begin{bmatrix} u \\ v \\ 0 \end{bmatrix} - \begin{bmatrix} p \\ 0 \\ r \end{bmatrix} \times \begin{bmatrix} x_s \\ y_s \\ z_s \end{bmatrix} \tag{2.3-21}$$

其中$v_{awu}$代表视风纵向分量；$v_{awv}$代表视风横向分量；$x_s, y_s, z_s$表示风帆受力中心点相对于船体质心的位置。

基于视风的矩阵表达式，视风角计算如公式（2.3-22）：

$$\alpha_{aw} = \arctan\left(\frac{V_{awv}}{-V_{awu}}\right) \tag{2.3-22}$$

在视风的速度以及方向确认的情况下，可以通过如下过程推导帆对船体产生的总力与力矩。首先，根据视风方向$\alpha_{aw}$与帆角$\delta_s$的关系，可得到帆的气动攻角$\alpha_{as} = \alpha_{aw} - \delta_s$，通过风帆的气动特性函数可得到升力系数$C_{ls}$与阻力系数$C_{ds}$。

风帆产生的升力与阻力由经典气动力公式（2.3-23）给出：

$$L_s = \frac{1}{2}\rho_a A_s V_{aw}^2 C_{ls}, D_s = \frac{1}{2}\rho_a A_s V_{aw}^2 C_{ds} \tag{2.3-23}$$

其中$\rho_a$为空气密度；$A_s$为帆面积；$V_{aw} = \sqrt{v_{awu}^2 + v_{awv}^2}$为视风风速大小。

风帆所产生的气动力作用方向与表观风方向相关。将升力与阻力分解到船体坐标系中，可得到帆对船体产生的纵向力$F_{sx}$与横向力$F_{sy}$，具体表示如公式（2.3-24）（2.3-25）：

$$F_{sx} = L_s \sin\ \alpha_{aw} - D_s \cos\ \alpha_{aw} \tag{2.3-24}$$

$$F_{sy} = L_s \cos\ \alpha_{aw} + D_s \sin\ \alpha_{aw} \tag{2.3-25}$$

由于帆的作用点与船体质心存在空间距离，上述气动力还会产生相应的力矩，具体可以分解为首由于帆高度产生的横摇力矩$M_x$以及绕垂直轴的艏摇力矩$M_z$，具体计算如（2.3-26）（2.3-27）所示：

$$M_x = -(L_s \cos\ \alpha_{aw} + D_s \sin\ \alpha_{aw}) z_s \tag{2.3-26}$$

$$M_z = -(L_s \sin\ \alpha_{aw} - D_s \cos\ \alpha_{aw}) X_{ce} \sin\ \delta_s + (L_s \cos\ \alpha_{aw} + D_s \sin\ \alpha_{aw})(X_m - X_{ce} \cos\ \delta_s) \tag{2.3-27}$$

其中$X_{ce}$为风帆气动中心相对于桅杆的位置；$X_m$为桅杆在船体坐标系中的纵向位置。

综上，风帆对船体产生的总力与力矩可以统一表示为公式（2.3-28）。

$$\boldsymbol{\tau}_{sail} = \begin{bmatrix} F_{sx} \\ F_{sy} \\ M_x \\ M_z \end{bmatrix} \tag{2.3-28}$$

对于作用在在船舵上的力和力矩计算过程与风帆类似，需要注意的是，尽管前文中提到假设帆船在静水当中航行，但是无法忽略帆船本身航行所产生的与静水的相对速度。首先依然是计算船体坐标系下的水流速度和角度，其中船舵处相对水流在船体坐标系中的纵向与横向分量分别如公式（2.3-29）（2.3-30）。

$$v_{aru} = -u + r\,y_r \tag{2.3-29}$$

$$v_{arv} = -v - r\,x_r + p\,z_r \tag{2.3-30}$$

其中$x_r, y_r, z_r$为船舵相对于船体质心的位置坐标。

由此可得到船舵处相对水流速度大小$V_{ar}$以及船舵入流方向与船体纵轴之间的夹角$\alpha_{ar}$，计算如公式（2.3-31）（2.3-32）所示：

$$V_{ar} = \sqrt{v_{aru}^2 + v_{arv}^2} \tag{2.3-31}$$

$$\alpha_{ar} = \arctan\left(\frac{v_{arv}}{-v_{aru}}\right) \tag{2.3-32}$$

考虑舵角$\delta_r$的影响，可得到舵的水动力攻角$\alpha_a = \alpha_{ar} - \delta_r$，根据舵的水动力特性函数，可以得到攻角对应的升力系数 $C_{lr}$与阻力系数 $C_{dr}$。因此船舵所产生的升力与阻力如公式（2.3-33）（2.3-34）：

$$L_r = \frac{1}{2}\rho_w A_r V_{ar}^2 C_{lr} \tag{2.3-33}$$

$$D_r = \frac{1}{2}\rho_w A_r V_{ar}^2 C_{dr} \tag{2.3-34}$$

其中$\rho_w$为水密度；$A_r$为船舵面积。

与风帆同理，将船舵的升力与阻力投影到船体坐标系中，可得到船舵对船体产生的纵向力$F_{rx}$与横向力$F_{ry}$，如公式（2.3-35）（2.3-36）：

$$F_{rx} = L_r \sin\,\alpha_{ar} - D_r \cos\,\alpha_{ar} \tag{2.3-35}$$

$$F_{ry} = L_r \cos\,\alpha_{ar} + D_r \sin\,\alpha_{ar} \tag{2.3-36}$$

由于船舵位于船体质心之后，其产生的侧向力会形成艏摇控制力矩。考虑舵在船体坐标系中的纵向位置$x_r$，艏摇力矩为$M_{zr}$，表示为公式（2.3-37）：

$$M_{zr} = (L_r \cos\,\alpha_{ar} + D_r \sin\,\alpha_{ar}) x_r \tag{2.3-37}$$

同时，由于船舵具有一定的垂向位置 $z_r$，横向力还会产生横摇力矩$M_{xr}$，表

示为公式（2.3-38）：

$$M_{xr} = -(L_r \cos\ \alpha_{ar} + D_r \sin\ \alpha_{ar}) z_r \tag{2.3-38}$$

综上， 船舵对船体产生的总力与力矩可以统一表示为公式（2.3-39）：

$$\boldsymbol{\tau}_{rudder} = \begin{bmatrix} F_{rx} \\ F_{ry} \\ M_{xr} \\ M_{zr} \end{bmatrix} \tag{2.3-39}$$

通过上述四自由度动力学模型，本文将在第三章中构建完整的仿真环境用于智能体的训练。

## 2.4 本章小结

本章介绍了无人帆船强化学习控制研究所涉及的基础理论与建模方法。首先，对深度学习与强化学习的基本原理进行了概述，重点说明了强化学习中的马尔可夫决策过程、Actor–Critic 结构以及涉及到训练稳定性的相关机制，为后续控制模型的设计奠定了理论基础。随后，建立了无人帆船的动力学模型，定义了惯性坐标系与船体坐标系，并基于分离式建模思想构建了包含气动力与水动力作用的四自由度运动方程。通过上述内容，为后续章节中强化学习算法的仿真验证与控制策略研究提供了必要的理论与模型基础。

# 3 训练交互环境

## 3.1 引言

强化学习本质上需要通过与环境的反复交互获取收集大量信息进而实现模型训练，交互环境的构建对于强化学习模型的训练与验证具有基础性作用。目前使用强化学习进行无人帆船自主航行的研究通常将路径规划部分与路径追踪部分进行独立讨论。对于全局路径规划的研究关注环境层面的设定，例如对含有环境因素的全局网格地图的构建，局部路径规划与路径追踪则更关注任务层面的设定，例如：避障效果、预期路径的偏离度等。与上述分层式控制框架不同，本文采用端到端的强化学习控制方法，使智能体能够根据当前可观测状态直接输出控制动作，从而实现无人帆船的自主航行决策。

基于上述研究需求，本文构建了专用的强化学习训练交互环境，将动力学模型、风场模型以及任务约束等集成到统一框架中，为后续模型研究奠定基础。下面，本节将从交互模型的构建、模拟风场的生成、实验任务的设定、交互噪声的引入以及交互速度的优化等方面，对训练环境的设计方法进行详细说明。

## 3.2 基础环境框架

为了方便进行模型交互与环境更新，本研究将第二章中所述的动力学模型构建在 Open AI Gym 框架之中。相较于 ROS 及 Gazebo 等机器人仿真平台侧重于部署前的系统性验证，Gym 框架结构简单、计算开销更低、同时支持 CPU 与 GPU 模拟，能够应对强化学习训练过程中大量、高频率的环境交互，从而显著提升模型训练效率。该框架以标准化接口形式描述智能体与环境之间的交互过程，其中最核心的包括环境初始化函数 reset()与状态推进函数 step(action)。在训练开始时，通过调用 reset()函数对环境进行初始化，将根据预设条件生成无人帆船以及环境参数的初始值，并返回所需要的初始观测$s_0$，随后在每一个时间步中，智能体将根据当前的观测状态$s_t$生成控制动作$a_t$,并将动作输入环境 step()接口。环境在接收到动作后，会根据动力学模型进行数值更新并输出下一时刻状态$s_{t+1}$、即时奖励$r_t$,并且判断任务是否完成或提前终止。

动力学模型本身计算得到的数值可以视为无人帆船状态参数的导数，对于下一时间步的具体数值迭代，本研究采用基于 Runge-Kutta methods 的四阶-五阶自

适应步长算法[73]，在保证计算精度的同时能够根据系统状态变化的剧烈程度自动调整积分步长。

在外部环境方面，本研究所考虑的是局部航迹点之间的实时控制调节策略，因此还需要同步构建可变化的模拟风场，具体使用 Dryden 模型进行风场的更新。Dryden 湍流模型提供了有理形式的功率谱密度函数，相比于 Ornstein–Uhlenbeck（OU）过程更适合作为风场仿真的基础模式。

在 Dryden 模型中，风速通常可以分解为稳定平均风速与随机湍流扰动两部分。设环境中的瞬时风速为$V(t)$，则可以表示为公式（3.2-1）：

$$V(t) = V_0 + v_t(t) \tag{3.2-1}$$

其中 $V_0$表示稳定的平均风速，$v_t(t)$ 表示由湍流引起的随机扰动分量。Dryden 模型通过随机微分方程来描述湍流速度的动态变化过程，其连续时间形式可表示为：

$$\frac{dx(t)}{dt} = -\frac{V}{L}x(t) + \sigma\sqrt{\frac{2V}{L}}\,w(t) \tag{3.2-2}$$

其中$x(t)$表示湍流速度分量，$V$为平均风速，$L$为湍流尺度长度，$\sigma$为湍流强度（即湍流速度的标准差），$w(t)$为单位高斯白噪声。该方程本质上是一个一阶线性随机系统，其输出信号具有指数衰减的时间相关性，因此能够较好地描述真实风场中风速扰动的时间连续特性。

本研究环境中采用离散时间步长进行状态更新，因此需要对上述随机微分方程进行离散化处理。设仿真时间步长为$dt$，则该模型可以转化为如下离散形式：

$$x_{k+1} = \alpha x_k + \beta\epsilon_k \tag{3.2-3}$$

其中各参数表示为：

$$\alpha = e^{-dt/\tau}, \beta = \sigma\sqrt{1-\alpha^2}, \tau = \frac{L}{V} \tag{3.2-4}$$

$\epsilon_k \sim N(0,1)$为标准高斯白噪声。

在本文的仿真中，风场扰动被分解为沿平均风向的湍流分量与垂直风向的湍流分量。设平均风向为$\theta$，基础风速为$V_0$，则平均风速在全局坐标系中的分量为：

$$\begin{aligned} V_x &= V_0\cos\,\theta \\ V_y &= V_0\sin\,\theta \end{aligned} \tag{3.2-5}$$

通过 Dryden 模型生成沿纵向湍流分量$u_t$与横向湍流分量$v_t$后，需要将其转换到全局坐标系中，其坐标变换关系为：

$$\begin{aligned} T_x &= u_t\cos\theta - v_t\sin\theta \\ T_y &= u_t\sin\theta + v_t\cos\theta \end{aligned} \tag{3.2-6}$$

因此，最终的风速向量可以表示为：

$$\begin{aligned} V_x^{total} &= V_x + T_x \\ V_y^{total} &= V_y + T_y \end{aligned} \tag{3.2-7}$$

在得到风速分量后，可进一步计算瞬时风速大小与风向角，如下：

$$\begin{aligned} V &= \sqrt{(V_x^{total})^2 + (V_y^{total})^2} \\ \psi_w &= \mathrm{atan2}(V_y^{total}, V_x^{total}) \end{aligned} \tag{3.2-8}$$

其中$V$表示当前时刻的环境风速，$\psi_w$表示风向角，$\mathrm{atan2}(\cdot)$表示四象限反正切函数，用于计算二维向量的角度。

此外，为避免在极端情况下风速过小导致气动力计算不稳定，本文在仿真中对风速设置了最小阈值限制（0.1 米/秒），从而保证无人帆船气动力模型在整个训练过程中的数值稳定性。

通过设定相关参数进行测试与海试获取的真实风场进行对照，如图 3.1、图 3.2、图 3.3、图 3.4 所示，验证了模拟风场在时间尺度上的物理合理性。

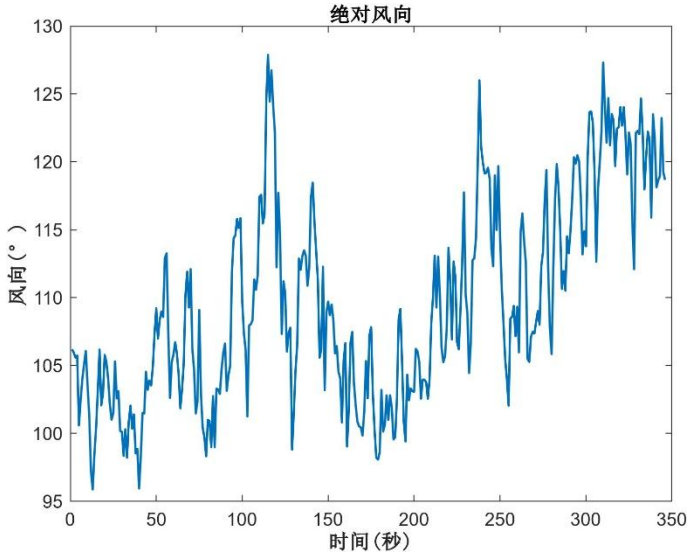



图 3.1 绝对风向（真实环境）。

Fig.3.1 Absolute wind direction (Real Environment).

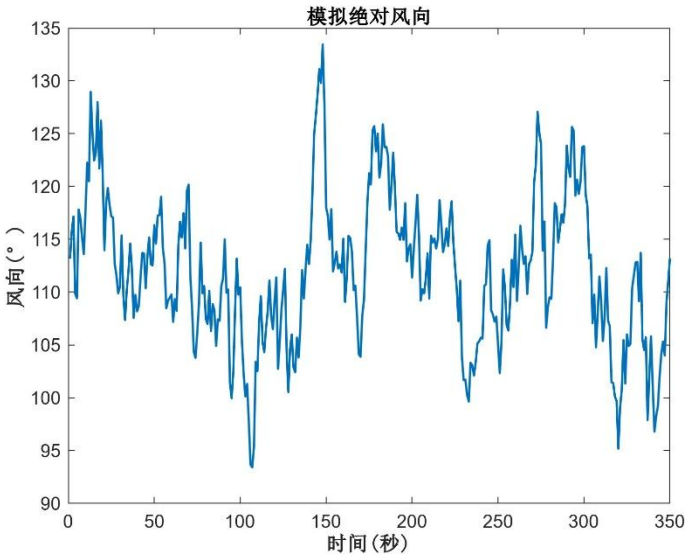



图 3.2 绝对风向（模拟环境）。

Fig.3.2 Absolute wind direction (Simulation Environment).

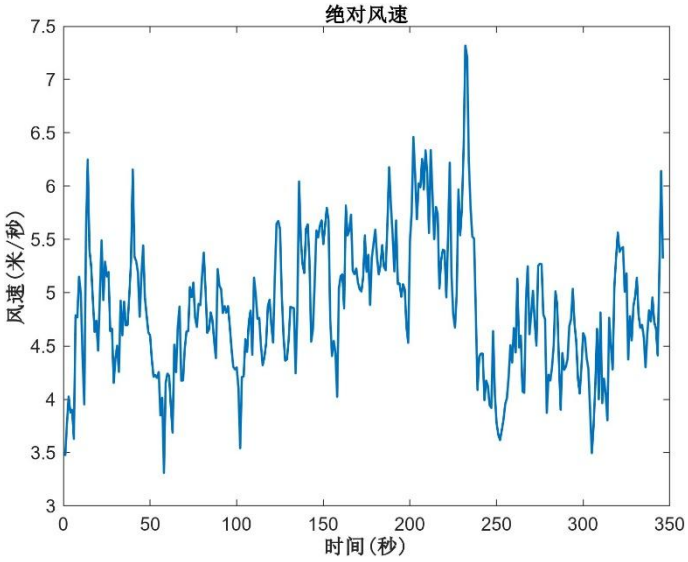



图 3.3 绝对风速（真实环境）。

Fig.3.4 Absolute wind speed (Real Environment).

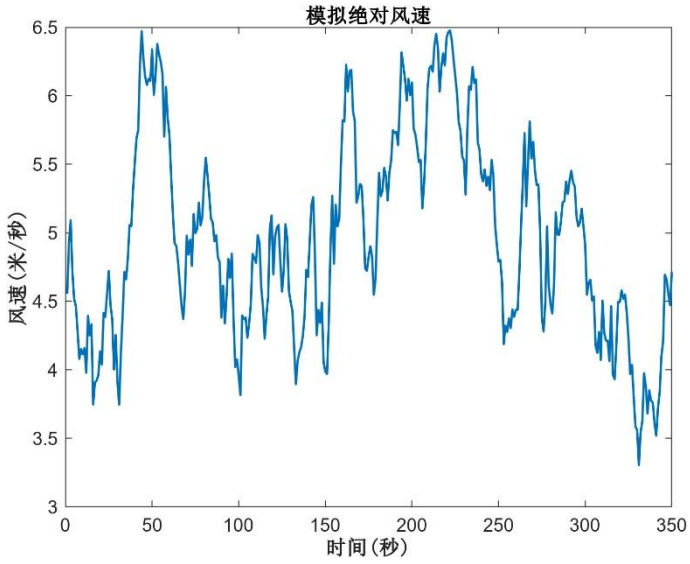



图 3.4 绝对风速（模拟环境）。

Fig.3.4 Absolute wind speed (Simulation Environment).

## 3.3 实验任务设定

在基于 Gym 框架构建的强化学习环境中，需要对智能体与环境交互所涉及的 观测空间和 动作空间进行明确的维度和精度定义。为提高计算效率并满足仿真需求，本研究中所有状态变量均采用单精度浮点数（Float32）进行表示。

对于观测空间的具体维度根据后续章节不同的研究内容存在着一定程度的差异，并且会结合奖励函数的设定进行展开论述。但动作空间的设定是相同的，具体表示为：

$$a_t = [\Delta\delta_s, \Delta\delta_r] \tag{3.3-1}$$

其中$\Delta\delta_s$代表帆角的变化量；$\Delta\delta_r$代表舵角的变化量。

与直接输出绝对控制角度相比，采用变化量控制方式能够使动作变化更加平滑，减少策略在训练初期产生的大幅度控制波动，提高系统的稳定性与可学习性。每一步执行动作后，新的控制角度通过累加方式更新：

$$\begin{aligned} \delta_s^{t+1} &= \delta_s^t + \Delta\delta_s \\ \delta_r^{t+1} &= \delta_r^t + \Delta\delta_r \end{aligned} \tag{3.3-2}$$

由于本研究所考虑的应用场景为部分可观测环境，在具体任务设定以及参数初始化设定上进行如下设定：

1、传统的自主航行策略均可以正确识别风向与风速并基于经验性的航行策略或数学模型进行相应的适配。但是在本研究中，智能体无法正常获取风向与风

速信息，这意味着检验智能体在不同风场，特别是不同风向下的自主航行能力（顺利到达目标点）是首要以及最重要的目标。因此在训练的过程中，对于环境参数初始化部分将会让$\theta$（平均风向）在[-180°，180°]区间内随机生成，以提升单一模型对顺风、逆风等情况的普适性。平均风速$V$设定为 8 米/秒。纵向和横向湍流尺度分别为 300 米与 150 米（对应约 38 秒和 19 秒的波动周期），纵向和横向湍流强度分别为 1.2 米/秒与 1.0 米/秒（湍流强度约 12.5%-15%，处于海面低空大气边界层的合理范围）。根据上文模型设定，可以计算得到瞬时风向偏离平均风向的标准差约为 7.2°，95%置信区间内的风向波动范围为±14.3°，95%置信区间内的风速在 8.0±2.4 米/秒范围内波动，对应 3-5 级风。

2、训练及测试任务的起点设置为（0,0），终点设置为（500,0），考虑到帆船的调节能力有限，当帆船距离终点小于 10 米。起点与终点间隔 500 米一方面比较符合常规方法下生成航迹点的间隔距离，另一方面意味着帆船通常需要稳定航行 3 到 6 分钟，在这个时间尺度下能够反映模型对于动态环境适应能力，并且极小概率出现风向突变的可能性。最后，对于目标指向性的强化学习任务，过长的任务周期意味着更加困难的训练，因此当前数值为各项因素综合取舍下的设定。

同时，为了让训练模型应对更加真实的环境，基于现实情况增加如下的设定：

1、帆角的范围设定为[-90°，90°]，舵角的范围设定为[-30°，30°]，意味着在仿真过程中当帆角或舵角偏转到范围上限时，此时智能体所输出的指令无法让帆角或舵角偏转到更大角度。动作空间中的帆角和舵角增量变化量设定为[-10°，10°]，并且该变化量在实际的仿真过程中会根据动态积分步长进一步细分。

2、对于帆船而言，海上航行时做到高频率的控制存在着诸多问题，一方面会提升控制所消耗的能量，并且损耗控制模块的寿命；另一方面，保持帆或舵的角度不变已经可以应对大部分情况。因此上述提及的模型计算单位时间步与风场迭代时间步均设定为 1 秒（模型求解方程的自适应步长基础值为 0.2 秒），对应控制频率 1Hz。

3、现实情况下，传感器噪声也是不可避免的。在与仿真模型交互收集观测数据的过程中会对相关数据添加固定噪声，例如：位置传感器噪声设定为±1m，角度传感器噪声设定为 1°，速度传感器噪声设定为 0.1m/s，角速度传感器噪声

设定为 0.1°/s，风向传感器噪声设定为 2°，风速传感器噪声设定为 0.5m/s。并且在智能体输出对应角度变化量的过程中会添加执行器噪声，具体包括：

（a）死区效应：执行器由于机械间隙、静摩擦力和控制系统分辨率限制，存在固有的死区特性。当控制指令幅值小于死区阈值时，执行器不产生实际动作。本研究中帆角和舵角的执行器死区均设定为 1°。

（b）量化误差：受限于编码器分辨率、齿轮传动比和控制系统的数字化精度，执行器无法实现连续角度调节，而是以离散步进方式工作。本研究中设定帆角执行器分辨率为 0.2°，舵角执行器分辨率为 0.15°。

（c）响应滞后：执行器在实际运行中受到机械摩擦、电磁阻尼、负载变化等因素影响，无法达到理想的 100%响应。本研究中设定帆角执行器平均响应系数为 0.95（即 95%响应，具体对应为 10°的调节指令实际执行约 9.5°），舵角执行器为 0.97。

（d）非线性特性：执行器在大幅度调节时，由于动态响应特性、负载非线性和控制系统饱和等因素，执行误差显著增大。本文设定当单次调节幅度超过最大范围的 70%时，触发非线性误差放大机制：正常调节（≤70%幅度）——执行误差为基础噪声（3%）；大幅度调节（>70%幅度）——执行误差放大，帆角放大 1.5 倍，舵角放大 1.3 倍。同时设定最大执行误差上限，防止噪声过大导致控制失效：帆角最大误差为 1.5°；舵角最大误差为 1.0°。

## 3.4 性能优化

对于强化学习算法而言，不论是 on-policy 的方法还是 off-policy 的方法都需要在人为设定的采样步数之后再进行周期性的网络权重更新。这意味强化学习方法的训练速度不仅仅需要像深度学习方法一样对神经网络计算进行优化，还需要额外考虑仿真环境的数据输出效率，即提升单位时间内仿真环境与模型交互并完成数值迭代输出结果的次数。

在本研究的实验过程中总结了以下几点较为有效的经验：

1、并行化环境采样。本研究在算法实现过程中采用了 Python 强化学习框架 Stable-Baselines3，并利用其提供的并行环境接口（SubprocVecEnv）构建多个并行仿真环境，使智能体能够在多个环境实例中同时进行交互与数据采样。通过这种方式，智能体在每个训练步长中可以同时获取来自多个环境的状态转移数据，

从而显著提高样本收集效率。与传统单环境逐步采样方式相比，并行化采样能够在相同时间内生成更多训练数据，从而加快策略网络的更新频率，提高算法的收敛速度。此外，由于不同环境实例在初始状态或随机扰动上存在差异，也能够增加训练样本的多样性，有助于提升策略在复杂环境中的泛化能力和稳定性。不过由于 Gym 库的环境仿真计算通常在 CPU 中，并行化环境数量受到服务器 CPU 的线程数影响。另外，智能体的模型通常在 GPU 中训练，并行化环境与模型的交互会收到数据传输能力的影响，因此总体的性能提升存在性能边际递减效应。本文涉及的实验通常启用 10 到 15 个并行环境。

此外，使用 Isaac Gym 库或通过 JAX 库进行向量化能够将并行仿真环境部署在 GPU 上，进一步提升计算效率并且降低 CPU 与 GPU 的数据传输损耗。但上述方法也存在着一定的缺陷，例如：1、Issac Gym 库主要面向刚体接触动力学，物理引擎并没有针对帆船的水/气动力学模型，依然需要自行部署。2、将常规基于 numpy 库的数学计算调整为使用 JAX 库的计算可以让整体仿真在 GPU 上并行化，但当前 JAX 库的兼容性相对较弱，对于本研究的复杂计算总体运行不够稳定。3、使用 GPU 的环境并行化方法不利于在不同终端开展代码与模型调试，更偏向于未来的工程化应用。

2、仿真环境部分参数预计算。3.1 节中提到的基于 Runge-Kutta methods 的四阶-五阶自适应步长算法中存在数次状态参数的迭代计算，通过对涉及固定参数的矩阵预计算与阻力/升力系数表插值预计算（迭代计算中可以直接通过查表获取对应系数）可以显著加快总体计算速度。同时，在实验中发现，理论上降低数值方法的计算阶数可以减少计算量，提升计算速度，但实际情况中降低数值方法的计算阶数造成了相邻阶数的误差不符合设定值，在多次迭代自适应步长的情况下反而产生了额外的计算量导致总体计算速度下降。本文所使用的阶数在数值精度与计算速度上达到了平衡状态。

3、环境终止优化。对于强化学习训练而言，尽管 off-policy 的算法会利用经验回放池提高样本的使用效率，但是训练前期过多的无效轨迹依然会影响整体的训练效率。因此，除了在 3.3 小节中提到基于完成任务的正常终止信号，本研究还额外添加了提前终止信号以减少无效或者较差样本。提前终止信号具体包括：1、仿真上限时间设定为 1000 秒，因为在基础设定下不论是顺风和逆风环境都足

以在 1000 秒内完成任务。2、设定一个以起点为圆心，半径 750 米的航行范围，当智能体的坐标超出这一范围时，提前终止。

## 3.5 本章小结

本章围绕强化学习模型训练所需的交互环境构建问题，对无人帆船仿真训练环境的整体设计方法进行了系统介绍。首先，在环境框架层面，将第二章建立的无人帆船动力学模型嵌入到强化学习框架中，并基于 Gym 接口实现智能体与环境之间的标准化交互过程，使无人帆船状态更新、动作输入及奖励反馈能够以统一形式进行迭代计算。

在外部环境建模方面，针对海洋环境中风场随机性与时变性的特点，引入 Dryden 湍流模型构建动态风场，使仿真环境能够在时间尺度上较为真实地反映海上风场变化，为后续算法训练提供更加接近实际条件的环境输入。

在交互过程方面，为提高仿真环境的工程真实性，本章进一步引入了传感器噪声与执行器误差模型，对观测数据加入比例噪声，并考虑执行器死区、量化误差以及响应滞后等因素，使控制指令与实际执行结果之间存在合理偏差，从而增强训练模型在实际应用场景中的鲁棒性。

此外，针对强化学习训练过程中大量环境迭代所带来的计算开销问题，本章还从数值积分方法选择、参数预计算以及仿真结构优化等方面提出了相应的效率提升策略，以提高单位时间内环境与模型交互的效率，为后续大规模训练实验提供计算基础。

# 4 基于强化学习的无人帆船控制模型

## 4.1 引言

帆船是一个典型的受外界环境驱动的非线性系统，在现有的分层式控制框架下，风场信息通常作为已知项，研究人员的工作主要集中在提升路径规划的效果以及路径追踪控制器对于预期航向的追踪精度。本研究提出的基于强化学习的无人帆船控制模型一方面不依赖风场信息即可实现自主航行，另一方面作为一段式的端到端模型，帆舵的控制决策本身就是寻找最优的航行方向，不存在上述的追踪精度要求。不过，不依赖风场信息的条件意味着需要对模型的最终任务完成率进行额外的考量，特别是在不同风向下帆船的航行策略存在着极大差异（在逆风航行时通常需要采取“Z”字形航行以避开禁航区）。

本章节主要内容包括：部分可观测条件下的模型优化方案、模型训练对应的奖励函数设定以及不同设定下的对比实验。

## 4.2 网络模型与算法

本文在第二章中对强化学习的基本原理以及马尔科夫决策过程进行了基础概念的介绍。传统强化学习方法通常假设环境满足完全可观测条件，即智能体在任意时刻都能够获取完整的环境状态信息，从而根据当前状态选择最优动作。然而，在实际应用场景中，该假设往往难以满足。在本文研究的无人帆船自主航行任务中，帆船的运动不仅受到自身控制输入的影响，还与外部环境因素密切相关，其中最关键的因素是风场信息，例如风速和风向等变量。然而，在本文的研究设定中，智能体无法直接获取这些环境信息，仅能够观测到帆船自身的运动状态，如位置、航向角以及控制量等。因此，智能体所获得的状态信息实际上只是环境真实状态的一部分，从而导致环境对智能体而言是部分可观测的。

在这种情况下，传统的 MDP 建模方式将难以准确描述环境动态。例如，当无人帆船处于相同的空间位置和航向角时，如果风向不同，则其最优控制策略可能完全不同。因此，该问题无法精确的对应马尔科夫性假设，即未来的状态仅依赖当前状态与动作，通常被视为部分可观测马尔科夫决策过程（POMDP）。

针对部分可观测马尔可夫决策过程（POMDP）问题，已有研究提出了多种解决方法[74]。一类常见的方法是通过信念状态对环境隐含状态进行概率估计，并

将 POMDP 转化为高维的完全可观测 MDP，从而利用传统强化学习或规划算法进行求解。然而，该方法需要对隐含状态的概率分布进行显式建模，在实际复杂环境中往往难以准确获得环境先验信息，计算复杂度也较高。另一类方法是通过历史观测信息来弥补当前观测的不足，例如利用循环神经网络或长短期记忆网络对时间序列信息进行建模，使智能体能够从历史观测中隐式推断环境的潜在状态。该类方法避免了对环境隐变量进行显式建模，在复杂动态环境中具有更好的适应性，因此在机器人控制与强化学习领域得到了广泛应用。

考虑到无人帆船航行过程中风场的变化会在一段时间内通过船舶运动状态逐渐体现出来，本文引入能够处理时间序列信息的神经网络结构——LSTM（长短期记忆网络），将历史观测信息融入策略学习过程中，以增强智能体对环境隐含状态的推断能力，从而在部分可观测环境下实现更加稳定和有效的控制策略学习。改进后的网络模型如下图 4.1 所示，模型中显示的网络结构为核心部分,其中 FC 代表全连接层，LSTM 代表长短期记忆网络层，每层所使用的神经元数量以及激活函数均表示在图中。另外需要注意的是 LSTM 层后衔接的是层归一化（Layer Normalization），主要作用是稳定隐藏状态的分布以提升梯度传播的稳定性。在状态特征输入前，本文引入 Z-score 标准化机制用于缓解多维状态变量在量纲与数值尺度上的差异对策略优化造成的不利影响。在最终输出端，策略（Actor）网络与价值（Critic）网络均包含显式的映射层设计，其中策略网络将第三全连接层（FC3）的输出特征映射为动作分布参数（均值与对数方差），并经重参数化完成最终动作输出，价值网络则是将第三全连接层（FC3）的输出特征通过线性映射为 Q 值。

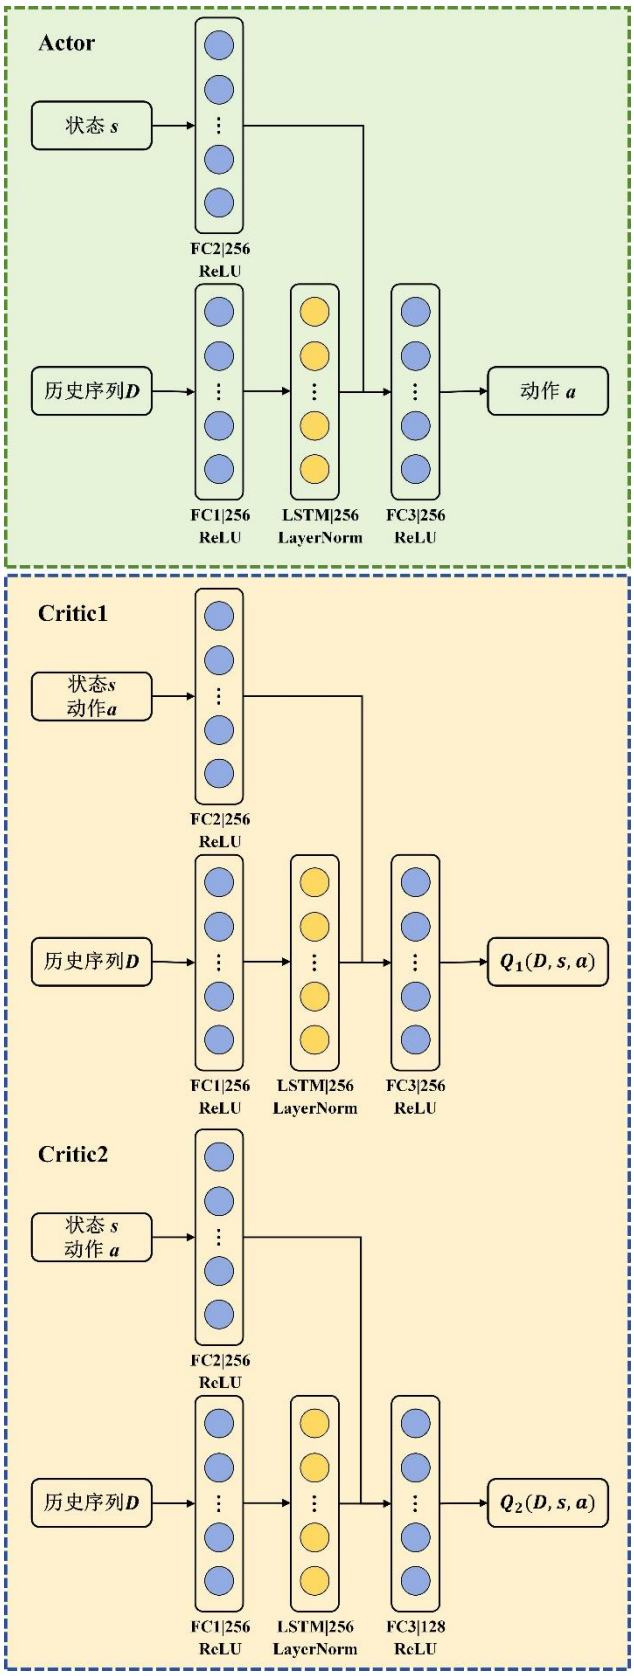



图 4.1 融入长短期记忆网络的模型结构。

Fig.4.1 Model structure integrated with long short-term memory network.

需要明确的是由于网络结构中引入了 LSTM 用于建模历史状态–动作序列，

因此模型需要利用一定时间窗口内的历史信息以恢复环境的隐含动态。在不同阶段，历史信息的输入方式有所不同。在训练过程中，为了提高训练稳定性并充分利用经验回放缓冲区中的数据，本研究采用固定长度的历史序列作为网络输入。具体而言，从经验回放池中随机采样长度为$K$的状态–动作序列：

$$D_t = \{(s_{t-1}, a_{t-1}), (s_{t-2}, a_{t-2}), \ldots, (s_{t-K}, a_{t-K})\} \quad (4.2\text{-}1)$$

其中$K$表示历史窗口长度。该序列首先经过初步的特征嵌入后输入至 LSTM 网络，由 LSTM 在时间维度上依次展开并计算隐藏状态，从而获得历史信息的时序特征表示。

在实际环境交互或测试阶段，智能体按照时间步依次接收新的观测信息，并输出控制动作，在这个过程中 LSTM 单元不会进行隐藏状态的重置（只有当环境触发终止信号，才会进行隐藏状态的重置），因此只需要在每次迭代时输入上一时刻状态$s_{t-1}$与对应动作$a_{t-1}$,并通过上一时间步保存的隐藏状态（$h_{t-1}, c_{t-1}$）进行新隐藏状态的更新，如公式（4.2-2）：

$$(h_t, c_t) = \text{LSTM}(x_t, h_{t-1}, c_{t-1}) \quad (4.2\text{-}2)$$

计算获得的隐藏状态可以继续进行后续的递推更新，从而在整个交互过程中持续维护历史信息。

本实验中将历史序列长度设定为$K = 10$，即每次训练样本包含最近 10 个时间步的状态–动作信息，该设定第一考虑到对于无人帆船航行控制问题，整体动力学在短时间尺度内具有较强的连续性，第二能够降低序列长度过长带来的训练复杂度与梯度不稳定问题，最后考虑到在保存历史序列时对每个节点都进行了单独存储，过大的序列长度会成倍的增加存储使用。对历史序列长度进行固定设置相当于对时序依赖关系进行有限时间窗口建模，使得网络在参数更新过程中主要利用近期的历史信息进行学习，更早的历史信息不会直接参与梯度传播。这意味着模型主要通过最近的时间窗口来学习状态演化规律。

根据目前各类控制领域的研究内容中对不同算法的对比，本文最终采用 SAC（Soft Actor-Critic）算法作为核心强化学习框架。整体的网络框架以及交互过程如图 4.2：

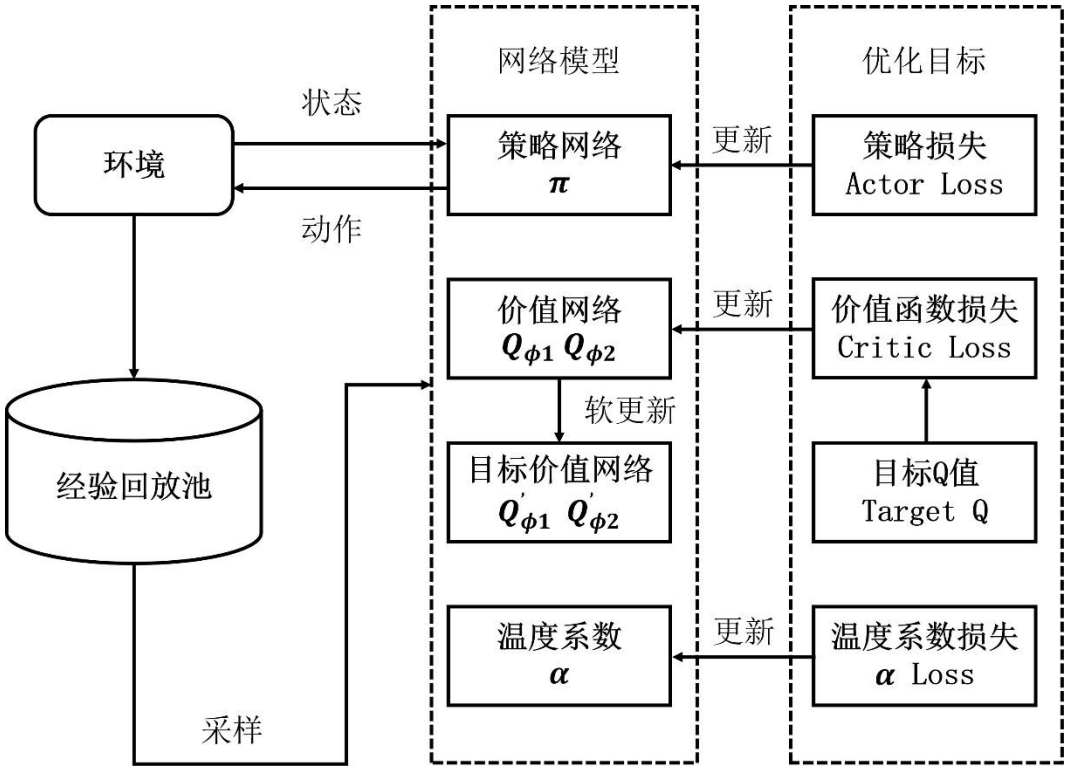



图 4.3 SAC 算法框架图。

Fig.4.3 SAC algorithm framework diagram.

在第二章中提到，SAC 的策略优化目标为：

$$J(\pi) = \mathbb{E}\left[\sum_t r\left(s_t, a_t\right) + \alpha\mathcal{H}(\pi(\cdot|\, s_t))\right] \tag{4.2-3}$$

在本实验引入 LSTM 结构对历史序列进行融入后，策略优化目标可以表示为：

$$J(\pi) = \mathbb{E}\left[\sum_t r\left((D_t, s_t), a_t\right) + \alpha\mathcal{H}(\pi(\cdot|\, (D_t, s_t)))\right] \tag{4.2-4}$$

完整的采样及网络更新伪代码如下表 4.1：

表 4.1 融入长短期记忆网络的 SAC 算法伪代码

Table.4.1 Pseudo-code of the SAC algorithm integrated with the long short-term memory network

伪代码 1: 融入长短期记忆网络的 SAC 算法

1. 配置参数：序列长度$K$、经验回放缓冲区容量$|\mathcal{D}|$、批量大小$M$、训练回合数$T$、每回合步数$N$、折扣因子$\gamma$、温度参数$\alpha$（自适应）、软更新系数$\tau$、学习率$l_c, l_a, l_\alpha$。
2. 初始化：初始化 Actor 网络$\mu_\theta$以及双 Q 网络$Q_{\phi_1}, Q_{\phi_2}$；设置目标网络 $Q'_{\phi_1}, Q'_{\phi_2} \leftarrow Q_{\phi_1}, Q_{\phi_2}$；初始化经验回放缓冲区 $\mathcal{D}$。
3. 对于每个回合$episode = 1, \dots, T$：
4. 环境初始化：重置环境并获取初始状态$s_0$；初始化状态–动作序列缓存：
5. $\mathcal{D}_t = \{(s_{t-1}, a_{t-1}), (s_{t-2}, a_{t-2}), \dots, (s_{t-K}, a_{t-K})\}$；重置 LSTM 隐状态$h_0$。
6. 交互与经验采集（单步输入）：对于每个时间步 $t = 1, \dots, N$：
7. 动作生成：基于上一时刻的状态–动作对及当前隐藏状态生成动作；隐藏状态更新。

$$a_t = \mu_\theta\{[(s_{t-1}, a_{t-1}), h_{t-1}], s_t\}$$

$$h_t = LSTM((s_{t-1}, a_{t-1}), h_{t-1})$$

8. 环境交互：执行动作$a_t$，获得相关信息。

$$s_{t+1}, r_t, d_t \sim \mathcal{P}(s_t, a_t)$$

9. 序列更新：将新状态–动作对移入序列。

$$D_{t+1} \leftarrow shift(D_t, (s_{t+1}, a_{t+1}))$$

10. 存储经验：

$$D \leftarrow D \cup \{(D_t, s_t, a_t, r_t, D_{t+1}, s_{t+1}, d_t)\}$$

11. 终止处理：若$d_t = \text{True}$，则重置 LSTM 隐状态并重新初始化序列。
12. 对于环境采样步数每增加 20 步，进行如下 4 次网络更新：
13. 经验采样：从经验回放缓冲区中采样 $M$条数据。

$$\left\{\left(D^i, s^i, a^i, r^i, D'^i, s'^i, d^i\right)\right\}_{i=1}^{M}$$

14. 目标值计算：(1)计算下一时刻动作及对数概率；(2)计算目标 Q 值；(3)构造目标。

$$a'^i, \log \pi'^i = \mu_\theta(D'^i, s'^i | h'_K)$$

$$Q_1'^i, Q_2'^i = Q_{\phi'}(D'^i, s'^i, a'^i)$$

$$y^i = r^i + (1 - d^i)\gamma\left(min\left(Q_1'^i, Q_2'^i\right) - \alpha \log \pi'^i\right)$$

表 4.1 融入长短期记忆网络的 SAC 算法伪代码（续）
Table.4.1 Pseudo-code of the SAC algorithm integrated with the long short-term memory network(continued)

伪代码 1: 融入长短期记忆网络的 SAC 算法

15. Critic 网络更新：

$$Q_1^i, Q_2^i = Q_\phi(D^i, s^i, a^i)$$

$$L_Q = \frac{1}{M}\sum_{i=1}^{M}[(Q_1^i - y^i)^2 + (Q_2^i - y^i)^2]$$

16. Actor 网络更新：

$$a^i, \log \pi^i = \mu_\theta(D^i, s^i|h_K)$$

$$Q_{1\pi}^i, Q_{2\pi}^i = Q_\phi(D^i, s^i, a^i)$$

$$L_\pi = \frac{1}{M}\sum_{i=1}^{M}(\alpha \log \pi^i - min(Q_{1\pi}^i, Q_{2\pi}^i))$$

17. 温度参数更新：

$$L_\alpha = -\frac{1}{M}\sum_{i=1}^{M}\log \alpha \cdot (\log \pi^i + \mathcal{H}_{\text{target}})$$

18. 目标网络软更新：

$$\phi_j' \leftarrow \tau\phi_j + (1-\tau)\phi_j', j = 1,2$$

结束所有回合训练。

## 4.3 奖励函数

深度强化学习的训练效果不仅取决于网络结构的设计，更在很大程度上依赖于经验元组中奖励函数的构建方式及其获取策略。奖励信号直接决定策略优化的方向，对智能体行为模式的形成具有决定性影响。较差的奖励设计可能会直接引导训练陷入奖励陷阱（reward hacking），即评估分数很高，但实际测试效果不符合预期。对于本研究涉及的无人帆船局部自主航行问题，所需要考虑的奖励/惩罚主要包括以下几个部分：1、帆船是否朝向目标点方向航行；2、帆船的帆舵推进效率；3、在不同风向条件下策略的鲁棒性。

在具体给出奖励计算公式之前，有必要首先对状态输入向量的构成进行说明，

如下：

$$s = [x, y, \phi, \psi, u, v, p, r, \delta_s, \delta_r, \Delta L, \Delta l, x_f, y_f] \quad (4.3\text{-}5)$$

本章研究的基础模型所采用的状态输入向量共包含 14 个维度。其中，前十个维度在第二章动力学原理介绍时进行了详细说明，具体为：$x$与$y$表示无人帆船在地理坐标系中的当前位置坐标；$\phi$表示帆船的横摇角，$\psi$表示艏向角，$u$与$v$分别为前向速度与横向漂移速度；$p$表示船体坐标系中的横摇角速度；$r$表示偏航角速度。$\delta_s$表示帆角，$\delta_r$表示舵角。

在 1.2.1 节提到的速度极线图直观的反映了帆船朝向不同方向的航行性能，因此在不同风向条件下帆船的最优航行策略存在显著差异，例如在顺风条件下帆船通常可以沿近似直线路径航行，而在逆风条件下则需要通过“之”字形或者 Z 形换舷航行以绕过禁航区，如图 4.4 所示。

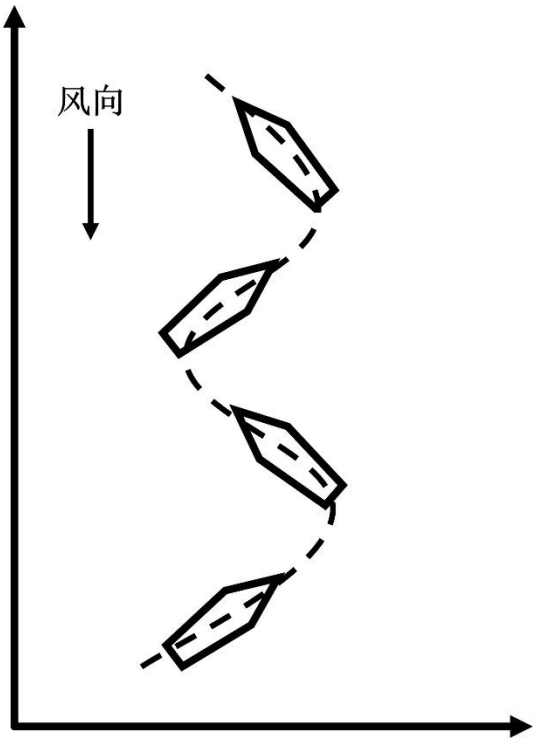



图 4.4 逆风条件下的 Z 字航行

Fig.4.4 Zigzag navigation in headwind conditions

因此仅依赖单一距离指标难以构建适用于多种风况的奖励函数。为此，本文引入两个与航迹变化相关的差分状态量$\Delta L$与$\Delta l$，用于构建能够兼顾不同风向情形的奖励评价指标。其中，$\Delta L$可直观理解为相邻两个采样时刻之间，帆船与目标点之间距离的绝对减少量。然而，若仅依赖$\Delta L$作为进度衡量指标，则在逆风航行条件下会存在一定局限性。当帆船以合理策略朝目标方向进行换舷航行时，其与目

标点之间的距离减少速度往往明显低于顺风航行的情况，甚至在某些阶段$\Delta L$可能出现负值，从而使模型误判当前状态或动作的合理性。

为缓解上述问题，本文进一步引入基于路径投影的进度量$\Delta l$。该量描述帆船在“起点—目标点”连线方向上的有效前进距离，即帆船在该理想直线路径上的投影位移。无论实际航迹如何变化，只要能够成功完成点到点的导航过程，其本质上都可以理解为沿该投影方向持续推进的过程。因此，通过引入$\Delta l$作为辅助指标，可以有效缓解仅使用$\Delta L$所带来的奖励稀疏或误导问题，尤其是在复杂逆风环境中，有助于提升模型对不同风况条件下航行策略的学习能力与泛化性能。$\Delta L$与$\Delta l$在导航路径中的几何意义如图 4.5 所示。

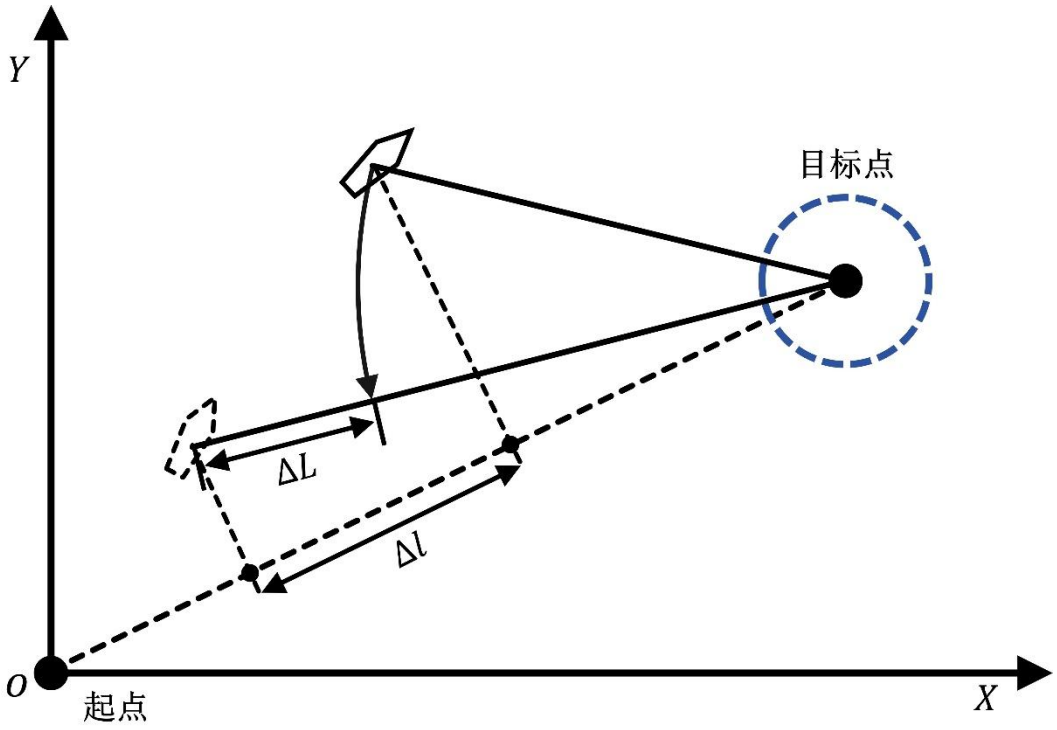



图 4.5 差分状态量示意图

Fig.4.5 Schematic Diagram of Differential State Variables

此外，$x_f$与$y_f$表示导航目标点的坐标位置。上述 14 个变量共同构成了每一个时间步中智能体所接收的状态输入向量。

动作输入向量表示为：

$$a = [\Delta\delta_s, \Delta\delta_r] \tag{4.3-6}$$

基于上述状态、动作输入向量，本研究的基础模型所采用的奖励函数总体构成如下：

$$R = \gamma \cdot \left(R_{progress} + R_{action}\right) + R_{checkpoint} + R_{arrival} + R_{penalty} \quad (4.3\text{-}7)$$

其中$R_{progress}$表示总体进度奖励，总体构成如公式：

$$R_{progress} = 2\Delta L + \Delta l + \frac{0.5u}{1 + |v|} \quad (4.3\text{-}8)$$

通过$\Delta L$与$\Delta l$来确定整体的航行是朝向目标点的，前进速度与横漂速度的比值则是鼓励更大的前进速度以及更小的横漂速度，避免智能体选择极端的航行方式到达终点。

$R_{action}$表示智能体输出动作的惩罚，总体构成如公式：

$$R_{action} = -\left\lfloor \frac{|\Delta\delta_s|}{\delta} \right\rfloor \cdot 0.1 - \left\lfloor \frac{|\Delta\delta_r|}{\delta} \right\rfloor \cdot 0.1; \delta = \frac{\pi}{180} \quad (4.3\text{-}9)$$

核心思想是通过对帆角和舵角变化的角度值进行惩罚，以避免帆船在频繁的角度调节中获利，使预期模型的策略能够更加符合真实情况。

上述$R_{progress}$与$R_{action}$占据核心的奖励部分，并通过$\gamma$系数进行比例缩放：

$$\gamma = \gamma_0 + \gamma_s + \gamma_r, \gamma_0 = 0.1 \quad (4.3\text{-}10)$$

$$\gamma_s = \begin{cases} 0.1\gamma_0, |\theta_s| \le \delta \\ 0, otherwise \end{cases}, \gamma_r = \begin{cases} 0.1\gamma_0, |\theta_r| \le \delta \\ 0, otherwise \end{cases}, \delta = \frac{\pi}{180} \quad (4.3\text{-}11)$$

其中$\gamma$系数的本质是鼓励帆船航行过程中保持帆角和舵角完全不变，尽可能降低能源消耗。

$R_{checkpoint}$与$R_{arrival}$本质上是相同的，都是对航行进度中的相关节点进行奖励，这在强化学习中可以看做是分段奖励，目的是通过一个相对大的固定值在累计回报的折扣计算中形成一个长周期的奖励，起到导向作用，具体计算如下：

$$\begin{aligned} R_{checkpoint} = &\begin{cases} 3, & if\ first\ d \le 375 \\ 0, & otherwise \end{cases} + \begin{cases} 5, & if\ first\ d \le 250 \\ 0, & otherwise \end{cases} \\ &+ \begin{cases} 12, & if\ first\ d \le 125 \\ 0, & otherwise \end{cases} \end{aligned} \quad (4.3\text{-}12)$$

$$R_{arrival} = \begin{cases} 20, if\ d \le 10 \\ 0, otherwise \end{cases} \quad (4.3\text{-}13)$$

$$d = \sqrt{(x - x_f)^2 + (y - y_f)^2} \quad (4.3\text{-}14)$$

$R_{penalty}$具体可以视为固定惩罚项，具体数值为负 0.2。

在后续对比实验中，选择完全可观测状态下的全连接层结构作为对照模型。在该模型中，相对应的状态输入向量由 14 维扩展到 16 维，具体表示为：

$$s = [x, y, \phi, \psi, u, v, p, r, \delta_s, \delta_r, \Delta L, \Delta l, x_f, y_f, W_D, W_V] \tag{4.3-15}$$

其中$W_D$与$W_V$代表观测到的风向和风速。

在有风场信息的基础上，可以对奖励函数进行经验性的修正，加入禁航区的条件判断，帮助模型更快地理解风对整体状态的影响。修正后的奖励函数如公式：

$$R = \gamma \cdot \left(R_{\text{progress}} + R_{\text{action}}\right) + R_{\text{checkpoint}} + R_{\text{arrival}} + R_{\text{penalty}} + R_{no-go} \tag{4.3-16}$$

$$R_{no-go} = \begin{cases} -2, if\ |\psi - W_D| > \theta_{no-go} \\ 0, otherwise \end{cases}, \theta_{no-go} = \frac{3\pi}{4} \tag{4.3-17}$$

强化学习的奖励函数的设定存在一定的经验性，例如对禁航区的条件判断就是禁止艏向和真风向夹角大于135°，这是在普遍的速度极线图上得出的。上述奖励设定以及相关系数并不一定对应全局最优解，其具体取值主要基于实验经验与问题特性进行选取。由于强化学习策略的收敛过程与环境动态具有较强的耦合关系，在不同任务条件或参数设置下，奖励函数各项权重仍可能需要进一步调节，以获得更加稳定且高效的策略学习结果。

## 4.4 实验结果与分析

本小节通过设计不同对照实验，对所提出模型结构及算法的有效性进行验证。通过在相同实验环境下对不同算法或不同模型结构进行比较分析，从训练收敛性能、模型测试成功率、航行耗时以及角度变化率等方面对实验结果进行评估。

### 4.4.1 基线对比实验

本研究构建了一种基于MPC的端到端控制方法作为强化学习方法的基线对照模型。基于强化学习的模型主要分为：1、在完全可观测状态下的SAC模型（SAC-wind）；2、在部分可观测状态下的SAC模型（SAC-nowind）；3、在部分可观测状态下的SAC-LSTM模型；4、在部分可观测状态下的TD3-LSTM模型；5、在部分可观测状态下的PPO-LSTM模型。后续说明均使用简称。

MPC方法采用与第二章完全相同的动力学模型，在每个控制时刻利用当前状态、目标位置及风场信息，预测未来有限时域内的状态演化，并通过在线求解优化问题获得当前控制输入。通过Gym库，MPC基线方法可以与强化学习方法实现相同的交互，通过一致的环境接口获取准确的状态值，并且将控制输入通过接口传输到环境中。当然，与强化学习方法不同的是MPC方法不依赖离线训练

并且观测的状态不添加任何噪声，通过显式构造系统模型与任务代价函数实现决策，因此作为本研究的最优控制决策基线。其中，任务代价函数的设定与 SAC-wind 模型设置相同。特别需要注意的是，MPC 方法中的最优性是在给定模型、约束条件及人为设计的代价函数下，对有限预测时域内控制序列的条件最优解。由于代价函数通常难以完备刻画复杂任务目标，且预测时域与模型精度均存在限制，该最优性并不等价于全局意义上的最优控制解，而更接近于一种工程上可实现的次优解。

在具体实现上，MPC 控制器采用滚动时域优化机制，预测时域长度设置为 20，控制时域长度设置为 1。对于预测模型的数值计算采用了与第三章相同的高阶 Runge-Kutta 方法。在具体实验中发现当预测模型中的自适应步长较大时，无法正确完成决策，因此也采用了 0.2 秒的自适应步长。

MPC 方法侧重于对时域长度进行参数设定，而强化学习方法则需要对训练超参数进行设定。本组对照实验中，不同模型各项超参数设定如表 4.2 所示：

表 4.2 不同模型超参数设定表

Table.4.2 Table of Hyperparameter Settings for Different Models

| 参数 | SAC | SAC-LSTM |
|---|---|---|
| 折扣因子 | 0.98 | 0.98 |
| 策略与价值网络学习率 | 3e-4 | 3e-4 |
| 初始温度系数 | 0.2 | 0.2 |
| 温度系数学习率 | 6e-5 | 6e-5 |
| 经验回放池容量 | 1e6 | 1e6 |
| 批量大小 | 256 | 256 |
| 软更新系数 | 0.002 | 0.002 |

PPO 算法以及 TD3 算法的超参数与 SAC 算法有所差异，例如 PPO 中存在裁剪阈值、GAE 系数；TD3 中存在策略探索噪声等，在本实验中均采取常见的默认值。此外，为了排除模型参数量对训练结果的影响，本研究增大了 SAC-wind 模型以及 SAC-nowind 模型全连接层的神经元数量，在总输入和总输出之间设计了 3 层全连接层，每层的神经元数量分别为 1024，512，256，其网络参数量整体

接近于 SAC-LSTM 模型。

本研究对强化学习方法的训练基于 Python 3.10 和 Pytorch 2.1.0 框架实现。程序使用 Anaconda3 虚拟环境，并基于 CUDA12.1 进行 GPU 加速。硬件方面，实验计算设备采用 Intel Core i7-14700kf CPU、32GB 内存以及 NVIDIA GeForce RTX 4090 24G 显卡。

基于强化学习方法的模型首先通过评估交互步数节点下的模型获得总奖励来反映模型的具体训练效果，上述模型的训练表现如图 4.6 所示：

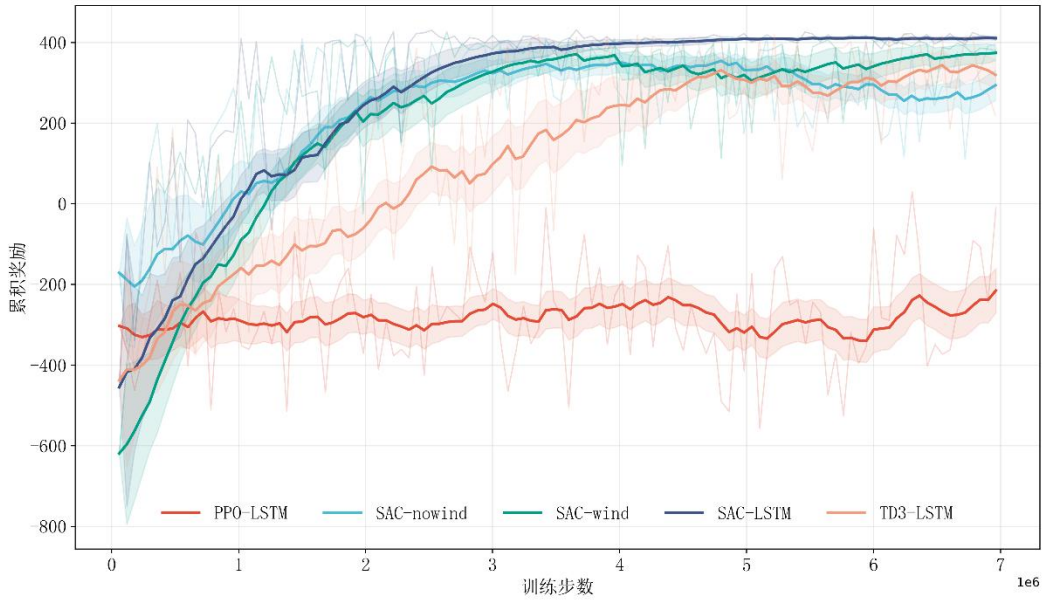



图 4.6 各模型训练评估结果图。

Fig.4.6 Training and evaluation results graphs of each model.

通过训练过程曲线可以看出，SAC-LSTM 模型在收敛后的稳定性方面明显优于其他各类模型，同时在收敛速度上亦处于领先水平，体现出较强的学习效率与策略稳定性。相比之下，SAC-wind 与 SAC-nowind 模型在整体收敛趋势上表现较为接近。这一现象主要源于随机风场生成机制中，不利风向（如逆风与斜逆风）的占比约为 25%，在统计意义上，有利风况对整体训练表现的影响更为显著，从而在一定程度上掩盖了两类模型在环境感知能力上的差异。

对于 PPO-LSTM 模型，其训练效果显著劣化。综合分析表明，该问题主要来源于时序结构与 on-policy 更新机制之间的矛盾。一方面，LSTM 结构通过引入隐藏状态刻画历史信息，需要依赖时间反向传播进行梯度更新，这本身对梯度稳定性提出了更高要求；另一方面，PPO 作为典型的 on-policy 方法，其策略更新严格依赖当前策略采样数据，样本利用率相对较低。在两者叠加作用下，训练

过程中梯度方差进一步放大，易导致策略更新不稳定甚至发散。上述因素共同作用，最终导致 PPO-LSTM 模型难以实现有效收敛。因此，在后续性能评估与对比分析中，不再将该模型纳入讨论范围。

对强化学习方法而言，仅仅通过奖励评估模型是不够全面的，因此本研究设计了以下几项评估指标：1、任务完成率，这项指标主要反映了模型在不同环境下的适应能力。 2、平均航行时间，这项指标主要反映了模型的总体航行速度。3、平均航行距离，这项指标主要反映了模型是否选择更短的航行路径。4、平均帆舵角度变化率，这项指标主要反映了模型在控制策略上是否有效且稳定。

测试一：在每次任务开始进行风向随机的环境中进行了 1000 次模拟以验证模型的总体性能，测试结果如表 4.3 所示：

表 4.3 不同模型综合测试结果

Table.4.3 Comprehensive test results of different models

| | SAC-wind | SAC-nowind | SAC-LSTM | TD3-LSTM |
|---|---|---|---|---|
| 任务完成率(%) | 93.5 | 87.0 | **99.6** | 89.9 |
| 平均航行时间(s) | 183.03 | 232.66 | **177.12** | 184.39 |
| 平均航行距离(m) | **585.04** | 653.37 | 586.78 | 595.34 |
| 帆角变化率(°/s) | 0.91 | 1.06 | 0.84 | **0.71** |
| 舵角变化率(°/s) | 0.73 | 0.93 | **0.67** | **0.67** |

由表中结果可知，SAC-LSTM 模型在各项指标上均表现出显著优势，其任务完成率达到 99.6%，接近完全成功，同时在平均航行时间与航行距离上均维持较优水平，表明该模型不仅具备更高的决策成功率，同时在路径效率上亦具有一定优势。进一步观察控制量变化率可以发现，SAC-LSTM 模型在帆角与舵角变化率上均处于较低水平，说明其控制策略更加平滑稳定，有利于实际系统执行与能耗控制。该模型的优势主要来源于时序信息建模能力的引入。相较于仅依赖当前观测状态的 SAC-wind 与 SAC-nowind 模型，LSTM 结构能够通过隐藏状态对历史观测进行编码，从而在部分可观测环境（POMDP）下恢复隐含的风场信息与系统动态特征。这种能力，使得策略在面对风向扰动或环境不确定性时，能够形成更具一致性的决策输出，从而显著提升任务完成率与路径稳定性。

对比 SAC-nowind 模型可以进一步验证上述结论。尽管其在训练阶段表现接近 SAC-wind 模型，但在大规模测试中，其任务完成率与航行效率均存在明显差距。这表明在缺乏风场信息输入且未引入时序建模机制的情况下，基于全连接网络的策略难以有效刻画环境动态，其决策本质上依赖于“瞬时观测-动作映射”，在复杂扰动条件下易出现策略退化。

此外，对比 TD3-LSTM 模型可以发现，尽管其同样引入了时序结构，但整体性能仍逊于 SAC-LSTM。这主要是由于 SAC 算法在策略更新过程中引入了熵正则项，使得策略在优化过程中能够在“探索-利用”之间取得更优平衡，从而在复杂环境中更容易收敛至鲁棒性更强的策略。而 TD3 作为确定性策略方法，在高维连续控制与噪声扰动环境下，策略多样性不足，限制了其性能上限。

综合来看，实验结果表明在无人帆船路径规划与控制问题中，融合最大熵强化学习框架与时序建模结构（LSTM），能够在提升任务成功率的同时，实现更高效且更平滑的控制效果。

测试二：选择四类具有代表性的风向（顺风：0°；横风：90°；斜逆风：150°；逆风：180°）各进行 100 次单一环境测试以验证 MPC 方法与强化学习模型在不同风向下的具体航行性能，测试结果如表 4.4、表 4.5 表 4.6 表 4.7 所示：

表 4.4 顺风环境下不同模型测试结果

Table.4.4 Test results of different models under tailwind conditions

| 指标 | MPC | SAC-wind | SAC-nowind | SAC-LSTM | TD3-LSTM |
|---|---|---|---|---|---|
| 任务完成率(%) | **100** | **100** | 99 | **100** | 96 |
| 平均航行时间(s) | 153.13 | 154.08 | 155.26 | **147.38** | 163.13 |
| 平均航行距离(m) | **505.83** | 508.90 | 529.15 | 508.15 | 507.70 |
| 帆角变化率(°/s) | 1.01 | 0.71 | 0.89 | **0.60** | 0.65 |
| 舵角变化率(°/s) | **0.30** | 0.44 | 0.62 | 0.47 | 0.45 |

表 4.5 横风环境下不同模型测试结果

Table.4.5 Test results of different models under crosswind conditions

| 指标 | MPC | SAC-wind | SAC-nowind | SAC-LSTM | TD3-LSTM |
|---|---|---|---|---|---|
| 任务完成率(%) | **100** | **100** | 95 | **100** | 88 |
| 平均航行时间(s) | **144.31** | 144.91 | 222.76 | 160.60 | 193.59 |
| 平均航行距离(m) | **524.39** | 536.54 | 700.68 | 556.57 | 592.33 |
| 帆角变化率(°/s) | 0.86 | 0.74 | 1.15 | 1.12 | **0.84** |
| 舵角变化率(°/s) | **0.44** | 0.49 | 0.90 | 0.65 | 0.45 |

表 4.6 斜逆风环境下不同模型测试结果

Table.4.6 Test results of different models under oblique headwind conditions

| 指标 | MPC | SAC-wind | SAC-nowind | SAC-LSTM | TD3-LSTM |
|---|---|---|---|---|---|
| 任务完成率(%) | **100** | 92 | 77 | 98 | 85 |
| 平均航行时间(s) | 276.35 | 290.11 | 333.57 | 275.85 | **275.84** |
| 平均航行距离(m) | **736.01** | 752.83 | 814.73 | 751.27 | 748.91 |
| 帆角变化率(°/s) | 0.74 | 0.82 | 0.99 | 1.09 | **0.73** |
| 舵角变化率(°/s) | **0.81** | 0.86 | 0.92 | 0.75 | 0.87 |

表 4.7 逆风环境下不同模型测试结果

Table.4.7 Test results of different models under headwind conditions

| 指标 | MPC | SAC-wind | SAC-nowind | SAC-LSTM | TD3-LSTM |
|---|---|---|---|---|---|
| 任务完成率(%) | **100** | 87 | 59 | **100** | 70 |
| 平均航行时间(s) | 323.18 | 301.82 | 349.39 | 318.78 | **277.44** |
| 平均航行距离(m) | **741.18** | 786.73 | 762.12 | 746.44 | 795.59 |
| 帆角变化率(°/s) | **0.81** | 0.95 | 1.22 | 1.11 | 0.71 |
| 舵角变化率(°/s) | **0.92** | 1.03 | 1.26 | 1.12 | 1.02 |

从整体结果来看，各模型在不同风向条件下呈现出明显的性能分化特征，其差异主要来源于状态信息完备性与策略表达能力的不同。

首先，在表 4.7 显示的逆风工况下，SAC-wind 模型相较于 SAC-nowind 模型

表现出更优的任务完成率与航行效率。这一结果符合马尔科夫决策过程（MDP）的基本假设，即状态信息的完备性直接决定策略最优性的上界。由于 SAC-wind 模型显式引入风场信息，使得智能体能够在决策过程中感知环境动力约束，从而学习到更符合物理机理的航行策略（如合理的迎风角与换舷行为）。相比之下，SAC-nowind 由于缺失关键环境变量，其策略在逆风场景中表现出明显退化，航行距离与时间均显著增加。

然而，SAC-wind 在逆风条件下的任务完成率仍未达到理想水平。这一现象的根本原因可能在于奖励函数设计中的禁航区惩罚项。该设计在训练早期能够有效抑制进入禁航区的无效行为，起到策略引导作用；但在后期策略收敛阶段，由于逆风航行本质上依赖“Z 字形”折线前进（即频繁跨越禁航区边界），该惩罚机制与最优航行策略之间产生了内在冲突，进而导致策略在局部区域出现不稳定甚至失败的情况。

本文提出的 SAC-LSTM 模型在各类风况下均表现出较强的鲁棒性与稳定性。一方面，其任务完成率在复杂工况（尤其是逆风与斜逆风）下保持较高水平；另一方面，在航行时间、路径长度以及控制量变化率等关键指标上，均与 MPC 基线方法保持接近甚至更优的表现。特别是在顺风与横风条件下，SAC-LSTM 能够在保证控制平滑性的同时实现更短的航行时间，体现出较优的策略结果。

综合来看，SAC-LSTM 模型通过引入时序建模能力（LSTM）弥补了传统强化学习在部分可观测环境（POMDP）中的不足，使策略能够隐式编码历史信息，从而逼近 MPC 方法的工程最优性能，验证了本研究提出强化学习方法在无人帆船控制问题中的有效性。

在完成定量指标对比分析的基础上，进一步对四类风向条件下的航行过程进行可视化表达，通过绘制航迹曲线及对应的帆角、舵角时序变化，对模型的控制行为进行刻画，具体表现如图 4.7、图 4.8、图 4.9、图 4.10 所示。

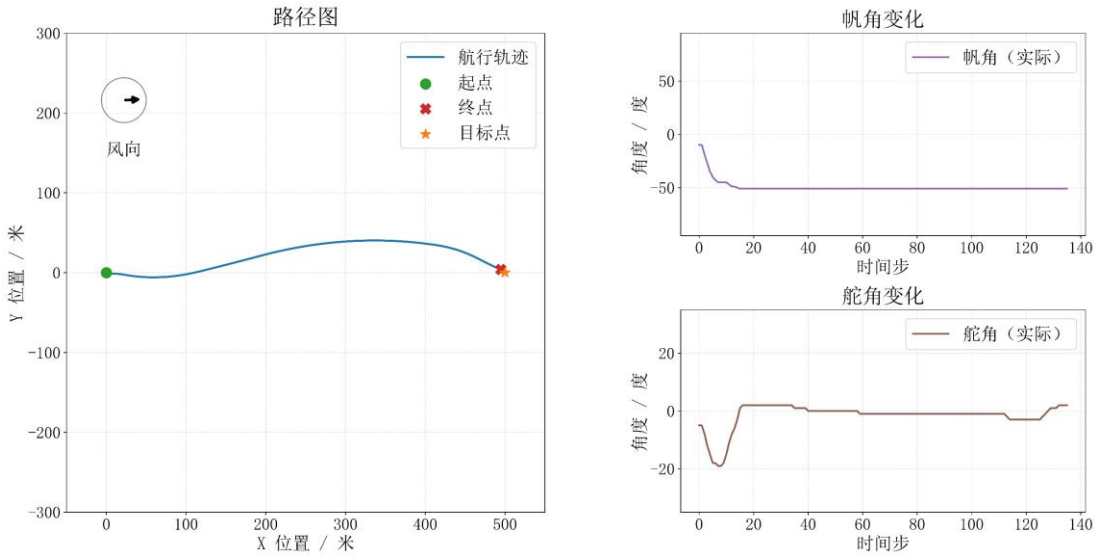



图 4.7 顺风环境下航行轨迹与控制策略。

Fig.4.7 Trajectory and control strategy under tailwind conditions.

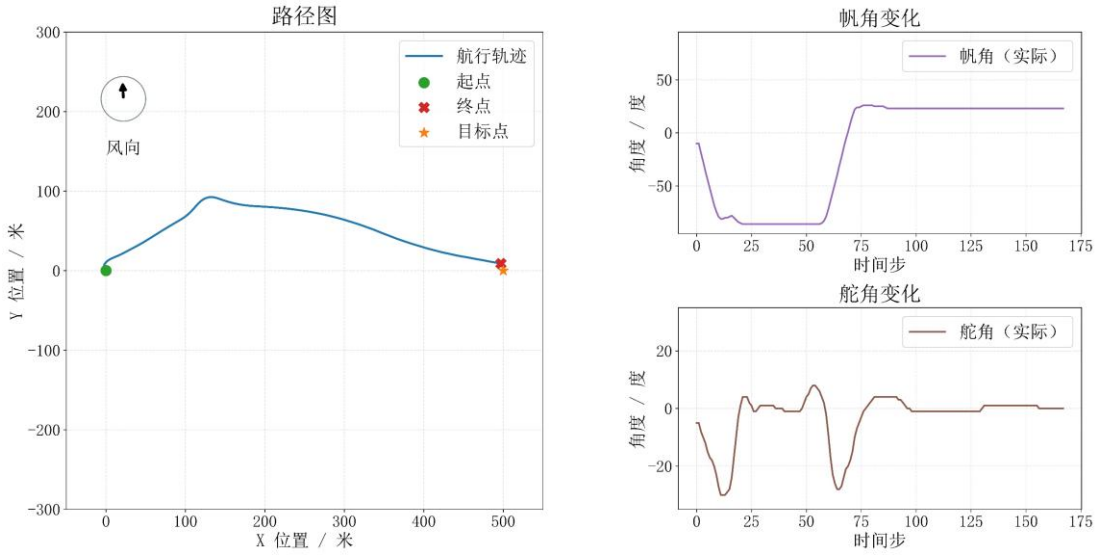



图 4.8 横风环境下航行轨迹与控制策略。

Fig.4.8 Trajectory and control strategy under crosswind conditions.

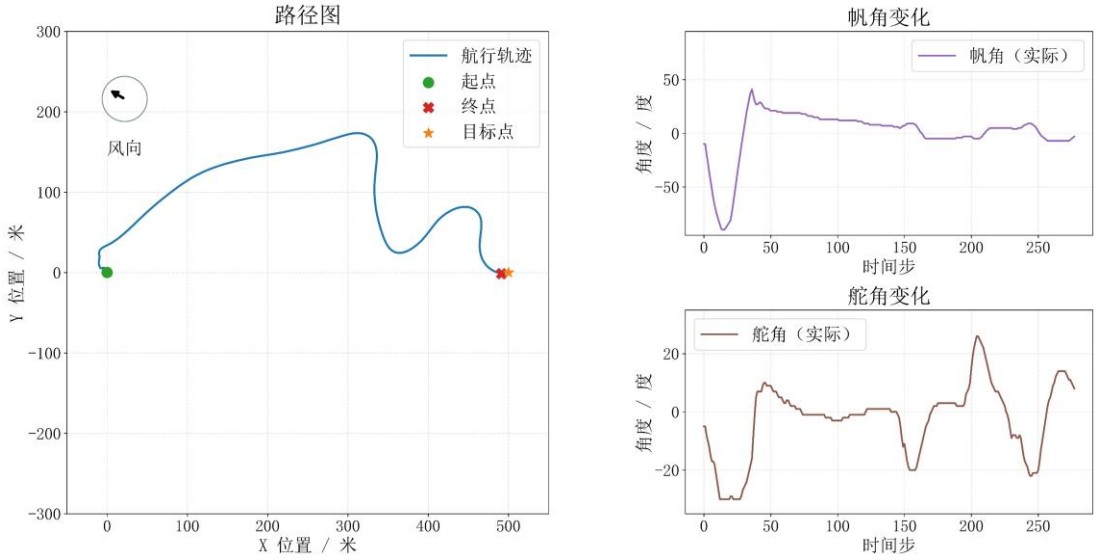



图 4.9 斜逆风环境下航行轨迹与控制策略。

Fig.4.9 Trajectory and control strategy under oblique headwind conditions.

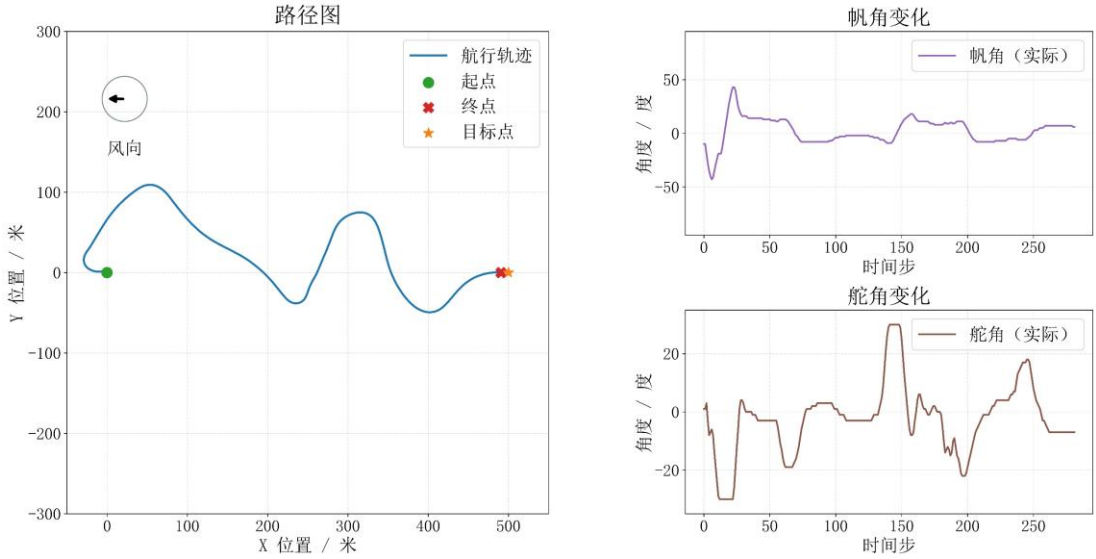



图 4.10 逆风环境下航行轨迹与控制策略。

Fig.4.10 Trajectory and control strategy under headwind conditions.

结果表明，在不同风向条件下，SAC-LSTM 模型均能够形成与常规帆船航行机理相一致的控制模式：在顺风与横风工况下，航迹较为平滑，控制量变化稳定；而在斜逆风及逆风条件下，模型能够自发形成类似“Z 字形”的换舷航行轨迹，并伴随周期性的舵角调整与帆角协同变化。上述可视化结果为定量实验结论提供了更直观的支撑，同时从控制机理层面进一步验证了所提方法的有效性与合理性，表明该模型具备良好的物理一致性与工程应用潜力。

### 4.4.2 模型鲁棒性测试

对于强化学习方法而言，鲁棒性测试旨在刻画策略在环境不确定性与动态扰动下的泛化能力与稳定性，是验证模型实际应用可行性的关键环节。由于本实验中的仿真环境并未显式建模波浪与水流等复杂海洋扰动因素，因此在模型适应性测试中主要通过对风场进行扰动构造不确定性，并且所有测试均基于未经后续微调的原始策略进行评估。具体而言，为了更全面地反映真实海洋环境中风场的复杂变化特性，本文从风场的不同尺度与突发性变化两个方面构建测试工况：一方面，通过设置不同的 Dryden 模型风场尺度来考察模型对不同扰动环境的适应能力；另一方面，在航行过程中引入风向的突变扰动，以模拟阵风或局部天气变化情形，从而评估策略在非平稳环境下的快速响应能力与稳定性表现。同时，提升环境中设定的固定噪声以验证模型对来自自身数据干扰的鲁棒性。需要说明的是，本文未对多种风速条件进行大规模扩展测试，主要基于以下考虑：首先，在无人帆船动力学中，风速的变化主要影响系统的推进强度，而对决策本身的影响相对有限。相比之下，风向变化及其时序不确定性对航行策略的影响更为关键，尤其体现在路径选择与航向调整等决策层面。

（a）不同风场尺度环境

本实验中的帆船模型参数属于中型帆船，在训练环境的风场尺度参数外设定强扰动，高频阵风以及综合极端环境，相关风场尺度如表 4.8：

表 4.8 不同场景风场尺度参数表

Table.4.8 Wind Field Scale Parameters under Different Scenarios

| | $L_u$(m) | $L_v$(m) | $\sigma_u$(m/s) | $\sigma_v$(m/s) |
|---|---|---|---|---|
| 训练 | 300 | 150 | 1.2 | 1.0 |
| 强扰动 | 300 | 150 | 2.0 | 1.6 |
| 高频阵风 | 100 | 50 | 1.2 | 1.0 |
| 综合极端环境 | 100 | 50 | 2.0 | 1.6 |

在各项参数调节后，同样进行不同风向下的综合性能测试，测试结果如表 4.9。

表 4.9 不同风场尺度下综合任务成功率

Table.4.9 Overall Task Success Rate under Different Wind Field Scales

| | SAC-wind | SAC-LSTM |
|---|---|---|
| 训练 | 93.5 | **99.6** |
| 强扰动 | 93.4 | **98.7** |
| 高频阵风 | 93.0 | **99.4** |
| 综合极端环境 | 92.6 | **98.4** |

通过上表结果得到，SAC-wind 模型的成功率由训练环境下的 93.5%分别下降至 93.4%、93.0%和 92.6%，整体降幅约为 0.1%–0.9%；而 SAC-LSTM 模型则由 99.6%下降至 98.7%、99.4%和 98.4%，降幅约为 0.2%–1.2%。可以看出，两类模型在不同风场尺度扰动下均表现出较强的稳定性，性能下降幅度整体较小，说明所学习策略已具备一定的跨环境泛化能力。值得注意的是，从绝对降幅来看，SAC-LSTM 模型在部分扰动条件下的性能下降略高于 SAC-wind 模型，这表明其对训练分布的依赖程度相对更强。然而，由于其基线性能显著更高，即使在分布外环境中出现一定退化，其绝对性能仍然保持在较优水平。

（b）风向突变环境

除了在风场尺度参数上进行对照测试，本实验还设计了风向突变环境以检测模型是否能够做出快速的响应以完成任务。具体设定为将局部航行区域以 x=250m 为轴分为左右半区，左右半区的风向中值分别相差 30°，60°，90°。以初始风向 180°，后续风向突变 90°为例，具体可以表示为图 4.11。

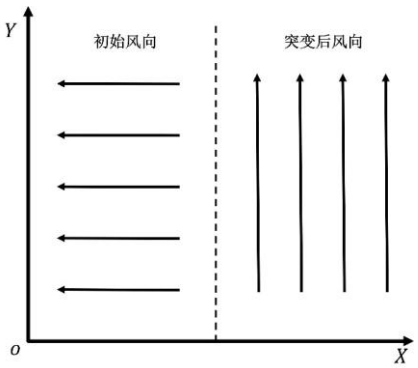



图 4.11 风向突变场景示意图。

Fig.4.11 Schematic of Wind Direction Shift Scenario.

不同突变风向下的综合测试结果如下表 4.10。

表 4.10 不同风向突变场景下综合任务成功率

Table.4.10 Overall Task Success Rate under Different Wind Direction Shift Scenarios

| | SAC-wind | SAC-LSTM |
|---|---|---|
| 无突变（训练） | 93.5 | **99.6** |
| 突变 30° | 93.4 | **98.4** |
| 突变 60° | 91.6 | **96.4** |
| 突变 90° | 90.8 | **95.6** |

由于模型在基础环境下已具备较强的适应能力，SAC-LSTM 模型在各类风向突变条件下的最终任务完成率仍然保持在较高水平。从实验结果来看，随着风向突变幅度由30°增加至90°，SAC-LSTM模型成功率由99.6%逐步下降至95.6%，SAC-wind 模型成功率由 93.5%逐步下降至 90.8%，均呈现单调下降趋势，表明突发性环境变化会对模型性能产生一定影响，且扰动强度越大，性能退化越明显。

这一性能下降主要源于 LSTM 结构对历史信息的依赖。当风向发生突变时，模型内部的隐藏状态在短时间内仍保留突变前的环境特征，从而导致策略输出存在一定的响应滞后，即需要经过若干时间步完成对新风场条件的重新表征与适应。因此，在突变发生初期，模型的控制效果会出现阶段性下降。然而，随着时间推进，隐藏状态逐渐更新并完成对当前环境的有效编码，模型能够恢复稳定的决策能力，并维持较高的任务完成率。这表明，尽管 SAC-LSTM 在面对突发扰动时存在一定的短时适应过程，但其依托时序信息建模所形成的全局决策能力，使其在整体任务执行层面仍表现出良好的鲁棒性与稳定性。

（c）不同固定噪声环境

在 3.3 节中，本研究设定了训练时的相关固定噪声，如：位置传感器噪声设定为 1m，角度传感器噪声设定为 1°，速度传感器噪声设定为 0.1m/s，角速度传感器噪声设定为 0.1°/s，风向传感器噪声设定为 2°，风速传感器噪声设定为 0.5m/s。以此为基准，在本小节的对比实验中，将噪声设定为 2 倍基准、3 倍基准、5 倍基准以验证模型对自身状态噪声的适应能力。为确保 SAC-LSTM 模型

与 SAC-wind 模型的一致性，风向和风速的噪声不做修改。

综合测试结果如下表 4.11 所示：

表 4.11 不同噪声环境下综合任务成功率

Table.4.11 Overall Task Success Rate under Different Noise Conditions

| | SAC-wind | SAC-LSTM |
|---|---|---|
| 基准噪声（训练） | 93.5 | **99.6** |
| 2 倍基准噪声 | 86.7 | **99.3** |
| 3 倍基准噪声 | 76.0 | **98.3** |
| 5 倍基准噪声 | 55.3 | **88.0** |

通过测试结果可以看出，随着噪声水平的不断扩大，SAC-wind 模型与 SAC-LSTM 模型的综合成功率从训练基准噪声下的 93.5%和 99.6%下降至 5 倍基准噪声下的 55.3%和 88.0%。在 2 倍、3 倍基准噪声的情况下，SAC-LSTM 模型依然能够保持较高的成功率，而 SAC-wind 模型则出现了明显的性能衰退。在 5 倍基准噪声的情况下，SAC-LSTM 模型的综合成功率迅速下降至 90%以下，标志着该模型开始进入性能衰退的临界点。噪声实验结果表明，LSTM 结构通过对历史状态信息的动态记忆与处理，不仅使模型在部分可观测环境中表现出色，还显著增强了模型的噪声容忍度。

### 4.4.3 敏感性分析

最后，为了分析不同状态变量对策略决策的影响程度，本文采用基于状态分布的敏感性分析方法。由于部分状态变量在系统运行过程中变化范围较小，例如横摇角速度。单纯基于梯度的敏感性分析可能会高估其重要性。因此本文结合状态变量的实际分布，对敏感度进行方差加权，从而更加准确地反映各变量在真实控制过程中的贡献。具体定义为：

$$I_i = \mathbb{E}_{s\sim D}\left|\frac{\partial \pi(s)}{\partial s_i}\right|\sigma_i \tag{4.4-1}$$

其中$D$表示策略运行过程中采集到的状态分布，$\sigma_i$表示状态变量$s_i$的标准差。

经过采样和计算，获得如图 4.12 所示的不同状态变量的敏感度。

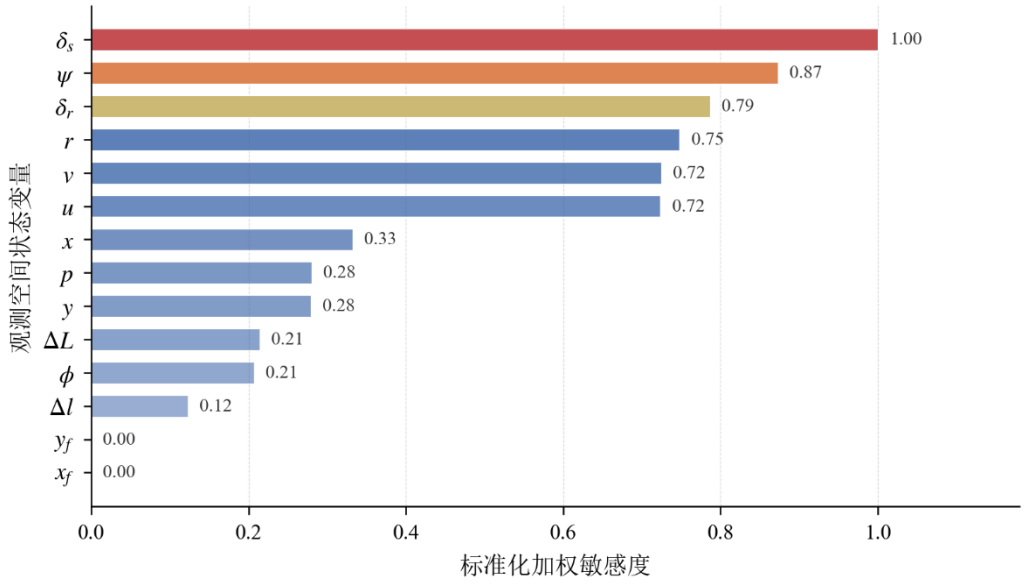



图 4.12 状态变量敏感度柱状图。

Fig.4.12 Bar Chart of State Variable Sensitivities.

从敏感性分析结果出发，可以对各类状态变量在策略决策中的作用进行逐一分析。首先，帆角$\delta_s$,、舵角$\delta_r$以及航向角$\psi$表现出最高敏感度，说明策略主要依赖于帆–舵协同控制来实现航行状态调节。其中，帆角直接决定气动力的生成，是推进能力的核心来源；舵角则主要用于航向调整，与航向角共同构成姿态控制闭环。其次，速度分量$u$、$v$以及角速度$r$同样具有较高敏感度，表明策略在决策过程中依赖系统的瞬时动力学状态。这类变量虽未全部在奖励函数中显式出现，但其变化会直接影响航向调整过程及目标逼近效率，从而通过动力学耦合关系间接作用于奖励累积。最后，部分辅助变量（如$\Delta L, \Delta l, x_f, y_f$等）敏感度相对较低甚至接近于 0。这一现象主要源于任务设定中终点位置为固定值，在长期训练过程中，目标位置信息逐渐被策略内化，从而降低了显式目标坐标对决策的直接影响。同时，这些变量所包含的信息并未完全失效，而是通过与航向、速度等关键状态变量之间的动力学耦合关系，以间接形式在策略中得到体现，即其作用可能已被其他高敏感变量所表征。此外，需要强调的是，本研究在状态构建过程中并未进行特征筛选，而是将所有相关物理量统一纳入模型输入。实验结果表明，这种完整状态表达并未对最终训练效果产生不利影响，说明所构建的状态空间具有一定冗余性和鲁棒性。

总的来说，强化学习模型决策主要依赖于与运动状态直接相关的关键变量，而非冗余的绝对位置信息。该敏感性分布与无人帆船的实际运动机理相一致，表

明模型在数据驱动框架下能够有效捕捉与物理过程相关的关键信息，从而体现出一定程度的物理一致性。

## 4.5 本章小结

本章围绕无人帆船在部分可观测环境下的自主航行控制问题，系统开展了模型构建、算法设计与性能验证研究。

首先，从问题建模层面出发，明确了部分可观测环境与完全可观测环境在决策机制上的本质差异，并引入基于历史信息建模的解决思路。在此基础上，对传统强化学习网络结构进行了针对性改进，将 LSTM 结构嵌入策略与价值网络之中，使模型具备对历史观测序列的编码能力，从而实现对隐含风场信息的间接重构，有效弥补了观测信息不足所带来的决策偏差。

其次，在算法设计方面，选取 SAC 作为核心强化学习框架，并结合无人帆船在不同风向条件下的动力学特性，构建了具有物理意义的奖励函数体系，使策略学习过程能够兼顾任务完成效率与控制平滑性。

在实验验证层面，通过多组对比与消融实验得出明确结论：引入 LSTM 结构后的 SAC-LSTM 模型在任务完成率、航行效率及控制平滑性等指标上综合性能优于 SAC-wind、SAC-nowind 及 TD3-LSTM 等模型，其任务完成率接近完全成功，并在复杂风场条件下表现出更强的稳定性。与传统 MPC 方法的对比表明，该模型在无需显式建模与在线优化的情况下，已能够逼近工程最优控制性能，体现出端到端强化学习方法的实际应用潜力。

在泛化与鲁棒性分析方面，通过未知风向条件及风向突变场景测试发现，模型整体表现出良好的鲁棒性与适应能力。此外，敏感性分析结果表明，各状态变量对决策的贡献具有明显差异，该分析增强了模型的可解释性，也为未来特征优化提供了依据。

# 5 面向静态障碍物环境的控制模型优化

## 5.1 引言

海洋环境复杂多变，航行过程中往往存在岛礁、浮标、船舶以及海上设施等多种静态或动态障碍物，这些因素都会对无人帆船的安全航行造成影响。与传统无人船相比，无人帆船的运动特性受到风速、风向以及帆船动力结构的影响，其航向调整和机动能力相对受限。因此，本章节需要在目标追踪和障碍物避让存在一定冲突的情况下，让控制策略实现有效协调。在上一节的研究基础上，本章节对静态障碍物环境下的无人帆船控制模型进行优化，通过融入注意力机制加强对隐藏状态的利用效果以提升整体的避障效果，使帆船最终能够在局部航行中以设定的安全距离避开静态障碍物。

## 5.2 避障问题的优化方案

为提升自主帆船在复杂航行场景中的避障能力，本文从网络结构和任务建模两个层面进行了针对性优化。一方面，本研究考虑到突然出现的障碍物信息需要对隐藏状态进行有选择的高效利用，因此在原有 SAC-LSTM 框架基础上引入注意力机制，使策略网络和价值网络能够从隐藏状态序列中自适应筛选对当前决策更关键的时序信息；另一方面，在训练环境中新增了静态障碍物的随机生成以及对障碍物的观测设定，在奖励函数中依据传统经验设计了障碍物相关奖励项，从而增强智能体在接近障碍物、绕障通过以及恢复航向等过程中的学习效率与行为稳定性。

### 5.2.1 网络结构优化

注意力机制旨在通过计算不同输入信息之间的相关性，对历史信息进行加权，从而突出对当前决策更为重要的部分[75]。在深度学习中，常用的形式为缩放点积注意力。给定查询向量（Query）、键向量（Key）和值向量（Value），注意力计算过程可以表示为:

$$\text{Attention}(Q,K,V)=\text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{5.2-1}$$

其中：$Q$表示查询矩阵（Query）；$K$表示键矩阵（Key）；$V$表示值矩阵（Value）；$d_k$表示键向量的维度；$QK^T$表示查询与各键之间的相似度；softmax(·)用于对相

似度进行归一化，得到不同历史信息的权重。

在该机制中，查询向量$Q$与键向量$K$的点积衡量当前输入与历史信息之间的相关性，而归一化后的权重用于对值向量$V$进行加权求和，从而获得综合考虑历史信息的重要特征表示。

本文所引入的注意力机制主要针对 LSTM 网络的隐藏状态序列以及当前决策。具体而言，将当前状态特征嵌入作为查询向量：

$$Q = W_q \phi(s_t) \tag{5.2-2}$$

同时，将 LSTM 输出序列映射为键和值：

$$K = W_k H, V = W_v H \tag{5.2-3}$$

其中 $W_q, W_k, W_v$为可学习参数矩阵，$H = [h_1, h_2, \dots, h_T]$表示 LSTM 在不同时间步输出的隐藏状态序列，通过滑动窗口方法可以设置$H$的序列长度

根据注意力计算公式，可以得到历史序列的权重分布：

$$\alpha = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \tag{5.2-4}$$

最终，通过对值向量进行加权求和得到时序上下文表示：

$$c_t = \alpha V \tag{5.2-5}$$

该向量$c_t$表示在当前状态条件下，从历史序列中提取出的最相关时序信息。最后与第四章的处理相同，向量$c_t$将与当前状态的提取特征进行拼接，用于后续输出动作分布或 Q 值估计。

优化后的网络结构模型以其中一个 Critic 网络为例，如图 5.1 所示：

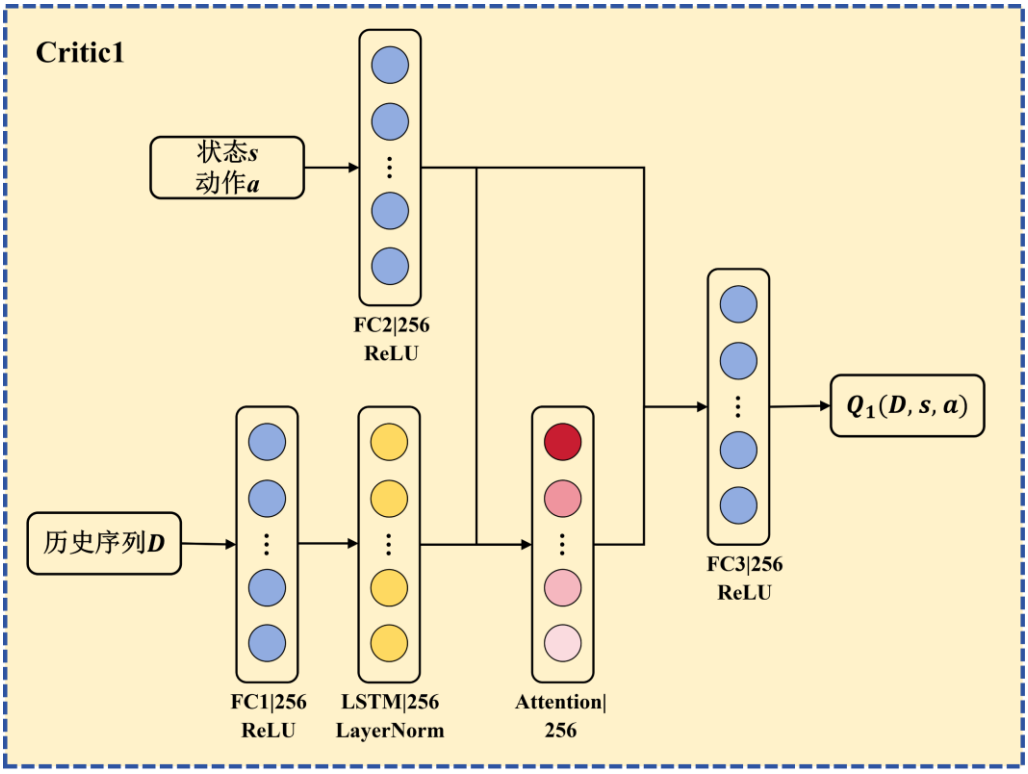



图 5.1 引入注意力层的 Critic 网络结构。

Fig.5.1 Critic Network Architecture with an Attention Layer.

### 5.2.2 避障环境

在避障环境设定方面，本文将环境观测空间扩展为十八维，除第四章所述的十四维外，额外加入了最近两个已观测障碍物的相对距离与相对艏向夹角信息。状态空间特征变量如下：

$$[x, y, \phi, \psi, u, v, p, r, \delta_s, \delta_r, \Delta L, \Delta l, x_f, y_f, d_{obst1}, \theta_{obst1}, d_{obst2}, \theta_{obst2}] \quad (5.2\text{-}6)$$

为增强任务真实性，障碍物并非全局可见，而是需要帆船在航行过程中自主探测。帆船的探测范围以假定的双目相机探测为主，以船艏为中心，视场角 120°，探测范围 150 米。在航行过程中，探测到的障碍物首先会进行相对距离$d$以及相对角度$\theta$的计算，并存入一个全局观测模块，并且障碍物如果持续存在于探测范围内也会同步更新相对距离以及相对角度。最后将当前时刻下，全局观测模块中相对距离最近的两个障碍物信息输出至观测状态用于模型控制决策。

在模拟环境中障碍物探测的相关参数表示为下图 5.2 所示：

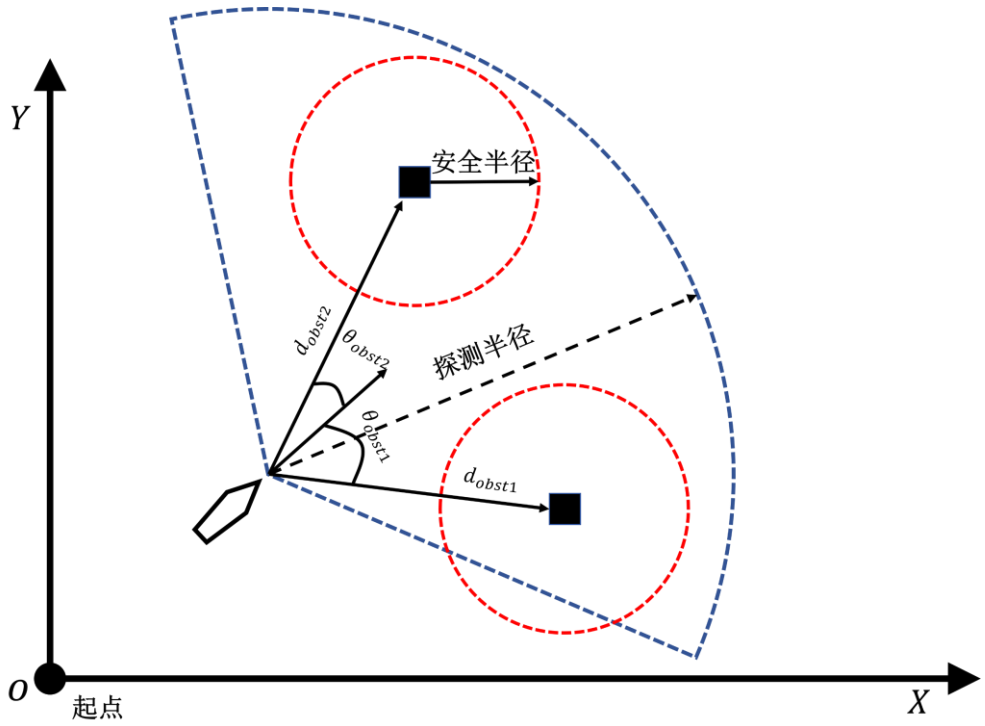



图 5.2 障碍物检测示意图。

Fig.5.2 Schematic of Obstacle Detection.

在环境初始化时，采用 30%无障碍物、70%含障碍物的混合场景生成方式，在含障碍物的场景中随机布置 5 到 8 个障碍物，同时约束障碍物与起点、目标点及彼此之间保持最小安全间距 140m，以避免训练样本过于单一或出现不可通行构型。此外，本实验将与障碍物距离 40m 判定为最小安全距离，小于该距离的情况下作为额外的采样中止条件之一。

在奖励函数设计方面，对避障设置了以距离为核心的指数型惩罚函数：当障碍物进入 150m 警戒范围后开始施加惩罚，并在距离逼近 40 m 碰撞边界时快速增大，以提前塑造风险规避意识。总体奖励如公式：

$$R = \gamma \cdot \left(R_{progress} + R_{action}\right) + R_{checkpoint} + R_{arrival} + R_{penalty} + R_{obst} \tag{5.2-7}$$

其中关于避障惩罚部分计算如公式：

$$R_{obst} = R_{obst1} + R_{obst2} \tag{5.2-8}$$

当$d_{obst1}$与$d_{obst1}$小于 150 米时：

$$R_{obst_i} = \alpha e^{-\frac{\left(d_{obst_i} - d_c\right)}{\beta}}, i = 1,2 \tag{5.2-9}$$

$$d_c = 40, \alpha = 1, \beta = 20$$

## 5.3 实验结果与分析

### 5.3.1 注意力机制对比实验

为系统评估注意力机制在无人帆船路径规划与控制任务中的有效性，本文围绕历史信息利用能力构建对比实验体系。在保证输入输出空间、训练策略及参数规模基本一致的前提下，仅改变历史信息的融合方式，从而剥离模型容量与特征表达能力的干扰，突出注意力机制本身的作用。

具体而言，本文设计三类模型进行对比。主模型采用基于注意力机制的 SAC-LSTM 结构，以当前时刻状态特征作为 Query，以 LSTM 输出的历史隐状态序列作为 Key 和 Value，通过注意力权重实现对历史信息的动态加权，从而增强模型在部分可观测环境中的决策能力。对照模型 1 在移除注意力机制的基础上，通过增加网络深度使参数量与主模型保持一致，仅依赖 LSTM 最终隐藏状态进行决策，用于验证性能提升是否来源于模型规模的增加。对照模型 2 则对历史 LSTM 状态进行线性投影以模拟注意力机制结构，并采用平均池化进行信息融合，该方法保留特征变换能力但不具备动态权重分配机制，用于分析注意力机制中加权选择过程的实际贡献。

为确保对比结果的公平性与可重复性，实验对关键变量进行了统一控制，包括模型参数规模、超参数、训练环境配置（风场分布与障碍物生成机制）、强化学习训练策略以及状态与动作空间定义等，避免非关键因素对实验结果产生干扰。

测试过程沿用第四章所构建的仿真环境，在多风向随机条件及含随机障碍物的场景下开展多组独立实验。考虑到障碍物分布与风向变化对航行策略具有显著影响，不同实验之间路径长度与时间等指标可比性较弱，因此本文选取航行成功率作为核心评价指标。训练结果如图 5.3 所示。

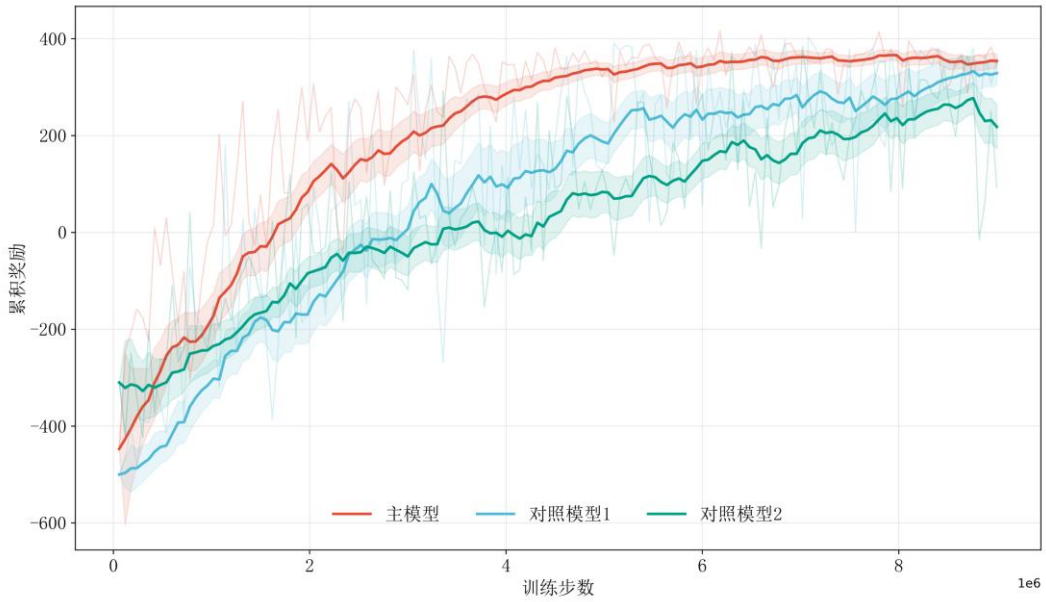



图 5.3 注意力机制对照实验训练结果。

Fig.5.3 Training Results of Ablation Experiments on the Attention Mechanism.

训练结果表明，引入注意力机制的 SAC-LSTM 模型在收敛速度、最终性能及训练稳定性方面均显著优于两类对照模型。在参数规模一致的条件下，对照模型 1 性能存在一定差距，说明性能提升并非源于模型复杂度增加；而对照模型 2 虽保留特征变换结构，但由于缺乏动态权重分配机制，其性能甚至比对照模型 1 更差，说明历史隐藏状态的利用并不能进行简单地糅合。进一步分析表明，注意力机制通过对历史隐藏状态的自适应加权，有效缓解了部分可观测环境中的信息不确定性，实现了对关键时序信息的选择性利用，从而显著提升了策略学习效率与决策性能。

具体环境测试结果如表 5.1 所示。

表 5.1 注意力机制对照实验中不同模型的任务成功率

Table.5.1 Task Success Rate of Different Models in Attention Mechanism Ablation Experiments

| | 主模型 | 对照模型 1 | 对照模型 2 |
|---|---|---|---|
| 综合成功率(%) | **95.3** | 93.3 | 80.8 |
| 顺风成功率(%) | 97.6 | **98.3** | 97.1 |
| 横风成功率(%) | **96.3** | 95.5 | 84.0 |
| 斜逆风成功率(%) | **93.2** | 89.5 | 32.5 |
| 逆风成功率(%) | **92.3** | 84.0 | 50.7 |

在前述训练过程分析的基础上，表中结果进一步从任务完成效果的角度验证了模型性能差异。可以看出，主模型在综合成功率以及横风、斜逆风和逆风等复杂工况下均保持领先，而在顺风条件下各模型表现接近。这一现象表明，不同模型之间的性能差距主要体现在复杂风场条件下的决策能力。相较而言，顺风场景对历史信息依赖较弱，各模型均能够获得较高成功率；而在斜逆风与逆风等受限工况中，航行策略对时序信息的利用程度显著提升，此时主模型优势更加突出。

因此，可以认为，前文所述注意力机制带来的性能提升，主要体现在其对复杂环境的适应能力上，而非对简单场景的基础性能提升。该结果从实验层面进一步印证了模型在部分可观测环境中的有效性。

本小节对障碍物位置进行了固定，在不同风向下进行测试，最后将引入注意力机制的 SAC-LSTM 模型结果进行可视化展示，如图 5.4、图 5.5、图 5.6、图 5.7。

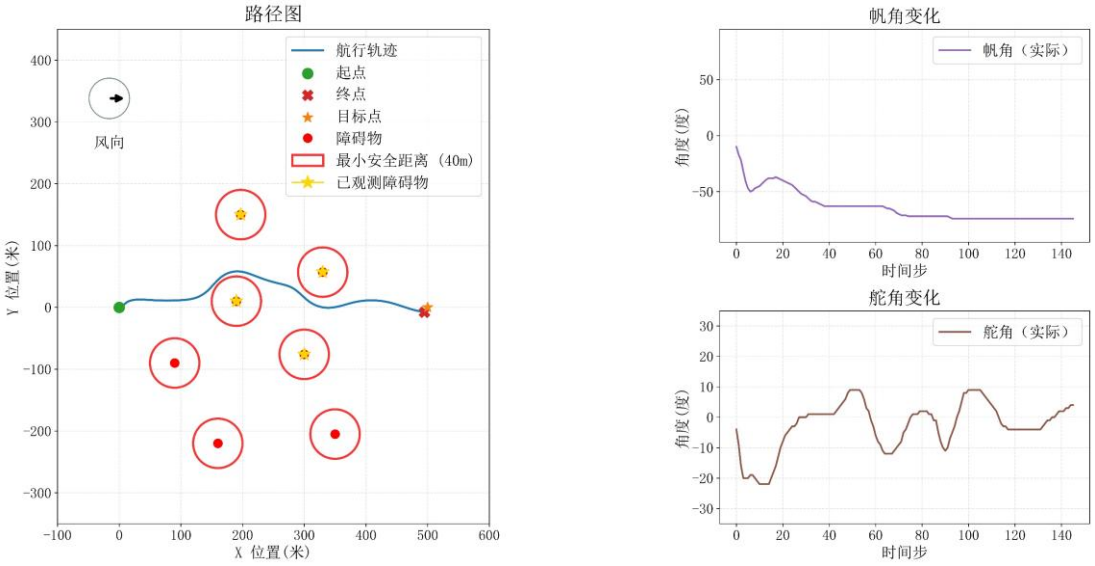



图 5.4 顺风环境下避障航行轨迹与控制策略。

Fig.5.4 Obstacle avoidance trajectory and control strategy under tailwind conditions.

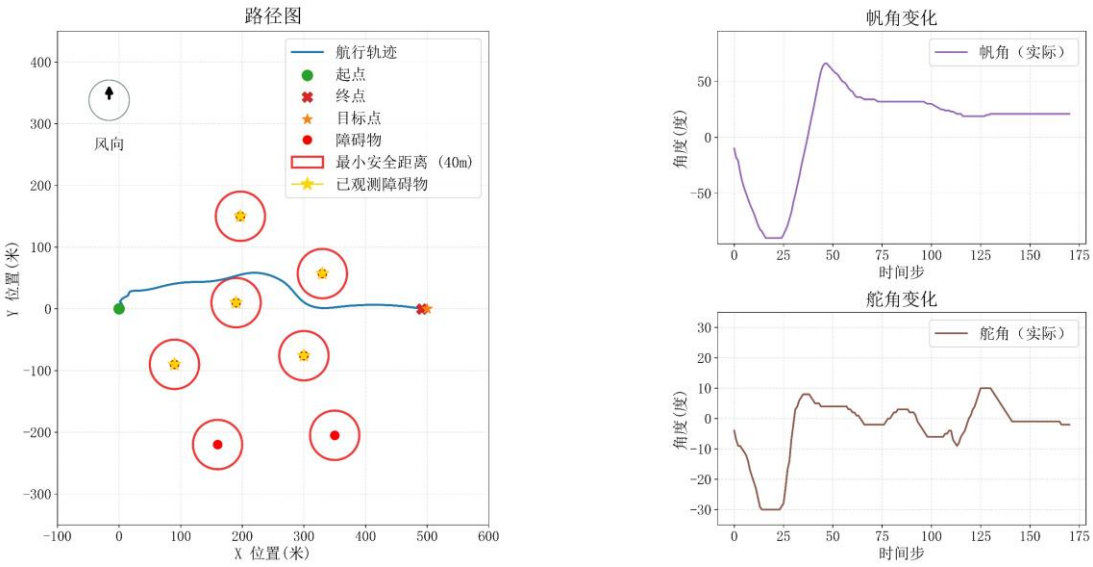



图 5.5 横风环境下避障航行轨迹与控制策略。

Fig.5.5 Obstacle avoidance trajectory and control strategy under crosswind conditions.

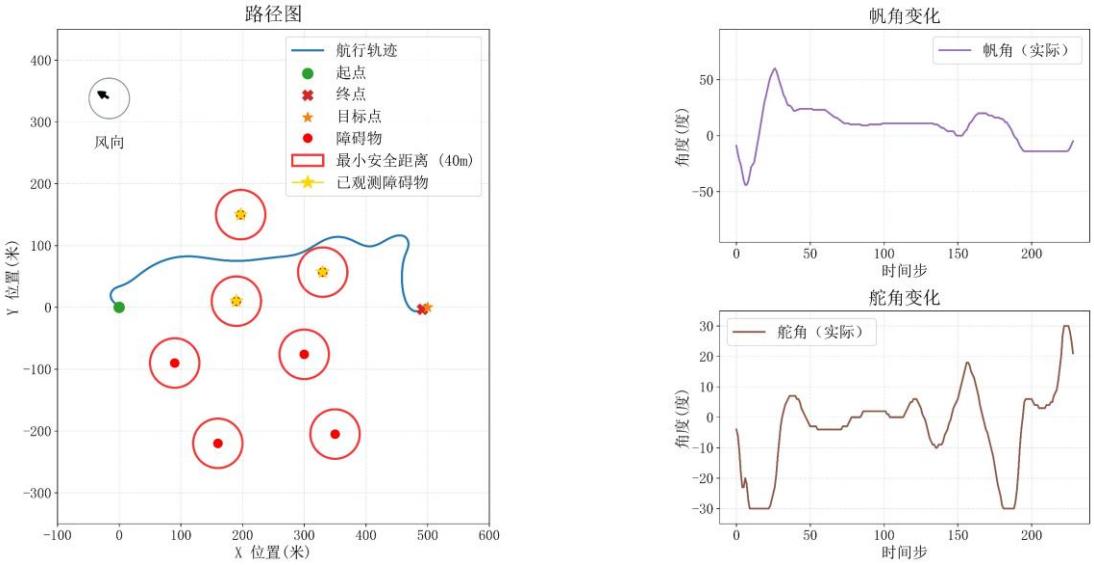



图 5.6 斜逆风环境下避障航行轨迹与控制策略。

Fig.5.6 Obstacle avoidance trajectory and control strategy under oblique headwind conditions.

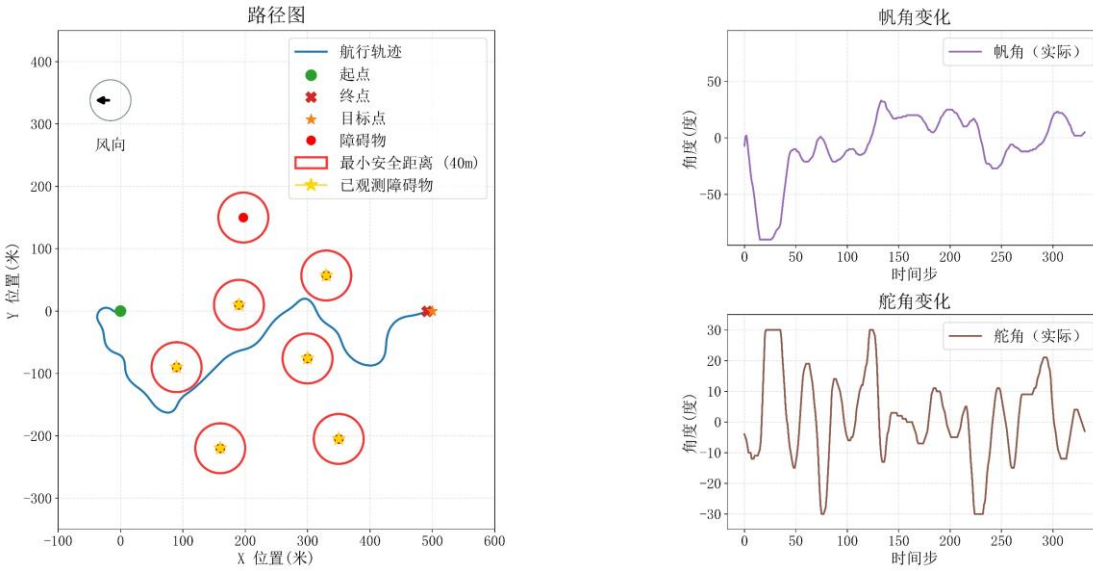



图 5.7 逆风环境下避障航行轨迹与控制策略。

Fig.5.7 Obstacle avoidance trajectory and control strategy under headwind conditions.

根据以上可视化结果表明，在不同风向条件下，模型均能够在最小安全距离的要求下实现避障航行任务。并且从图中看出，不同风向下的航行轨迹均存在着与最小安全距离十分接近的部分，特别是顺风和横风环境中，航行轨迹在避障过程中几乎与设定的最小安全圆弧平行，说明模型对需要规避的区域有准确的认知。模型最终在该认知判断上实现局部避障与完成航行目标的决策平衡，并且基于奖励函数中的帆舵角度控制幅度惩罚项实现了相对稳定有效的控制。

### 5.3.2 注意力滑动窗口长度对比实验

在引入注意力机制后，模型需要对历史隐藏状态序列进行加权融合。为控制参与注意力计算的历史信息范围，本文在模型中引入滑动窗口机制，其长度记为$K$，用于限定参与加权计算的历史隐藏状态数量。窗口长度的选取可能影响模型对历史信息的利用能力与决策稳定性，因此对其进行系统分析。

需要说明的是，在强化学习训练过程中，模型对历史状态的接收方式存在结构性约束。具体而言，训练阶段采用基于经验回放的序列采样机制，仅能获取长度为$K$的截断序列作为输入。因此，注意力机制在训练过程中能够实际利用的历史信息上限即为采样序列长度。

基于上述约束关系，在本组消融实验中，将注意力滑动窗口长度与经验回放中保存的序列长度保持一致，即统一设置为相同的$K$值，以避免因信息不匹配带来的额外干扰。在此基础上，分别选取$K=5$、$K=10$和$K=20$三种典型窗口长

度进行模型训练与测试，从短期依赖、中期依赖和长期依赖三个层面分析历史信息范围对模型性能的影响。各模型训练结果如图 5.8 所示。

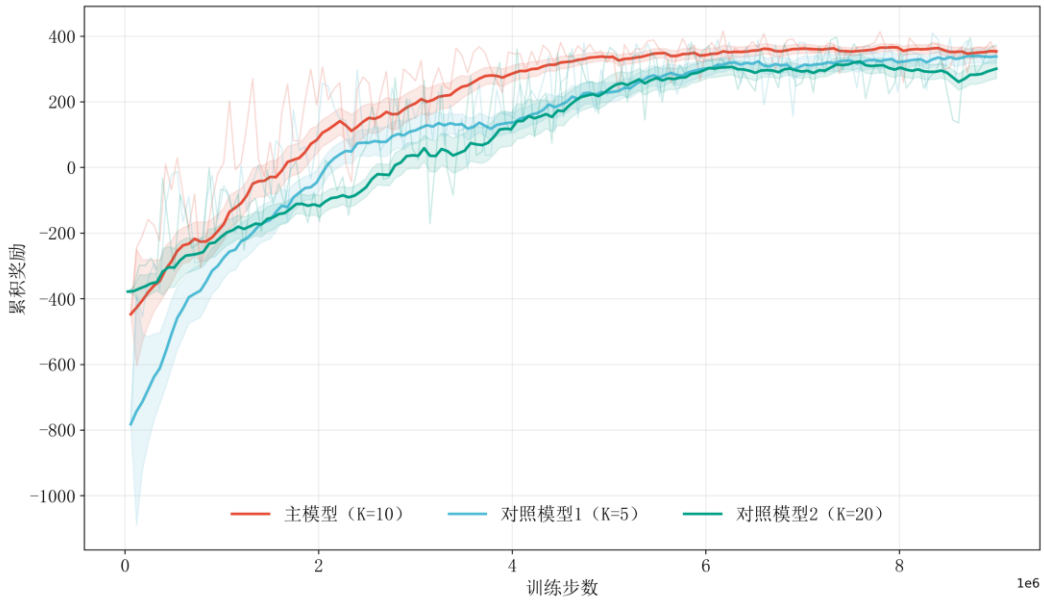



图 5.8 不同滑动窗口长度模型训练结果

Fig.5.8 Training Results of Models with Different Sliding Window Lengths

对比实验训练结果显示，当$K = 10$情况下的模型训练效果在收敛速度上具有优势，在最终整体评价结果上与对照模型 1 接近。但三类模型在最终平均评估结果上差异较小，因此需要对这三个模型开展进一步的风场测试工作以确认模型的推理能力，测试结果如表 5.2：

表 5.2 滑动窗口长度对比实验中不同模型的任务成功率

Table.5.2 Task Success Rate of Different Models in Sliding Window Length Comparison Experiments

| | 主模型 | 对照模型 1 | 对照模型 2 |
|---|---|---|---|
| 综合成功率(%) | **95.3** | 94.0 | 81.2 |
| 顺风成功率(%) | 97.6 | **98.0** | 84.7 |
| 横风成功率(%) | 96.3 | **98.0** | 78.0 |
| 斜逆风成功率(%) | **93.2** | 90.3 | 77.3 |
| 逆风成功率(%) | **92.3** | 90.0 | 69.3 |

实验结果表明，滑动窗口长度对模型性能具有显著影响。在 K=5 时，由于历史信息不足，模型难以充分捕捉风场变化趋势及系统动态特性，导致在复杂航

行条件下性能略有下降；当 K=10 时，模型在综合成功率及各类风向条件下均取得最优表现或次优表现，说明该窗口长度在信息充分性与有效性之间达到了良好的平衡。

相比之下，当窗口长度进一步增加至 K=20 时，模型性能出现明显下降。这主要是由于过长的历史序列引入了大量低相关甚至过时的信息，增加了时序建模难度，并导致决策过程对历史状态的依赖增强，从而降低了对当前环境变化的响应能力。该问题在逆风等强约束场景中尤为明显，模型的任务成功率甚至不足 70%。

因此，可以认为在无人帆船的部分可观测决策问题中，历史信息的利用存在一个最优时间尺度，过短或过长的时间窗口均不利于模型性能的提升。

### 5.3.3 注意力权重分析

在完成机制对比实验与滑动窗口长度对比实验后，本小节进一步选取典型避障航行过程，对模型在决策过程中的注意力权重进行采样分析。考虑到多障碍物环境中环境感知对象具有动态变化特性，本节结合航行过程中的关键事件（包括障碍物切换（Switch）、接近（Approach）及远离（Leave）阶段），对不同滑动窗口长度模型的注意力分布进行对比研究。首先对不同阶段的注意力分布曲线进行说明，相关曲线如图 5.9、图 5.10、图 5.11。

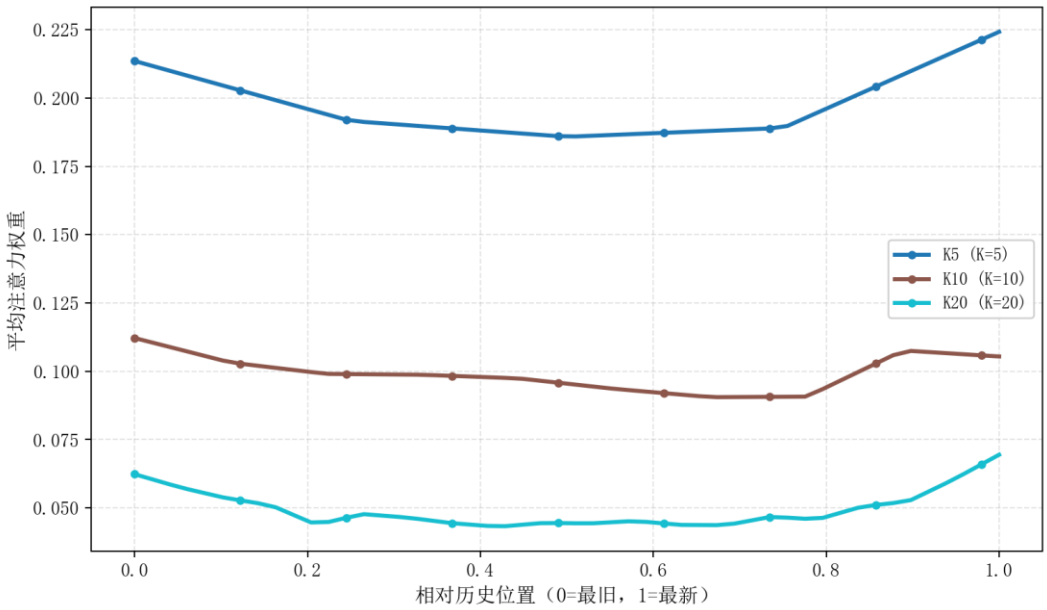



图 5.9 障碍物切换事件注意力分布图。

Fig.5.9 Attention distribution during obstacle switching events.

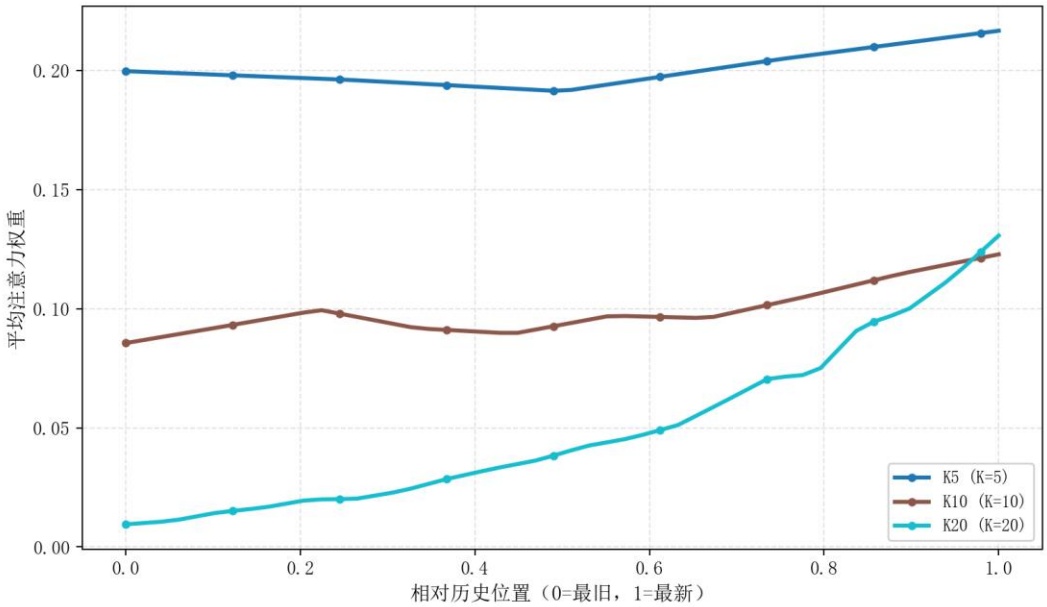



图 5.10 障碍物接近事件注意力分布图。

Fig.5.10 Attention distribution during obstacle approaching events.

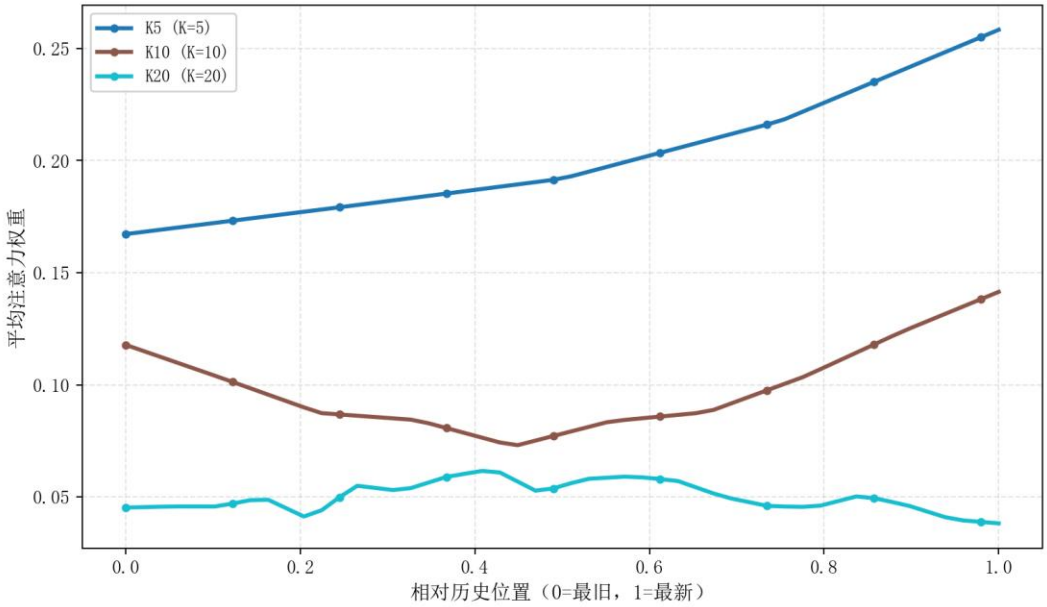



图 5.11 障碍物远离事件注意力分布图。

Fig.5.11 Attention distribution during obstacle leaving events.

需要指出的是，由于滑动窗口长度不同，各时间步的平均权重存在差异，因此以下分析主要基于分布形态及其变化趋势展开，而非单一时间步的权重绝对值。

在障碍物切换（switch）阶段，各模型的注意力分布整体较为平缓，未呈现出明显的集中结构。虽然在时间序列两端存在一定程度的权重抬升，但中间区域

并未出现显著的权重压低，因此整体仍可视为近似均匀分布。该现象主要来源于有限时间窗口下的边界效应，而非模型对特定时间段的主动选择。从不同窗口长度来看，K=5 模型在近期区域表现出轻微偏移，K=20 模型由于窗口较长，其权重分布在数值上更为平缓，但整体变化趋势与其他模型基本一致；K=10 模型在整个时间范围内均保持一定权重分配。总体而言，在该阶段模型倾向于综合利用历史信息完成环境认知的更新，而未对特定时间段形成显著依赖

在接近障碍物（approach）阶段，各模型的注意力分布均表现出向近期区域偏移的趋势，反映出在风险逐渐增加的过程中，模型对当前观测信息的依赖增强。其中，K=20 模型在窗口末端形成相对明显的权重集中趋势，表现为注意力向近期区域收缩；K=5 模型同样表现出对近期信息的偏重，但由于时间窗口较短，其注意力主要分布在有限的局部时间范围内；相比之下，K=10 模型在保持对近期信息关注的同时，仍在中后段时间范围内保留一定权重分配，使注意力在更长时间尺度上得到分布。

在远离障碍物（leave）阶段，注意力分布整体由集中状态逐步向分散过渡，但不同模型呈现出差异化的分布形态。其中，K=5 模型仍表现出对近期信息的持续依赖，注意力主要集中在窗口后段；K=20 模型的权重分布在整个时间范围内较为均匀，未表现出明显的局部集中趋势；而 K=10 模型则呈现出不同于前两者的分布特征，其注意力在时间序列两端均保持一定权重，而中间区域相对较低，表现出一定的双峰结构。该现象表明，在风险解除后，K=10 模型并非简单地均匀利用历史信息，而是对不同时间段进行选择性关注：一方面保留远期历史信息以维持航行策略的连续性，另一方面强化对当前状态的响应，而对中间过渡信息的依赖相对较弱。相比之下，短窗口模型更偏向局部信息驱动，而长窗口模型则缺乏明确的时间选择结构。

本节进一步对注意力分布特征进行定量刻画，引入信息熵、近期中心及近期权重占比三个指标，对不同滑动窗口长度模型在各类事件中的表现进行对比分析，如图 5.12、图 5.13、图 5.14。

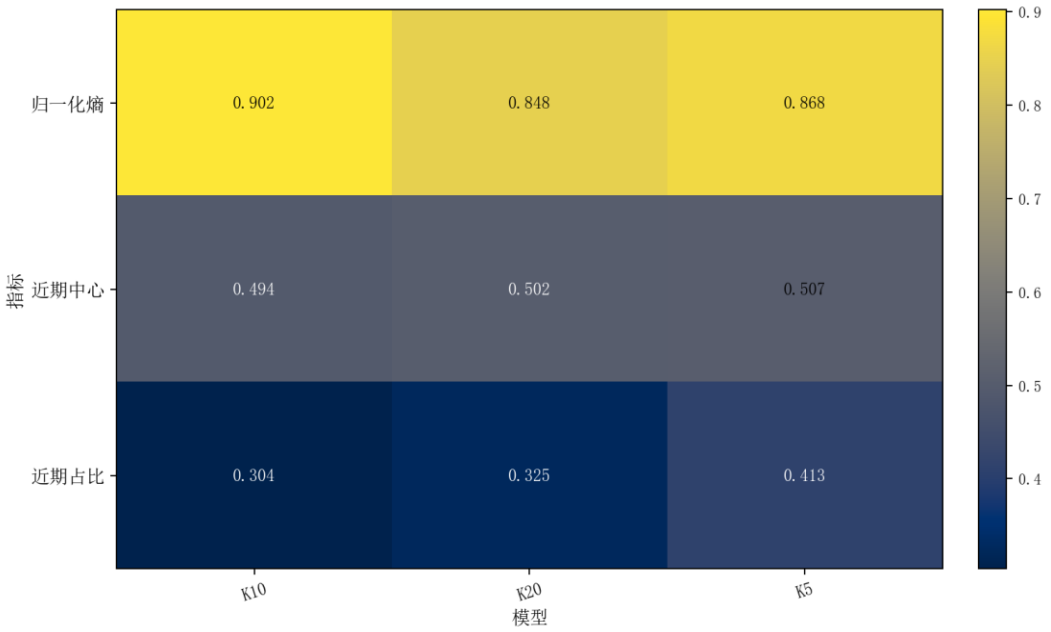



图 5.12 障碍物切换事件指标热力图。

Fig.5.12 Heatmap of metrics during obstacle switching events.

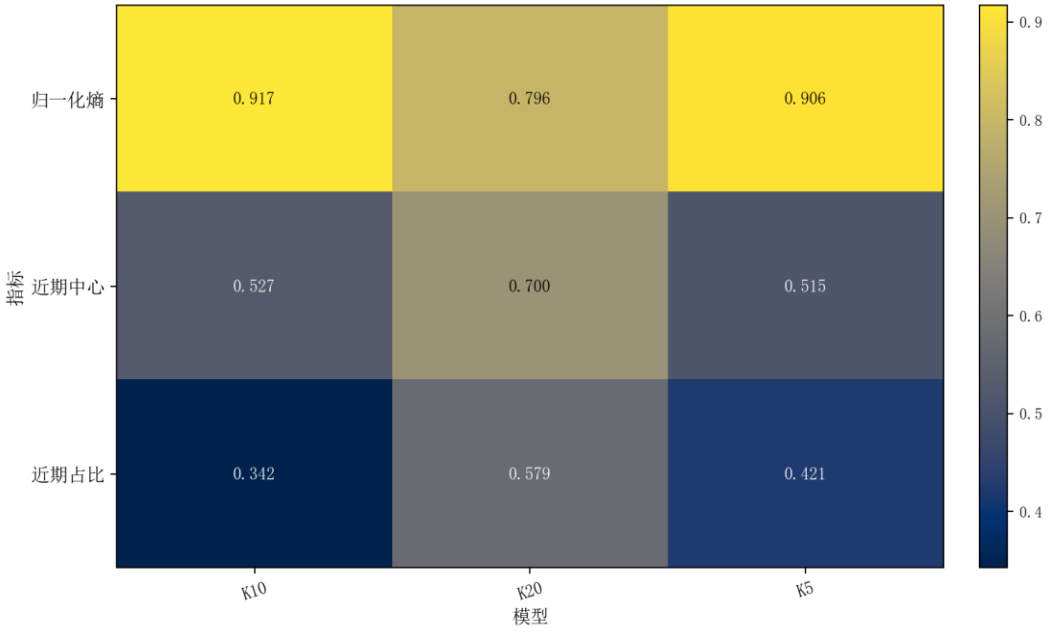



图 5.13 障碍物接近事件指标热力图。

Fig.5.13 Heatmap of metrics during obstacle approaching events.

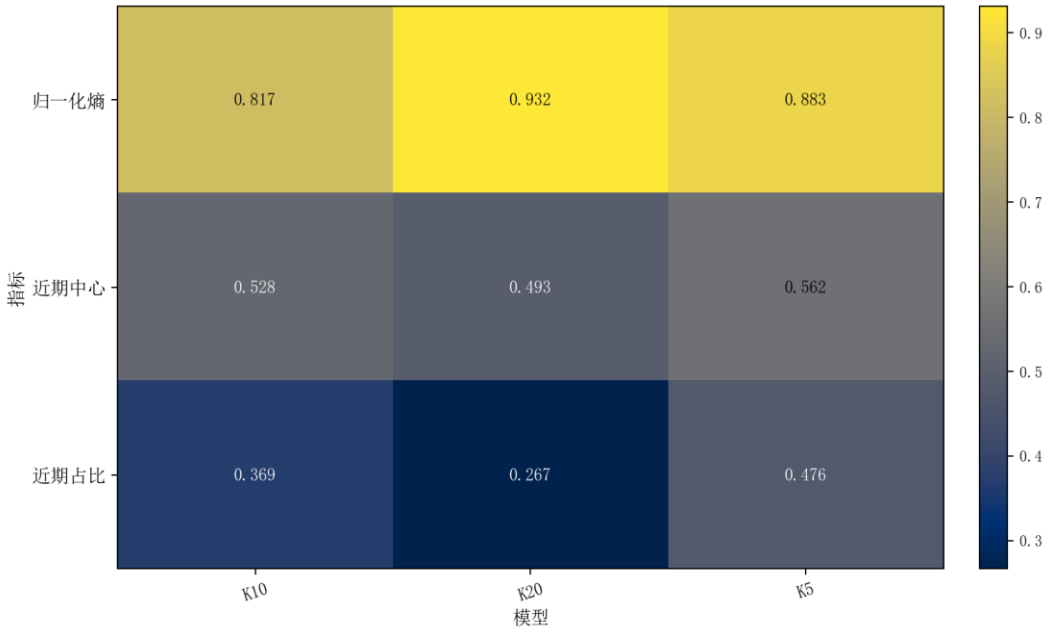



图 5.14 障碍物远离事件指标热力图。

Fig.5.14 Heatmap of metrics during obstacle leaving events.

图 5.12 显示，在 switch 阶段，各模型指标差异较小。近期中心均接近 0.5，信息熵处于较高水平，表明注意力在时间维度上整体分布较为均衡，仅 K=5 模型在近期权重占比上略高，表现出轻微的近期偏向。

图 5.13 显示，在 approach 阶段，K=20 模型的近期中心与近期权重占比显著高于其他模型，同时信息熵最低，表明其在该阶段对近期信息的依赖显著增强；相比之下，K=5 与 K=10 模型的指标变化相对平缓，仍保留一定程度的历史信息利用。

图 5.14 显示，在 leave 阶段，模型间差异进一步扩大：K=20 模型信息熵最高且近期权重占比最低，表现出更为分散的注意力分布；K=5 模型则维持较高的近期权重占比，体现出持续的短期信息依赖；K=10 模型各项指标均处于中间水平，未表现出明显的时间偏移特征。

结合注意力权重分析结果可以进一步解释 5.3.2 节中不同滑动窗口长度模型性能差异的内在原因。短窗口（K=5）模型由于历史序列长度受限，可用于决策的时间范围较小，其注意力主要分布在有限的时间窗口内，表现为较高的近期权重占比。这一现象反映的是信息利用范围的限制，而非模型对近期信息的主动偏好，在复杂环境（特别是逆风避障环境）下难以充分捕捉长时序动态特性。相比

之下，长窗口（K=20）模型虽然具备更丰富的历史信息，但同时也增加了信息筛选与建模难度，其注意力分布在不同阶段呈现出较大的变化幅度，反映出在长时序信息中进行有效选择的稳定性不足。K=10 模型则在信息范围与选择难度之间取得相对平衡，其注意力分布在各阶段未出现明显的极端偏移，从而能够在历史信息利用与当前环境响应之间维持较为稳定的决策行为。

因此，滑动窗口长度对模型性能的影响，本质上源于其对可利用信息范围与信息选择难度之间关系的调节：过短窗口限制了时序建模能力，而过长窗口增加了信息筛选负担，在适中的时间尺度下，模型才能实现对历史信息的有效整合，从而提升整体决策性能。

## 5.4 本章小结

本章围绕静态障碍物环境下无人帆船的自主避障控制问题，在第四章控制模型研究的基础上，对模型结构与训练机制进行了针对性优化。

首先，从任务建模角度出发，结合海洋环境中典型障碍物场景，对仿真交互环境进行扩展，引入基于感知范围的障碍物探测机制，并在状态空间中增加障碍物相对距离与方位信息，使模型具备对局部环境变化的感知能力。同时，在奖励函数中融入与避障行为相关的约束项，引导智能体在目标跟踪与安全避障之间实现合理权衡。

在模型结构方面，针对复杂动态环境中历史信息利用不足的问题，在原有 SAC-LSTM 框架基础上引入注意力机制，使模型能够对历史隐藏状态进行动态加权，从而强化对关键时序信息的提取能力，提升决策的针对性与稳定性。

在实验验证层面，通过构建多组对比与消融实验，系统评估了注意力机制及滑动窗口长度对模型性能的影响。结果表明，引入注意力机制后模型在避障成功率方面得到明显提升；同时，不同窗口长度对历史信息利用存在明显差异，合理的窗口设定能够在信息充分性与冗余性之间取得平衡。进一步结合典型航行过程中的注意力权重分布分析，揭示了模型在障碍物出现及切换过程中的决策关注重点，验证了所提出方法在避障环境下的有效性。

# 6 结论与展望

## 6.1 主要结论

本文围绕无人帆船在部分可观测环境下的自主航行控制问题，系统开展了仿真环境构建、强化学习模型设计及复杂任务验证研究。通过多层次实验分析，本文在以下几个方面取得了具有明确指向性的研究结论。

首先，在基础控制能力验证中，通过对比实验与鲁棒性测试结果表明，引入时序建模能力的 SAC-LSTM 模型在任务成功率、收敛稳定性及控制平滑性等指标上均显著优于传统强化学习模型。在不同风向及扰动条件下，该模型仍能保持较高成功率，说明利用历史观测信息可以有效弥补环境不可观测带来的决策不确定性。这一结果表明：在缺乏显式风场信息的条件下，基于状态序列的隐式环境建模是实现稳定航行控制的可行路径。

其次，在敏感性分析中发现，模型决策主要依赖与运动状态直接相关的关键变量，而对绝对位置信息等冗余变量敏感性较低，该分布特征与无人帆船实际动力学机理保持一致。这一结果从侧面验证了所提出方法能够在数据驱动框架下学习到具有物理意义的决策规律，说明强化学习模型不仅具备一定的控制性能，同时具有物理一致性与可解释性。

接着在引入静态障碍物的复杂环境中，通过对比实验与消融实验结果可以看出，注意力机制的引入显著提升了模型在避障任务中的成功率与决策稳定性；同时，不同滑动窗口长度对模型性能产生明显影响，适当的历史信息范围能够有效提升决策效果，而过短或过长的序列均会限制模型性能。结合注意力权重分布分析可以发现，模型在障碍物出现及切换过程中能够动态调整对历史信息的关注重点，从而实现对关键时序信息的有效提取。上述结果表明：在复杂动态任务中，对历史信息进行选择性建模比简单累积更为关键。

综合全文实验结果可以得出：对于受环境驱动且信息不完全可观测的无人帆船系统，通过时序建模和注意力筛选的强化学习框架，可以在无显式环境建模的条件下，实现接近工程可用水平的局部自主航行与避障控制。

总体而言，本文的研究不仅证明了端到端强化学习方法在无人帆船控制中的有效性，也揭示了历史信息利用方式对决策性能的关键影响，为复杂海洋环境下自主航行控制方法的发展提供了新的理论依据与技术路径。

## 6.2 本文创新点

本文的创新性主要体现在以下三个方面：

（1）提出端到端的无人帆船强化学习控制框架

针对传统无人帆船控制方法中普遍采用分层结构所带来的模型依赖强、及模块耦合复杂等问题，本文构建了一种基于强化学习的端到端控制框架。该方法以无人帆船的状态信息为输入，直接输出帆角与舵角控制指令，实现从感知到决策再到控制执行的一体化映射关系。实验结果表明，该端到端模型在航行成功率、控制平滑性及收敛稳定性方面均能够达到甚至接近传统最优控制方法的性能水平，验证了强化学习方法在无人帆船控制问题中的工程可行性。

（2）提出无风场信息条件下的隐式环境感知控制方法

针对现有研究通常依赖风速、风向等外部环境信息作为先验输入的问题，本文在部分可观测条件下开展控制模型设计，构建了一种不依赖显式风场信息的控制方法。该方法仅基于无人帆船的自身运动状态（如速度、航向及其变化）进行决策，通过状态序列的变化规律对环境特征进行隐式推断。实验结果表明，在无人帆船这一典型受环境驱动的系统中，通过神经网络对自身状态变化进行推理，可以在一定程度上替代对外部环境的直接观测，杂海洋环境下的自主航行提供了一种新的解决思路。

（3）面向部分可观测航行任务的时序信息自适应利用机制

针对无人帆船在复杂环境下存在的部分可观测性问题，本文将注意力机制引入强化学习时序建模过程中，用于提升模型对历史信息的利用效率。本文通过对历史隐藏状态序列进行动态加权，使模型能够根据当前决策需求自适应选择关键时序信息。实验结果表明，引入动态权重分配机制后，模型在避障成功率与决策稳定性方面均得到明显提升。同时，通过对注意力权重分布的可视化分析，揭示了模型在障碍物接近及切换过程中对关键历史状态的关注规律。为后续强化学习模型在无人帆船自主航行领域的研究提供了重要参考。

## 6.3 未来展望

本研究取得了预期成果，由于作者专业知识与时间有限，仍然有一些方面可以进一步完善和深入探索：

1、在网络结构与算法方面，本研究提出的 SAC 算法结合融入 LSTM 层的网

络结构在仿真测试环节中取得了较为明显的成绩，但仍然存在进一步探索的空间。例如可以使用目前更加前沿的分层强化学习方法、基于分类的强化学习方法等开展对比实验，其中基于分类的强化学习方法可以适配更深层的全连接层网络（通常可以做到几十层甚至上百层，而本研究所做的基于差分的方法最多只能适配 4-5 层）。

2、在仿真环境方面，本研究采用 Xiao 等人提出的四自由度模型，并尽可能通过提升环境复杂度来验证模型的鲁棒性，但不考虑波浪与水流的作用使得环境整体与现实还是存在着差异性。同时第五章中所考虑的障碍物也只限于静态范围。因此，建立一个便于强化学习模型交互且具备更强物理真实性的通用仿真框架，并且以此框架为基座开展后续研究是未来大规模应用的研究方向。

3、在应用方面，本研究目前只进行了仿真实验尚未开展实船测试。本研究的强化学习模型是一段式端到端的模型，不涉及与传统方法例如 PID 的结合，因此从本质上需要进行更深入的可解释性分析来确保控制策略的完全有效性以便后续部署的调试工作。同时模型的鲁棒性和轻量化也是应用阶段所需要考虑的，例如对真实环境数据的采样并进行模型后训练，在仿真训练阶段使用参数量更大的模型并在实际部署时进行轻量化操作都是未来此类方法能够完整应用于无人帆船边缘计算的必要工作。

# 参考文献

[1] 冷疏影,朱晟君,李薇,等.从“空间”视角看海洋科学综合发展新趋势[J].科学通报,2018,63(31):3167-3183.

[2] 卢晓亭,俞建成,孙朝阳,等.基于海洋机器人的科学观测与实验系统研究现状与展望[J].海洋技术学报,2023,42(04):107-120.

[3] ATHANASIOS MOGIAS, BOUBONARI T, THEODOROS KEVREKIDIS. Examining the presence of ocean literacy principles in Greek primary scho ol textbooks[J/OL]. International Research in Geographical and Environment al Education, 2021, 30(4): 314-331[2025-04-08]. https://doi.org/10.1080/1038 2046.2021.1877953.

[4] 俞建成,孙朝阳,张艾群.无人帆船研究现状与展望[J].机械工程学报,2018,54(2 4):98-110.

[5] CHAI F, JOHNSON K S, CLAUSTRE H, 等. Monitoring ocean biogeoche mistry with autonomous platforms[J/OL]. Nature Reviews Earth & Environ ment, 2020, 1(6): 315-326. https://doi.org/10.1038/s43017-020-0053-y.

[6] VERFUSS U K, ANICETO A S, HARRIS D V, 等. A review of unmann ed vehicles for the detection and monitoring of marine fauna[J/OL]. Marin e Pollution Bulletin, 2019, 140: 17-29. https://doi.org/10.1016/j.marpolbul.20 19.01.009.

[7] Silva A, Matos A, Soares C, et al. Measuring underwater noise with high endurance surface and underwater autonomous vehicles[C]//2013 OCEANS-San Diego. IEEE, 2013: 1-6.

[8] Abril J, Salom J, Calvo O. Fuzzy control of a sailboat[J]. International Jo urnal of Approximate Reasoning, 1997, 16(3-4): 359-375.

[9] Saildrone Completes First Autonomous Circumnavigation of Antarctica[EB/ OL]. www.saildrone.com, [2026][2026-12]. https://www.saildrone.com/news/u nmanned-vehicle-completes-antarctica-circumnavigation.

[10] Ricciardulli L, Foltz G R, Manaster A, et al. Assessment of Saildrone extreme wind measurements in Hurricane Sam using MW satellite sensors[J]. Remote Sensing, 2022, 14(12): 2726.

[11] Revolutionary Reef Restoration[EB/OL]. https://www.oceanaero.com/thoughts/reefrestoration.

[12] AN Y, YU J, HU F, et al. Towards a general design evaluation tool: The development and validation of a VPP for autonomous sailing monohulls[J/OL]. Applied Ocean Research, 2022, 120: 103053. https://linkinghub.elsevier.com/retrieve/pii/S0141118722000098.

[13] “海鸥”号海洋观测无人帆船完成首次海上试验[J].军民两用技术与产品,2019,(11):66.DOI:10.19385/j.cnki.1009-8119.2019.11.025.

[14] SUN Z, FENG A, YU J, et al. Development of autonomous sailboat sails and future perspectives: A review[J/OL]. Renewable and Sustainable Energy Reviews, 2025, 207: 114918. https://linkinghub.elsevier.com/retrieve/pii/S1364032124006440.

[15] 安洋.面向航速最优的无人帆船设计与优化方法研究[D].中国科学院大学(中国科学院沈阳自动化研究所),2023.DOI:10.27589/d.cnki.gsyzs.2023.000001.

[16] 海洋气象史首次！浙大“信天翁”穿越台风眼[EB/OL]. www.zju.edu.cn, [2026][2026-12]. https://www.zju.edu.cn/2025/0730/c76700a3072228/page.htm.

[17] Rhee K P, Kim K. A new sea trial method for estimating hydrodynamic derivatives[J]. Journal of ship and ocean technology, 1999, 3(3): 25-44.

[18] Jaulin L. Modelisation et commande dun bateau a voile[C]//Proceedings of 3rd Conference Internationale Francophone dAutomatique, Douz, Tunisie. 2004.

[19] Slooff J W. The aero-and hydromechanics of keel yachts[M]. Springer, 2015.

[20] Xiao L, Jouffroy J. Modeling and nonlinear heading control of sailing yachts[J]. IEEE Journal of Oceanic engineering, 2013, 39(2): 256-268.

[21] Fossen T I. Guidance and control of ocean vehicles[J]. (No Title), 1994.

[22] Fossen T I. Marine control system-guidance, navigation and control of ships, rigs and underwater vehicles[J]. Marine Cybemetics, 2002.

[23] Fossen T I. Handbook of marine craft hydrodynamics and motion control [M]. John wiley & sons, 2011.

[24] Kerwin J E. A Velocity Prediction Program for Ocean Racing Yachts[M].[s. l]: Massachusetts Institute of Technology, Department of Ocean Engineering, 1978.

[25] Roux Y, Huberson S, Hauville F, et al. Yacht performance prediction: Towards a numerical VPP[C]//High Performance Yacht Design Conference, Auckland. 2002: 11-20.

[26] Roux Y, Durand M, Leroyer A, et al. Strongly coupled VPP and CFD RANSE code for sailing yacht performance prediction[C]//3rd High Performance Yacht Design Conference Auckland, New Zeeland. 2008.

[27] An Y, Yu J, Hu F, et al. Towards a general design evaluation tool: The development and validation of a VPP for autonomous sailing monohulls[J]. Applied Ocean Research, 2022, 120: 103053.

[28] 荆纬,李浩,咸琳涛,等.基于强化学习的自动帆船路径规划算法研究[J]. 中国海洋大学学报 (自然科学版), 2021, 51(8): 79-87.

[29] Bingham B, Agüero C, McCarrin M, et al. Toward maritime robotic simulation in gazebo[C]//OCEANS 2019 MTS/IEEE SEATTLE. IEEE, 2019: 1-10.

[30] Paravisi M, H. Santos D, Jorge V, et al. Unmanned surface vehicle simulator with realistic environmental disturbances[J]. Sensors, 2019, 19(5): 1068.

[31] Tipsuwan Y, Sanposh P, Techajaroonjit N. Overview and control strategies of autonomous sailboats—A survey[J]. Ocean Engineering, 2023, 281: 114879.

[32] Santos D, Junior A G S, Negreiros A, et al. Design and implementation of a control system for a sailboat robot[J]. Robotics, 2016, 5(1): 5.

[33] Langbein J, Stelzer R, Frühwirth T. A rule-based approach to long-term routing for autonomous sailboats[C]//Robotic Sailing: Proceedings of the 4th

International Robotic Sailing Conference. Berlin, Heidelberg: Springer Berli n Heidelberg, 2011: 195-204.

[34] Yuan S, Zhu Z, Xue Y, et al. Path planning for unmanned sailboats using improved potential field and a* algorithm[C]//OCEANS 2024-Singapore. IE EE, 2024: 1-7.

[35] Saoud H, Hua M D, Plumet F, et al. Routing and course control of an au tonomous sailboat[C]//2015 European Conference on Mobile Robots (ECM R). IEEE, 2015: 1-6.

[36] Nian R, Shen Z, Ding W. Research on global path planning of unmanned sailboat based on improved ant colony optimization[C]//2021 6th Internatio nal Conference on Automation, Control and Robotics Engineering (CACR E). IEEE, 2021: 428-432.

[37] Shen Z, Ding W, Liu Y, et al. Path planning optimization for unmanned s ailboat in complex marine environment[J]. Ocean Engineering, 2023, 269: 113475.

[38] Gong Y, Luo M, Wang C, et al. A path planning method based on impro ved particle swarm optimization algorithm[C]//2020 7th International Confer ence on Information Science and Control Engineering (ICISCE). IEEE, 202 0: 106-110.

[39] Silva Junior A G, Santos D H, Negreiros A P F, et al. High-level path pl anning for an autonomous sailboat robot using q-learning[J]. Sensors, 2020, 20(6): 1550.

[40] Liu L, Wang C, Gao H, et al. High-level path planning of unmanned sailb oat for sailing championship and innovative education[C]//2022 IEEE Intern ational Conference on Unmanned Systems (ICUS). IEEE, 2022: 1557-1562.

[41] Suda T, Nikovski D. Deep reinforcement learning for optimal sailing upwi nd[C]//2022 International Joint Conference on Neural Networks (IJCNN). I EEE, 2022: 1-8.

[42] Plumet F, Saoud H, Hua M D. Line following for an autonomous sailboat using potential fields method[C]//2013 MTS/IEEE OCEANS-Bergen. IEEE, 2013: 1-6.

[43] 项天远,张延伟,谭华,等.基于概率势场的无人帆船实时路径规划研究[J].国外电子测量技术,2020,39(05):17-22.DOI:10.19652/j.cnki.femt.2001994.

[44] 康梦萁,许劲松,徐建云,等.无人帆船短途路径规划研究[J].船舶工程,2016,38(09):1-5.DOI:10.13788/j.cnki.cbgc.2016.09.001.

[45] Jaulin L, Le Bars F. A simple controller for line following of sailboats[C]//Robotic sailing 2012: proceedings of the 5th international robotic sailing conference. Berlin, Heidelberg: Springer Berlin Heidelberg, 2013: 117-129.

[46] An Y, Yu J, Zhang J. Autonomous sailboat design: A review from the performance perspective[J]. Ocean Engineering, 2021, 238: 109753.

[47] Herrero P, Jaulin L, Vehi J, et al. Guaranteed set-point computation with application to the control of a sailboat[J]. International journal of control, automation and systems, 2010, 8(1): 1-7.

[48] Wille K L, Hassani V, Sprenger F. Modeling and course control of sailboats[J]. IFAC-PapersOnLine, 2016, 49(23): 532-539.

[49] Zhang S, Yong E M, Zhou Y, et al. Dynamic backstepping control for pure-feedback non-linear systems[J]. IMA Journal of Mathematical Control and Information, 2020, 37(2): 674-697.

[50] Li M, Li S, Zhang J, et al. Neural adaptive funnel dynamic surface control with disturbance-observer for the pmsm with time delays[J]. Entropy, 2022, 24(8): 1028.

[51] Zhang G, Li J, Li B, et al. Improved integral LOS guidance and path-following control for an unmanned robot sailboat via the robust neural damping technique[J]. The Journal of Navigation, 2019, 72(6): 1378-1398.

[52] Wirz J, Tranzatto M, Liniger A, et al. AEOLUS, the ETH autonomous model sailboat[C]//World Robotic Sailing championship and International Robotic Sailing Conference. Cham: Springer International Publishing, 2015: 103-112.

[53] Dong Y, Wu N, Qi J, et al. Predictive course control and guidance of aut onomous unmanned sailboat based on efficient sampled Gaussian process[J]. Journal of Marine Science and Engineering, 2021, 9(12): 1420.

[54] Liu S, Yu Z, Wang T, et al. Mpc-based collaborative control of sail and r udder for unmanned sailboat[J]. Journal of Marine Science and Engineering, 2023, 11(2): 460.

[55] Sun Q, Qiao Z, Strombeck C, et al. Tacking control of an autonomous sai lboat based on force polar diagram[C]//2018 13th World Congress on Intell igent Control and Automation (WCICA). IEEE, 2018: 467-473.

[56] Chen Y, Liu S, Wang T, et al. Sail-rudder Collaborative Control of Unman ned Sailboat Based on Reinforcement Learning[C]//OCEANS 2024-Singapor e. IEEE, 2024: 1-6.

[57] Petres C, Romero-Ramirez M A, Plumet F, et al. Modeling and reactive n avigation of an autonomous sailboat[C]//2011 IEEE/RSJ International Confe rence on Intelligent Robots and Systems. IEEE, 2011: 3571-3576.

[58] Plumet F, Petres C, Romero-Ramirez M A, et al. Toward an autonomous s ailing boat[J]. IEEE Journal of Oceanic Engineering, 2014, 40(2): 397-407.

[59] Liu K, Sun Z, Qu Y, et al. Research on key methods of autonomous sailb oat's position keeping control[C]//OCEANS 2022-chennai. IEEE, 2022: 1-6.

[60] Yingjie D, Xianku Z, Guoqing Z. Fuzzy logic based speed optimization an d path following control for sail-assisted ships[J]. Ocean Engineering, 2019, 171: 300-310.

[61] Abrougui H, Nejim S, Dallagi H. Modeling and autopilot design for an au tonomous catamaran sailboat based on feedback linearization[C]//2019 Inter national Conference on Advanced Systems and Emergent Technologies (IC_ ASET). IEEE, 2019: 130-135.

[62] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computati on, 1997, 9(8): 1735-1780.

[63] Watkins C J C H, Dayan P. Q-learning[J]. Machine learning, 1992, 8(3): 2 79-292.

[64] Rummery G A, Niranjan M. On-line Q-learning using connectionist systems[M]. Cambridge, UK: University of Cambridge, Department of Engineering, 1994.

[65] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. nature, 2015, 518(7540): 529-533.

[66] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. Cambridge: MIT press, 1998.

[67] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.

[68] Fujimoto S, Hoof H, Meger D. Addressing function approximation error in actor-critic methods[C]//International conference on machine learning. PMLR, 2018: 1587-1596.

[69] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//International conference on machine learning. Pmlr, 2018: 1861-1870.

[70] Hasselt H. Double Q-learning[J]. Advances in neural information processing systems, 2010, 23.

[71] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning: U.S. Patent 10,776,692[P]. 2020-9-15.

[72] Lin L J. Self-improving reactive agents based on reinforcement learning, planning and teaching[J]. Machine learning, 1992, 8(3): 293-321.

[73] Dormand J R, Prince P J. A family of embedded Runge-Kutta formulae[J]. Journal of computational and applied mathematics, 1980, 6(1): 19-26.

[74] Lauri M, Hsu D, Pajarinen J. Partially observable markov decision processes in robotics: A survey[J]. IEEE Transactions on Robotics, 2022, 39(1): 21-40.

[75] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

# 作者简历

## 1 个人信息

## 2 教育经历

## 3 科研成果

（盲审时请务必填写相关科研成果，录用的也要写，在审的也需写上，隐去姓名导师即可） 定稿时信息需填写完整，格式同参考文献。

（1）

（2）

## 4 项目经历

## 5 在校荣誉