分类号：_____ 单位代码：10335

密　级：无 学　　号：22334006

浙江大学

硕士学位论文

中文论文题目 ：基于强化学习的无人帆船控制模型研究

英文论文题目 ：**The Research on Unmanned Sailboat Control Model Based on Reinforcement Learning**

申请人姓名：杨 潮

指导教师：黄 慧

合作导师：李培良 郭卜瑜

专业名称：电子信息

研究方向：

所在学院：

论文提交日期： 二〇二六年十二月

基于强化学习的无人帆船控制模型研究

杨潮　浙江大学

基于强化学习的无人帆船控制模型研究

论文作者签名:_____

指导教师签名:_____

论文评阅人 1：盲审

评阅人 2：盲审

评阅人 3：盲审

评阅人 4：

评阅人 5：

答辩委员会主席：

委员 1：

委员 2：

委员 3：

委员 4：

委员 5：

答辩日期：

The Research on Unmanned Sailboat Control Model Based on Reinforcement Learning

Author's signature:_____

Supervisor' s signature:_____

External Reviewers: 盲审

盲审

Examining Committee Chairperson:

Examining Committee Members:

Date of oral defence：

浙江大学研究生学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得**浙江大学**或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：　　签字日期：　年　月　日

学位论文版权使用授权书

本学位论文作者完全了解**浙江大学**有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权**浙江大学**可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后适用本授权书）

学位论文作者签名：　　导师签名：

签字日期：年　月　日　　签字日期：年　月　日

致谢

××××××

摘要

无人帆船利用风能获得推进力，具有低能耗、长续航等特点，在海洋长期自主观测中具有重要应用潜力。风速和风向不仅决定风帆受力，也是无人帆船路径规划、航向决策和帆舵控制中常用的环境信息，其获取通常依赖外置风场传感器。在长期海上运行以及具有跨介质航行需求的应用场景中，外置设备在安装、防护、维护和收纳等方面可能受到平台与环境条件限制。基于这一工程背景，本文从部分可观测控制角度开展方法研究与仿真验证，旨在研究当风速和风向不作为控制策略直接输入时，能否利用船体历史运动响应和控制信息补充当前决策所需的环境信息，并进一步研究任务约束增加后历史信息的有效组织与利用方式。

本文基于四自由度非线性无人帆船动力学模型，构建包含时变随机风场、观测噪声和有限分辨率动作执行的强化学习交互环境，并建立面向航迹点间局部自主航行的端到端帆舵控制框架。控制策略依据船体运动状态、帆舵状态和目标相关信息直接生成帆角与舵角调节量，不预先设定局部参考航向或待跟踪轨迹，从而将局部航行决策与帆舵联合控制纳入统一的策略学习过程。

针对无显式风场输入造成的状态信息缺失，本文提出基于历史观测—动作信息的时序控制方法，在软 Actor-Critic 算法中引入长短期记忆网络，对此前控制作用及其对应的船体运动响应进行编码，使策略无需单独重构风场即可利用历史交互信息辅助当前决策。随机风向测试中，SAC-LSTM 模型平均任务成功率达到 99.36%，显著高于仅依据当前观测决策的 SAC-nowind 模型。进一步的隐藏状态读出与历史截断分析表明，循环表示中包含可提取的风向相关信息，且历史信息变化会影响当前帆舵动作输出，说明历史运动响应在本文仿真条件下能够形成支持部分可观测控制的有效时序信息。

在此基础上，本文进一步面向静态障碍物环境研究历史信息的选择性利用问题。针对目标推进、障碍规避和船体动态响应共同影响当前决策的特点，在 LSTM 时序编码基础上引入由当前观测驱动的时间注意力机制，使不同历史时刻的信息能够根据当前航行情境动态参与决策，将历史信息利用由统一编码进一步扩展为面向当前需求的选择性融合。在 1000 个随机障碍场景中，Attention 模型任务成功率达到 95.5%，高于历史直接融合和等权融合模型。窗口配置及注意力干预实验进一步表明，历史信息并非时间范围越长越有效，动态权重能够实际影响帆舵

动作及后续航行过程，其作用同时受到信息获取提前量和任务条件的影响。

综上，本文形成了由历史交互信息编码到当前状态驱动历史选择性融合的递进式无人帆船局部控制方法，并在统一四自由度仿真环境中验证了其可行性。研究结果表明，控制作用下的历史运动响应可以为无显式风场输入条件下的帆舵决策提供时序补充，且其有效利用与信息融合方式、时间范围及具体任务条件密切相关。该结果从部分可观测控制角度深化了对无人帆船历史交互信息作用的认识，并为不将实时风速、风向作为局部控制策略必要输入的补充控制方法提供了仿真依据，可为直接风场测量受到平台条件约束时的后续控制研究提供参考。

关键词：无人帆船；强化学习；端到端控制；部分可观测；时序信息融合

Abstract

Unmanned sailboats are propelled by wind energy and offer the advantages of low energy consumption and long endurance, making them promising platforms for long-term autonomous ocean observation. Wind speed and wind direction not only determine the aerodynamic loads acting on the sail, but also serve as commonly used environmental information for path planning, heading decision-making, and sail–rudder control. Such information is typically acquired using externally mounted wind sensors. However, during long-duration marine operations and in applications involving cross-medium operation, external devices may be subject to constraints in installation, protection, maintenance, and stowage due to platform and environmental conditions. Motivated by this engineering background, this thesis investigates the problem from the perspective of partially observable control through methodological development and simulation-based validation. Specifically, it examines whether historical vessel motion responses and control information can provide the environmental information required for current decision-making when wind speed and wind direction are not directly provided to the control policy. It further investigates how historical information can be effectively organized and utilized as task constraints become more complex.

Based on a four-degree-of-freedom nonlinear dynamic model of an unmann ed sailboat, a reinforcement learning environment is established that incorporate s time-varying stochastic wind fields, observation noise, and finite-resolution act uation. An end-to-end sail–rudder control framework is then developed for loca l autonomous navigation between waypoints. The control policy directly generat es sail-angle and rudder-angle adjustments from the vessel motion states, sail a nd rudder states, and target-related information, without prescribing a local refe rence heading or a predefined trajectory. In this way, local navigation decision-making and coordinated sail–rudder control are integrated into a unified policy-learning process.

To address the missing state information caused by the absence of explicit wind inputs, a temporal control method based on historical observation–action information is proposed. A long short-term memory network is incorporated int o the Soft Actor-Critic algorithm to encode previous control actions together w ith the corresponding vessel motion responses, allowing the policy to exploit hi

storical interaction information for current decision-making without explicitly reconstructing the wind field. In tests with randomly varying wind directions, the SAC-LSTM model achieves an average task success rate of 99.36%, substantially higher than that of the SAC-nowind model, which makes decisions solely from the current observation. Further hidden-state decoding and history-truncation analyses show that wind-direction-related information can be extracted from the recurrent representation, and that changes in historical information affect the current sail and rudder commands. These results indicate that, under the simulation conditions considered in this study, historical motion responses can provide effective temporal information to support partially observable control.

Building on this approach, the selective utilization of historical information is further investigated in environments containing static obstacles. Because current decisions are jointly influenced by goal-directed progress, obstacle avoidance, and vessel dynamic responses, a temporal attention mechanism conditioned on the current observation is introduced on top of the LSTM-based temporal encoder. This mechanism enables information from different historical time steps to contribute dynamically to the current decision according to the ongoing navigation context, thereby extending historical information utilization from unified sequence encoding to demand-driven selective fusion. Across 1,000 randomly generated obstacle scenarios, the Attention model achieves a task success rate of 95.5%, outperforming both the direct-history fusion model and the equal-weight fusion model. Further experiments on history-window configurations and attention interventions show that a longer historical window does not necessarily lead to better performance. The dynamically assigned attention weights can directly affect sail–rudder commands and subsequent navigation behavior, while their effectiveness depends on both how far in advance relevant information becomes available and the specific task conditions.

In summary, this thesis develops a progressive local control methodology for unmanned sailboats, ranging from the temporal encoding of historical interaction information to current-state-driven selective fusion of historical information, and validates its feasibility within a unified four-degree-of-freedom simulation environment. The results demonstrate that historical motion responses generated under control actions can provide useful temporal information for sail–rudder decision-making when explicit wind-field information is unavailable to the policy.

The effectiveness of such historical information depends closely on the information-fusion scheme, temporal range, and specific task conditions. From the perspective of partially observable control, these findings provide a deeper understanding of the role of historical interaction information in unmanned sailboat control. They also provide simulation-based evidence for local control strategies that do not require real-time wind speed and wind direction to be indispensable direct inputs to the control policy, and may serve as a reference for future control studies when direct wind-field measurements are constrained by platform conditions.

Keywords: Unmanned Sailboat; Reinforcement Learning; End-to-end Control; Partial Observability; Temporal Information Fusion

目录

致谢 I
摘要 II
ABSTRACT IV
目录 VII
1 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 4
1.2.1 无人帆船建模与性能预测 4
1.2.2 无人帆船自主航行与控制 6
1.2.3 观测受限条件下的无人帆船控制研究 11
1.3 研究内容与章节安排 13
2 理论基础与无人帆船动力学模型 16
2.1 神经网络与时序信息建模基础 16
2.2 强化学习与连续控制基础 20
2.3 无人帆船动力学模型 29
2.4 本章小结 35
3 训练交互环境 36
3.1 引言 36
3.2 基础环境框架 36
3.3 实验任务设定 40
3.4 训练效率优化 44
3.5 本章小结 45
4 无显式风场输入的强化学习控制模型 46
4.1 引言 46
4.2 基于历史信息编码的 SAC-LSTM 控制模型 46
4.3 面向点到点航行的奖励函数设计 52
4.4 实验结果与分析 57
4.4.1 基线对比实验 57

4.4.2 奖励消融实验 67
4.4.3 风场与观测扰动下的鲁棒性分析 68
4.4.4 历史信息利用分析 73
4.5 本章小结 76
5 面向静态障碍物环境的控制模型优化 78
5.1 引言 78
5.2 静态避障任务与控制模型扩展 78
5.2.1 避障环境与观测空间 78
5.2.2 注意力时序融合网络 80
5.2.3 避障奖励设计 82
5.3 实验结果与分析 83
5.3.1 不同历史信息融合方式对比实验 83
5.3.2 历史窗口长度对控制性能的影响 86
5.3.3 任务条件变化下的适应性与航行行为分析 89
5.3.4 时间注意力的作用分析 99
5.4 本章小结 103
6 结论与展望 105
6.1 主要结论 105
6.2 本文创新点 106
6.3 未来展望 107
参考文献 109
作者简历 118

1 绪论

1.1 研究背景与意义

海洋科学是一门以观测为基础的数据密集型学科[1]。观测对于海洋科学研究至关重要，观测资料缺乏是制约海洋科学发展的瓶颈[2]。海洋覆盖地球表面约 70%的面积，但其中得到直接探索的区域仍较为有限[3]。海洋多圈层相互作用是当前海洋科学的重要研究内容，海气相互作用是其中的典型研究方向之一。现有海洋观测技术主要包括天基观测、海基观测和水下观测等不同方式，各类技术具有不同的适用范围与优势，但单一观测方式难以同时满足海气界面长航时、大范围和连续获取观测数据的需求[4]。

近年来，随着海洋机器人技术与传感器技术的不断发展，海洋机器人已逐渐成为传统船基采样方式的重要补充[5]，在提高数据获取效率和数据质量等方面发挥了积极作用[6]。目前，用于科学观测任务的海洋机器人主要包括水下滑翔机、自主水下航行器（Autonomous Underwater Vehicle，AUV）、无人帆船和波浪滑翔机等。其中，无人帆船与波浪滑翔机均能够利用海洋环境能源维持长期航行，可用于开展海气界面长航时、大范围的自主连续观测[2][7]。无人帆船依靠风能获得推进力，并能够主动调整航向，在海表气象要素及浅水水文信息获取等任务中具有较好的应用潜力，可作为海洋综合观测体系中的移动观测平台。

国外自 20 世纪 90 年代开始开展无人帆船相关研究[8]，随后在平台研制、航行控制及海洋观测应用等方面持续发展，部分无人帆船已用于实际海洋观测任务。2019 年，Saildrone 公司开发的一艘配备科学传感器的自主帆船完成南大洋环航任务，任务持续 196 天、航行距离达 11879 海里，并获取了南大洋原位碳通量数据[9]。2021 年，美国国家海洋和大气管理局（NOAA）与 Saildrone 公司合作，利用无人帆船对飓风“山姆”进行监测，实现风暴中心影像的实时传输，并获取空气温度、气压、大气湿度、波高和洋流等观测数据，为相关飓风研究与预测提供数据支持[10]。2022 年，两艘名为“TRITON”的自主航行船被部署于红海苏沙哈岛附近，用于获取水深、视频及水化学采样数据，为后续珊瑚礁环境研究提供观测资料[11]。部分具有代表性的国外无人帆船如图 1.1 所示。

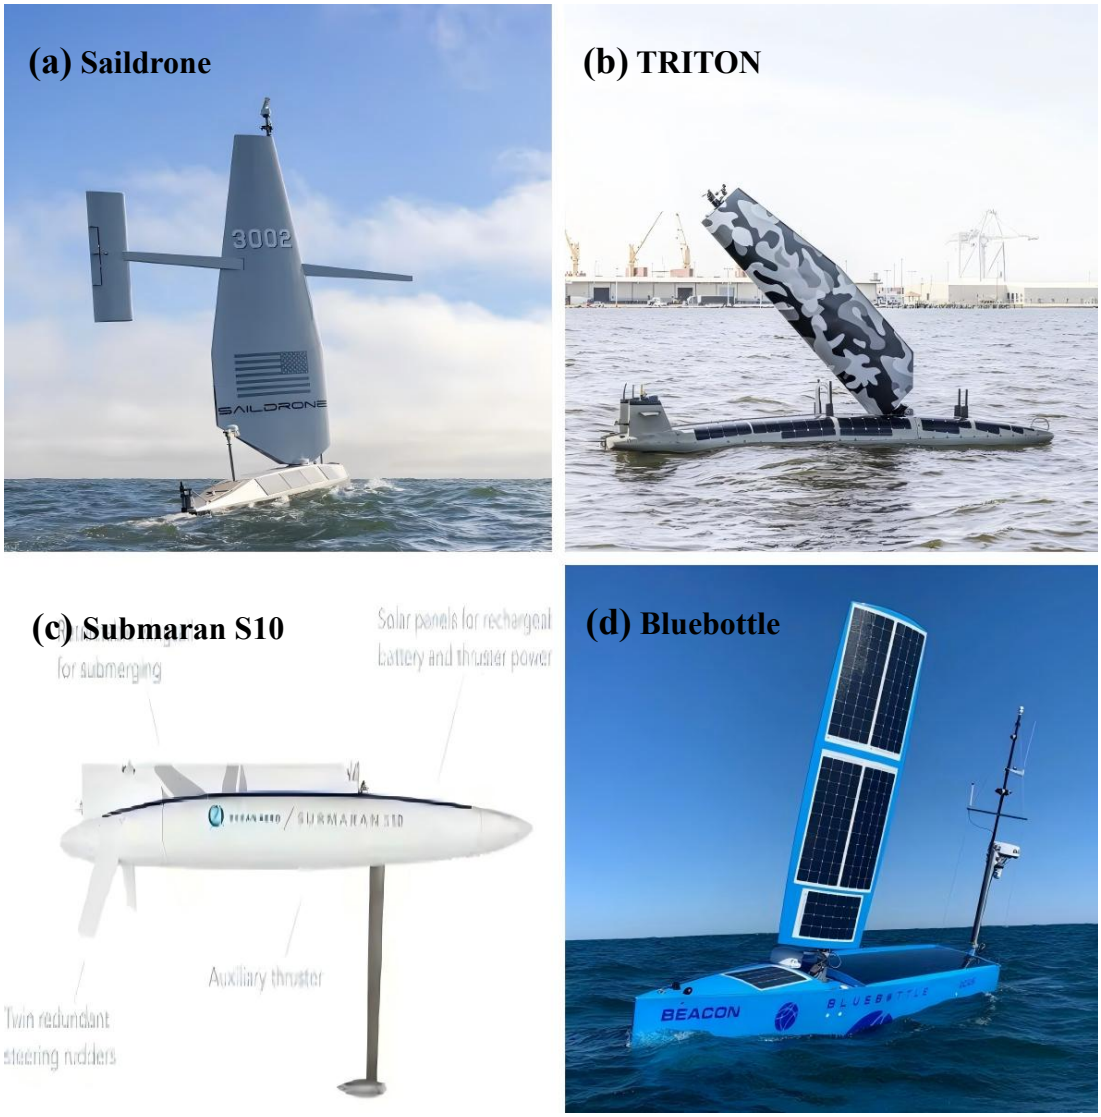


图 1.1 国外著名无人帆船。

Fig.1.1 Famous foreign unmanned sailboats.

国内多个高校与科研院所近年来也持续开展无人帆船相关研究，上海交通大学、香港中文大学、哈尔滨工程大学、浙江大学、大连海事大学和青岛大学等单位均开展了相关研究工作[2]。中国科学院沈阳自动化研究所开展了“海鸥号”无人帆船的研制工作，并于 2019 年完成首次海上试验[12]，同时围绕无人帆船设计与性能优化开展了相关研究[13][14]。浙江大学海洋学院“信天翁”号无人帆船于 2025 年穿越“蝴蝶”和“韦帕”台风核心区域，获取了台风过程中的气象、海浪等现场观测数据[15]。部分国内开展研究与应用的无人帆船如图 1.2 所示。



图 1.2 国内无人帆船。

Fig.1.2 Domestic unmanned sailboats.

目前，无人帆船的关键技术主要聚焦于高海况适应性技术、风能高效利用技术和智能航行控制技术等[2]。其中，自主航行控制是无人帆船执行长航时、无人值守任务的重要基础。不同于采用螺旋桨等主动推进方式的常规无人水面航行器，无人帆船主要利用风能获得推进力，其运动过程与环境风场存在密切耦合关系。风速与风向不仅影响风帆产生的推进力，也会进一步影响无人帆船的航行速度、航向、横摇及侧向运动等状态。因此，风场既是无人帆船的重要动力来源，也是航行决策与控制过程中需要考虑的关键环境因素。

在现有无人帆船自主航行系统中，风速和风向通常是路径规划、航向决策以及帆角调节的重要环境信息。相关信息通常由布置于船体外部、需要与外部气流直接接触的风速和风向传感器获取。长期海上运行过程中，外置设备需要持续面

对盐雾、高湿、海水飞溅及机械冲击等环境，其安装、防护和维护均会增加系统复杂度。对于具有跨介质航行需求的无人平台，水面航行与水下潜航之间的介质转换还会进一步对传感器布置、收纳及水密防护提出要求。因此，在风场观测无法稳定获取或不宜作为必要控制输入的条件下研究无人帆船控制方法，具有一定的现实背景与研究价值。

从控制问题的角度看，不直接获取风速和风向并不意味着环境作用完全不可感知。风场对无人帆船产生的持续作用会通过动力学响应反映在航行速度、航向、姿态等运动状态的变化过程中，因此一段时间内的运动状态演化可能包含与外部风场作用相关的间接信息。当风速和风向不作为控制策略的直接观测输入时，策略能够获得的船体可观测状态、目标相关信息及历史交互信息仍只构成完整环境状态的一部分，相应任务具有部分可观测特征。基于此，本文关注如何利用无人帆船可观测状态及历史观测—动作信息学习局部自主航行策略，并通过仿真实验研究该类方法的可行性以及历史信息对帆舵决策的作用。相关研究旨在为环境信息受限条件下的无人帆船自主控制提供一种研究思路，并为后续面向实际平台的进一步验证提供参考。

1.2 国内外研究现状

无人帆船自主航行涉及动力学建模、航行性能表征、路径规划与帆舵控制等多个相互关联的研究环节。为明确本文研究问题与现有工作的关系，本节首先梳理无人帆船动力学建模与性能预测研究，为后续航行控制方法的讨论提供基础；随后从自主航行与控制角度综述路径规划、制导、航向与速度控制以及帆舵协同等代表性研究，并关注不同方法对风场信息的利用方式；最后结合观测受限条件下的控制与时序信息利用研究，对与本文问题直接相关的工作进行归纳。

1.2.1 无人帆船建模与性能预测

无人帆船动力学模型用于描述船体在风帆气动力、水动力及帆舵控制作用下的运动响应，是开展控制算法设计与数值仿真的重要基础。由于无人帆船主要利用风能获得推进力，其运动状态同时受到环境风场、船体水动力以及帆舵调节的耦合作用，动力学过程具有明显的非线性与多自由度耦合特征。针对不同的研究目标和计算需求，现有研究通常采用不同自由度及不同复杂程度的动力学模型，在运动特征描述能力与计算复杂度之间进行权衡。

在船舶操纵运动建模领域，分离式建模是一类具有代表性的建模思路。MMG（Maneuvering Modeling Group）方法将影响船舶操纵运动的主要受力来源分别建立子模型，再通过力与力矩的组合描述整船运动响应[16]。经典 MMG 模型主要围绕船体、推进器和舵等组成部分建立操纵运动模型。对于风力驱动的帆船，其推进方式和受力组成与常规动力船舶存在差异，但同样需要分别考虑船体、龙骨、风帆和舵等部件产生的气动力与水动力，并在统一的运动方程中描述各部分作用对船体运动的共同影响。因此，分部描述不同受力来源并建立整船动力学关系，是帆船动力学建模中的重要基础思路。

在面向自主航行与控制的无人帆船模型中，为降低模型复杂度并保留与主要控制任务相关的运动特征，研究者通常根据具体研究对象对完整六自由度运动进行适当简化。Jaulin 采用不显式包含横摇的简化平面动力学模型描述帆船航行过程[17]。该模型结构较为简洁，为后续无人帆船航向控制与路径跟踪研究提供了基础的动力学描述。

随着对帆船耦合运动特性的进一步研究，横倾与横摇对航行性能和控制过程的影响也受到关注。帆船发生横倾后，风帆及船体附体所处的相对流动状态会发生变化，并进一步影响相应的气动力和水动力特性；横摇运动也会与航向及侧向运动产生耦合[18]。Xiao 和 Jouffroy 在 Fossen 海洋航行器动力学框架基础上，构建了包含纵荡、横荡、横摇与艏摇的非线性四自由度帆船模型[19]。该模型沿用统一的向量化动力学表达[20][21][22]，并分别考虑风帆、舵、龙骨及船体相关的气动力和水动力，可用于控制导向的动力学分析与数值仿真。本文后续仿真环境采用的无人帆船动力学模型即以该四自由度模型为基础，具体结构与计算过程将在第二章中进一步介绍。

除描述帆船瞬态运动响应的动力学模型外，航行性能预测也是帆船建模研究的重要组成部分。速度预测程序（Velocity Prediction Program，VPP）通常结合帆船气动力、水动力特性及平衡关系，计算不同风速、风向条件下的稳态航行性能，并可进一步通过速度极线图（polar diagram）进行直观表征。速度极线图反映了帆船航速随风速及相对风向的变化关系，并能够表征迎风禁航区等典型航行特征，因此常用于帆船性能评估，并为后续路径规划与航行策略设计提供参考。典型速度极线图如图 1.3 所示。

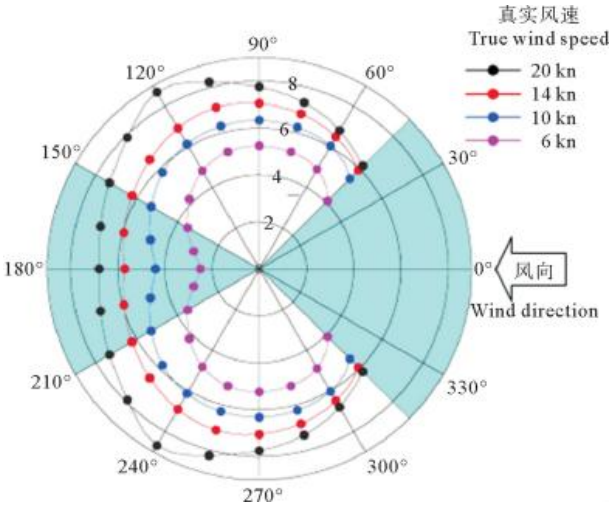


图 1.3 速度极线图[23]。

Fig.1.3 Velocity Polar diagram.

VPP 的研究逐步由早期基于经验与半经验模型的性能计算，向结合数值流体力学与优化算法的综合预测方向发展。Kerwin 于 20 世纪 70 年代开展了较早的帆船速度预测程序研究，建立了面向竞赛帆船的 VPP 方法[24]。随着计算流体力学方法的发展，研究者逐步将更精细的气动力与水动力计算引入性能预测过程。Roux 等人将气动和水动力数值计算与 VPP 相结合，并进一步研究 VPP 与 CFD-RANSE 方法的强耦合计算[25][26]。针对自主单体帆船的设计与性能评估需求，An 等人构建了面向自主帆船的通用 VPP，并结合优化算法提高不同工况下的求解效率[27]。

除针对特定帆船建立动力学与性能预测模型外，海洋机器人领域还发展了面向算法开发和控制验证的通用仿真平台。Bingham 等人基于 Gazebo 构建了 Virtual RobotX（VRX）仿真环境，为无人水面航行器在复杂海洋场景中的算法开发与测试提供了开源仿真工具[28]。Paravisi 等人开发的 USVSim 则进一步考虑风、波浪和海流等环境扰动，可用于不同环境条件下无人水面航行器导航与控制算法的仿真验证[29]。此类通用仿真平台能够提供可重复、可配置的数值测试环境，但针对风帆气动力及帆舵耦合等无人帆船特有动力学过程，仍需结合具体研究对象构建相应的模型。

总体而言，动力学模型、航行性能预测方法与数值仿真平台分别从运动描述、性能表征和算法验证等层面构成了无人帆船自主航行研究的模型基础，为后续制导与控制方法的设计提供了支撑。

1.2.2 无人帆船自主航行与控制

无人帆船自主航行通常可以按照制导、导航与控制（Guidance, Navigation and Control，GNC）的功能结构进行描述[22][30]。其中，导航模块根据船载传感器信息确定或估计无人帆船的位置、速度、航向等运动状态；制导模块结合航行任务、导航状态及相关环境信息生成路径、期望航向或期望速度等参考指令；控制模块则根据参考指令与当前运动状态计算相应的执行控制量。对于无人帆船，舵和帆是主要的控制执行机构，舵角主要参与航向调节，帆角则直接影响风能利用与航行速度，因此环境风场信息也常参与制导和帆舵控制过程[30]。典型的无人帆船 GNC 功能关系如图 1.4 所示。

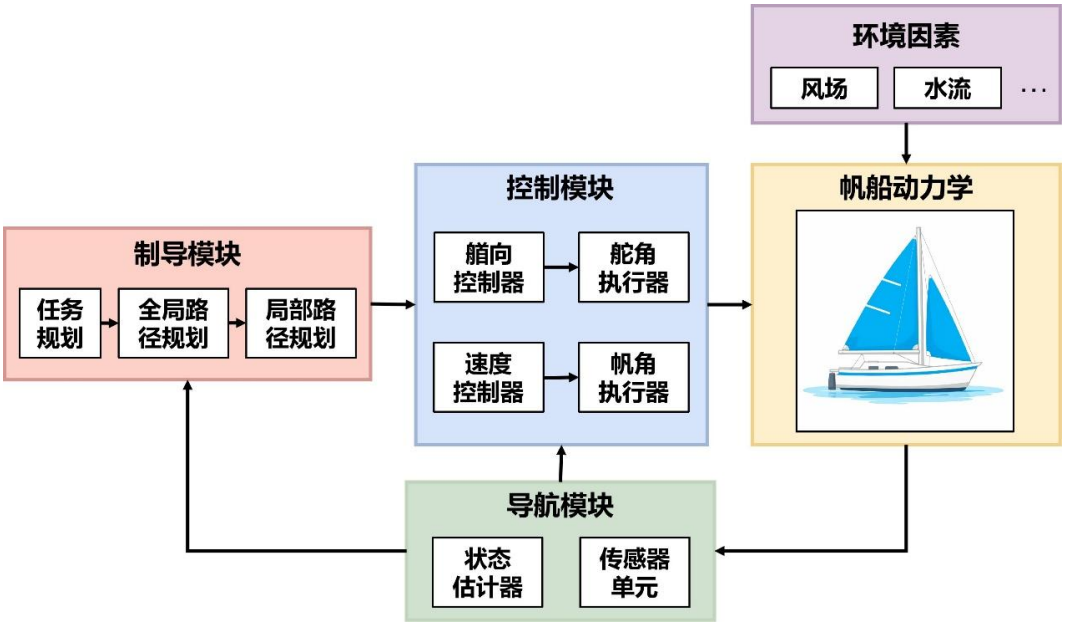


图 1.4 无人帆船 GNC 系统。

Fig.1.4 Unmanned sailboat GNC system.

(1)导航模块

导航模块主要负责获取或估计无人帆船当前运动状态，为后续制导与控制提供状态信息。实际航行平台通常通过卫星定位、航向传感器及其他船载传感器获取位置、航向和速度等信息，并根据具体控制结构获取风速、风向等环境观测。在仿真研究中，控制器所使用的观测量可以由仿真状态按照设定构造，并进一步加入测量噪声以模拟实际传感过程，因此动力学状态演化与导航状态获取在功能上应予以区分。Santos 等构建的 N-Boat 自主帆船采用 GPS、数字罗盘和风传感器作为主要感知设备，并通过预设航迹点完成自主航行，在仿真及实船平台上对控制体系进行了验证[31]。

(2)制导模块

制导模块根据航行任务、导航状态以及相关环境信息，为无人帆船生成后续控制所需的航路、航迹点或期望航向等参考信息。与常规动力船舶相比，无人帆船的可航方向和航行速度受到风向、风速及自身航行性能的显著影响，因此制导过程除考虑目标位置、航行区域和障碍物等空间约束外，还需要结合风场条件与帆船运动特性。按照任务尺度和环境信息的使用方式，相关研究通常可以分为全局航路规划与局部制导两个层次：全局航路规划主要针对较大任务区域生成由若干航迹点组成的整体航路；局部制导则在航路执行过程中，根据相邻航迹点、实时船舶状态以及局部环境变化进一步确定当前阶段可执行的航行方向或局部航迹[30][32]。

在全局航路规划方面，经典图搜索与采样搜索方法经过针对帆船运动特性的改进后得到了广泛研究。Langbein 等人针对无人帆船长期航行任务，在 A*算法基础上根据变化的天气条件动态调整底层航路图，使航路能够随预测环境变化进行更新[33]。Yuan 等人将改进势场方法与 A*算法结合，用于无人帆船路径规划，以同时考虑航路搜索与局部环境约束[34]。Saoud 等人则采用概率路线图（Probabilistic Roadmap，PRM）构建搜索空间，并使用经过调整的 Dijkstra 算法进行全局航路规划，在航路评价中考虑帆船运动特性及风场空间分布，使路径代价由单纯的几何距离进一步转向实际航行时间[35]。近年来，Sidoti 等人针对时变风场和海流条件下的最快航路问题，将天气、海流与船舶速度极线共同纳入非线性航段代价计算[36]；邓英杰等人则针对固定风场下无人帆船路径成本具有非凸、非对称特征的问题，以最小航行时间为目标改进 RRT*算法，并利用不同风向下的航速关系进行路径代价计算[37]。由此可见，无人帆船全局航路规划的评价目标逐渐由几何可达性扩展到结合风场和帆船航行性能的实际航行代价优化。

除图搜索与采样规划外，群智能和启发式优化方法也被广泛用于无人帆船航路规划。Nian 等人针对无人帆船全局航路规划提出了改进蚁群优化（Improved Ant Colony Optimization，IACO）方法，以适应风力驱动帆船的运动特性[38]。Shen 等人将改进自适应蚁群优化与滚动窗口方法结合，在环境模型中加入风场因素和障碍物约束，并从路径长度、航行时间和安全性等方面改进路径评价，实现全局规划与航行过程中实时局部避障的结合[39]。此外，Gong 等人将无人帆船自动采样过程中的多任务点航路优化转化为组合优化问题，并采用改进粒子群算法进行

求解[40]。这些方法从不同角度利用群体搜索机制处理复杂航路空间，为多约束条件下的无人帆船路径优化提供了另一类技术路线。

随着数据驱动方法的发展，强化学习也逐渐应用于无人帆船的高层航路规划和航行决策。Silva Junior 等人基于 Q-learning 构建无人帆船全局路径规划器，根据风向调整可选动作及奖励关系，使规划结果能够考虑迎风禁航区以及障碍物和航行边界等约束[32]。荆纬等人综合考虑帆船平面运动模型、海风、海流和障碍物等环境因素，利用 Q-learning 实现起点至目标点之间的路径规划与障碍物规避[23]。Liu 等人进一步将高斯过程与 Q-learning 结合，用于风场作用下无人帆船的高层路径规划，并面向竞赛航行及绕标任务开展研究[41]。Suda 和 Nikovski 则将深度强化学习用于随机变化风速、风向条件下的迎风航行问题，使策略能够根据环境变化学习驶向上风目标点的航行决策[42]。上述研究表明，强化学习已经被用于无人帆船的航路生成与高层航行决策，并为处理风场变化下难以通过固定规则描述的决策过程提供了数据驱动的研究途径。

与全局航路规划相比，局部制导更加关注相邻航迹点之间的实时航行行为，需要结合当前风况、船舶运动状态及局部障碍物信息生成短时间尺度内可执行的参考航向或局部航迹。Pêtrès 等人提出了基于人工势场的无人帆船反应式导航方法，将风向变化、帆船运动约束以及已探测障碍物统一表示为周期更新的局部势场，并据此实时计算可行航向，相关方法通过数值仿真和缩比帆船湖上试验进行了验证[43]。Plumet 等人在势场框架基础上进一步引入基于视线法（Line-of-Sight，LOS）的航迹吸引项，使无人帆船能够保持在相邻航迹点连线附近航行，并通过与航速相关的排斥势改善局部障碍物附近的避障轨迹[44]。国内方面，康梦萁等人针对无人帆船短途路径规划提出速度最优方法，并与传统 A*方法进行了比较[45]；项天远等人针对无人帆船实时路径规划问题研究了基于概率势场的方法[46]。袁鹏等人则在 VPP 性能预测基础上提出速度选择切换型 LOS 方法，通过不同航向下的速度信息与切换型 LOS 相结合实现无人帆船循迹航行，并在不同风向条件下开展湖上试验[47]。这些研究体现了局部制导方法由几何航迹跟踪向同时考虑风场、帆船速度特性及障碍物约束的方向拓展。

近年来，学习方法也开始进入无人帆船局部制导环节。刘方成等人针对传统制导算法难以充分考虑迎风和顺风换舷特性的问题，提出基于深度确定性策略梯

度（Deep Deterministic Policy Gradient，DDPG）的路径跟踪制导方法，以无人帆船运动状态和位置信息作为输入，由 DDPG 策略网络生成参考航向角，再通过 PID 航向控制器实现实际航向对参考航向的跟踪[48]。上述工作体现了强化学习在无人帆船航路生成与高层航行决策中的应用，其输出仍主要位于航路或航向决策层。

总体而言，现有制导研究已覆盖从全局航路规划到局部实时制导的多个层次，其输出通常表现为航路、航迹点或参考航向，并需要由控制模块进一步转换为帆角和舵角等执行控制量。

（3）控制模块

控制模块主要根据制导模块生成的参考航向、航迹或速度等信息以及无人帆船当前运动状态，计算帆角与舵角等执行控制量。无人帆船具有明显的非线性和多输入多输出特征，其中舵主要用于调节航向和艏摇运动，帆则通过改变气动力影响推进性能和航速，同时二者对横摇、侧向运动及航向变化存在一定的动力学耦合[30][49]。在较多传统控制结构中，航向控制与帆角或速度控制分别进行设计，以降低控制器设计复杂度，但这种功能划分并不意味着帆舵在动力学上完全解耦。

在航向与航迹控制方面，比例控制、PID 控制以及基于航向误差的反馈方法具有结构简洁、易于实现等特点，是无人帆船控制中的基础技术路线。Jaulin 和 Le Bars 围绕无人帆船线路跟踪设计了较为简洁的控制方法[50]，Plumet 等人也在自主帆船系统中采用反馈控制实现航向及航迹跟踪[51]。国内方面，张雪飞等人采用模糊控制在线调整 PID 参数，以提高不同航速和扰动条件下的航向控制适应能力[52]。随着对帆船非线性、横漂及环境扰动问题研究的深入，反馈线性化、反步、自适应控制和模型预测控制等方法也逐渐得到应用[53]。例如，Wille 等人通过对航向控制结果进行漂角修正，将控制目标进一步扩展至实际航迹方向[54]；Dong 等人将高斯过程学习模型与模型预测控制相结合，研究无人帆船航向与航迹跟踪问题[56]。邵康健和刘道发则将漂角观测与反步自适应控制结合，用于无人帆船路径跟踪[58]。

在帆角与航速控制方面，现有方法通常根据风速、风向以及帆船航行性能确定合适的帆角，以获得较为有效的风能利用。较早的研究多依据速度极线或经验关系形成风场条件与帆角之间的对应关系[59]，后续研究进一步引入模糊控制及

在线优化等方法。Shen 等人基于速度极线给出的帆角初始值，利用极值寻优方法在线调整帆角，实现无人帆船航速优化[60]；Liu 等人也将航速优化与模糊 PID 航向控制结合，用于无人帆船定点保持任务[61]。在相邻的风帆助推船舶研究中，Deng 等人采用模糊逻辑开展速度优化与路径跟踪研究[62]，相关方法对风能利用与帆角调节同样具有参考意义。针对逆风航行中的换舷过程，研究者还提出了专门的控制策略，例如 AEOLUS 项目采用包括 LQR 在内的方法研究自主换舷控制[63]，Sun 等人则利用力极线图分析不同风况下的帆船受力特性并设计换舷控制策略[64]。

由于帆角和舵角共同影响无人帆船的航向、速度和横摇等状态，将二者完全独立设计难以充分反映其动力学耦合关系，因此近年来帆舵协同控制受到更多关注。Liu 等人基于四自由度无人帆船模型提出帆舵协同 MPC 方法，以航向角和横摇角为控制目标，同时求解帆角与舵角控制量[65]。国内方面，贾金恒等人针对“海鸥”号无人帆船构建帆舵联合 MPC 轨迹跟踪方法，将动力学特性及执行器约束纳入滚动优化，并对变化风向和逆风航行情形进行了仿真研究[66]。数据驱动方法也开始进入帆舵联合控制领域，Chen 等人采用强化学习研究无人帆船航行过程中的帆舵协同控制[67]；谢天等人进一步开展了基于深度学习的无人帆船帆舵联合航路点跟踪控制研究[68]。这些工作体现了无人帆船控制由航向、航速分别调节向显式考虑帆舵耦合关系的联合优化与数据驱动协同控制拓展。

总体来看，现有无人帆船控制已覆盖经典反馈、非线性与优化控制以及帆舵协同等多种技术路线，近期也开始引入数据驱动方法。上述代表性方法的制导与控制过程通常直接利用风速、风向、视风信息或由其形成的航行性能参数；当这些环境信息不能被完整直接利用时，控制问题所对应的信息条件随之发生变化，由此引出观测受限条件下的自主决策研究。

1.2.3 观测受限条件下的无人帆船控制研究

当部分环境状态不能被控制系统直接观测时，相同或相近的当前观测可能对应不同的隐含环境状态，并需要采取不同的控制行为。以本文关注的风场信息为例，当风速和风向不作为策略直接观测输入时，相近的船体位置、航向和速度等状态可能对应不同风况，从而产生不同的帆舵决策需求。此类观测信息不完整条件下的序列决策问题可以采用部分可观测马尔可夫决策过程（Partially

Observable Markov Decision Process，POMDP）进行描述[69]。在 POMDP 中，信念状态可用于表示给定历史动作和观测条件下对隐藏系统状态的概率描述，并作为后续决策的信息基础。

针对部分可观测条件下难以直接获得完整状态的问题，除显式维护隐藏状态或信念状态估计外，另一类方法通过历史观测与动作序列形成时序表示，使策略能够利用系统过去的响应辅助当前决策。Heess 等将循环神经网络引入无模型连续控制方法，在部分可观测物理控制任务中利用 LSTM 处理噪声观测及隐含系统参数等时序信息[70]。Ni 等进一步系统研究了循环无模型强化学习在多类 POMDP 任务中的表现，表明循环策略可以作为处理部分可观测强化学习问题的一类有效基线[71]。这些研究为利用历史观测—动作关系补充单时刻观测信息提供了方法基础。

在无人帆船领域，减少对电子风场传感器直接依赖的研究较早已有探索。Sliwka 等针对长航时自主帆船提出船艏风向标自操舵装置，利用机械结构根据相对风向调节航行姿态，使控制系统不再需要单独的电子风向传感器[72]。Xiao 等进一步提出基于 Voronoi 图的无风传感器控制策略，通过对航行空间进行分区并预先设置候选航行方向，仅利用 GPS 和罗盘完成航向选择，同时结合航速反馈在线调整帆角，并通过仿真及实际帆船试验验证了该方法[73]。这类研究表明，在不直接获取电子风场测量数据的条件下，仍可以通过机械反馈、预设航行规则以及船体运动反馈实现自主航行，其控制结构与直接利用历史序列学习连续帆舵策略存在明显差异。

另一类研究思路是保留风场信息在后续控制体系中的作用，通过状态估计或数据融合改善风场信息的可获得性。Cabrera-Gámez 等提出基于粒子滤波的虚拟风传感器，利用帆船动力学模型从船体运动信息中估计风速和风向[74]。国内方面，何成龙等针对无人帆船姿态变化对风场测量的影响，将姿态信息、相对风与航行风进行融合，并结合卡尔曼滤波和扩展卡尔曼滤波计算真风风速与风向[75]。该方法仍以相对风测量为输入，重点在于减小船体运动对真风解算的影响，而非取消风传感器。Sun 等提出基于运动观测的风场估计方法 MoWe，通过分析无人帆船自身机动响应，并结合运动分析与数据驱动方法，在不直接使用风场测量的条件下估计风向和风速，并通过仿真与实际试验进行了验证[76]。

总体来看，针对无人帆船风场观测受限问题，现有研究大致形成了两类技术路径：一类通过数据融合或状态估计提高风场信息的可获得性与测量质量，并显式获得风速、风向等环境变量；另一类通过机械反馈、预设规则或船体运动响应降低对直接风场测量的依赖。与此同时，部分可观测强化学习研究表明，历史观测与动作本身也可以作为补充当前观测信息的重要时序来源。相比之下，在无人帆船控制中，不首先显式重构风场，而是将风速和风向从策略直接观测中移除，并利用当前可观测状态及历史观测—动作关系直接完成连续帆舵决策的研究仍相对有限。因此，本文围绕这一信息条件开展方法研究与仿真验证，重点考察历史信息能否为无显式风场输入条件下的局部帆舵控制提供有效的决策信息。进一步地，当局部环境中引入障碍物等额外约束后，历史信息的融合方式及其有效时间范围如何影响决策，也构成本文后续进一步分析的问题。

1.3 研究内容与章节安排

本文围绕无显式风场输入条件下的无人帆船局部自主航行问题，研究历史观测—动作信息对连续帆舵决策的作用。研究主要回答三个相互关联的问题：在风速和风向不直接进入策略输入时，历史运动响应能否改善不同风况下的目标航行；引入静态障碍物后，当前观测驱动的历史信息融合能否改善目标推进与局部绕行之间的协调；上述作用体现在哪些任务表现和信息利用特征上，又受到哪些环境与观测条件的限制。

围绕这些问题，本文在统一动力学模型和任务规则下构建强化学习交互环境，依次研究基于历史编码的局部帆舵控制方法和面向静态障碍物的历史选择性融合方法，并通过模型对照、奖励消融、扰动测试及固定策略分析，评价历史信息对任务完成、航行效率、控制调节和障碍规避的影响。

本文主要研究内容及章节安排如下：

第一章为绪论。首先介绍海洋观测与无人帆船的发展背景，分析无人帆船自主航行过程中对风场信息的依赖以及风场观测受限条件下开展控制研究的现实意义；随后从动力学建模与性能预测、自主航行与控制以及观测受限条件下的控制研究三个方面梳理国内外相关研究进展，并在此基础上明确本文的研究问题与总体研究思路。

第二章介绍本文研究涉及的相关理论与动力学基础。首先对深度学习与强化

学习中的基本概念和主要方法进行介绍，包括神经网络、长短期记忆网络、马尔可夫决策过程、Actor–Critic 结构以及 PPO、TD3 和 SAC 等强化学习算法；随后介绍本文采用的无人帆船四自由度动力学模型，对船体坐标系、运动方程以及风帆、舵和船体所受主要气动力与水动力的计算过程进行说明，为后续仿真环境构建和控制模型研究提供理论与模型基础。

第三章构建强化学习训练所需的无人帆船仿真交互环境。将第二章中的四自由度动力学模型集成到强化学习交互框架中，并建立动态风场模型，使无人帆船在时变风场作用下完成状态更新。在此基础上，对局部航行任务的观测空间、动作空间、初始状态及终止条件进行统一设定，并进一步考虑传感器噪声和执行器误差等因素。针对强化学习训练过程中大量环境交互所带来的计算开销，还对并行采样、数值计算和环境终止条件等环节进行相应优化，为后续模型训练和性能测试提供统一的仿真实验基础。

第四章研究无显式风场输入条件下的无人帆船局部帆舵控制问题。在 SAC 框架中引入 LSTM 历史编码分支，将历史观测—动作信息与当前观测融合，并结合点到点航行任务设计奖励函数。通过不同信息条件和网络结构下的控制性能对比、奖励消融及扰动测试，分析模型的任务完成能力与控制行为；进一步利用隐藏状态风向读出和历史截断实验，研究历史信息在策略内部的表示及其对动作输出的影响。

第五章进一步研究静态障碍物环境下的无人帆船局部自主航行问题。 在第四章控制模型基础上扩展障碍物观测空间和避障奖励设定，并在 SAC-LSTM 结构中引入注意力机制，对历史隐藏状态进行选择性融合，使模型能够根据当前决策需求对不同时刻的历史信息进行动态加权。通过注意力机制对比实验、不同滑动窗口长度实验以及典型避障过程中的注意力权重分析，研究历史信息的融合方式和时间范围对复杂局部航行任务决策性能的影响。

第六章对全文研究工作进行总结与展望。首先归纳本文在端到端局部帆舵控制、无显式风场输入条件下的历史信息利用以及静态障碍物环境中的历史选择性融合等方面获得的主要研究结论，并在此基础上总结本文的主要创新点。随后结合当前单层端到端控制结构、统一仿真模型、有限观测条件及局部任务范围分析研究局限，并从分层与安全强化学习、仿真到真实环境迁移以及更长时间尺度的

部分可观测决策等方面讨论后续研究方向。

本文总体研究框架如图 1.5 所示。

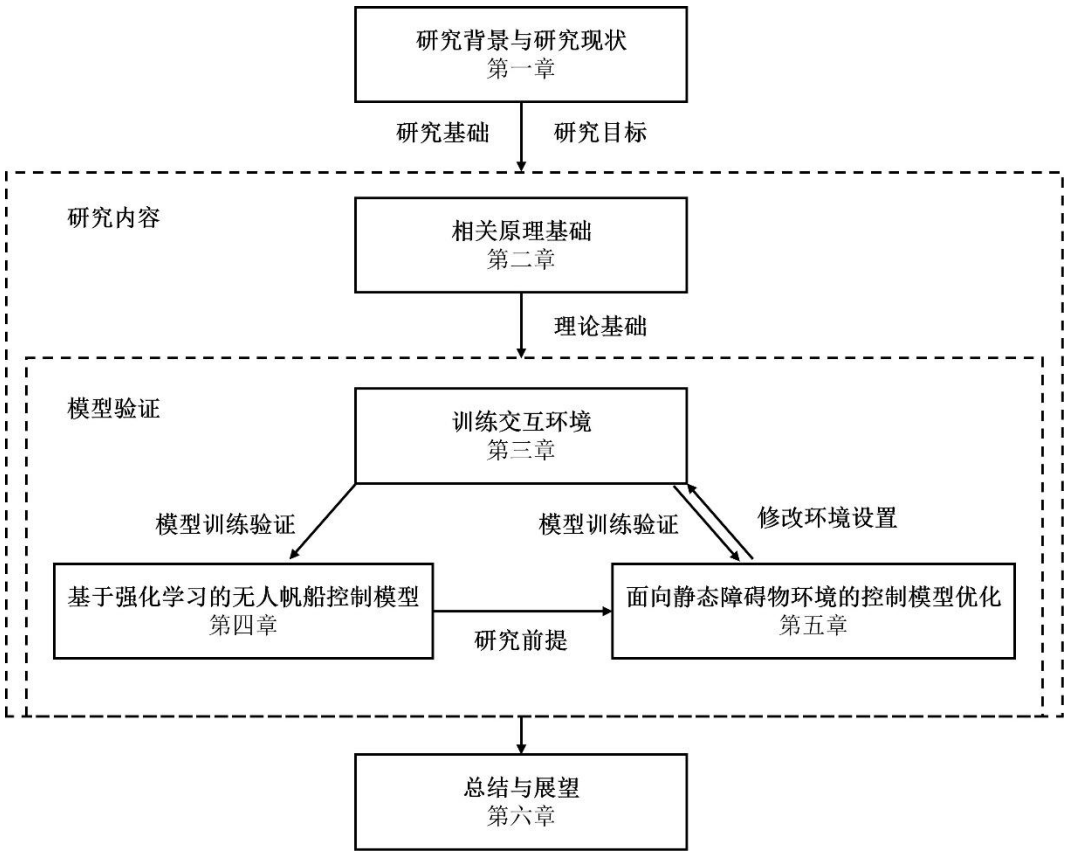


图 1.5 论文研究框架。

Fig.1.5 Research framework of the thesis.

2 理论基础与无人帆船动力学模型

本文采用深度强化学习方法研究无人帆船航迹点之间的局部连续帆舵控制问题。控制模型的构建一方面涉及神经网络对策略与价值函数的表示以及历史信息的时序建模，另一方面需要通过无人帆船动力学模型描述控制动作、环境作用与船体运动状态之间的关系。因此，本章首先介绍后续模型设计所需的神经网络与时序信息建模基础，随后介绍强化学习的基本决策框架及连续控制算法，最后给出本文仿真环境采用的四自由度无人帆船动力学模型。

2.1 神经网络与时序信息建模基础

神经网络是一类由多层参数化计算单元构成的非线性函数模型，可通过数据驱动的参数优化学习输入变量与输出变量之间的复杂映射关系。在深度强化学习中，神经网络通常用于表示策略函数、状态价值函数或动作价值函数，使智能体能够在高维、非线性的状态与动作空间中进行决策。本文后续控制模型采用全连接神经网络作为基本函数逼近结构，并进一步利用长短期记忆网络（Long Short-Term Memory，LSTM）对历史观测与动作信息进行时序编码。因此，本节主要介绍与后续模型结构直接相关的前馈神经网络、参数优化方法以及 LSTM 的基本原理。

（1）前馈神经网络与全连接层

前馈神经网络（Feedforward Neural Network，FNN）是神经网络的一种基本结构，其信息按照输入层、隐藏层和输出层的方向逐层传播。当相邻两层中的每个神经元均与下一层全部神经元建立连接时，相应网络层称为全连接层（Fully Connected Layer，FC），其基本结构如图 2.1 所示。

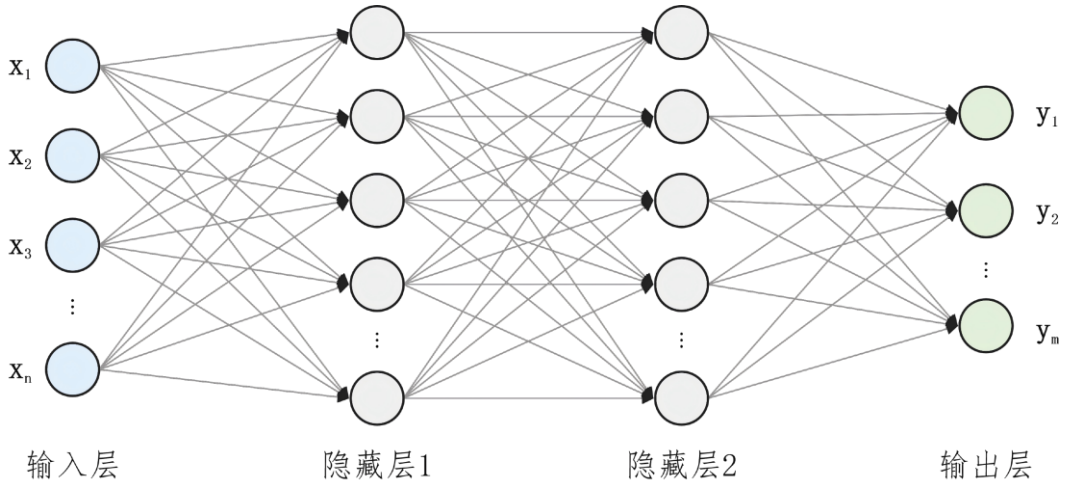


图 2.1 前馈网络与全连接结构示意图。

Fig.2.1 Schematic diagram of feedforward network and fully connected structure.

对于第 l层神经网络，其计算过程可表示为：

$$\boldsymbol{h}^{(l)} = f\left(\boldsymbol{W}^{(l)}\boldsymbol{h}^{(l-1)} + \boldsymbol{b}^{(l)}\right), \tag{2-1}$$

式中，$\boldsymbol{h}^{(l-1)}$和$\boldsymbol{h}^{(l)}$分别表示第$l-1$层和第l层的输出，$\boldsymbol{W}^{(l)}$为权重矩阵，$\boldsymbol{b}^{(l)}$为偏置向量，$f(\cdot)$为激活函数。网络首先利用权重和偏置对输入特征进行线性组合，再通过激活函数完成非线性变换。神经网络的训练过程即根据给定的优化目标不断调整上述参数，使网络逐步学习任务所需的输入—输出映射关系。

若各层之间仅进行线性变换，多层线性映射仍可以等效为单一线性映射，难以表示复杂的非线性关系。因此，神经网络通常在线性变换之后引入非线性激活函数。本文后续网络结构主要涉及 ReLU、Sigmoid 和 tanh 三类激活函数，其定义分别为：

$$ReLU(z) = max(0, z), \tag{2-2}$$

$$\sigma(z) = \frac{1}{1+e^{-z}}, \tag{2-3}$$

$$\tanh(z) = \frac{e^{z} - e^{-z}}{e^{z} + e^{-z}}. \tag{2-4}$$

其中，ReLU 在输入为正时保持线性响应，在输入为负时输出为零，常用于前馈网络隐藏层的非线性特征变换；Sigmoid 将输入映射至$0 \sim 1$区间，可用于表示门控比例；tanh 将输入映射至$-1 \sim 1$区间。本文后续模型中的全连接特征提取层主要采用 ReLU，而 Sigmoid 与 tanh 主要用于 LSTM 的门控与状态更新过程。

多个全连接层与非线性激活函数组合后，可以形成具有非线性函数逼近能力的前馈网络。

（2）网络参数优化与反向传播

神经网络中的权重和偏置需要通过训练过程进行调整。设神经网络的输入为$\boldsymbol{x}$，网络参数统一记为$\boldsymbol{\theta}$，其输出可以表示为$F(\boldsymbol{x};\boldsymbol{\theta})$。在给定具体学习任务后，可进一步构造相应的目标函数或损失函数$\mathcal{L}(\boldsymbol{\theta})$，并通过迭代优化网络参数，使目标函数沿期望方向变化。因此，神经网络的训练本质上可以表示为针对参数$\boldsymbol{\theta}$的数值优化过程。

为获得各网络参数的更新方向，通常利用反向传播（Backpropagation）算法计算目标函数相对于网络参数的梯度。网络首先通过前向传播，根据当前输入和网络参数得到输出及相应的目标函数值；随后依据链式法则，由网络输出端向输入方向逐层计算各层参数对目标函数的偏导数，从而得到参数梯度：

$$\nabla_{\theta}\mathcal{L}(\theta). \tag{2-5}$$

以基本梯度下降方法为例，第k次迭代后的参数更新可以表示为：

$$\theta_{k+1} = \theta_k - \eta\nabla_{\boldsymbol{\theta}}\mathcal{L}(\boldsymbol{\theta}_k), \tag{2-6}$$

式中，η为学习率，用于控制单次参数更新的幅度。经过重复的前向计算、梯度求解和参数更新，网络参数逐步适应相应的优化目标。对于需要最大化的目标函数，也可以通过最小化其负值采用相同的梯度优化框架。

（3）循环神经网络与长短期记忆网络

前馈神经网络在每次计算时主要根据当前输入生成输出，其网络内部不显式保留前一时刻的计算状态。对于时间序列或动态系统，当前输出往往不仅与当前输入有关，还可能与此前一段时间的信息相关。循环神经网络（Recurrent Neural Network，RNN）通过在相邻时间步之间传递隐藏状态，使网络能够在处理当前输入的同时保留此前序列中的部分信息。其基本递推关系可表示为：

$$\boldsymbol{h}_t = \phi(\boldsymbol{W}_x\boldsymbol{x}_t + \boldsymbol{W}_h\boldsymbol{h}_{t-1} + \boldsymbol{b}_h), \tag{2-7}$$

式中，$\boldsymbol{x}_t$为当前时刻输入，$\boldsymbol{h}_{t-1}$和$\boldsymbol{h}_t$分别为上一时刻和当前时刻的隐藏状态，$\boldsymbol{W}_x$、$\boldsymbol{W}_h$和$\boldsymbol{b}_h$为网络参数，$\phi(\cdot)$为非线性激活函数。与前馈神经网络相比，RNN 的当前隐藏状态同时受到当前输入和此前隐藏状态的影响，因此信息能够通过隐藏状态沿时间方向递推传递。

然而，当序列较长时，普通 RNN 在时间维度的反向传播过程中可能出现梯度逐步衰减等问题，使较早时刻的信息难以对当前网络参数更新产生有效影响，

从而限制长期依赖关系的学习。Hochreiter 和 Schmidhuber 提出的长短期记忆网络（Long Short-Term Memory，LSTM）通过引入独立的单元状态和门控机制改善信息在时间维度上的传递，使网络能够更有效地学习跨越较长时间间隔的序列关系[77]。

LSTM 在循环隐藏状态$\boldsymbol{h_t}$的基础上引入单元状态$\boldsymbol{c_t}$，并通过遗忘门、输入门和输出门控制历史信息的保留、新信息的写入以及当前状态的输出，其基本结构如图 2.2 所示。在时间步 t，LSTM 根据当前输入$\boldsymbol{x_t}$、上一时刻隐藏状态$\boldsymbol{h_{t-1}}$和单元状态$\boldsymbol{c_{t-1}}$更新内部状态，并得到新的隐藏状态$\boldsymbol{h_t}$和单元状态$\boldsymbol{c_t}$。

遗忘门用于控制上一时刻单元状态中信息的保留程度：

$$\boldsymbol{f_t} = \sigma\big(\boldsymbol{W_f}[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_f}\big). \tag{2-8}$$

上述公式中，$\boldsymbol{f_t}$为遗忘门输出，$\boldsymbol{W_f}$和$\boldsymbol{b_f}$分别为对应的权重矩阵和偏置向量，$[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}]$表示两个向量的拼接。由于 Sigmoid 函数的输出范围为$0 \sim 1$，遗忘门可以对上一时刻单元状态中的不同信息进行不同程度的保留或抑制。

输入门用于控制当前产生的新信息写入单元状态的程度：

$$\boldsymbol{i_t} = \sigma(\boldsymbol{W_i}[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_i}), \tag{2-9}$$

同时生成候选单元状态：

$$\tilde{\boldsymbol{c}}_t = tanh(\boldsymbol{W_c}[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_c}), \tag{2-10}$$

式中，$\boldsymbol{i_t}$表示当前信息的写入比例，$\tilde{\boldsymbol{c}}_t$表示当前时间步生成的候选状态信息。在此基础上，当前单元状态更新为：

$$\boldsymbol{c_t} = \boldsymbol{f_t} \odot \boldsymbol{c_{t-1}} + \boldsymbol{i_t} \odot \tilde{\boldsymbol{c}}_t, \tag{2-11}$$

式中，$\odot$表示逐元素乘法。第一项表示经遗忘门调节后保留的历史信息，第二项表示经输入门调节后写入的新信息，从而实现信息在不同时间步之间的递推更新。输出门用于控制当前单元状态中参与隐藏状态输出的信息：

$$\boldsymbol{o_t} = \sigma(\boldsymbol{W_o}[\boldsymbol{h_{t-1}}, \boldsymbol{x_t}] + \boldsymbol{b_o}), \tag{2-12}$$

当前隐藏状态为：

$$\boldsymbol{h_t} = \boldsymbol{o_t} \odot \tanh(\boldsymbol{c_t}). \tag{2-13}$$

其中，$\boldsymbol{o_t}$为输出门，$\boldsymbol{h_t}$为当前时间步的隐藏状态。隐藏状态既可以作为当前时刻的时序特征表示，也会继续参与下一时间步的状态更新。各门控分支具有独立的权重和偏置，并在训练过程中共同优化。

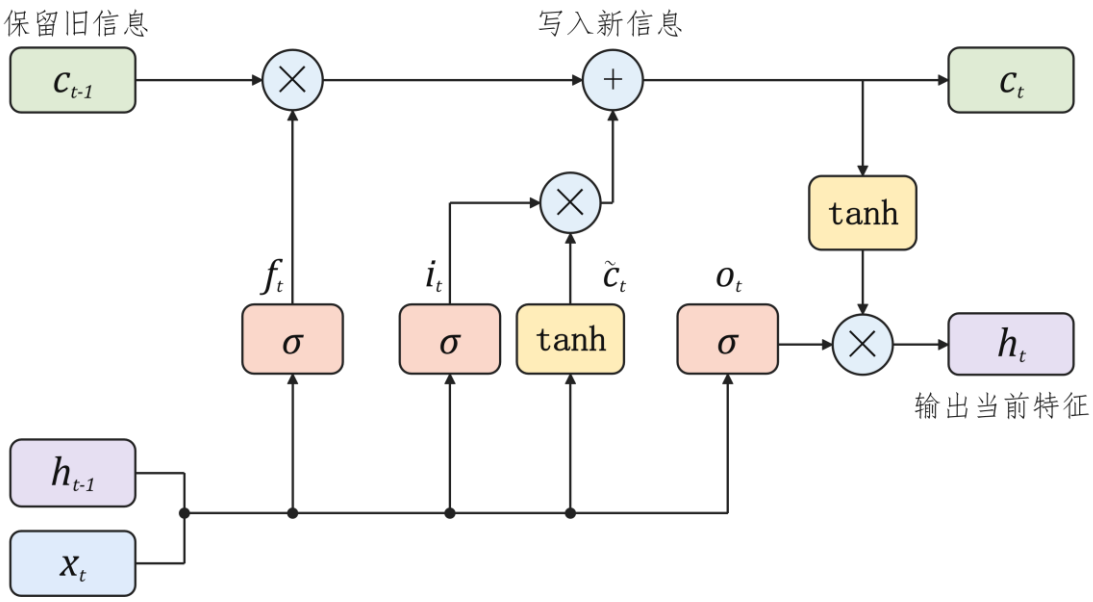


图 2.2 长短期记忆网络结构。

Fig.2.2 Long Short-Term Memory Network Structure.

（4）注意力机制

循环神经网络能够通过隐藏状态对序列信息进行递推编码，但在具体决策时，不同时间位置的信息对当前输出的重要程度可能并不相同。注意力机制（Attention Mechanism）通过计算当前查询信息与一组候选特征之间的相关程度，为不同特征分配相应权重，并采用加权求和的方式形成面向当前任务的特征表示[78]。

常见的缩放点积注意力将输入表示为查询向量（Query）、键向量（Key）和值向量（Value）。其中，查询向量用于表示当前的信息需求，键向量用于与查询进行相关性匹配，值向量则作为最终被加权汇聚的内容。其基本形式为：

$$Attention(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2-14}$$

式中，d_k为查询和键的特征维度，缩放项用于减小特征维度增大时点积幅值过大的影响。经过 Softmax 归一化后，各候选信息获得非负且和为 1 的权重，从而形成加权特征表示。

与固定使用某一个序列位置或对全部序列特征进行等权汇聚相比，注意力机制能够使网络根据当前输入动态调整不同历史信息的贡献程度。本文第五章将在 LSTM 时序编码基础上，将该机制用于不同历史隐藏状态之间的信息选择。

2.2 强化学习与连续控制基础

强化学习（Reinforcement Learning，RL）是一类通过智能体与环境持续交互来学习决策策略的方法。与针对单次输入输出映射进行优化的问题不同，强化学习中的动作不仅会产生即时奖励，还会影响环境后续状态以及未来能够获得的奖励，因此其核心是对具有时间关联的序列决策过程进行优化。智能体通过在环境中执行动作、接收新的观测与奖励，并根据交互经验调整策略，以提高长期累积回报[79]。

本节依次介绍强化学习的智能体—环境交互过程、马尔可夫决策过程、价值函数、策略梯度与 Actor–Critic 框架，并进一步说明本文涉及的连续控制算法及相关训练机制。

（1）强化学习交互过程与马尔可夫决策过程

强化学习系统通常由智能体（Agent）和环境（Environment）两部分构成。智能体是产生决策的主体，环境则包含智能体以外并能够受到其动作影响的系统及外部条件。在离散时间步t，智能体根据当前能够获得的信息选择动作a_t，环境在动作作用下发生状态转移，并向智能体反馈相应的观测和奖励。上述过程不断重复，从而形成随时间展开的交互序列，其基本关系如图 2.3 所示。

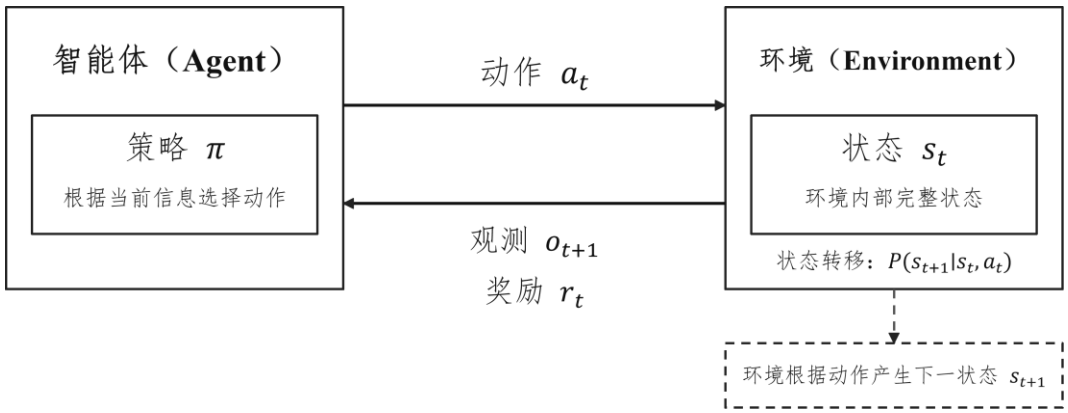


图 2.3 强化学习交互过程。

Fig.2.3 The interaction process of reinforcement learning.

动作a_t表示智能体在当前时刻施加于环境的决策；奖励r_t是评价相应状态转移或控制行为的标量反馈；策略π描述智能体根据当前可用信息选择动作的决策规则。对于随机策略，策略表示为动作的条件概率分布$\pi(a_t \mid s_t)$；确定性策略则直接给出状态到动作的映射。

在强化学习问题中，还需要区分环境状态（state）与智能体实际获得的观测（observation）。环境状态s_t描述决定环境状态转移所需的信息，而观测o_t表示智

能体在时刻t实际能够获得并用于决策的信息。在完全可观测条件下，观测可以构成环境状态的充分表征；当观测不能充分表征影响状态转移的环境信息时，则形成部分可观测问题。

为对上述序列决策过程进行数学描述，通常采用马尔可夫决策过程（Markov Decision Process，MDP）作为基本建模框架[79]。一个 MDP 可以表示为：

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma), \tag{2-15}$$

式中，$\mathcal{S}$为状态空间，$\mathcal{A}$为动作空间；P为状态转移概率，$P(s_{t+1}, | s_t a_t)$描述在状态s_t下执行动作a_t后转移至状态s_{t+1}的概率；R为奖励函数，用于评价相应的状态转移或控制行为；$\gamma \in [0, 1)$为折扣因子，用于调节未来奖励在当前决策中的权重。

MDP 的关键假设是状态具有马尔可夫性，即在给定当前状态与当前动作后，下一时刻状态的概率分布不再依赖更早的状态与动作历史，可以表示为：

$$P(s_{t+1}, |, s_0, a_0, \ldots s_t a_t) = P(s_{t+1}, | s_t a_t). \tag{2-16}$$

因此，MDP 中的状态应包含足以描述系统后续演化的信息。以下基础理论均先在完全可观测的 MDP 框架下介绍回报、价值函数与策略优化。

在给定策略π后，智能体根据当前信息选择动作，环境按照相应状态转移规律产生下一状态和奖励，由此形成随时间展开的交互轨迹：

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \ldots). \tag{2-17}$$

为对策略的长期决策效果进行评价，需要进一步引入回报与价值函数。

（2）回报、价值函数与 Bellman 方程

在序列决策过程中，智能体在某一时刻采取的动作不仅影响当前获得的奖励，还会通过改变后续环境状态影响未来的决策结果。因此，仅使用单步奖励难以完整评价一个动作的长期影响。强化学习通常采用回报（Return）对当前时刻之后的一系列奖励进行累计评价。对于回合式任务，奖励累计至终止时刻；对于无限时间范围的折扣任务，可表示为：

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots . \tag{2-18}$$

$\gamma \in [0, 1)$为折扣因子。较大的γ使未来奖励在当前评价中保持较高权重，而较小的γ则使评价更加侧重近期奖励。

在给定策略π后，由于初始状态、环境状态转移以及动作选择均可能具有随

机性，不同交互过程可能产生不同的累积回报。因此，通常采用策略所产生轨迹上的期望回报评价其整体性能，其目标函数可表示为：

$$J(\pi) = \mathbb{E}_{\tau\sim\pi}[G_0]. \tag{2-19}$$

相应的最优策略可表示为：

$$\pi^* = \arg\max_{\pi} J(\pi). \tag{2-20}$$

强化学习的目标并不是在每一个时间步独立选择即时奖励最大的动作，而是通过优化策略提高整个交互过程中的长期期望回报。为了进一步评价具体状态和动作对长期回报的影响，引入状态价值函数和动作价值函数。对于给定策略 π，状态价值函数定义为：

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s], \tag{2-21}$$

动作价值函数定义为：

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi}[G_t, \mid s_t = sa_t = a]. \tag{2-22}$$

其中，$V^{\pi}(s)$描述从状态s出发并按照策略π持续决策时能够获得的期望回报；$Q^{\pi}(s,a)$则进一步描述在状态s下首先执行动作a，随后继续按照策略π决策时的期望回报[79]。因此，状态价值用于评价某一状态的长期价值，而动作价值能够进一步比较同一状态下不同动作对长期结果的影响。

由于折扣回报满足递归关系$G_t = r_t + \gamma G_{t+1}$，价值函数也可以通过当前奖励与下一时间步的价值递归表示。对于动作价值函数，其 Bellman 期望方程可写为：

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi}[r_t, +\gamma Q^{\pi}(s_{t+1}, a_{t+1}) \mid s_t = s, a_t = a], \tag{2-23}$$

其中$a_{t+1} \sim \pi(\cdot \mid s_{t+1})$。该关系表明，一个状态—动作对的长期价值可以由当前奖励以及下一状态下后续决策的折扣价值共同表示。Bellman 方程由此将跨越多个时间步的长期评价转化为相邻时间步之间的递归关系，为值函数的迭代估计以及后续 Actor–Critic 方法中的价值学习提供了理论基础[79]。

当目标进一步转向寻找最优策略时，可定义最优动作价值函数$Q^*(s,a) = \max_{\pi} Q^{\pi}(s,a)$。对于离散动作问题，其 Bellman 最优方程可表示为：

$$Q^*(s,a) = \mathbb{E}\left[r_t, +\gamma \max_{a'} Q^*(s_{t+1}, a') \mid s_t = s, a_t = a\right]. \tag{2-24}$$

当最优动作价值函数已知时，可通过选择使动作价值最大的动作构造相应策略：

$$\pi^*(s) \in \arg\max_a Q^*(s,a). \tag{2-25}$$

在实际价值学习中，可以利用即时奖励与下一状态的价值估计构造一步学习目标，并根据该目标与当前预测值之间的差异更新价值函数，这类方法称为时序差分（Temporal-Difference，TD）学习[79]。Watkins 和 Dayan 提出的 Q-learning 通过交互样本逐步更新状态—动作价值估计，并在相应条件下收敛至最优动作价值函数[80]；SARSA 则根据当前策略产生的下一动作进行时序差分更新，属于 on-policy 方法[81]。随着深度神经网络的发展，DQN 使用神经网络逼近动作价值函数，并通过经验回放和目标网络等机制提高深度价值学习的可训练性，使价值函数方法能够用于高维输入下的离散动作决策问题[82]。

然而，当动作空间为连续变量时，难以像有限离散动作一样直接枚举全部候选动作并选择使$Q(s,a)$最大的动作。本文涉及的连续控制问题中常采用参数化策略直接生成连续动作。基于这一需求，下一部分介绍策略梯度方法及 Actor–Critic 框架。

（3）策略梯度与 Actor–Critic 框架

在连续动作空间中，根据动作价值函数选择动作通常需要额外求解优化问题。另一种常用处理方式是直接对策略进行参数化，使其根据输入产生动作或动作分布，并通过调整策略参数改善决策结果。

设随机策略为$\pi_\theta(a \mid s)$，其中θ表示策略参数。对于连续动作，$\pi_\theta(a \mid s)$表示条件概率密度，策略网络可以输出该分布的参数，再通过采样获得动作。确定性策略则直接表示为映射$a = \mu_\theta(s)$。两者均可利用神经网络进行参数化，但其动作生成方式和策略更新形式有所不同[83][84]。

对于随机策略，将前述策略目标写为$J(\theta) = J(\pi_\theta)$。在策略可微等常规条件下，针对期望折扣回报，其策略梯度可以表示为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau\sim\pi_\theta}\left[\sum_{t=0}^{\infty} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) Q^{\pi_\theta}(s_t,a_t)\right]. \tag{2-26}$$

$\nabla_\theta \log \pi_\theta(a_t \mid s_t)$描述策略参数变化对当前动作选择倾向的影响，$Q^{\pi_\theta}(s_t,a_t)$则提供该动作的长期价值评价。该表达式使策略梯度能够依据当前策略产生的交互样本进行估计，而不需要对环境状态转移模型本身求导。

实际训练时，真实动作价值通常未知，需要通过采样回报或学习得到的价值

函数进行估计。为减小梯度估计中的采样波动，可以在价值评价中减去一个不依赖当前动作的状态基线。当基线取为状态价值函数时，得到优势函数：

$$A^{\pi}(s,a) = Q^{\pi}(s,a) - V^{\pi}(s). \tag{2-27}$$

优势函数衡量在状态s下采取动作a，相对于按照当前策略选择动作的平均表现具有多大的长期收益差异。正优势表示该动作优于当前策略在该状态下的平均水平，负优势则表示相对较差。使用优势函数可以从相对于当前策略平均表现的角度评价动作，为策略更新提供更加直接的相对评价信息。

Actor–Critic 是将策略优化与价值估计结合起来的一类算法框架。其中，Actor 表示参数化策略，负责产生动作或动作分布；Critic 表示价值估计器，负责估计$V_{\omega}(s)$或$Q_{\omega}(s,a)$，并为策略更新提供评价信息，ω为价值函数参数。采用神经网络实现时，二者分别对应策略网络和价值网络。不同 Actor–Critic 算法采用的价值估计形式与策略更新信号有所不同。在训练过程中，环境反馈的奖励用于构造价值学习目标，Critic 据此估计长期回报，并为 Actor 的策略更新提供评价信息。具体交互关系如图 2.4 所示。

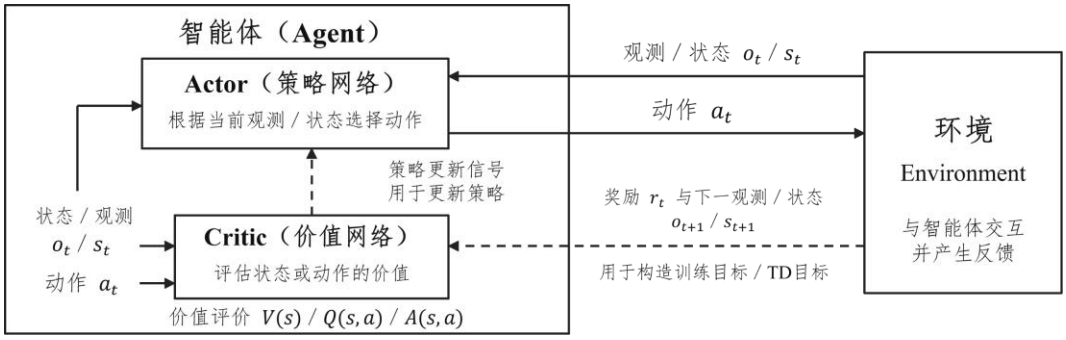


图 2.4 Actor-Critic 关系示意图

Fig.2.4 Actor-Critic Relationship Diagram

（4）连续控制中的代表性算法

在参数化策略与 Actor–Critic 框架下，不同算法在策略形式、训练数据使用方式及更新目标方面存在差异。按照数据采集策略与被评估或优化策略之间的关系，可以区分同策略（on-policy）与异策略（off-policy）方法。同策略方法主要依据当前或最近一轮策略采集的数据进行更新；异策略方法允许利用由其他行为策略产生的数据进行学习，因此能够结合经验回放重复使用历史样本。

（a）近端策略优化算法

近端策略优化（Proximal Policy Optimization，PPO）是一类随机策略优化方法。PPO 的常用裁剪形式利用新旧策略对同一动作的概率密度比，对过大的策略

变化不再提供额外的优化收益，从而抑制单次策略更新幅度过大[85]。设采集当前批次数据时的策略参数为θ_{old}，新旧策略对同一动作的概率密度比为：

$$\rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\text{old}}}(a_t \mid s_t)}. \tag{2-28}$$

PPO 的裁剪代理目标为：

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t\left[\min\left(\rho_t,(\theta)\hat{A}_t \text{ clip}(\rho_t,(\theta), 1-\epsilon 1+\epsilon)\hat{A}_t\right)\right]. \tag{2-29}$$

其中，$\hat{A}_t$为优势估计，ϵ为裁剪阈值，$\hat{\mathbb{E}}_t$表示对采样数据求经验平均。当优势为正时，目标函数鼓励提高对应动作的选择概率；当优势为负时则相反。裁剪操作限制概率比继续变化所带来的目标收益，从而抑制过大的策略更新。

PPO 通常交替进行数据采集和网络更新：首先使用当前策略获得一批交互数据，再基于该批数据执行若干轮小批量优化，随后重新采样。

（b）双延迟深度确定性策略梯度算法

双延迟深度确定性策略梯度（Twin Delayed Deep Deterministic Policy Gradient，TD3）是在深度确定性策略梯度算法 DDPG 基础上发展的一种异策略 Actor–Critic 方法[86]。其 Actor 使用确定性映射$\mu_\theta(s)$直接生成连续动作，Critic 估计状态—动作价值，并通过价值函数对动作的梯度为策略更新提供方向。

TD3 主要采用三项机制处理函数近似误差及其对策略学习的影响。首先，使用两个 Critic，并在构造价值学习目标时取较小的目标 Q 值，以降低过高价值估计被传播的风险。其次，采用延迟策略更新，即 Critic 更新若干次后，再更新一次 Actor 及相应目标网络，减少策略对尚不稳定的价值估计的快速跟随。最后，在计算下一状态的目标价值时，对目标 Actor 产生的动作加入受限噪声，形成目标策略平滑，使价值目标考虑该动作附近的局部变化。

目标策略平滑用于训练阶段的目标值计算；环境交互阶段还可以向确定性策略输出加入探索噪声，以增加动作探索。

（c）软 Actor–Critic 算法

软 Actor–Critic（Soft Actor-Critic，SAC）是一种基于最大熵强化学习的异策略随机 Actor–Critic 方法。与仅优化期望累积奖励的目标不同，最大熵框架同时考虑奖励和策略熵，使策略在追求较高回报的同时保留一定的动作分布随机性[87]。在前述折扣框架下，其目标可以表示为：

$$J_{\mathrm{ME}}(\pi)=\mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{\infty}\gamma^{t}\left(r_{t}+\alpha\mathcal{H}\left(\pi(\cdot\mid s_{t})\right)\right)\right]. \tag{2-30}$$

对于连续动作分布，策略熵采用微分熵形式：

$$\mathcal{H}\left(\pi(\cdot\mid s)\right)=-\mathbb{E}_{a\sim\pi(\cdot|s)}[\log\pi\left(a\mid s\right)]. \tag{2-31}$$

式中，$\alpha>0$ 为温度系数，用于调节熵项相对于奖励项的权重。策略熵用于度量动作分布的随机性；温度系数越大，优化目标越重视策略随机性。

在 SAC 中，温度系数可以固定设置，也可以根据预设的目标熵进行自适应更新。后一种方式根据当前策略的平均熵水平调整熵项权重，使其与给定目标相适应，不过目标熵仍需根据算法及动作空间进行设定。

SAC 的 Actor 输出连续动作的随机分布。对于具有上下界的动作，常用实现先从参数化高斯分布采样，再通过tanh变换将动作限制在规定区间，因此最终动作分布不再是未经变换的高斯分布。其参数更新可通过重参数化方式，将随机采样写成网络输出与外部噪声的组合，从而对动作生成过程进行梯度计算。

在价值学习方面，SAC 使用与熵正则目标相对应的软动作价值函数，并结合经验回放、双 Critic 和目标网络进行更新。这里的软价值不仅与后续奖励有关，还包含未来策略熵的影响，因此其目标值计算与上一部分只考虑奖励的 Bellman 关系有所区别[88]。在策略更新时，Actor 利用 Critic 的价值估计调整动作分布，使策略倾向于产生较高价值的动作，同时保留熵项所鼓励的随机性。

（5）经验回放与价值学习中的关键机制

TD3 和 SAC 均属于异策略 Actor–Critic 方法，并使用经验回放、目标网络和双 Critic 等机制进行价值学习，下面分别介绍其基本作用。

（a）经验回放

经验回放通过保存已获得的交互经验，使其能够在后续训练中被再次利用。Lin 的早期研究已经讨论了这一思路[89]；在 DQN、DDPG 等深度强化学习方法中，经验通常存入有限容量的回放缓冲区，并通过随机小批量采样参与网络更新。

记经验回放缓冲区为$\mathcal{D}$，其中保存的单步交互记录可写为$(s_t,a_t,r_t,s_{t+1},d_t)$。除状态、动作、奖励和下一状态外，$d_t$表示是否转移至不再累计后续回报的终止状态。训练时从缓冲区中抽取小批量样本，同一条经验可以参与多次参数更新，从而提高已有数据的利用程度。相较于直接按采集顺序使用连续样本，随机采样

还能够减弱训练批次中的时间相关性。

（b）目标网络与软更新

价值函数学习通常需要利用下一状态的价值估计构造当前训练目标。若预测值和目标值同时依赖快速变化的网络参数，一次参数更新不仅改变当前预测，也可能改变其后续学习目标。目标网络通过维护一套更新较慢的参数，为价值学习提供相对缓慢变化的参考，从而减弱预测值与训练目标同步变化带来的不稳定反馈。

设当前价值网络参数为 ω，目标网络参数为 $\bar{\omega}$。目标网络可以定期完整复制当前网络参数，也可以采用渐进式软更新。后一种形式为：

$$\bar{\omega} \leftarrow \tau_{soft}\omega + \left(1-\tau_{soft}\right)\bar{\omega}, 0 < \tau_{soft} \leq 1. \tag{2-32}$$

式中，τ_{soft}为软更新系数；较小的系数使目标参数对当前网络变化的跟随更缓慢。目标网络通过减缓训练目标随当前网络参数变化的速度，提高价值学习过程的稳定性[84]。

（c）双估计器与双 Critic

当动作价值存在估计误差时，直接选择估计值最大的动作，可能同时偏向那些被高估的动作。经典 Double Q-learning 使用两个价值估计器，将动作选择与该动作的价值评价适当分离，以减弱最大化操作引起的过估计偏差[90]。

TD3 和 SAC 中的双 Critic 分别维护两组价值网络参数，并在相应目标计算中采用两个估计值的较小者。例如，对同一个状态—动作对，可以使用 $\min_{i=1,2}Q_{\bar{\omega}_i}(s,a)$构造目标。这种方式可以降低单个 Critic 过高估计对目标值的影响，但也可能带来一定程度的低估。

（d）上述机制在 SAC 价值更新中的结合

为说明经验回放、目标网络与双 Critic 的配合方式，以采用双目标 Q 网络的 SAC 版本为例。记其软动作价值网络为 $Q_{\omega_i}^{\mathrm{soft}}$，相应目标网络为 $Q_{\bar{\omega}_i}^{\mathrm{soft}}$，其中 $i=1,2$。对于从经验回放中抽取的单步转移，其训练目标可以写为：

$$\begin{aligned} y_t = r_t + \gamma(1-d_t)[&\min_{i=1,2} Q_{\bar{\omega}_i}^{\mathrm{soft}}(s_{t+1},\tilde{a}_{t+1}) \\ &-\alpha\log\pi_\theta\left(\tilde{a}_{t+1} \mid s_{t+1}\right)], \end{aligned} \tag{2-33}$$

其中，$\tilde{a}_{t+1} \sim \pi_\theta(\cdot \mid s_{t+1})$ 是根据下一状态由当前策略重新采样的动作。目标中的

第一部分为即时奖励，后一部分综合下一状态的目标软价值与策略熵项；当转移到终止状态时，后续价值项不再参与计算[88]。

两个 Critic 分别通过减小预测值与目标值之间的平方误差更新参数：

$$\mathcal{L}_Q(\omega_i) = \mathbb{E}\left[\frac{1}{2}\left(Q_{\omega_i}^{\text{soft}}(s_t, a_t) - y_t\right)^2\right], i = 1,2. \tag{2-34}$$

式中，期望对应经验回放中的转移采样及目标动作采样。求取该损失对 ω_i 的梯度时，将 y_t 作为固定目标；目标网络参数则通过式（2-33）单独更新。由此，经验回放提供可重复使用的样本，目标网络控制价值目标的变化速度，双 Critic 限制单个过高估计对目标值的影响，共同构成 SAC 价值学习的基本过程。

以上介绍了本文后续控制模型所需的强化学习基本原理及主要训练机制。

2.3 无人帆船动力学模型

本文后续强化学习模型需要通过与仿真环境反复交互获得船体运动状态，因此无人帆船动力学模型构成训练环境中的物理状态转移基础。本文沿用 Xiao 和 Jouffroy 四自由度帆船模型的主体动力学结构[19]，动力学模型涉及的船体参数、附体几何参数、经验系数以及风帆、舵和龙骨的气/水动力系数表均直接采用其公开仿真模型中的原始参数，未针对特定无人帆船重新进行参数辨识或标定。在此基础上，本文结合强化学习训练需求完成数值求解与交互环境实现。相较于完整六自由度模型，该模型忽略垂荡和纵摇运动，保留与本文局部帆舵控制密切相关的纵荡、横荡、横摇和艏摇运动，并分别考虑风帆、舵、龙骨及船体的气动力和水动力作用。因此，该模型能够在保持主要帆舵—船体耦合关系的同时，为后续大量强化学习环境交互提供统一的控制导向动力学模型。

本文沿用该模型的主体动力学结构，并根据实际仿真实现给出状态变量、总体运动方程及主要受力关系。

（1）坐标系与总体运动方程

完整模型的惯性坐标系与船体坐标系，坐标轴和六自由度运动分量如图 2.4 所示。惯性坐标系采用北—东—地（North-East-Down，NED）方向约定，x_n、y_n 和 z_n 轴分别指向北、东和竖直向下方向。船体坐标系原点位于船体质心，x_b 轴沿船体纵向指向船艏，y_b 轴指向右舷，z_b 轴按右手坐标系指向船体下方。图中 u, v, w 分别表示沿三个船体坐标轴的线速度，p, q, r 分别表示相应的角速度。

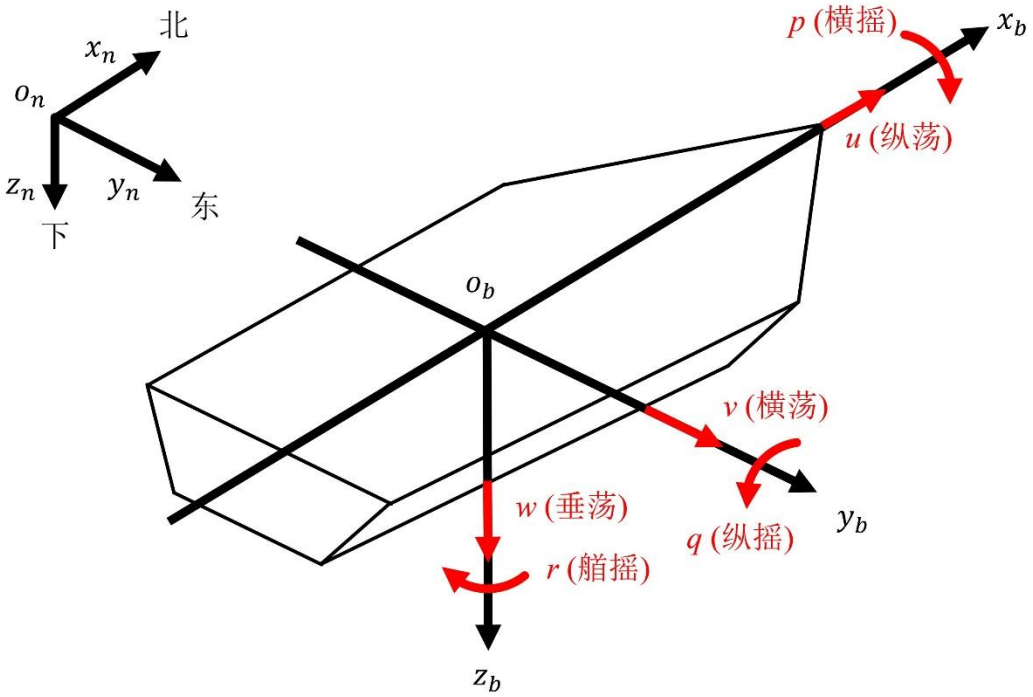


图 2.5 惯性坐标系与船体坐标系。

Fig.2.5 Inertial coordinate system and hull coordinate system.

由于当前所使用的模型忽略垂荡和纵摇，广义速度向量和广义位置—姿态向量进而定义为：

$$\boldsymbol{\nu} = [u, v, p, r]^T, \boldsymbol{\eta} = [x, y, \phi, \psi]^T, \tag{2-35}$$

式中，x, y为无人帆船在惯性坐标系中的平面位置，ϕ为横摇角，ψ为艏向角；u, v分别为船体纵向与横向速度，p, r分别为横摇和艏摇角速度。本文将船体视为刚体，在静水条件下进行建模，不考虑波浪和环境水流产生的附加载荷；附加质量系数取常数，舵、龙骨及船体等效受力点位于船体纵向对称面。

帆船的总体四自由度动力学方程可以表示为：

$$\boldsymbol{M\dot{\nu}} + [\boldsymbol{C_{RB}(\nu)} + \boldsymbol{C_A(\nu)}]\boldsymbol{\nu} + \boldsymbol{D(\nu, \phi)} + \boldsymbol{g(\phi)} = \boldsymbol{\tau_{sail}} + \boldsymbol{\tau_{rudder}}, \tag{2-36}$$

式中，M 为总惯性矩阵；C_{RB} 与 C_A分别为刚体及附加质量引起的科氏—向心项矩阵；D 为水动力阻尼广义力向量；g 为恢复广义力向量；τ_{sail} 和 τ_{rudder}分别为风帆与舵产生的广义力向量。上述四维广义力向量中的分量依次对应纵向力、横向力、横摇力矩和艏摇力矩。

广义速度与惯性坐标系位置、姿态之间的运动学关系为

$$\dot{\eta} = J(\phi,\psi)v, J(\phi,\psi) = \begin{bmatrix} \cos\psi & -\sin\psi\cos\phi & 0 & 0 \\ \sin\psi & \cos\psi\cos\phi & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & \cos\phi \end{bmatrix}. \tag{2-37}$$

总惯性矩阵由刚体质量矩阵与附加质量矩阵组成，即$M = M_{RB} + M_A$,详细矩阵表示为：

$$M_{RB} = \begin{bmatrix} m & 0 & 0 & 0 \\ 0 & m & 0 & 0 \\ 0 & 0 & I_{xx} & -I_{xz} \\ 0 & 0 & -I_{xz} & I_{zz} \end{bmatrix}, M_A = \begin{bmatrix} a_{11} & 0 & 0 & 0 \\ 0 & a_{22} & a_{24} & a_{26} \\ 0 & a_{24} & a_{44} & a_{46} \\ 0 & a_{26} & a_{46} & a_{66} \end{bmatrix}, \tag{2-38}$$

其中，m 为船体质量，I_{xx}、I_{zz} 分别为横摇和艏摇方向的转动惯量，I_{xz} 为相应惯性积；a_{ij} 为四自由度模型中的附加质量及耦合系数。下标仍沿用船舶六自由度运动编号，因此其中的 1、2、4、6 分别对应纵荡、横荡、横摇与艏摇。

刚体及附加质量对应的科氏—向心项为：

$$C_{RB} = \begin{bmatrix} 0 & -mr & 0 & 0 \\ mr & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix},$$
$$C_A = \begin{bmatrix} 0 & 0 & 0 & -\Gamma \\ 0 & 0 & 0 & a_{11}u \\ 0 & 0 & 0 & 0 \\ \Gamma & -a_{11}u & 0 & 0 \end{bmatrix}, \tag{2-39}$$
$$\Gamma = a_{22}v + a_{24}p + a_{26}r.$$

（2）船体与龙骨水动力

本文模型中的水动力阻尼由龙骨水动力、船体阻力以及横摇和艏摇阻尼共同构成：

$$D = D_{keel} + D_{hull} + D_{rot}. \tag{2-40}$$

其中，各项均直接表示四维广义力向量。对于龙骨，首先根据船体运动计算其受力点处相对于静水的流速。设龙骨受力中心相对于船体质心的位置为(x_k, y_k, z_k)，则：

$$v_{aku} = -u + ry_k, v_{akv} = -v - rx_k + pz_k,$$
$$V_{ak} = \sqrt{v_{aku}^2 + v_{akv}^2}, \alpha_{ak} = \text{atan2}(v_{akv}, -v_{aku}). \tag{2-41}$$

其中，V_{ak}为龙骨处相对水流速度，α_{ak}为其来流方向，atan2表示四象限反正切函数，攻角在系数查表前映射至$[-\pi, \pi)$区间。龙骨阻力系数进一步考虑升力

诱导项：

$$C_{dk} = C_{dk,0} + \frac{C_{lk}^2 A_k}{2\pi\zeta_k d_k^2},$$
$$L_k = \frac{1}{2}\rho_w A_k V_{ak}^2 C_{lk}, D_k = \frac{1}{2}\rho_w A_k V_{ak}^2 C_{dk}, \tag{2-42}$$

其中，C_{lk} 和 $C_{dk,0}$分别为查表获得的龙骨升力系数和基础阻力系数，A_k 为龙骨面积，d_k 为龙骨吃水尺度，ζ_k 为效率参数，ρ_w 为水密度。

将升力与阻力分解至船体坐标系：

$$F_{kx} = L_k \sin\alpha_{ak} - D_k \cos\alpha_{ak}, F_{ky} = L_k \cos\alpha_{ak} + D_k \sin\alpha_{ak}. \tag{2-43}$$

由于龙骨广义力在式（2-35）中以阻尼形式位于方程左侧，因此其对应项写为

$$D_{keel} = \begin{bmatrix} -F_{kx} \\ -F_{ky} \\ z_k F_{ky} \\ -x_k F_{ky} \end{bmatrix}. \tag{2-44}$$

船体自身的水动力阻力同样根据相对来流方向进行分解。设船体等效阻力作用点为 (x_h, y_h, z_h)，则

$$v_{ahu} = -u + r y_h, v_{ahv} = \frac{-v - r x_h + p z_h}{\cos\phi},$$
$$\alpha_{ah} = \operatorname{atan2}(v_{ahv}, -v_{ahu}). \tag{2-45}$$

船体阻力幅值根据龙骨相对流速大小从船体阻力表中通过三次插值得到。由此，船体阻力对应的广义力向量为

$$D_{hull} = F_{rh} \begin{bmatrix} cos\,\alpha_{ah} \\ -sin\,\alpha_{ah}\,cos\,\phi \\ z_h\,sin\,\alpha_{ah}\,cos\,\phi \\ -x_h\,sin\,\alpha_{ah}\,cos\,\phi \end{bmatrix}. \tag{2-46}$$

此外，模型以二次阻尼形式描述横摇及艏摇转动阻尼：

$$D_{\mathrm{rot}} = \begin{bmatrix} 0 \\ 0 \\ c_p\,p\,|\,p\,| \\ c_r\,\dot{\psi}\,|\,\dot{\psi}\,|\cos\phi \end{bmatrix}, \dot{\psi} = r\cos\phi, \tag{2-47}$$

其中，c_p 和 c_r分别为横摇和艏摇阻尼系数。

恢复力采用原模型中的经验横摇恢复力矩关系。当前模型中移动配重输入固定为零，因此恢复广义力向量可写为：

$$g(\phi)=\begin{bmatrix}0\\0\\a_g\phi_{\deg}^2+b_g\phi_{\deg}\\0\end{bmatrix},\phi_{\deg}=\frac{180}{\pi}\phi, \tag{2-48}$$

式中，a_g 和 b_g为模型给定的横摇恢复力矩拟合系数。该拟合关系使用角度制的横摇角 $\phi_{\deg}$，而其余三角运算中的角度均采用弧度制。

（3）风场变换与风帆气动力

风帆气动力取决于风帆相对于周围空气的视风速度及方向。设环境风速大小为 v_w，风速矢量在惯性坐标系中的方向为 α_w，则环境风速向量表示为

$$v_w^n=\begin{bmatrix}v_w\cos\alpha_w\\v_w\sin\alpha_w\\0\end{bmatrix}. \tag{2-49}$$

本文采用的风向 α_w表示风速矢量的吹向方向，其零方向与惯性坐标系 x_n 轴一致。考虑风速随高度的变化，风帆受力高度处的风速采用对数关系进行修正：

$$\tilde{v}_w^n=\lambda_w v_w^n,\lambda_w=\frac{\ln(|z_s|\cos\phi/h_0)}{\ln(h_1/h_0)}, \tag{2-50}$$

其中，z_s为风帆受力中心在船体坐标系中的垂向坐标，h_0 为海面空气动力粗糙度长度，h_1 为环境风速对应的参考高度。

随后根据当前艏向角和横摇角，将风速由惯性坐标系变换至船体坐标系：

$$R_\psi=\begin{bmatrix}\cos\psi&\sin\psi&0\\-\sin\psi&\cos\psi&0\\0&0&1\end{bmatrix},R_\phi=\begin{bmatrix}1&0&0\\0&\cos\phi&\sin\phi\\0&-\sin\phi&\cos\phi\end{bmatrix},$$
$$v_w^b=R_\phi R_\psi\tilde{v}_w^n. \tag{2-51}$$

风帆视风的平面分量按下式计算：

$$v_{awu}=v_{w,x}^b-u,v_{awv}=v_{w,y}^b-v. \tag{2-52}$$

根据视风平面分量，可得到视风速度及方向：

$$V_{aw}=\sqrt{v_{awu}^2+v_{awv}^2},\alpha_{aw}=\operatorname{atan2}(v_{awv},-v_{awu}). \tag{2-53}$$

设当前实际帆角为 δ_s，则风帆气动攻角为

$$\alpha_{as}=\operatorname{wrap}_{[-\pi,\pi)}(\alpha_{aw}-\delta_s). \tag{2-54}$$

其中$\operatorname{wrap}_{[-\pi,\pi)}(\cdot)$表示将角度映射至$[-\pi,\pi)$区间。

风帆升力系数 C_{ls}与阻力系数 C_{ds}由离散气动系数表根据 α_{as}进行三次插值

得到。风帆升力与阻力分别为

$$L_s = \frac{1}{2}\rho_a A_s V_{aw}^2 C_{ls}, D_s = \frac{1}{2}\rho_a A_s V_{aw}^2 C_{ds}, \tag{2-55}$$

式中，ρ_a 为空气密度，A_s 为风帆面积。

将升力和阻力分解至船体纵向和横向，可得

$$\begin{aligned} F_{sx} &= L_s \sin\alpha_{aw} - D_s \cos\alpha_{aw}, \\ F_{sy} &= L_s \cos\alpha_{aw} + D_s \sin\alpha_{aw}. \end{aligned} \tag{2-56}$$

考虑风帆气动力作用点相对于船体质心的位置关系，风帆产生的四维广义力可以统一写为

$$\tau_{\text{sail}} = \begin{bmatrix} F_{sx} \\ F_{sy} \\ -z_s F_{sy} \\ -F_{sx}x_{ce}\sin\delta_s + F_{sy}(x_m - x_{ce}\cos\delta_s) \end{bmatrix}, \tag{2-57}$$

其中，x_{ce} 表示风帆气动中心相对于桅杆的距离参数，x_m 表示桅杆相对于船体质心的纵向位置参数。

（4）舵水动力

本文假设水域本身静止，但无人帆船运动会使舵相对于周围水体产生相对来流，因此仍需要计算舵所受到的水动力。设舵受力中心相对于船体质心的位置为 (x_r, y_r, z_r)，则其相对水流的纵向和横向分量分别为

$$v_{aru} = -u + ry_r, v_{arv} = -v - rx_r + pz_r. \tag{2-58}$$

相对流速大小与来流方向为

$$V_{ar} = \sqrt{v_{aru}^2 + v_{arv}^2}, \alpha_{ar} = \text{atan2}(v_{arv}, -v_{aru}). \tag{2-59}$$

设当前实际舵角为 δ_r，则舵的水动力攻角为

$$\alpha_r = \text{wrap}_{[-\pi,\pi)}(\alpha_{ar} - \delta_r). \tag{2-60}$$

舵的基础升力系数 C_{lr}与阻力系数 $C_{dr,0}$同样由离散水动力系数表经过三次插值得到，并对阻力系数加入升力诱导阻力修正：

$$C_{dr} = C_{dr,0} + \frac{C_{lr}^2 A_r}{2\pi\zeta_r d_r^2}, \tag{2-61}$$

式中，A_r 为舵面积，d_r 为舵的垂向尺度，ζ_r 为效率参数。

舵产生的升力与阻力为

$$L_r = \frac{1}{2}\rho_w A_r V_{ar}^2 C_{lr}, D_r = \frac{1}{2}\rho_w A_r V_{ar}^2 C_{dr}. \tag{2-62}$$

进一步将其分解至船体坐标系：

$$F_{rx} = L_r \sin\alpha_{ar} - D_r \cos\alpha_{ar}, F_{ry} = L_r \cos\alpha_{ar} + D_r \sin\alpha_{ar}. \tag{2-63}$$

由舵的作用位置可得到舵产生的广义力向量：

$$\tau_{rudder} = \begin{bmatrix} F_{rx} \\ F_{ry} \\ -z_r F_{ry} \\ x_r F_{ry} \end{bmatrix}. \tag{2-64}$$

上述即为本文所涉及的无人帆船动力学模型相关的计算过程。

2.4 本章小结

本章围绕后续无人帆船强化学习控制模型所需的理论基础与动力学模型进行了介绍。首先，从神经网络的基本结构出发，说明了全连接网络的非线性函数逼近方式以及基于梯度的参数优化过程，并进一步介绍了循环神经网络与长短期记忆网络的时序信息建模机制，说明了前馈网络与时序网络的基本计算方式。

随后，对强化学习中的智能体—环境交互过程、马尔可夫决策过程、回报与价值函数等基本概念进行了说明，并在此基础上介绍了策略梯度与 Actor–Critic 框架，以及 PPO、TD3 和 SAC 等连续控制算法的主要特点。进一步介绍了经验回放、目标网络、双 Critic 和软更新等机制及其在价值学习中的基本作用。

最后，本文采用已有四自由度非线性帆船模型，对无人帆船的纵荡、横荡、横摇和艏摇运动进行描述，并梳理了船体与龙骨水动力、风场与风帆气动力以及舵水动力等主要计算关系。下一章将在此基础上进一步构建强化学习训练交互环境，并介绍动态风场、任务条件及具体交互设置。

3 训练交互环境

3.1 引言

强化学习模型的训练与验证依赖智能体与环境之间持续、重复的交互，因此需要构建能够描述无人帆船运动状态演化、环境变化及任务约束的仿真交互环境。在第二章提到本文采用包含纵荡、横荡、横摇和艏摇运动的四自由度模型，主要考虑其能够保留与帆舵控制直接相关的主要运动状态及耦合关系，同时相较于更高自由度模型具有较低的计算复杂度，更适合强化学习训练过程中大量、重复的数值交互。本文研究重点并非建立高保真无人帆船动力学模型，而是在统一动力学条件下研究部分可观测环境中的帆舵控制与历史信息利用问题。

在此基础上，本章首先介绍强化学习环境的基本交互框架及动态风场模型，随后对基础点到点航行任务中的环境初始化、观测与动作、执行约束以及终止条件进行统一设定，并进一步说明为提高强化学习训练效率所采用的环境计算优化方法。

3.2 基础环境框架

为实现强化学习智能体与无人帆船动力学模型之间的连续交互，本文基于 Open AI Gym 接口对仿真环境进行封装。环境主要通过 reset() 和 step(action) 两类接口完成初始化与状态推进：在每个回合开始时，reset() 根据预设条件初始化无人帆船状态及环境参数，并返回初始观测；在后续每个控制时间步中，智能体根据当前观测生成控制动作，环境接收动作后调用动力学模型计算船体状态变化，并返回下一时刻观测、即时奖励以及任务终止信息。由此形成智能体与仿真环境之间逐步迭代的闭环交互过程。

第二章所述四自由度动力学模型每次迭代输出各状态变量的时间导数，因此还需要通过数值积分获得下一时刻的船体状态。本文采用四阶—五阶 Runge–Kutta 自适应步长方法进行积分[91]，根据局部截断误差动态调整积分步长，以兼顾状态更新精度与计算开销。环境以控制周期为外层更新单位，并在一个控制周期内完成动力学方程的数值积分，从而得到下一控制时刻的船体状态。

无人帆船主要依靠风能获得推进力，因此除船体动力学外，还需要构建能够随时间变化的环境风场。本文借鉴 Dryden 湍流模型的纵向一阶成形滤波形式，

构建二维时变随机风场。沿平均风向与垂直平均风向的扰动均采用相互独立的一阶高斯–马尔可夫过程生成，并与平均风速矢量叠加。其中，横向扰动采用一阶近似，不保留标准 Dryden 模型的横向谱形。该模型用于构造具有可调扰动强度和时间相关性的风场，以评价控制策略在时变风扰动下的性能，后续表述为简化 Dryden 模型。概念上，瞬时风速可以表示为平均风速与湍流扰动之和：

$$V_w(t) = V_0 + v_{\mathrm{tur}}(t) \tag{3-1}$$

式中，V_0 为平均风速，$v_{\mathrm{tur}}(t)$ 表示平均风速基础上的随机湍流扰动。实际仿真中进一步将湍流扰动分解为沿平均风向和垂直平均风向的两个分量。

对于任一方向的湍流速度分量，其连续时间变化过程表示为：

$$\frac{dx(t)}{dt} = -\frac{V_0}{L}x(t) + \sigma\sqrt{\frac{2V_0}{L}}\,w(t) \tag{3-2}$$

式中，$x(t)$ 表示当前方向的湍流速度分量；V_0 为平均风速；L 为该方向对应的湍流尺度长度；σ 为湍流强度，用于表征该方向湍流速度的标准差；$w(t)$ 为单位高斯白噪声。由式（3-2）可以看出，当前湍流状态不仅受到随机扰动影响，同时与前一阶段的风场状态存在时间联系，从而形成连续变化的随机风场。

由于强化学习环境按照离散时间步进行更新，本文进一步采用式（3-2）对应的离散形式：

$$x_{k+1} = \alpha x_k + \beta\epsilon_k \tag{3-3}$$

其中：

$$\alpha = e^{-dt/\tau}, \beta = \sigma\sqrt{1-\alpha^2}, \tau = \frac{L}{V_0} \tag{3-4}$$

式中，dt 为风场离散更新时间间隔；τ 为由湍流尺度长度与平均风速确定的时间尺度；α 表示相邻时间步之间的状态相关程度；β 为随机扰动项的幅值系数；$\epsilon_k \sim N(0,1)$ 为标准高斯随机变量。

在二维水平风场中，设平均风向为 θ，则平均风速 V_0在全局坐标系中的两个分量分别为：

$$\begin{aligned} V_x &= V_0\cos\theta\,, \\ V_y &= V_0\sin\theta\,. \end{aligned} \tag{3-5}$$

本文分别利用式（3-3）生成沿平均风向的纵向湍流分量 u_t和垂直于平均风向的横向湍流分量 v_t。将二者变换至全局坐标系后得到：

$$\begin{aligned} T_x &= u_t \cos\theta - v_t \sin\theta, \\ T_y &= u_t \sin\theta + v_t \cos\theta. \end{aligned} \tag{3-6}$$

式中，T_x 和 T_y分别表示湍流扰动在全局坐标系 x和 y方向上的分量。由平均风场与湍流扰动叠加得到当前时刻的总风速分量：

$$\begin{aligned} V_x^{\text{total}} &= V_x + T_x, \\ V_y^{\text{total}} &= V_y + T_y. \end{aligned} \tag{3-7}$$

进而可以计算当前时刻的瞬时风速大小 V_w与风向 ψ_w：

$$\begin{aligned} V_w &= \sqrt{\left(V_x^{\text{total}}\right)^2 + \left(V_y^{\text{total}}\right)^2}, \\ \psi_w &= \text{atan2}\left(V_y^{\text{total}}, V_x^{\text{total}}\right). \end{aligned} \tag{3-8}$$

式中，$\text{atan2}(\cdot)$为四象限反正切函数。由此得到的 V_w和 ψ_w作为仿真环境内部的风场状态，并输入第二章所述风帆气动力计算过程，从而通过气动力作用影响无人帆船的运动状态。需要注意的是，风场在动力学计算中始终存在，而其是否作为智能体的直接观测信息，由后续具体实验设定决定。

为避免极低风速条件下气动力计算出现数值异常，本文将瞬时风速下限设置为 $0.1\ \text{m/s}$。为观察上述风场模型生成序列的时间变化特征，本文将一组模拟风场结果与实测风场记录进行对照，如图 3.1～图 3.4 所示。两组数据均表现出连续的风速与风向波动，说明当前参数下生成的模拟风场能够提供具有一定时间相关性的动态扰动。

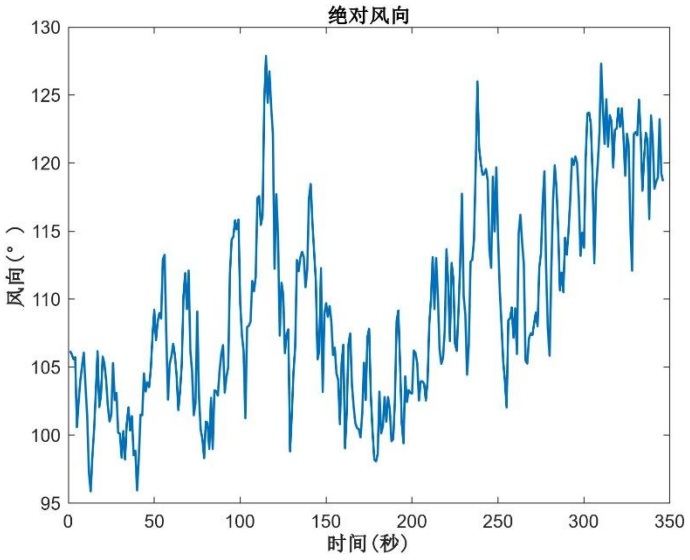


图 3.1 绝对风向（真实环境）。

Fig.3.1 Absolute wind direction (Real Environment).

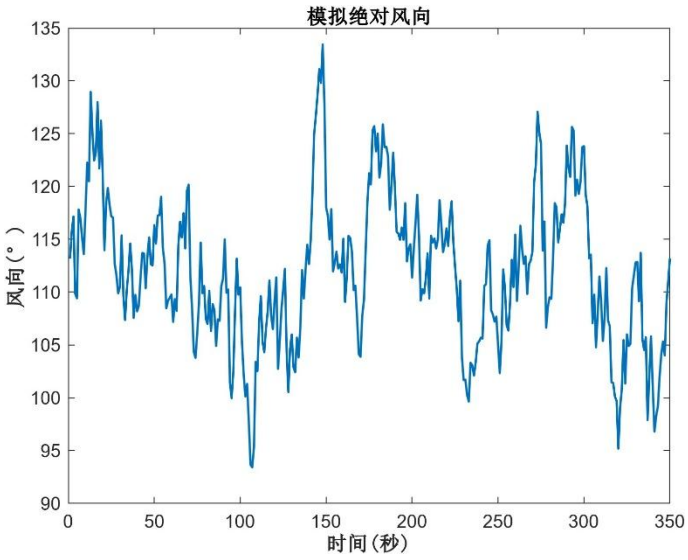


图 3.2 绝对风向（模拟环境）。

Fig.3.2 Absolute wind direction (Simulation Environment).

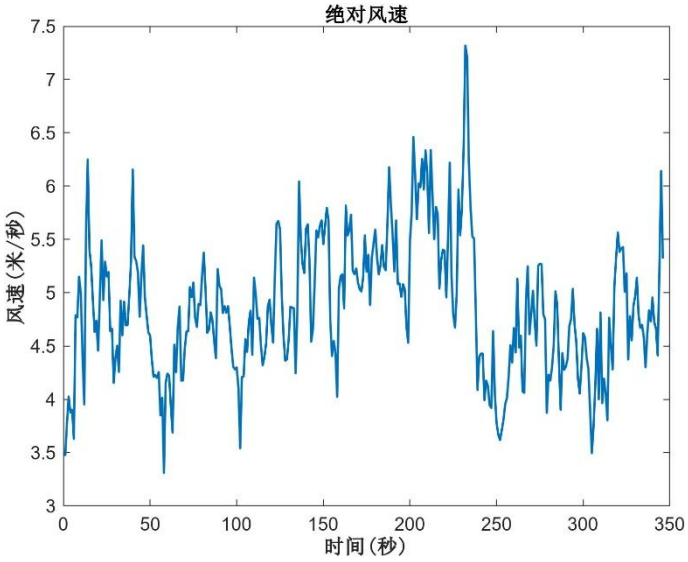


图 3.3 绝对风速（真实环境）。

Fig.3.4 Absolute wind speed (Real Environment).

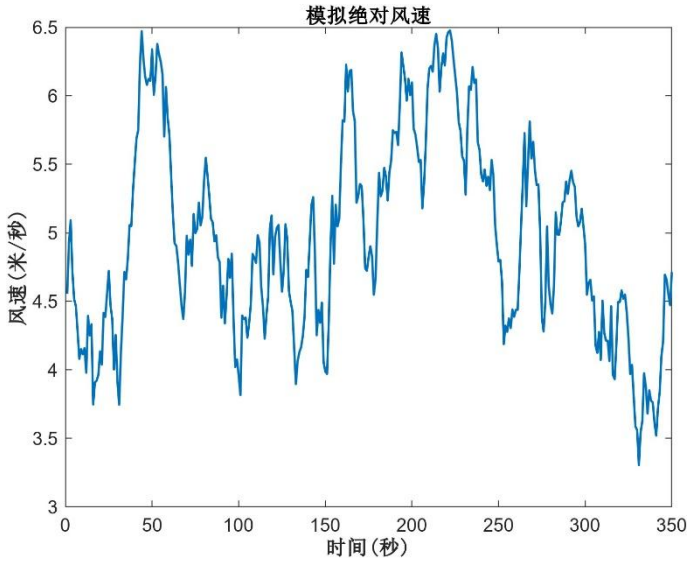


图 3.4 绝对风速（模拟环境）。

Fig.3.4 Absolute wind speed (Simulation Environment).

3.3 实验任务设定

在前述交互环境基础上，本文将无人帆船在相邻航迹点之间的局部航行定义为回合式任务，并对任务目标、环境初始化、观测与动作、控制周期及交互误差进行设定。

（1）任务目标与环境初始化

基础训练及测试任务的起点设置为 $(0,0)$，目标点设置为 $(500,0)$，坐标单位均为米。智能体通过调节帆角与舵角，使无人帆船在规定的时间和航行范围内到达目标区域。

起点与目标点之间的距离设置为 500 米，主要综合考虑局部航迹点之间的航行尺度、动态环境适应过程以及强化学习训练难度。在本文基础设定下，该距离通常对应约 3～6 分钟的有效航行过程，能够使无人帆船经历一段持续的风场变化与控制调节，从而考察策略在连续航行过程中的适应能力。过长的任务距离会增加到达目标所需的决策步数，使任务完成反馈与前期动作之间的关联更加难以学习，因此采用上述距离作为基础任务规模。

由于本文重点考察无显式风场输入条件下的自主航行能力，训练任务需要覆盖不同风向，而非仅针对某一有利风况。在每个训练回合初始化时，平均风向 θ 在 $[-180°, 180°]$内随机生成，使同一策略能够在顺风、横风和逆风等条件下进行学习。平均风速及纵、横向湍流参数设置如表 3.1 所示：

表 3.1 简化 Dryden 模型的默认参数配置

Table.3.1 The default parameter configuration of the simplified Dryden model

参数	符号	设定值
平均风速	V_0	8 m/s
纵向湍流尺度长度	L_u	300 m
横向湍流尺度长度	L_v	150 m
纵向湍流强度	σ_u	1.2 m/s
横向湍流强度	σ_v	1.0 m/s

其中，纵向和横向分别指沿平均风向及垂直于平均风向的方向，L_u, L_v 与 σ_u, σ_v分别对应 3.2 节中两个方向的尺度长度和湍流强度。根据 $\tau = L/V_0$，纵向和横向扰动的相关时间尺度分别约为 38 秒和 19 秒；湍流强度与平均风速之比分别为 15%和 12.5%。这些参数共同控制风场扰动的变化速度与幅度。

在平稳、小扰动近似下，瞬时风向相对平均风向的标准差约为7.2°，约 95%的风向波动位于平均风向附近的$\pm 14.3°$范围内，风速的相应近似波动范围为$8.0 \pm 2.4\ \mathrm{m/s}$。从风速数值上对照风力等级，该范围大致相当于 4～5 级风。

（2）观测空间与动作空间

为统一环境交互中的数据表示，并兼顾计算效率，本文状态变量采用单精度浮点数（Float32）表示。智能体的观测主要包括无人帆船运动状态、当前帆角与舵角以及目标相关信息。不同研究任务所使用的观测维度有所差异，具体变量及其构造方式将在后续章节结合控制模型与奖励函数进行说明。

各任务采用相同的二维连续动作空间，策略输出帆角和舵角的增量：

$$a_t = [\Delta\delta_s, \Delta\delta_r]. \tag{3-9}$$

式中，$\Delta\delta_s$ 和 $\Delta\delta_r$分别表示当前控制时间步内的帆角变化指令和舵角变化指令。采用增量控制时，新的控制角度在当前角度基础上累加得到。不考虑执行误差与角度限幅时，其更新关系为：

$$\begin{aligned} \delta_s^{t+1} &= \delta_s^t + \Delta\delta_s, \\ \delta_r^{t+1} &= \delta_r^t + \Delta\delta_r. \end{aligned} \tag{3-10}$$

其中，δ_s^t 和 δ_r^t分别为当前控制时刻的帆角与舵角。本文采用二维连续动作空间，策略输出帆角和舵角的调节增量，两个动作分量均限制在 $[-10°, 10°]$范围内。

与直接输出绝对角度相比，增量控制结合单步调节幅度限制，使帆舵指令始

终基于当前角度进行调整，避免相邻决策之间出现过大的角度跳变。这一设定有助于减少训练初期探索造成的大幅控制波动，并使策略逐步学习通过连续调节完成航行任务。并且符合正常的舵机控制逻辑，避免出现短时间大幅度高频率跳变导致航行结果看似有效，实际根本无法执行的情况。

（3）控制周期与动作执行

本文将控制周期与风场更新时间间隔均设置为 1 秒，对应控制频率和风场更新频率均为1 Hz。动力学求解采用 3.2 节所述自适应积分方法，积分步长的基础值设置为 0.05 秒。在一个控制周期内，帆角与舵角变化量根据实际积分步长进一步细分，并在数值推进过程中施加于动力学模型，帆角的允许范围设置为 $[-90°, 90°]$，舵角的允许范围设置为 $[-30°, 30°]$。当累积控制结果达到相应边界后，后续动作不能使帆角或舵角继续超出规定范围。

上述控制周期主要考虑无人帆船的调节需求与执行机构的工作负担。过于频繁的帆舵调节可能增加控制能耗与机械磨损，而在航行状态相对稳定时，帆角和舵角可以在一定时间内保持不变，无需持续进行大幅调整。因此，本文采用 1 秒的控制周期，在保留环境变化响应能力的同时，避免将过高频率的控制作为完成任务的必要条件。

（4）观测噪声与非理想动作执行

为避免控制模型仅在完全准确的状态观测和理想动作执行条件下进行训练与验证，本文在基础仿真环境中进一步加入观测噪声和有限分辨率的动作执行过程。相关设置主要用于为不同控制模型提供统一、可控的非理想交互条件，并不用于精确复现某一具体传感器或执行机构的误差特性。

对于控制时刻 k的无噪声观测向量 o_k，实际输入控制模型的观测表示为：

$$\tilde{o}_k = o_k + \varepsilon_k. \tag{3-11}$$

其中，各观测通道分别加入零均值高斯噪声：

$$\varepsilon_{i,k} \sim \mathcal{N}(0, \sigma_i^2). \tag{3-12}$$

式中，σ_i 表示第 i个观测变量对应的噪声标准差。不同观测通道及不同控制时刻的随机噪声分别独立采样。

考虑到位置、姿态和速度等物理量具有不同的量纲与数值尺度，本文分别为不同观测量设定基础误差参考尺度 E_i，并取：

$$\sigma_i = \frac{E_i}{3}. \tag{3-13}$$

因此，表 3-2 所列的 E_i可视为相应高斯噪声的 $3\sigma_i$参考尺度，用于直观表示各类观测量的基础扰动水平，但并非随机误差的严格上下限。基础设置如下表所示。

表 3.2 观测噪声的基础配置

Table.3.2 The basic configuration of the observation noise

观测量	基础误差参考尺度 E_i
位置 x, y	1.0 m
横摇角 ϕ	0.5°
艏向角 ψ	1.0°
纵向、横向速度 u, v	0.1 m/s
横摇、艏摇角速度 p, r	0.1°/s
距离变化特征	0.5 m
风速	0.1 m/s
风向	0.5°

注：风速和风向观测仅用于后续包含显式风场信息的对照模型；无风场输入控制模型不接收上述两项信息。

其中，距离变化特征并非独立传感器的直接测量结果，而是由环境根据船体位置与目标位置计算得到的派生观测量。本文在其计算结果上直接加入相应扰动，用于表示该类导航特征在非理想观测条件下存在的等效误差。

上述噪声模型主要描述围绕真实状态随机波动的观测误差，不进一步考虑固定偏置、长期漂移、数据丢失及传感器失效等复杂情况。采用这一简化设定的目的，是在保持实验条件可控和可重复的基础上，使控制模型能够在一定程度的状态信息扰动下进行训练与测试，而非建立完整的实际传感器误差模型。

除观测误差外，本文还在动作执行阶段引入有限角度分辨率。上一小节定义的帆角和舵角增量均由策略网络在连续动作空间中产生，而进入仿真环境后，控制指令进一步按照 1°的角度分辨率进行量化，再作用于无人帆船动力学模型。控制周期内部，帆角和舵角由当前值逐步变化至本周期对应的执行角度，并参与动力学状态积分。

（5）任务终止条件

为明确任务完成标准，并限制长时间滞留或过度偏离任务区域的采样过程，基础航行任务设置到达目标、超时和越界三类终止条件。

到达目标。当无人帆船与目标点之间的距离小于 10 米时，判定任务成功并终止当前回合。采用目标区域而非要求精确到达单一坐标点，主要考虑无人帆船机动与调节能力有限，使任务评价集中于能否完成点到点航行。

超时终止。单回合仿真时间上限设置为 1000 秒。达到时间上限仍未进入目标区域时，终止当前回合，并判定该次任务未完成。该上限相较于基础任务的典型航行时间留有余量，用于容纳顺风、逆风等不同条件下的航行耗时差异，同时避免长期未能完成任务的轨迹持续占用采样资源。

越界终止。将以起点为圆心、半径 750 米的圆形区域设为允许航行范围。当无人帆船位置超出该范围时，提前终止当前回合，并判定该次任务未完成。该范围为绕行和换舷等航行行为保留一定空间，同时限制船体持续远离目标区域的无效探索。

3.4 训练效率优化

强化学习模型的训练需要通过大量环境交互获得状态转移样本。对于本文所采用的无人帆船仿真环境，每个控制时间步均涉及动态风场更新、气动力与水动力计算以及动力学方程的数值积分，因此环境状态推进本身会产生较大的计算开销。为提高单位时间内的样本获取效率，本文主要从并行环境采样、重复计算预处理以及无效轨迹提前终止三个方面对训练过程进行优化。

首先，采用多环境并行采样方式提高交互数据的生成效率。本文基于强化学习框架构建多个相互独立的仿真环境，各环境具有独立的无人帆船状态、初始条件及随机风场，并同时执行环境状态推进。与单环境按时间顺序持续采样相比，并行环境能够在相同的实际运行时间内获得更多交互样本，同时不同环境中的随机初始化与风场扰动也能够增加训练数据的多样性。实际并行数量根据计算设备的处理能力进行配置，以避免环境进程过多造成额外的调度与数据传输开销。

其次，对动力学计算过程中重复使用的固定参数及部分数值关系进行预计算处理。第二章动力学模型在每次数值积分过程中均需要进行矩阵运算以及风帆、舵和龙骨相关气动力、水动力系数计算，其中部分参数在整个训练过程中保持不变。对于此类固定矩阵，可在环境初始化阶段提前计算并保存；对于由离散系数

表确定的升力和阻力系数，则提前完成相应的数据处理，在状态推进过程中根据当前攻角直接进行插值计算。通过减少每个积分步骤中的重复计算，可以降低单次环境状态更新的计算开销。

最后，3.3 节设置的任务超时和航行范围限制除用于明确任务失败条件外，也能够减少训练过程中长期无法到达目标或持续远离任务区域的无效轨迹。当满足相应终止条件时，环境及时结束当前回合并重新初始化，使后续计算资源用于新的交互过程。该处理在训练早期策略尚未形成稳定航行行为时尤其有助于减少无效环境推进。

通过上述处理，本文在保持各并行环境使用相同动力学模型、风场模型与任务规则的基础上，提高了强化学习训练过程中环境样本的生成效率，为第四章和第五章所涉及的大规模模型训练与对比实验提供计算基础。

3.5 本章小结

本章围绕后续强化学习控制模型所需的仿真交互环境进行了构建。基于第二章介绍的四自由度无人帆船动力学模型，完成了动力学计算与强化学习交互框架的结合，并引入具有时间相关性的动态风场，实现控制动作、环境作用与船体状态之间的连续迭代更新。

在此基础上，对基础点到点航行任务的环境初始化、观测与动作空间、控制周期、任务终止条件等进行了统一设定，并通过观测噪声和有限分辨率的动作执行构造非理想交互条件。同时，针对强化学习训练过程中较大的环境计算开销，从并行采样、重复计算预处理及无效轨迹提前终止等方面提高环境交互效率。

上述环境构成后续控制模型训练与性能验证的基础。第四章将在该环境下研究无显式风场输入条件下的无人帆船帆舵控制方法，第五章则进一步在此基础上扩展静态障碍物环境。

4 无显式风场输入的强化学习控制模型

4.1 引言

第三章构建了包含无人帆船动力学、动态风场、观测噪声及动作执行约束的强化学习交互环境。本章在此基础上研究风速和风向不作为策略直接观测输入时的局部帆舵控制问题。控制策略根据船体运动状态、当前帆舵状态、目标相关信息及历史交互信息，直接生成帆角和舵角调节量，通过与环境的连续交互完成从起点至目标区域的航行。航行过程中，策略自主决定帆舵调节方式及相应航迹，无需预先给定参考航向或待跟踪的完整路径。

不同风况对应不同的航行需求。顺风条件下，无人帆船可以沿较为直接的航迹接近目标；逆风条件下，则需要通过换舷和迂回运动保持有效推进。在缺少直接风场观测时，利用船体运动响应判断航行状态并协调帆舵动作，是实现上述控制的关键。为此，本章在 SAC 框架中引入 LSTM，对历史观测—动作信息进行编码，并结合点到点航行任务设计奖励函数。随后，通过控制性能对比、奖励消融、扰动测试及历史信息利用分析，考察模型的任务完成能力、航行效率、控制行为及其与历史信息之间的联系。

4.2 基于历史信息编码的 SAC-LSTM 控制模型

风场通过风帆气动力影响无人帆船运动。当风速和风向不作为策略输入时，相近的当前位置、航向和速度可能对应不同的隐藏风况及后续运动趋势，因而该任务具有部分可观测特征。船体状态的连续变化以及此前施加的帆舵动作共同记录了环境作用下的动力学响应，将二者按时间关系进行编码，可以为当前决策提供补充信息。

本文选择软 Actor–Critic（Soft Actor-Critic，SAC）作为基础算法。其连续动作策略适用于帆角和舵角增量控制，异策略训练方式能够通过经验回放重复利用动力学仿真样本，最大熵优化目标则为策略探索提供支持。在保留 SAC 策略优化与价值学习机制的基础上，引入 LSTM 历史信息分支，构成 SAC-LSTM 控制模型。

（1）当前信息与历史信息的融合结构

SAC-LSTM 由一个策略网络 Actor 和两个价值网络 Critic 组成。各网络均设

置当前信息分支和历史信息分支：Actor 根据当前观测及历史信息生成动作，Critic 进一步接收待评价动作，估计相应的长期价值。Actor 与两个 Critic 分别维护独立的网络参数和循环状态，其结构如图 4.1 所示。

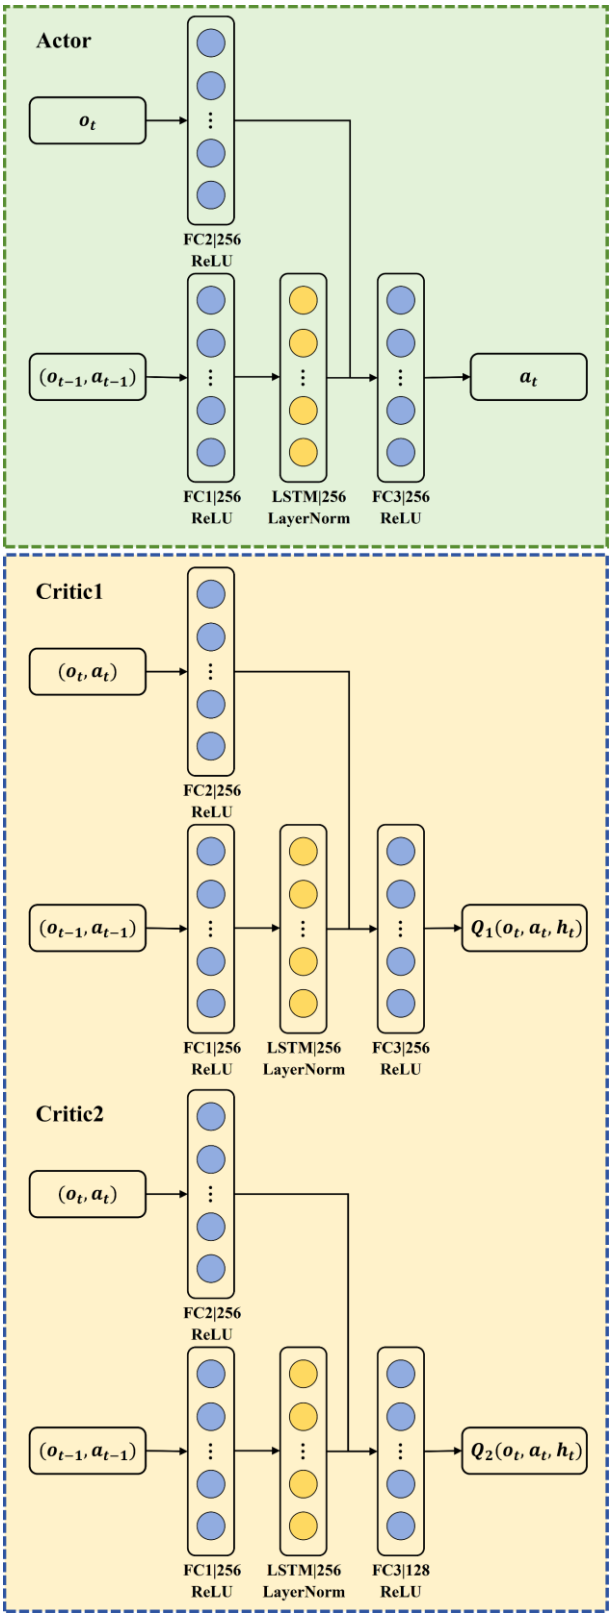


图 4.1 融入长短期记忆网络的模型结构。

Fig.4.1 Model structure integrated with long short-term memory network.

如图所示历史信息分支将同一时间步的观测与动作拼接，经全连接层进行特征映射后，按时间顺序输入 LSTM。LSTM 输出经过层归一化处理，形成历史特征。当前信息分支通过全连接层提取即时特征，其中 Actor 的输入为当前观测，Critic 的输入为当前观测与待评价动作。两类特征拼接后，再经全连接层完成融合。

Actor 根据融合特征输出动作分布的均值与对数标准差，通过重参数化采样和 tanh 变换获得有界动作，并按第三章规定的动作上限转换为帆角、舵角调节量。两个 Critic 分别输出一个 Q 值，用于评价给定当前观测和历史信息时的候选动作。图中 FC 表示全连接层，各层配置标注于相应模块，LSTM 的基本计算原理见第二章。

（2）观测标准化

由于位置、角度和速度等观测变量的量纲与数值范围不同，输入网络前对各维观测进行 Z-score 标准化：

$$\hat{o}_{t,i} = \frac{o_{t,i} - \mu_i}{\sqrt{v_i} + \varepsilon}, \varepsilon = 10^{-6}, \tag{4-1}$$

其中，$o_{t,i}$ 为时间步 t的第 i个观测分量，μ_i 和 v_i分别为相应的累计均值与方差，ε 用于避免分母接近零。该处理调整观测的数值尺度，不进行额外的区间裁剪。

训练过程中，标准化统计量根据经验回放中采样得到的观测批次累计更新。完成统计更新后，当前观测、下一观测及其对应历史观测统一使用同一组统计参数。环境交互时的动作选择使用已有统计量；模型测试时，加载检查点中保存的统计量并保持固定。当前动作与历史动作均按既定动作尺度处理，不采用上述观测标准化。

（3）历史序列组织与循环状态更新

为保存训练所需的时序信息，本文在数据采集过程中为每个环境分别维护观测序列缓存和动作序列缓存。记当前观测为 o_t，当前动作为 a_t，历史长度为 K。在历史充分时，当前决策对应的两组序列为：

$$S_t = [o_{t-K}, \dots, o_{t-1}], A_t = [a_{t-K}, \dots, a_{t-1}]. \tag{4-2}$$

历史观测与动作按同一时间步配对，循环分支依次处理的输入为：

$$[(o_{t-K}, a_{t-K}), \dots, (o_{t-1}, a_{t-1})]. \tag{4-3}$$

上述历史截至$t-1$时刻，当前观测o_t由当前信息分支单独处理。其包含的船体状态、帆舵状态及目标相关变量在 4.3 节具体定义。执行a_t后，缓存移除最早的一组数据，并追加当前观测—动作对，形成下一决策位置的历史：

$$S_{t+1} = [o_{t-K+1}, \dots, o_t], A_{t+1} = [a_{t-K+1}, \dots, a_t]. \tag{4-4}$$

此时，S_{t+1}和A_{t+1}截至t时刻，下一观测o_{t+1}作为下一决策的当前输入单独保存。本文取$K = 10$。回合开始时，以初始观测重复填充观测缓存，并将动作缓存置零；随着交互推进，填充内容逐步由实际历史替换。新回合开始时，重新初始化对应环境的缓存。

经验回放池以单步状态转移及其配套历史为存储单位，每条经验表示为：

$$e_t = (S_t, A_t, o_t, a_t, r_t, S_{t+1}, A_{t+1}, o_{t+1}, d_t). \tag{4-5}$$

式中，r_t 为执行动作 a_t后获得的即时奖励，d_t 为环境返回的回合结束标记；当满足第三章规定的到达、超时或越界条件时，$d_t = 1$。一条经验同时保存当前和下一决策位置所需的信息，可直接用于相应价值预测与训练目标计算。

训练时，按照样本优先级概率有放回地抽取B条经验，并取得相应的重要性采样权重。每条经验已包含完整的历史缓存，采样后即可进行时序编码。批次中的经验可以来自不同时间位置，各条经验内部的历史序列则保持原有顺序。

对于抽取的经验，各网络从零隐藏状态和零单元状态开始，分别编码当前历史与下一历史，并以最后一次 LSTM 输出形成历史特征。两次编码独立完成，循环状态不跨训练批次保存；目标 Critic 也通过各自的循环分支处理下一历史。每条经验在当前决策位置计算一次单步损失，梯度通过 LSTM 向历史编码步骤反向传播，从而学习与当前决策相关的时序特征。

在线控制采用回合内持续递推的循环状态。Actor 为每个环境维护隐藏状态和单元状态，利用上一时刻的观测—动作对更新记忆，再结合当前观测生成动作，其递推关系为：

$$(h_t^{\pi}, c_t^{\pi}) = f_{\mathrm{LSTM}}^{\pi}(\phi_h^{\pi}, ([\hat{o}_{t-1}; a_{t-1}]), h_{t-1}^{\pi}, c_{t-1}^{\pi}), \tag{4-6}$$

其中，ϕ_h^{π} 表示 Actor 历史分支中的全连接特征映射，h_t^{π} 和 c_t^{π}分别为其隐藏状态与单元状态。回合首步使用零初始化记忆，后续记忆随交互持续更新，回合结束后重置。因此，训练阶段通过固定长度窗口控制计算与存储开销，在线阶

段则通过循环状态积累回合内的历史信息。初期随机动作采集阶段仅维护历史缓存并保存经验，不推进 Actor 循环状态。

（4）策略与价值网络更新

在上述经验组织方式下，将各网络内部的历史编码统一包含在策略函数与 Q 函数中，记为：

$$\pi_\theta(a,|,S_tA_to_t),Q_{\omega_j}(S_t,A_t,o_t,a),j=1,2, \tag{4-7}$$

其中，θ 为 Actor 参数，ω_j 为第 j个在线 Critic 参数。以下训练计算中的观测均采用前述标准化处理，各网络分别对输入历史进行编码。

首先构造 Critic 的单步学习目标。当前 Actor 根据下一历史及下一观测重新采样动作：

$$a'_{t+1}\sim\pi_\theta(\cdot,|,S_{t+1},A_{t+1},o_{t+1}). \tag{4-8}$$

两个目标 Critic 对该动作进行评价，并结合即时奖励及策略熵项构造目标值：

$$\begin{aligned}y_t=r_t+\gamma(1-d_t)[&\min_{j=1,2}Q_{\bar{\omega}_j}(S_{t+1},A_{t+1},o_{t+1},a'_{t+1})\\&-\alpha\log\pi_\theta\,(a'_{t+1},|,S_{t+1}A_{t+1}o_{t+1})],\end{aligned} \tag{4-9}$$

其中，γ 为折扣因子，α 为温度系数，$\bar{\omega}_j$ 为目标 Critic 参数。目标计算使用经验中保存的下一历史和当前策略重新生成的下一动作；当$d_t=1$时，目标值仅保留即时奖励。

在线 Critic 对经验中实际保存的当前动作进行价值预测。考虑优先级采样的重要性权重，两个 Critic 的联合损失为：

$$J_Q(\omega_1,\omega_2)=\frac{1}{B}\sum_{b=1}^{B}w_b\sum_{j=1}^{2}\left(Q_j^{(b)}-y^{(b)}\right)^2, \tag{4-10}$$

其中，b 为批次内的样本编号，w_b 为该样本的重要性采样权重，$Q_j^{(b)}$ 为第 j个 Critic 对该样本当前转移的预测值，$y^{(b)}$ 为对应目标值。权重调节各样本对损失的贡献，目标值在 Critic 参数更新时作为固定回归目标。

Actor 更新时，保持经验中的历史信息不变，根据当前观测与当前历史重新采样动作，并最小化以下目标：

$$J_\pi(\theta)=\mathbb{E}\left[\alpha\log\pi_\theta\,(\tilde{a}_t,|,S_t,A_t,o_t)-\min_{j=1,2}Q_{\omega_j}(S_t,A_t,o_t,\tilde{a}_t)\right], \tag{4-11}$$

该目标利用两个 Critic 中较小的 Q 值引导策略生成高价值动作，同时通过熵

项保留动作分布的随机性。Actor 优化使用当前策略生成的新动作，历史动作序列仍采用经验中记录的内容。

温度系数根据当前策略熵与预设目标熵自适应更新。两个目标 Critic 按照以下方式进行软更新，更新范围包括前馈分支与循环分支：

$$\bar{\omega}_j \leftarrow \tau\omega_j + (1-\tau)\bar{\omega}_j, j = 1,2, \tag{4-12}$$

其中，τ为软更新系数。训练过程交替执行环境采样和网络更新：Actor 与环境交互，回放池保存附带历史的单步经验，再通过批次采样优化策略与价值网络。整体流程如图 4.2 所示，具体执行顺序见表 4.1。并行采样时，各环境分别维护历史缓存与 Actor 循环状态。

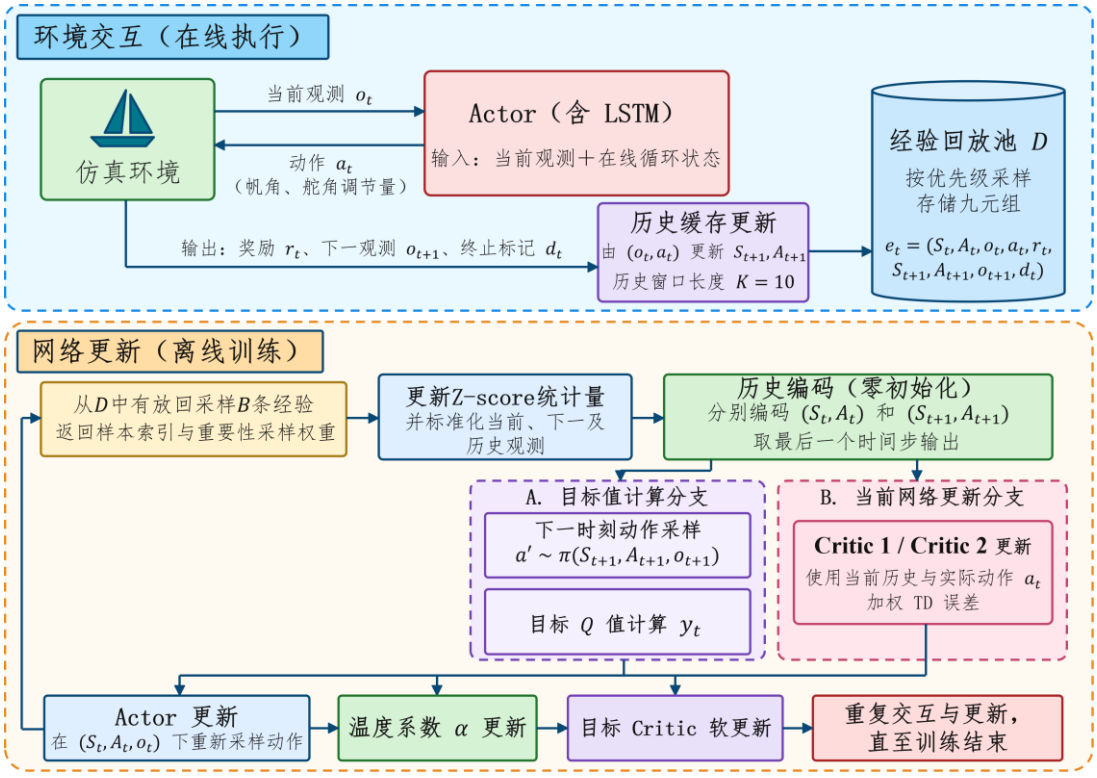


图 4.2 SAC-LSTM 模型训练与参数更新流程

Fig.4.2 Training and parameter-update process of SAC-LSTM

表 4.1 SAC-LSTM 模型训练流程

Table.4.1 Training procedure of the SAC-LSTM model

伪代码 1: SAC-LSTM 训练流程

1. 输入：历史序列长度 K，经验回放池容量 N，批量大小 B，总训练步数 T，折扣因子 γ，温度系数 α，软更新系数 τ，Actor 与 Critic 学习率及网络更新参数。
2. 初始化：初始化 Actor、两个 Critic 及对应的目标 Critic；初始化经验回放池 D、观测标准化统计量、历史序列缓存及 Actor 在线循环状态。

3. while 总交互步数未达到 Tdo
4. if 处于初期随机采样阶段 then
   随机生成动作 a_t，不更新 Actor 循环状态；
   else
   根据上一时刻观测—动作对更新 Actor 循环状态，并结合当前观测 o_t生成动作 a_t；
   end if
5. 在仿真环境中执行动作，获得奖励 r_t、下一观测 o_{t+1}和终止标记 d_t。
6. 更新历史观测—动作序列，得到 S_{t+1}和 A_{t+1}，并将经验
$$(S_t, A_t, o_t, a_t, r_t, S_{t+1}, A_{t+1}, o_{t+1}, d_t)$$
存入经验回放池 D。
7. 若当前回合结束，则重新初始化环境、历史序列及 Actor 循环状态。
8. if 经验数量满足训练要求且达到网络更新条件 then
9. for 每一次网络更新 do
10. 按照优先级概率从 D中采样 B条经验，并获得重要性采样权重。
11. 更新观测 Z-score 统计量，并对当前、下一及历史观测进行标准化。
12. 将训练使用的循环状态初始化为零，分别编码当前历史 (S_t, A_t)和下一历史 (S_{t+1}, A_{t+1})，获得相应历史特征。
13. 根据下一历史和下一观测计算单步 TD 目标，并更新两个 Critic。
14. 根据当前历史和当前观测重新采样动作，更新 Actor 及温度系数 α。
15. 软更新两个目标 Critic。
16. end for
17. end if
18. end while
19. 输出：训练后的 Actor 网络及对应的观测标准化统计量。

4.3 面向点到点航行的奖励函数设计

无人帆船点到点航行既要求策略持续接近目标，也要求其根据风况协调推进与转向。本文围绕航行进度、帆舵调节和任务完成构建奖励函数，通过连续进度反馈与阶段性奖励引导目标趋近，并以动作变化惩罚和时间代价兼顾控制平滑性

与航行效率。

（1）观测变量与航行进度特征

在控制时间步t，无显式风场输入模型接收的基础观测为：

$$o_t = [x_t, y_t, \phi_t, \psi_t, u_t, v_t, p_t, r_t, \delta_{s,t}, \delta_{r,t}, x_f, y_f, \Delta, L_t \Delta l_t] \tag{4-13}$$

共包含 14 个维度。其中，x_t 和 y_t表示无人帆船在惯性坐标系中的当前位置；ϕ_t 和 ψ_t分别表示横摇角和艏向角；u_t 和 v_t分别表示船体坐标系下的纵向速度和横向速度；p_t 和 r_t分别表示横摇角速度和艏摇角速度；$\delta_{s,t}$ 和 $\delta_{r,t}$分别表示当前帆角和舵角；(x_f, y_f)表示当前局部航行任务的目标点坐标。ΔL_t和 Δl_t为根据船体位置与目标位置构造的航行进度特征。各类观测的噪声处理沿用第三章的设置。

如第一章所述，无人帆船在不同相对风向下具有不同的航行性能。顺风等条件下，航迹可以较为直接地指向目标；逆风条件下，则通常通过交替换舷形成迂回航迹，如图 4.3 所示。这类航行过程在保持总体推进的同时，可能出现短时目标距离增加，因此本文从目标距离变化和任务方向推进两个角度描述航行进度。

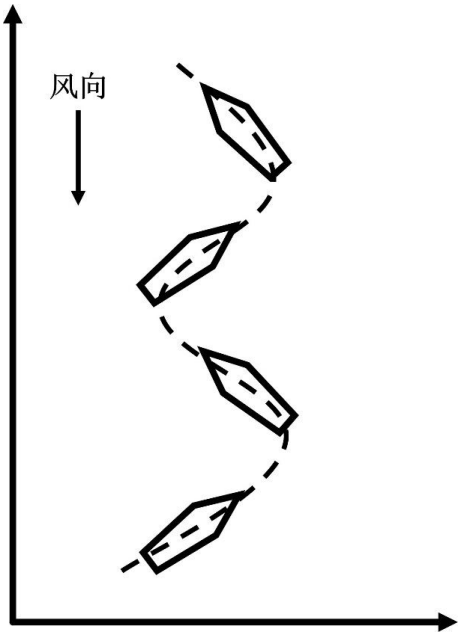


图 4.3 逆风条件下的 Z 字航行

Fig.4.3 Zigzag navigation in headwind conditions

首先，定义无人帆船当前位置与目标点之间的欧氏距离：

$$L_t = \sqrt{(x_f - x_t)^2 + (y_f - y_t)^2}. \tag{4-14}$$

相邻两个控制时间步之间的目标距离减少量定义为

$$\Delta L_t = L_{t-1} - L_t. \tag{4-15}$$

ΔL_t为正时表示船体更加接近目标，为负时表示目标距离暂时增加。该变量直接反映局部运动对目标接近程度的影响。

其次，以当前回合起点(x_0, y_0)与目标点之间的连线作为任务总体方向，定义起点至目标点的直线距离：

$$D_0 = \sqrt{(x_f - x_0)^2 + (y_f - y_0)^2}, \tag{4-16}$$

当前位置相对于起点在该方向上的投影距离为：

$$l_t = \frac{(x_t - x_0)(x_f - x_0) + (y_t - y_0)(y_f - y_0)}{D_0}. \tag{4-17}$$

由此得到相邻控制时刻的投影进度增量：

$$\Delta l_t = l_t - l_{t-1}. \tag{4-18}$$

Δl_t为正时，表示船体沿起点—目标方向取得了正向进展。与目标距离减少量相比，该指标直接描述沿任务总体方向的推进，能够补充迂回航行中的方向性反馈。两个进度特征的几何关系如图 4.4 所示。

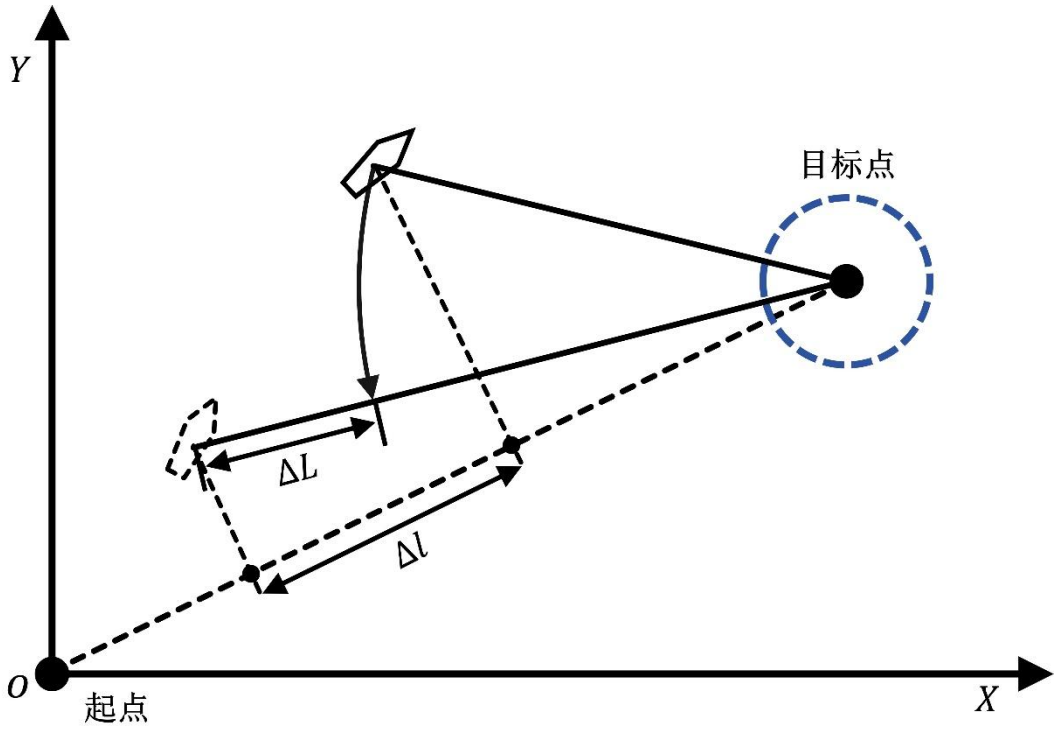


图 4.4 航行进度特征的几何示意图

Fig.4.4 Geometric illustration of navigation progress features

（2）航行进度奖励与动作变化惩罚

在上述观测设置下，控制策略输出帆角与舵角的调节增量，动作向量表示为

$$a_t = [\Delta\delta_{s,t}, \Delta\delta_{r,t}], \tag{4-19}$$

其中，$\Delta\delta_{s,t}$ 和 $\Delta\delta_{r,t}$分别为当前控制时间步的帆角和舵角调节指令，动作范围与执行方式沿用第三章的设定。环境执行 a_t后，根据船体运动结果及本次控制量计算单步奖励，记为 R_t，对应 4.2 节经验记录中的即时奖励 r_t。

基础奖励函数由航行进度奖励、动作变化惩罚、阶段奖励、到达奖励和时间步惩罚组成：

$$\begin{aligned} R_t = \lambda_t\left(R_{progress,t} + R_{action,t}\right) + R_{checkpoint,t} \\ + R_{arrival,t} + R_{penalty,t}. \end{aligned} \tag{4-20}$$

其中，$R_{\text{progress},t}$ 和 $R_{\text{action},t}$分别评价单步航行进展与帆舵调节幅度，并通过系数 λ_t进行整体缩放；其余三项分别提供航行阶段、任务完成及时间消耗方面的反馈。

航行进度奖励同时使用执行当前动作后的目标距离减少量、投影进度增量和速度辅助项：

$$R_{progress,t} = 2\Delta L_{t+1} + \Delta l_{t+1} + \frac{0.5u_{t+1}}{1+|\,v_{t+1}\,|}. \tag{4-21}$$

其中，ΔL_{t+1}和Δl_{t+1}分别评价本次状态转移的目标接近程度与方向性推进。速度辅助项结合纵向速度u_{t+1}和横向速度绝对值，在纵向速度为正时鼓励有效的前向运动，并降低较大船体横向速度对应的奖励。这里的横向速度定义于船体坐标系，描述船体的侧向运动；它与前述几何进度项共同评价航行效果。

为控制单步帆舵调节幅度，本文按照完整角度单位对动作增量施加离散计数惩罚：

$$R_{\text{action},t} = -0.1\left\lfloor\frac{|\,\Delta\delta_{s,t}\,|}{\delta}\right\rfloor - 0.1\left\lfloor\frac{|\,\Delta\delta_{r,t}\,|}{\delta}\right\rfloor, \delta = \frac{\pi}{180}. \tag{4-22}$$

式中，取整符号表示向下取整，δ对应 1°。帆角或舵角调节量每增加一个完整角度单位，相应惩罚项减少 0.1。该项将帆舵变化纳入策略优化，使策略在取得航行进展的同时减少不必要的调节。

上述进度奖励与动作惩罚通过随动作幅度变化的系数进行缩放：

$$\lambda_t = \lambda_0 + \lambda_{s,t} + \lambda_{r,t}, \lambda_0 = 0.2, \tag{4-23}$$

其中，

$$\lambda_{s,t}=\begin{cases}0.1\lambda_0, & |\Delta\delta_{s,t}|\le\delta,\\ 0, & \text{其他},\end{cases}\quad \lambda_{r,t}=\begin{cases}0.1\lambda_0, & |\Delta\delta_{r,t}|\le\delta,\\ 0, & \text{其他}.\end{cases} \tag{4-24}$$

基础系数为 0.2。当帆角或舵角调节量不超过 1°时，对应修正项增加 0.02，因此λ_t取 0.20、0.22 或 0.24。该系数根据控制幅度调整两项奖励之和的大小，对正向收益和负向代价采用相同的缩放关系。

（3）阶段奖励、到达奖励与时间代价

在持续进度反馈的基础上，本文设置三个目标距离阈值，分别在无人帆船首次进入相应距离范围时给予阶段奖励：

$$\begin{aligned}R_{checkpoint,t}=&\,3I_{first}\left(L_{t+1}\le 375\right)+5I_{first}\left(L_{t+1}\le 250\right)\\&+12I_{first}\left(L_{t+1}\le 125\right).\end{aligned} \tag{4-25}$$

三个阈值分别为 375 m、250 m 和 125 m，对应奖励为 3、5 和 12。各阈值在每个回合内分别记录触发状态，首次满足条件时给予奖励，后续再次进入相同范围不重复触发。阶段奖励将目标趋近过程划分为若干中间节点，在完成整个航行任务之前提供任务反馈。

当无人帆船进入目标点周围半径为 10 m 的区域时，给予到达奖励并结束当前回合：

$$R_{\text{arrival},t}=\begin{cases}20, & L_{t+1}\le 10,\\ 0, & \text{其他}.\end{cases} \tag{4-26}$$

到达奖励用于表达完成点到点航行的终端收益，与阶段奖励共同构成任务层面的稀疏反馈。

此外，每个控制时间步设置固定时间代价：

$$R_{\text{penalty},t}=-0.2. \tag{4-27}$$

在 1 s 控制周期下，航行时间越长，累计时间代价越大。该项使策略在推进任务的同时考虑完成时间，并对长期停滞持续施加负反馈。

（4）显式风场输入参考模型的奖励设置

上述基础奖励用于无显示风场输入的模型。作为显式风场输入参考，SAC-wind 在基础观测上增加风向和风速观测，形成 16 维输入：

$$o_t^{\text{wind}}=\left[o_t,\hat{\psi}_{w,t},\hat{V}_{w,t}\right], \tag{4-28}$$

其中，风向与风速观测按照第三章的噪声设置构造。结合迎风航行受限的特点，SAC-wind 进一步使用风向相关的禁航区惩罚，为训练提供相对风向反馈。

沿用第二章中风向表示风速矢量吹向的约定，执行动作后的艏向与风向之差为：

$$\Delta\psi_{w,t+1} = \mathrm{wrap}_{[-\pi,\pi]}\left(\psi_{t+1} - \hat{\psi}_{w,t+1}\right), \tag{4-29}$$

将角度差映射至$[-\pi,\pi]$后，按照以下关系计算禁航区惩罚：

$$R_{\text{no-go},t} = \begin{cases} -2, & |\Delta\psi_{w,t+1}| > \theta_{\text{no-go}}, \\ 0, & \text{其他}, \end{cases} \quad \theta_{\text{no-go}} = \frac{3\pi}{4} \tag{4-30}$$

当夹角绝对值大于 135°时，艏向处于迎风方向两侧各 45°的范围内，此时施加负奖励。该项以软惩罚方式引导航向选择。SAC-wind 的总奖励为：

$$R_t^{\text{wind}} = R_t + R_{\text{no-go},t}. \tag{4-31}$$

本节各项系数与阈值结合任务尺度、航行特征及训练经验设定。不同奖励组成项对任务表现的作用将在 4.4.2 节通过消融实验进一步分析。

4.4 实验结果与分析

本节围绕控制性能、奖励作用、扰动适应能力和历史信息利用开展实验。首先比较不同信息条件下的 SAC 模型，并结合 MPC 分析代表性风况下的航行表现；随后通过奖励消融考察各奖励项的作用，通过风场变化与观测噪声测试分析性能变化，最后从隐藏状态表征和动作输出两个方面研究策略对历史信息的利用。

4.4.1 基线对比实验

（1）对照模型与实验设置

本文设置 SAC-nowind、SAC-wind 和 SAC-LSTM 三种学习型控制模型。

SAC-nowind 采用全连接网络，输入为 4.3 节定义的 14 维基础观测，依据当前可获得的信息生成帆舵动作，不设置额外的历史编码分支。SAC-LSTM 采用相同的当前观测和基础奖励，并通过循环分支利用历史观测—动作信息。二者的对比用于分析历史信息编码对无显式风场输入控制的影响。

SAC-wind 同样采用全连接网络，在基础观测上增加含噪声的风速和风向，并使用 4.3 节定义的禁航区惩罚，构成结合显式风场输入与风向相关奖励指导的学习型参考。

此外，引入模型预测控制（Model Predictive Control，MPC）作为模型驱动参考。MPC 使用与仿真环境一致的四自由度动力学模型，根据当前船体状态、目标位置及风场信息求解滚动优化问题。MPC 主要通过代价函数来进行控制优化，其本质上与奖励函数都是在对行为进行“好坏”的赋值，但是优化方向相反。本次实验中将代价函数直接建立在有显示风向输入奖励函数的基础上并取负值。在本实验中预测时域设为 20 个控制步，控制时域设为 1 个控制步，每个控制周期重新求解并执行当前控制量。其结果在代表性风向测试中单独报告。

上述对照分别考察历史编码、显式风场信息参考和模型驱动控制三个方面。SAC-nowind 与 SAC-LSTM 采用相同的基础观测和奖励，二者的主要区别在于是否设置历史观测—动作编码分支；SAC-wind 结合显式风场输入与风向相关奖励，作为另一种信息条件下的学习型参考；MPC 则用于展示利用已知动力学和风场信息进行在线优化的控制表现。各类对照共同用于评价本文方法在既定任务中的能力与特点。

三种 SAC 模型采用相同的训练环境、随机化方式、总交互步数与主要优化参数，并通过调整全连接模型的隐藏层规模，使各模型的总体参数量保持在相近范围。训练超参数见表 4.2。

表 4.2 不同模型超参数设定表

Table.4.2 Table of Hyperparameter Settings for Different Models

参数	SAC-nowind/SAC-wind	SAC-LSTM
折扣因子	0.98	0.98
策略与价值网络学习率	3×10^{-4}	3×10^{-4}
初始温度系数	0.2	0.2
温度系数学习率	6×10^{-5}	6×10^{-5}
经验回放池容量	1×10^{6}	1×10^{6}
批量大小	256	256
软更新系数	0.002	0.002

航行任务沿用第三章的设定，起点为$(0,0)$，目标点为$(500,0)$，坐标单位为米；目标区域半径为 10 m，单回合时间上限为 1000 s。训练回合的平均风向随机初始化，并叠加简化 Dryden 模型，使策略在顺风、横风和逆风条件下持续学习。控制周期、观测噪声、动作执行约束及越界终止规则均保持一致。

实验基于 Python 3.10 和 PyTorch 2.1.0 实现，采用 CUDA 进行 GPU 加速。计算平台配置为 Intel Core i7-14700KF 处理器、32 GB 内存及 NVIDIA GeForce RTX 4090 24 GB 显卡。各学习模型采用 5 个随机种子独立训练，训练完成后固定策略进行测试。

对应测试回合采用一致的初始条件、风场生成规则和外部随机扰动设置。评价指标包括任务成功率、平均航行时间、平均航行距离、帆角变化率和舵角变化率，分别反映任务完成、航行效率及单位时间内的控制调节强度。任务成功率基于全部测试回合计算，其余指标基于各模型成功到达目标的回合计算。

（2）训练过程分析

训练过程中，按固定交互步数间隔记录独立评估回报，并同步记录 Critic 与 Actor 损失。评估回报用于观察策略对奖励目标的学习进展，网络损失用于检查价值估计与策略更新过程，结果如图 4.5 所示。

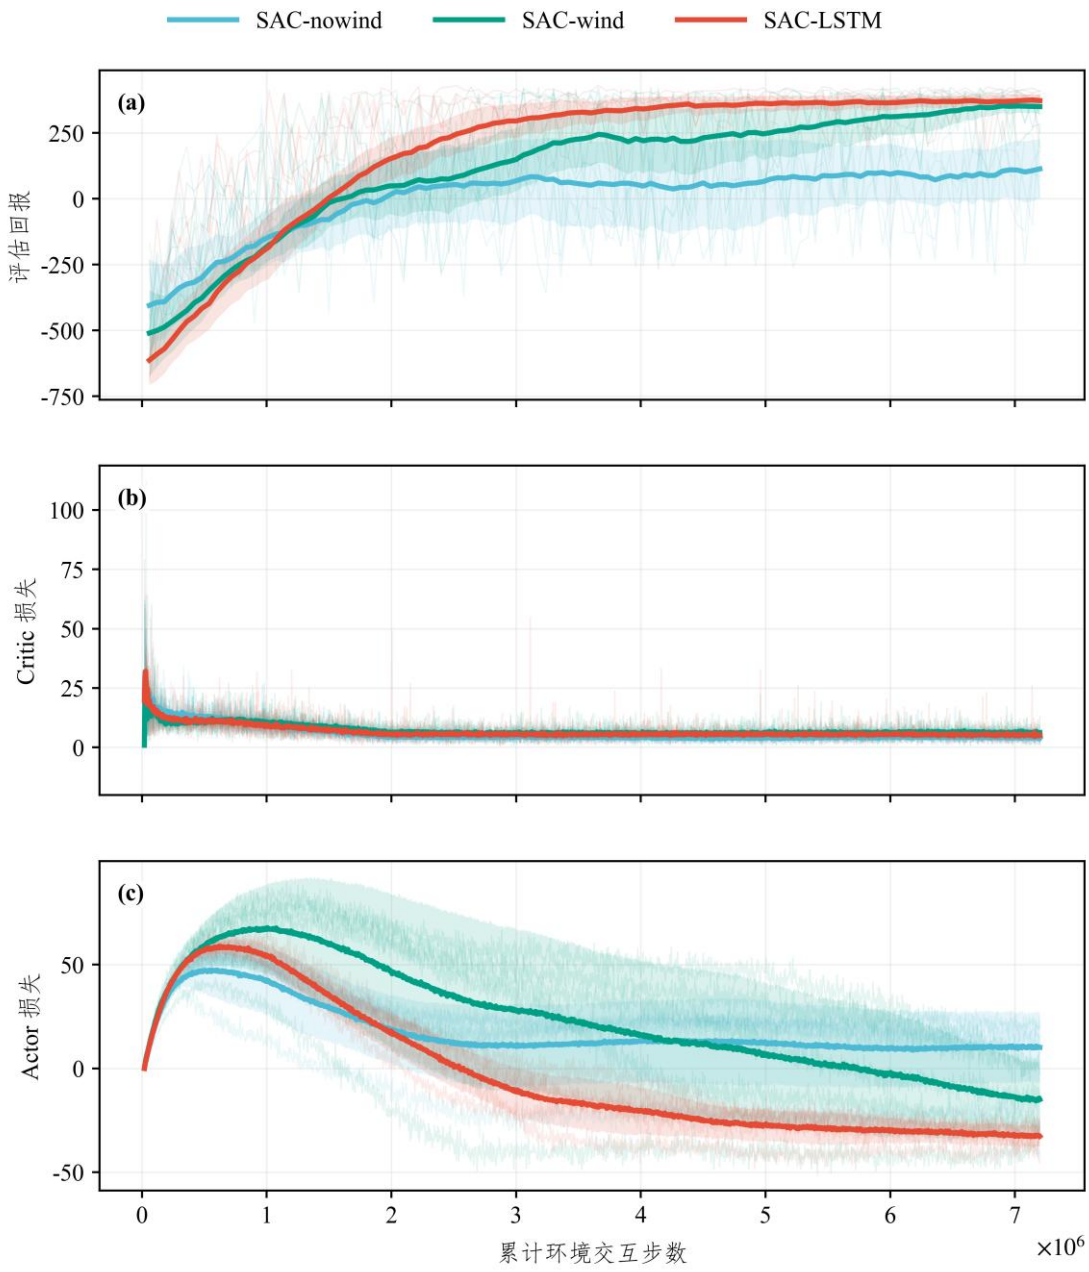


图 4.5 各模型训练评估结果图。

Fig.4.5 Training and evaluation results graphs of each model.

图 4.6(a)显示，三种模型的评估回报在训练初期均逐步提高。SAC-nowind 在约2×10^6个交互步之后提升幅度减小，随后维持在较低回报区间；SAC-LSTM 则持续提升，并在约$(2 \sim 3) \times 10^6$个交互步后进入较稳定的高回报区域。在相同当前观测和基础奖励下，历史信息编码改善了策略的学习结果。

SAC-wind 的评估回报在训练中前期上升相对缓慢，后期继续提高并逐渐接近 SAC-LSTM 的数值区间。由于 SAC-wind 使用含禁航区惩罚的奖励，其回报曲线主要呈现该模型自身的学习过程，模型间的航行表现由下文统一任务指标进

行比较。

图 4.6(b)中，Critic 损失在训练初期较快下降，随后保持在相对稳定的范围。图 4.6(c)中，Actor 损失经历先上升后下降的变化，SAC-LSTM 较早进入下降阶段，SAC-wind 的下降过程持续时间较长，SAC-nowind 后期变化较小。三种模型的损失曲线均未出现持续发散，训练中的策略与价值更新保持了数值稳定。

（3）随机风向下的综合性能

随机风向测试用于评价策略在多种风况共同构成的任务分布中的表现。每个回合的平均风向在$[-180°, 180°]$内随机生成，动态风场与观测噪声沿用基础设置，不同训练策略均进行 500 次回合测试，结果见表 4.3。

表 4.3 随机风向条件下三种 SAC 模型的航行性能

Table.4.3 Navigational performance of three SAC models under random wind conditions

指标	SAC-nowind	SAC-wind	SAC-LSTM
任务成功率(%)	39.64±1.65	95.24±0.38	99.36±0.26
	[37.59, 41.69]	[94.76, 95.72]	[99.04, 99.68]
平均航行时间 (s)	207.64±6.98	178.77±1.92	177.22±1.61
	[198.98, 216.30]	[176.38, 181.16]	[175.23, 179.22]
平均航行距离(m)	610.25±2.93	584.81±2.49	586.38±4.15
	[606.62, 613.89]	[581.72, 587.89]	[581.24, 591.53]
帆角变化率(°/s)	1.195±0.022	0.865±0.014	0.875±0.008
	[1.168, 1.223]	[0.847, 0.883]	[0.866, 0.885]
舵角变化率(°/s)	0.840±0.017	0.675±0.009	0.633±0.013
	[0.819, 0.861]	[0.664, 0.687]	[0.617, 0.649]

注：结果为 5 个独立训练策略的均值±策略间标准差，方括号为 95%置信区间。任务成功率基于全部测试回合统计，其余指标基于各策略成功到达目标的回合统计。

根据上表结果可以分析，在相同无显式风场当前观测条件下，SAC-LSTM 的任务成功率达到 99.36%，高于 SAC-nowind 的 39.64%。这一结果表明，将历史控制输入与船体运动响应纳入决策后，模型能够在随机隐藏风况下保持更可靠的目标趋近行为。

在各自成功完成的回合中，SAC-LSTM 的平均航行时间由 SAC-nowind 的 207.64 s 降至 177.22 s，平均航行距离及帆舵角变化率也同时降低。历史编码带

来的改善由此同时体现在任务完成能力、成功航行效率和控制平滑性上。

与 SAC-wind 相比，SAC-LSTM 的任务成功率高于其 95.24%的水平，成功回合的平均航行时间、距离及帆角变化率总体接近，舵角变化率则由 0.675°/s 降至 0.633°/s。因此，SAC-LSTM 在不直接输入风速和风向的情况下，获得了较高的任务完成率，并保持了与显式风场输入参考接近的航行效率。

（4）代表性风向下的航行性能

为分析上述差异主要出现在哪些航行条件下，本文进一步选取 0°顺风、90°横风、150°斜逆风和 180°逆风四种代表性平均风向。测试仅固定每个回合的平均风向，其余动态扰动、任务条件及评价指标保持不变，不同风向下的不同训练模型均进行 125 次测试，结果见表 4.4。

表 4.4 代表性风向环境下不同模型的测试结果

Table.4.4 Test results of different models under representative wind conditions

风向	测试指标	SAC-nowind	SAC-wind	SAC-LSTM
0°	任务成功率(%)	90.56±1.91 [88.19, 92.93]	100.00±0.00 [100.00, 100.00]	99.84±0.36 [99.40, 100.00]
	平均航行时间 (s)	196.08±6.80 [187.64, 204.52]	148.98±1.23 [147.46, 150.51]	148.46±1.10 [147.10, 149.83]
	平均航行距离(m)	607.93±7.61 [598.49, 617.38]	516.00±1.53 [514.11, 517.90]	509.99±1.14 [508.57, 511.41]
	帆角变化率(°/s)	1.086±0.027 [1.053, 1.120]	0.657±0.011 [0.644, 0.671]	0.584±0.018 [0.561, 0.606]
	舵角变化率(°/s)	0.839±0.011 [0.826, 0.853]	0.480±0.027 [0.446, 0.514]	0.470±0.014 [0.453, 0.487]
90°	任务成功率(%)	66.24±2.43 [63.23, 69.25]	100.00±0.00 [100.00, 100.00]	99.68±0.44 [99.14, 100.00]
	平均航行时间 (s)	227.40±19.77 [202.85, 251.94]	145.91±1.70 [143.79, 148.02]	153.61±2.80 [150.14, 157.08]
	平均航行距离(m)	639.13±18.19 [616.55, 661.72]	531.35±3.40 [527.12, 535.58]	548.56±2.06 [546.01, 551.12]
	帆角变化率(°/s)	1.375±0.019 [1.351, 1.398]	0.870±0.023 [0.842, 0.898]	1.094±0.014 [1.076, 1.111]

风向	测试指标	SAC-nowind	SAC-wind	SAC-LSTM
	舵角变化率(°/s)	0.792±0.009 [0.780, 0.804]	0.573±0.014 [0.555, 0.591]	0.606±0.021 [0.580, 0.632]
150°	任务成功率(%)	0.00±0.00 [0.00, 0.00]	78.24±3.17 [74.30, 82.18]	99.20±0.57 [98.50, 99.90]
	平均航行时间 (s)	NA	281.58±6.62 [273.37, 289.80]	238.94±2.39 [235.98, 241.91]
	平均航行距离(m)	NA	736.56±8.52 [725.99, 747.14]	733.97±3.59 [729.52, 738.43]
	帆角变化率(°/s)	NA	0.758±0.018 [0.736, 0.780]	1.161±0.021 [1.135, 1.186]
	舵角变化率(°/s)	NA	0.852±0.012 [0.838, 0.867]	0.762±0.010 [0.750, 0.775]
180°	任务成功率(%)	0.00±0.00 [0.00, 0.00]	88.80±4.42 [83.31, 94.29]	99.20±1.39 [97.48, 100.00]
	平均航行时间 (s)	NA	299.68±4.30 [294.34, 305.02]	293.24±5.82 [286.01, 300.47]
	平均航行距离(m)	NA	793.11±3.41 [788.88, 797.35]	812.82±5.86 [805.55, 820.09]
	帆角变化率(°/s)	NA	0.965±0.013 [0.949, 0.981]	1.082±0.020 [1.057, 1.107]
	舵角变化率(°/s)	NA	1.055±0.011 [1.042, 1.069]	1.073±0.009 [1.061, 1.085]

注：结果为 5 个独立训练策略的均值±策略间标准差，方括号为 95%置信区间。任务成功率基于全部测试回合统计，其余指标基于成功回合统计；NA 表示对应工况下无成功回合。

顺风和横风条件下，三种模型均产生了成功航行回合，其中 SAC-LSTM 的成功率分别为 99.84%和 99.68%，SAC-wind 均为 100%。SAC-nowind 的成功率分别为 90.56%和 66.24%，表明仅依赖当前观测已能够学习部分风况下的控制行为，但其任务完成能力随风况变化较大。

在 150°和 180°两类逆风相关工况中，SAC-nowind 均未获得成功回合，而 SAC-LSTM 的成功率均达到 99.20%。这一差异表明，在本文观测构造与训练条

件下，缺少历史编码分支的策略难以稳定形成相应的迎风机动。将此前的控制输入与船体运动响应共同纳入决策后，策略能够获得支持持续航向调整和帆舵配合的补充信息，从而改善迎风条件下的任务完成能力

航行时间与距离体现了不同风况的机动需求。顺风条件下，SAC-LSTM 的平均航行距离为 509.99 m，接近起点与目标之间的直线距离；斜逆风和逆风条件下，其平均航行时间分别增加至 238.94 s 和 293.24 s，航行距离也随迂回运动增加。SAC-wind 与 SAC-LSTM 在具体指标上表现出不同特点：SAC-wind 在横风条件下的航行时间和距离较低，SAC-LSTM 则在斜逆风条件下获得更高成功率，并缩短了成功回合的平均航行时间。

MPC 在相同四种代表性风向下分别进行 20 次测试，结果单独列于表 4.5。

表 4.5 代表性平均风向下 MPC 控制器的航行性能

Table.4.5 Navigational performance of the representative average wind-down MPC controller

指标	0°	90°	150°	180°
任务成功率(%)	100 [83.89, 100]	100 [83.89, 100]	100 [83.89, 100]	100 [83.89, 100]
平均航行时间(s)	190.30±15.44 [183.07, 197.53]	143.05±13.07 [136.93, 149.17]	310.90±29.49 [297.10, 324.70]	365.44±50.10 [341.99, 388.89]
平均航行距离(m)	712.76±79.78 [675.42, 750.10]	573.17±42.85 [553.12, 593.22]	606.30±37.03 [588.97, 623.63]	734.92±49.42 [711.79, 758.05]
帆角变化率(°/s)	1.08±0.16 [1.01, 1.15]	0.92±0.26 [0.80, 1.04]	0.42±0.23 [0.31, 0.53]	0.49±0.16 [0.42, 0.56]
舵角变化率(°/s)	0.22±0.14 [0.15, 0.29]	0.28±0.10 [0.23, 0.33]	0.44±0.10 [0.39, 0.49]	0.64±0.16 [0.57, 0.71]

注：任务成功率基于全部测试回合统计，其余指标基于成功回合统计。“±”表示标准差，方括号为 95%置信区间。

MPC 在每种风向下均完成全部 20 次测试，展示了利用动力学模型和显式风场信息进行在线优化的控制表现。其平均航行时间在横风条件下为 143.05 s，在斜逆风和逆风条件下分别为 310.90 s 和 365.44 s。不同风向对应的耗时差异进一步体现了迎风航行对机动与推进协调的要求，并为下文的轨迹分析提供模型驱动

参考。

（5）典型航行轨迹与帆舵控制

为观察不同控制方式形成的航行行为，本文选取四类风况下的代表性测试回合，对 SAC-nowind、SAC-wind、SAC-LSTM 及 MPC 的航迹进行比较，如图 4.6 所示。

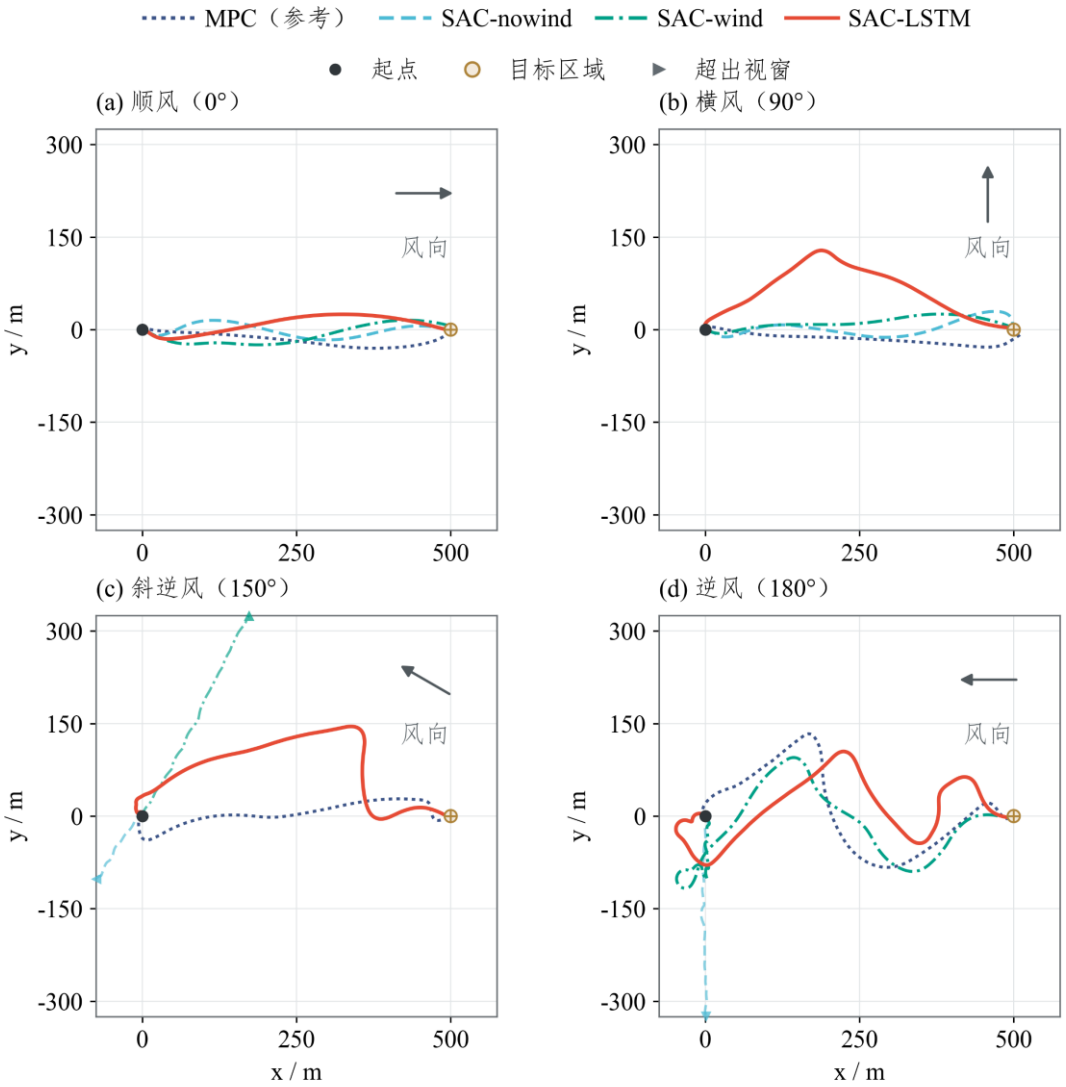


图 4.6 顺风环境下航行轨迹与控制策略。

Fig.4.6 Trajectory and control strategy under tailwind conditions.

顺风和横风回合中，各方法均到达目标，差异主要体现在航迹弯曲程度与横向偏移。进入斜逆风和逆风工况后，成功航迹包含更明显的转向及迂回过程。图示 150°回合中，SAC-LSTM 与 MPC 完成任务，SAC-nowind 和 SAC-wind 发生较大偏离；在 180°回合中，SAC-LSTM、SAC-wind 与 MPC 通过不同形态的迂回航迹到达目标。这些轨迹展示了表 4.4 和表 4.5 统计结果所对应的具体航行行

为。

进一步选取 SAC-LSTM 的顺风与逆风回合，同时展示航迹以及实际帆角、舵角的时间变化，分别见图 4.7 和图 4.8。

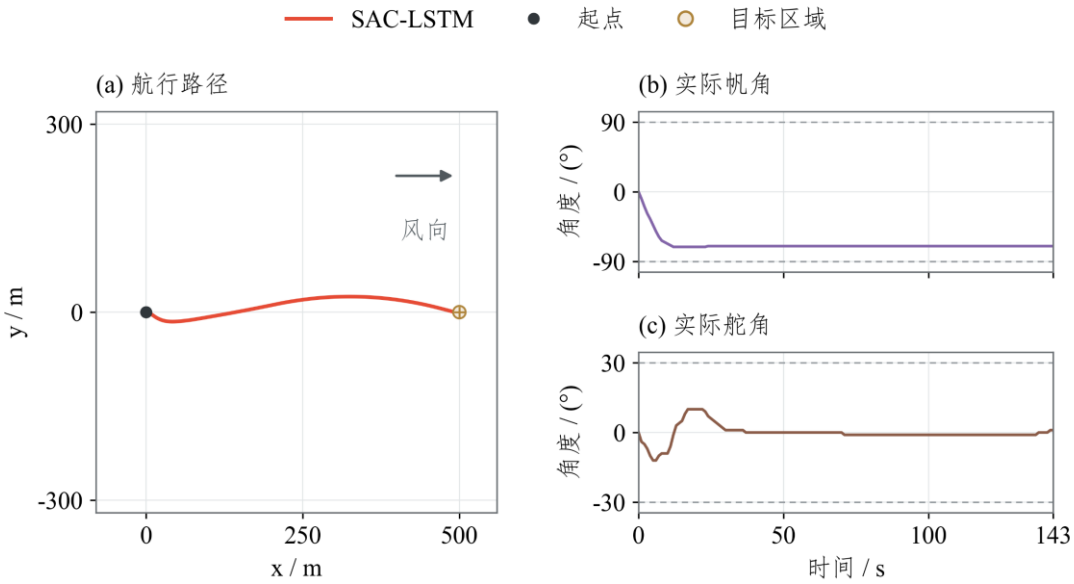


图 4.7 SAC-LSTM 在顺风条件下的航行轨迹与帆舵角变化

Fig.4.7 SAC-LSTM's navigation trajectory and sail/rudder angle changes under tailwind conditions

图 4.7 中，无人帆船在初始调整后沿平缓航迹持续接近目标。帆角在航行初期完成调整，此后基本保持稳定；舵角主要在初始阶段发生变化，随后维持在较小范围。该过程体现了顺风工况下以稳定帆角维持推进、以较小舵角调节修正航迹的控制特点。

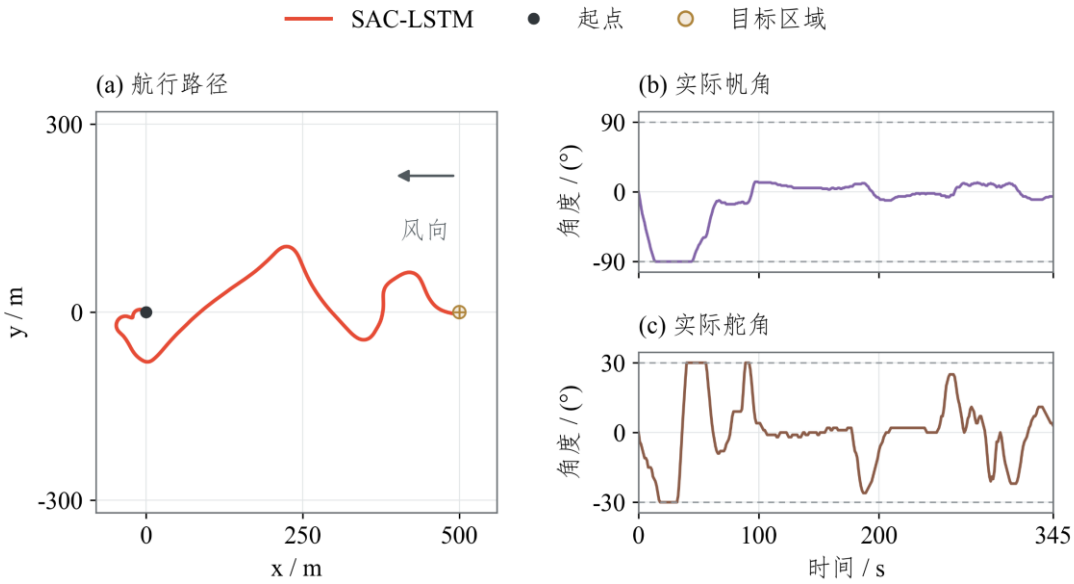


图 4.8 SAC-LSTM 在逆风条件下的航行轨迹与帆舵角变化

Fig.4.8 SAC-LSTM's navigation trajectory and sail/rudder angle changes under headwind conditions

图 4.8 中，航迹包含多次横向迂回和航向转换。与顺风回合相比，帆舵调节贯穿更多航行阶段：舵角在转向过程中出现较大变化，帆角随航行姿态与换舷过程调整，并在部分航段维持相对稳定。SAC-LSTM 由此将推进与转向相互配合，在逆风条件下逐步取得朝向目标的有效进展。

4.4.2 奖励消融实验

为分析奖励设计对上述航行行为的影响，本文以完整 SAC-LSTM 模型为基础，分别去除航行进度奖励、动作变化惩罚、阶段奖励和到达奖励。各组保持网络结构、基础观测、训练流程及主要超参数一致，固定时间步惩罚保持不变，并重新进行独立训练。测试采用 4.4.1 节的随机风向设置，任务完成与航行效率结果见表 4.6，帆舵角变化率见表 4.7。不同训练模型均进行 500 次测试。

表 4.6 不同奖励配置下的任务成功率与航行效率

Table.4.6 Task success rate and navigation efficiency under different reward configurations

奖励配置	任务成功率(%)	平均航行时间(s)	平均航行距离(m)
完整模型	99.36±0.26 [99.04, 99.68]	177.22±1.61 [175.23, 179.22]	586.38±4.15 [581.24, 591.53]
去除进度奖励	1.76±0.74 [0.84, 2.68]	390.30±28.26 [355.20, 425.39]	671.54±75.97 [577.22, 765.87]
去除动作惩罚	98.48±0.33 [98.06, 98.90]	179.81±3.07 [176.00, 183.63]	572.03±4.62 [566.30, 577.76]
去除阶段奖励	99.56±0.33 [99.15, 99.97]	194.37±2.39 [191.41, 197.34]	639.58±5.40 [632.87, 646.29]
去除到达奖励	99.88±0.11 [99.74, 100.00]	176.75±1.69 [174.65, 178.86]	594.38±4.58 [588.69, 600.07]

注：结果为 5 个独立训练策略的均值±策略间标准差，方括号为 95%置信区间；任务成功率基于全部测试回合，其余指标基于各配置成功回合统计。

表 4.7 不同奖励配置下的帆舵角变化率

Table.4.7 Sail/rudder angle variation rate under different reward configurations

奖励配置	帆角变化率（°/s）	舵角变化率（°/s）
完整模型	0.875 ± 0.008 [0.866, 0.885]	0.633 ± 0.013 [0.617, 0.649]
去除进度奖励	0.031 ± 0.006 [0.023, 0.038]	0.024 ± 0.005 [0.018, 0.029]
去除动作惩罚	1.222 ± 0.018 [1.200, 1.244]	1.148 ± 0.011 [1.135, 1.161]

奖励配置	帆角变化率（°/s）	舵角变化率（°/s）
去除阶段奖励	0.869 ± 0.012 [0.855, 0.884]	0.678 ± 0.015 [0.660, 0.697]
去除到达奖励	0.825 ± 0.011 [0.812, 0.839]	0.583 ± 0.007 [0.574, 0.591]

注：结果为 5 个独立训练策略的均值±策略间标准差，方括号为 95%置信区间；任务成功率基于全部测试回合，其余指标基于各配置成功回合统计。

航行进度奖励对任务学习的影响最为突出。去除该项后，任务成功率由 99.36%降至 1.76%，少量成功回合的平均航行时间也增加至 390.30 s。持续进度反馈因此构成了策略学习目标趋近行为的主要信号，使控制动作能够在到达最终目标之前获得与任务进展相关的评价。

动作变化惩罚主要影响控制调节强度。去除该项后，模型仍保持 98.48%的成功率，平均航行时间为 179.81 s，与完整模型接近；但帆角变化率由 0.875°/s 增至 1.222°/s，舵角变化率由 0.633°/s 增至 1.148°/s，分别增加约 39.7%和 81.4%。这表明，在维持较高任务完成率的同时，动作变化惩罚有效降低了帆舵调节强度，尤其对舵角变化具有较明显的抑制作用。

阶段奖励进一步改善航行效率。去除该项后，成功率仍为 99.56%，平均航行时间却由 177.22 s 增加至 194.37 s，平均航行距离由 586.38 m 增加至 639.58 m。中间距离阈值提供的反馈强化了阶段性推进，使策略以更高的时间与路径效率接近目标。

到达奖励在当前奖励组合中的独立影响相对有限。去除该项后，成功率为 99.88%，平均航行时间为 176.75 s，主要任务指标与完整模型接近。

各奖励项在当前组合中承担的作用并不相同。持续进度反馈对形成目标趋近行为的影响最为突出；阶段奖励主要改善成功航行的时间与路径效率；动作变化惩罚则在保持较高任务完成率的同时降低帆舵调节强度。相比之下，去除到达奖励后，任务成功率和平均航行时间未出现不利变化，说明在已有连续进度与阶段反馈的条件下，该项未表现出提高上述指标的独立增益。由此，奖励消融明确了不同反馈的功能分工，也表明奖励组合需要在目标推进、航行效率和控制调节之间进行协调，而非通过增加奖励项数量持续改善所有指标。

4.4.3 风场与观测扰动下的鲁棒性分析

前述实验验证了 SAC-LSTM 在基础测试条件下的控制性能，并通过奖励函

数消融分析了不同奖励项对航行行为的具体作用。在实际控制过程中，模型所面对的环境条件可能与训练阶段存在一定差异，因此有必要进一步考察训练完成后的策略在环境参数发生变化时能否保持有效控制。

本节考察训练完成的策略在测试条件变化后的控制表现。保持模型参数和观测标准化统计量固定，分别改变风场统计参数、构造空间分区风向变化以及提高观测噪声水平。各组以相应基础工况为参照，保留其余任务设置，并以 SAC-wind 作为显式风场输入参考。

（1）风场统计参数变化实验

简化 Dryden 模型的湍流强度决定风场波动幅度，尺度长度影响扰动的时间相关性。本组保持平均风速不变，在基准工况上分别增强湍流、缩短尺度长度，并同时改变两类参数形成组合扰动，具体设置见表 4.8。

表 4.8 风场统计参数扰动工况设置

Table.4.8 Setting of wind field statistical parameter disturbance conditions

	L_u(m)	L_v(m)	σ_u(m/s)	σ_v(m/s)
基准	300	150	1.2	1.0
增强湍流	300	150	2.0	1.6
短尺度	100	50	1.2	1.0
组合扰动	100	50	2.0	1.6

增强湍流工况将纵、横向湍流强度分别由 1.2 m/s 和 1.0 m/s 提高至 2.0 m/s 和 1.6 m/s；短尺度工况将纵、横向尺度长度由 300 m 和 150 m 减小至 100 m 和 50 m，使风场扰动的相关时间尺度缩短；组合扰动同时采用上述两项变化。各工况均进行随机风向综合测试 500 次，结果见表 4.9。

表 4.9 不同风场统计参数工况下的航行性能

Table.4.9 Navigation performance under different wind field statistical parameter conditions

工况	指标	SAC-LSTM	SAC-wind
基准	任务成功率（%）	99.8 [98.9, 100.0]	94.6 [92.3, 96.3]
	平均航行时间（s）	180.26 ± 61.62	178.93 ± 64.67
	帆角变化率（°/s）	0.800 ± 0.290	0.850 ± 0.291
	舵角变化率（°/s）	0.625 ± 0.244	0.648 ± 0.270
增强湍流	任务成功率（%）	98.4 [96.9, 99.2]	94.4 [92.0, 96.1]
	平均航行时间（s）	192.26 ± 97.02	193.86 ± 100.64

	帆角变化率（°/s）	0.851 ± 0.324	0.903 ± 0.298
	舵角变化率（°/s）	0.682 ± 0.280	0.696 ± 0.284
短尺度	任务成功率（%）	99.8 [98.9, 100.0]	94.8 [92.5, 96.4]
	平均航行时间（s）	180.96 ± 66.98	179.08 ± 70.26
	帆角变化率（°/s）	0.817 ± 0.306	0.861 ± 0.290
	舵角变化率（°/s）	0.650 ± 0.259	0.672 ± 0.292
组合扰动	任务成功率（%）	97.4 [95.6, 98.5]	95.8 [93.7, 97.2]
	平均航行时间（s）	188.27 ± 76.74	194.06 ± 104.17
	帆角变化率（°/s）	0.890 ± 0.345	0.953 ± 0.317
	舵角变化率（°/s）	0.740 ± 0.326	0.755 ± 0.319

注：任务成功率基于全部测试回合统计，方括号为95%置信区间；其余指标基于成功回合统计，数据表示为均值±标准差。

SAC-LSTM在四种工况下均保持97%以上的成功率。单独缩短尺度长度时，成功率仍为99.8%，平均航行时间与基准接近；增强湍流后，成功率降至98.4%，平均航行时间及帆舵角变化率上升；组合扰动下，成功率为97.4%，帆舵角变化率进一步增加。在本组参数范围内，波动幅度增大对控制表现的影响较为明显，而单独缩短扰动时间尺度造成的变化较小。

SAC-wind的成功率处于94.4%～95.8%，其帆舵角变化率也随湍流增强而上升。两种策略均能够适应所测试的风场参数变化，SAC-LSTM在各工况下保持了较高任务完成率，说明其通过历史运动响应形成的决策信息能够支持不同扰动统计特性下的持续控制。

（2）空间分区风向变化实验

为进一步考察空间非均匀风场的影响，本组以x=250m为分界线，将任务区域划分为两个平均风向不同的区域。船体跨越分界线后，所处风场的平均方向随位置改变，各区域内部仍叠加基础简化Dryden模型扰动。区域平均风向差分别设为30°、60°和90°，并以0°风向差作为参照，场景如图4.9所示。

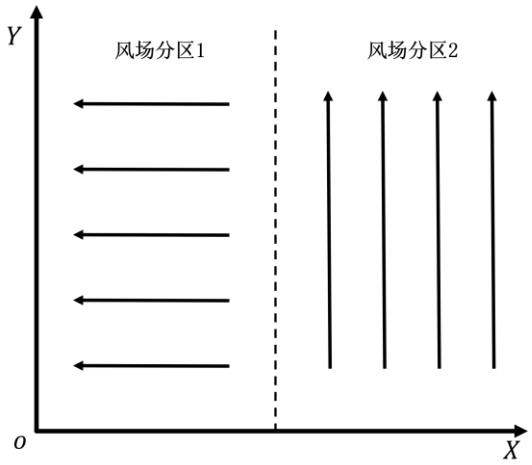


图 4.9 空间分区风向变化测试场景

Fig.4.9 Space partitioning wind direction variation test scenario

与前一组仅改变风场波动特性的测试相比，本组要求策略在航行中适应平均风向的区域性变化。不同区域各类风向差下的 500 次测试结果见表 4.10。

表 4.10 不同区域平均风向差下的航行性能

Table.4.10 Navigation performance under the difference in average wind direction across different regions

工况	指标	SAC-LSTM	SAC-wind
0°	任务成功率（%）	99.8 [98.9, 100.0]	94.6 [92.3, 96.3]
	平均航行时间（s）	180.26 ± 61.62	178.93 ± 64.67
	帆角变化率（°/s）	0.800 ± 0.290	0.850 ± 0.291
	舵角变化率（°/s）	0.625 ± 0.244	0.648 ± 0.270
30°	任务成功率（%）	98.4 [96.9, 99.2]	94.6 [92.3, 96.3]
	平均航行时间（s）	184.74 ± 56.42	181.58 ± 74.59
	帆角变化率（°/s）	0.839 ± 0.292	0.887 ± 0.301
	舵角变化率（°/s）	0.673 ± 0.263	0.674 ± 0.269
60°	任务成功率（%）	94.4 [92.0, 96.1]	95.0 [92.7, 96.6]
	平均航行时间（s）	194.72 ± 76.44	189.84 ± 75.60
	帆角变化率（°/s）	0.915 ± 0.302	0.980 ± 0.343
	舵角变化率（°/s）	0.737 ± 0.260	0.720 ± 0.264
90°	任务成功率（%）	93.4 [90.9, 95.3]	93.6 [91.1, 95.4]
	平均航行时间（s）	195.35 ± 72.77	201.46 ± 86.84
	帆角变化率（°/s）	0.988 ± 0.315	1.075 ± 0.369
	舵角变化率（°/s）	0.787 ± 0.266	0.768 ± 0.241

注：任务成功率基于全部测试回合统计，方括号为 95%置信区间；其余指标基于成功回

合统计，数据表示为均值±标准差。

随着区域风向差由 0°增至 90°，SAC-LSTM 的成功率依次为 99.8%、98.4%、94.4%和 93.4%，平均航行时间由 180.26 s 增加至 195.35 s。帆角与舵角变化率分别由 0.800°/s 和 0.625°/s 增加至 0.988°/s 和 0.787°/s，表现为区域差异增大后任务完成难度与控制调节强度同步上升。

SAC-wind 在四种工况下的成功率处于 93.6%～95.0%，变化相对较小。两种模型在 60°和 90°风向差下的成功率接近，SAC-LSTM 在 90°条件下仍完成了 93.4%的测试任务。结果表明，循环策略能够根据跨区域后的运动反馈继续组织帆舵控制，同时其任务成功率对较大的区域风向差表现出更明显的下降趋势。

（3）不同观测噪声水平

前两组测试改变环境风场，本组进一步考察策略输入信息质量的变化。保持动力学模型、风场及动作执行设置不变，通过噪声水平参数 a 设置 0、3、5、7 和 10 五组工况（其中 a=0 作为基准），不同的数字代表了在第三章噪声设定中基础误差参考尺度的额外叠加倍数。比较观测扰动增强时的任务完成情况与帆舵控制变化，结果见表 4.11。

表 4.11 不同噪声环境下综合任务成功率

Table.4.11 Overall Task Success Rate under Different Noise Conditions

工况	指标	SAC-LSTM	SAC-wind
a=0	任务成功率（%）	99.2 [98.0, 99.7]	94.0 [91.6, 95.8]
	平均航行时间（s）	185.92 ± 59.31	192.17 ± 83.99
	帆角变化率（°/s）	0.815 ± 0.274	0.862 ± 0.280
	舵角变化率（°/s）	0.644 ± 0.239	0.687 ± 0.281
a=3	任务成功率（%）	98.6 [97.1, 99.3]	86.6 [83.3, 89.3]
	平均航行时间（s）	196.92 ± 78.81	202.62 ± 104.16
	帆角变化率（°/s）	1.567 ± 0.440	1.626 ± 0.654
	舵角变化率（°/s）	0.860 ± 0.314	1.273 ± 0.453
a=5	任务成功率（%）	89.8 [86.8, 92.2]	68.0 [63.8, 71.9]
	平均航行时间（s）	236.90 ± 155.43	198.33 ± 103.02
	帆角变化率（°/s）	2.450 ± 0.481	2.134 ± 0.621
	舵角变化率（°/s）	1.121 ± 0.341	1.577 ± 0.455
a=7	任务成功率（%）	70.2 [66.0, 74.0]	44.0 [39.7, 48.4]

	平均航行时间（s）	256.08 ± 178.93	244.69 ± 129.66
	帆角变化率（°/s）	3.383 ± 0.461	2.507 ± 0.416
	舵角变化率（°/s）	1.466 ± 0.288	1.878 ± 0.421
a=10	任务成功率（%）	35.6 [31.5, 39.9]	19.8 [16.5, 23.5]
	平均航行时间（s）	255.52 ± 144.53	475.12 ± 215.48
	帆角变化率（°/s）	4.534 ± 0.316	2.929 ± 0.308
	舵角变化率（°/s）	2.203 ± 0.255	2.445 ± 0.267

注：任务成功率基于全部测试回合统计，方括号为 95%置信区间；其余指标基于成功回合统计，数据表示为均值±标准差。

在 a=0 和 a=3 时，SAC-LSTM 的成功率分别为 99.2%和 98.6%，保持了较稳定的任务完成能力；当a增至 5 时，成功率下降至 89.8%；进一步增至 7 和 10 时，分别下降至 70.2%和 35.6%。由此形成了从较稳定完成任务到明显性能退化的连续变化过程。

与 SAC-wind 相比，SAC-LSTM 在全部测试噪声水平下均具有更高成功率。其中，a=5 和 a=7 时，SAC-wind 的成功率分别为 68.0%和 44.0%，与 SAC-LSTM 的差距较大。利用历史交互信息的循环策略在观测质量下降时保持了更强的任务完成能力，但较高噪声仍对两种策略造成明显影响。

控制变化率体现了这一退化过程的另一侧面。随着a由 0 增至 10，SAC-LSTM 的帆角变化率由 0.815°/s 增至 4.534°/s，舵角变化率由 0.644°/s 增至 2.203°/s，成功回合的平均航行时间也由 185.92 s 增加至约 256 s。观测扰动增强伴随着更大的控制波动和更高的航行耗时。

两个控制通道的相对表现有所不同：SAC-LSTM 在各噪声水平下的舵角变化率均低于 SAC-wind，而在 a≥5 时，其帆角变化率更高。因此，本组实验中循环策略的主要优势体现为任务完成率和舵角调节表现；在较强噪声下，帆角波动仍是其控制性能退化的重要表现。

4.4.4 历史信息利用分析

在控制性能测试的基础上，本节进一步分析历史信息在策略内部的表示及其对动作输出的影响。两项实验均使用训练完成的固定 SAC-LSTM 策略和已采集航行轨迹：风向读出实验研究隐藏状态中可提取的环境信息，历史截断实验研究改变可用历史后帆舵输出的变化。

（1）隐藏状态的风向信息读出

本文将风向预测器作为独立的事后分析工具，利用航行过程中记录的特征预测船体当前位置的瞬时真实风向，以检验这些特征中包含的风向信息。控制策略本身保持固定，风向读出结果仅用于分析，原有在线帆舵决策流程保持不变。

考虑风向的周期性，读出器分别对真实风向的正弦和余弦分量进行岭回归，再通过反正切恢复连续角度。实验比较当前观测、当前及前一时刻观测、LSTM 隐藏状态、当前观测与隐藏状态组合四类输入，并设置常方向预测作为基线。数据按完整航行回合划分为训练集、验证集和测试集，分别包含 384、128 和 128 个回合，测试集共有 4677 个采样时刻。

预测误差采用预测方向与真实方向之间的圆周最短夹角。平均绝对误差 MAE 描述整体预测水平，P90 为绝对误差的第 90 百分位数，用于表征较大误差的分布情况。结果见表 4.12。

表 4.12 不同读出输入下的瞬时风向预测误差

Table.4.12 Instantaneous wind direction prediction errors under different input readings

读出输入	MAE / °	P90 / °
当前观测	38.49 [36.05, 41.22]	86.64 [77.37, 95.83]
当前及前一时刻观测	35.53 [33.18, 38.14]	79.86 [71.62, 89.31]
LSTM 隐藏状态	18.15 [17.08, 19.24]	38.36 [35.85, 41.47]
当前观测＋隐藏状态	17.26 [16.20, 18.33]	36.70 [33.94, 39.91]
常方向基线	90.25 [88.12, 92.30]	158.97 [151.91, 166.32]

注：MAE 为风向绝对误差均值，P90 为绝对误差的第 90 百分位数；方括号为 95%置信区间。

仅使用当前观测时，MAE 为 38.49°；加入前一时刻观测后，降至 35.53°。相邻时刻的运动信息已经能够改善风向读出，说明船体动态响应中存在可用于判断风向的线索。

采用 LSTM 隐藏状态时，MAE 进一步降至 18.15°，较当前观测减少 20.34°；P90 由 86.64°降至 38.36°，整体误差与较大误差均得到降低。当前观测与隐藏状态组合后，MAE 为 17.26°，相较单独使用隐藏状态进一步降低 0.89°。在所比较的线性读出条件下，隐藏状态提供了比瞬时观测更清晰的风向相关信息，当前观测能够在此基础上作进一步补充。

上述结果表明，经过航行控制训练的 LSTM 将历史运动响应编码为包含局

部风向相关信息的内部表征。这些信息可以由简单的线性读出器提取，说明历史观测—动作序列为策略提供了直接风场观测之外的环境信息来源。

（2）历史截断对动作输出的影响

为分析历史信息是否参与当前控制输出，本文在固定轨迹上开展历史截断分析。保持当前观测与模型参数不变，从不同长度的历史窗口重新计算循环状态，并将动作输出与完整历史条件下的结果比较。

实验选取航行时间不小于 50 s 的采样位置，每 5 s 分析一次，共包含 640 个回合中的 18265 个共同采样时刻。历史长度分别设为 0 s、1 s、5 s、10 s、20 s 和 50 s，完整历史指从回合开始持续递推至当前时刻所形成的循环状态。对于截断历史，在窗口起点将隐藏状态和单元状态置零，再按照原始 1 s 控制周期依次输入记录的观测—动作对，最后结合相同的当前观测计算动作。0 s 条件直接使用零初始化循环状态。

分别统计帆动作绝对偏差、舵动作绝对偏差及两通道联合动作 L2 偏差，均在归一化动作空间内计算。数值越小，表示截断历史下的输出越接近完整历史策略。结果见表 4.13。

表 4.13 不同历史长度下相对完整历史的归一化动作偏差

Table.4.13 The normalized action deviation of relatively complete history under different historical lengths

历史长度（s）	帆动作绝对偏差	舵动作绝对偏差	联合动作 L2 偏差
0	0.0497 [0.0475, 0.0519]	0.0536 [0.0514, 0.0559]	0.0819 [0.0788, 0.0852]
1	0.1471 [0.1392, 0.1550]	0.2119 [0.2061, 0.2179]	0.2887 [0.2797, 0.2975]
5	0.0308 [0.0289, 0.0327]	0.0482 [0.0460, 0.0503]	0.0623 [0.0593, 0.0651]
10	0.0157 [0.0146, 0.0169]	0.0231 [0.0219, 0.0243]	0.0300 [0.0283, 0.0316]
20	0.0082 [0.0074, 0.0090]	0.0105 [0.0098, 0.0113]	0.0143 [0.0132, 0.0154]
50	0.0013 [0.0012, 0.0015]	0.0018 [0.0016, 0.0020]	0.0024 [0.0021, 0.0027]
完整历史	0（参照）	0（参照）	0（参照）

注：各动作偏差均在归一化动作空间内计算，以完整历史条件下的动作输出为参照；方括号为 95%置信区间。

极短历史条件下，动作偏差呈现非单调变化：0 s 时联合动作 L2 偏差为 0.0819，1 s 时增加至 0.2887。零初始化与仅经过一次循环更新对应不同的输出状态，少量历史输入并未立即使动作接近完整历史结果。

随着历史长度进一步增加，输出逐步接近完整历史策略。5 s、10 s、20 s 和

50 s 条件下，联合动作 L2 偏差分别为 0.0623、0.0300、0.0143 和 0.0024，帆、舵两个通道也呈现相同趋势。其中，5～20 s 范围内的偏差持续减小，50 s 条件下的平均动作输出已与完整历史结果十分接近。

一种可能的解释是，零初始化记忆经过一次循环更新后仍处于短暂的状态调整阶段，尚未形成与连续航行过程相近的历史表示，因此极短历史并未立即改善动作一致性。随着连续观测—动作对逐步输入，循环状态逐渐接近完整历史下的表示，动作偏差相应减小。这一现象提示，历史信息的作用不仅取决于输入数量，也与循环状态的初始化及连续更新过程有关。

这一结果与 4.2 节的训练和执行方式相呼应：训练使用 10 步历史窗口，在线控制通过循环状态持续积累回合内的信息。在动作一致性分析中，20 s 和 50 s 历史比 10 s 历史进一步减小了输出偏差，体现了持续递推所保留的更早交互信息对当前动作的影响。

风向读出与历史截断从两个方面揭示了历史信息的作用。前者表明，经过控制任务训练的 LSTM 隐藏状态包含较当前观测更易由线性模型提取的风向相关信息；后者表明，历史范围及循环状态的构造方式会影响当前帆舵输出。两项结果共同说明，历史观测—动作信息既参与了环境相关表征的形成，也参与了策略的动作计算，为理解无显式风场输入条件下的控制能力提供了依据。

4.5 本章小结

本章研究了无显式风场输入条件下的无人帆船局部帆舵控制问题。在 SAC 框架中引入 LSTM，对历史观测—动作信息进行编码，并与当前观测融合，用于策略决策和价值估计；结合点到点航行特征构建奖励函数，引导策略兼顾目标推进、航行效率与帆舵调节。

对比实验表明，历史信息编码能够改善部分可观测条件下的航行表现。随机风向测试中，SAC-LSTM 的任务成功率达到 99.36%，高于 SAC-nowind 的 39.64%，成功回合的航行时间及帆舵角变化率也有所降低。与显式风场输入参考 SAC-wind 相比，SAC-LSTM 具有更高任务成功率，成功航行效率总体接近。代表性风向测试进一步表明，该模型能够在顺风、横风、斜逆风和逆风下形成相应控制行为，历史信息在迎风相关工况中的作用尤为突出。

奖励消融显示，持续进度反馈是策略学习目标趋近行为的主要信号，阶段奖

励进一步改善航行效率，动作变化惩罚有效降低帆舵调节强度。扰动测试表明，模型能够适应所测试的风场统计参数变化，并在较大区域风向差下继续完成大部分任务；观测噪声增强则伴随成功率下降和控制波动增加，揭示了输入信息质量对策略表现的影响。

历史信息利用分析进一步表明，LSTM 隐藏状态包含可由线性读出器提取的局部风向相关信息，改变决策前的历史范围会影响帆舵动作输出。上述结果从任务表现、奖励作用、扰动响应及内部信息利用等方面验证了历史编码方法在无显式风场输入局部航行控制中的可行性。在此基础上，下一章引入静态障碍物，进一步研究复杂局部航行任务中的历史信息融合与控制决策。

5 面向静态障碍物环境的控制模型优化

5.1 引言

第四章在无显式风场输入条件下，利用历史观测—动作信息建立了无人帆船局部帆舵控制模型，使策略能够根据船体运动响应完成不同风向下的目标航行。在此基础上，本章进一步引入静态障碍物，将控制任务由单一的目标趋近扩展为目标推进与局部避障的协调。障碍物改变了可通行的局部空间，帆船则仍需通过帆舵调节维持有效推进，因此绕行方向和时机需要与当前航速、艏向及此前的控制响应相适应。

在局部避障过程中，当前障碍物的距离和方位决定可选择的绕行空间，历史观测—动作信息则反映船体此前的运动变化与控制响应。随着障碍信息进入和绕行过程推进，不同历史时刻对当前决策的作用也随之变化。为此，本章在 SAC-LSTM 框架中引入由当前观测驱动的时间注意力，对历史隐藏状态进行选择性融合，并结合局部障碍观测与距离惩罚，构建面向静态障碍物环境的帆舵控制模型。

本章首先介绍避障任务、观测构造及注意力融合结构，随后通过不同历史融合方式和窗口配置的对比，评价模型的任务完成能力与航行表现；进一步考察无障碍航行、障碍探测距离变化和递增障碍布局下的控制行为；最后结合注意力权重统计、离线干预和闭环干预，分析历史动态加权对动作生成与航行过程的作用。

5.2 静态避障任务与控制模型扩展

本章沿用前述无人帆船动力学、动态风场和连续帆舵动作设定，在环境中增加静态障碍物及其局部观测，并对历史特征融合和奖励反馈进行扩展。控制策略继续根据可获得的信息直接输出帆角与舵角增量，航迹由连续控制动作与船体动力学共同形成。

5.2.1 避障环境与观测空间

训练环境采用无障碍与含障碍的混合场景，其中无障碍场景占 30%，含障碍场景占 70%。含障碍场景随机布置 5～8 个静态障碍物（障碍物坐标分布在$x \in [120,380], y \in [-250,250]$的区间内），并约束障碍物与起点、目标点及其他障碍物之间的距离不小于 120 m，使训练同时包含基础目标航行和局部绕行过程。各障碍物在单个回合内保持位置不变。

障碍物的首次探测采用距离与视场联合判定：以船体当前位置为中心，探测距离为 150 m，角度范围为艏向左右各 60°。设船体位置为$\boldsymbol{p}_t = (x_t, y_t)$，第$i$个障碍物的全局坐标为$\boldsymbol{p}_i^{obs} = \left(x_i^{obs}, y_i^{obs}\right)$，其相对距离与方位角分别为

$$d_{t,i} = \| \mathbf{p}_i^{\text{obs}} - \mathbf{p}_t \|_2,$$
$$\theta_{t,i} = wrap_{[-\pi,\pi]}\left[atan2\left(y_i^{obs} - y_t, x_i^{obs} - x_t\right) - \psi_t\right]. \tag{5-1}$$

式中，ψ_t为当前艏向角，$atan2$为四象限反正切函数，$wrap_{[-\pi,\pi]}$表示将角度映射到$[-\pi, \pi]$。障碍物进入 150 m 范围且相对方位角位于$[-\pi/3, \pi/3]$时，其全局坐标被加入本回合的已观测障碍物集合。

已观测集合保存障碍物的静态位置，记录在回合重置时统一清除。后续每个控制步根据船体当前位置重新计算集合内障碍物的相对距离，从 150 m 以内的已知障碍物中选取最近两个，更新其相对距离和方位角。因此，已发现的障碍物即使离开当前角度视场，只要仍处于 150 m 以内，就仍可参与观测；超过该距离后暂不占用观测槽位，其位置记录继续保留。

在第四章 14 维基础观测的末尾增加两个障碍物槽位，得到 18 维观测向量：

$$\boldsymbol{o}_t = \left[\left(\boldsymbol{o}_t^{base}\right)^T, d_{t,1}, \theta_{t,1}, d_{t,2}, \theta_{t,2}\right]^T \in \mathbb{R}^{18}. \tag{5-2}$$

其中，$\boldsymbol{o}_t^{base}$表示第四章定义的基础观测，$d_{t,j}$和$\theta_{t,j}$分别表示第j个槽位中的障碍距离与相对方位角。槽位按当前距离排序，其对应的障碍物可随航行位置变化而切换。当只有一个有效障碍时，第二个槽位填充$(0,0)$；当不存在有效障碍时，四个障碍分量均为零。有效性由距离分量是否大于零判断，无需增加单独的标志维度。

上述处理将静态位置维护与时序特征编码分别组织：已观测集合负责保存已发现障碍的位置，LSTM 负责提取历史观测—动作关系。障碍相对量由仿真坐标直接计算，策略所接收的是经过探测与距离筛选的局部信息。图 5.1 给出了帆船进行静态障碍物探测以及障碍物的安全半径示意图。

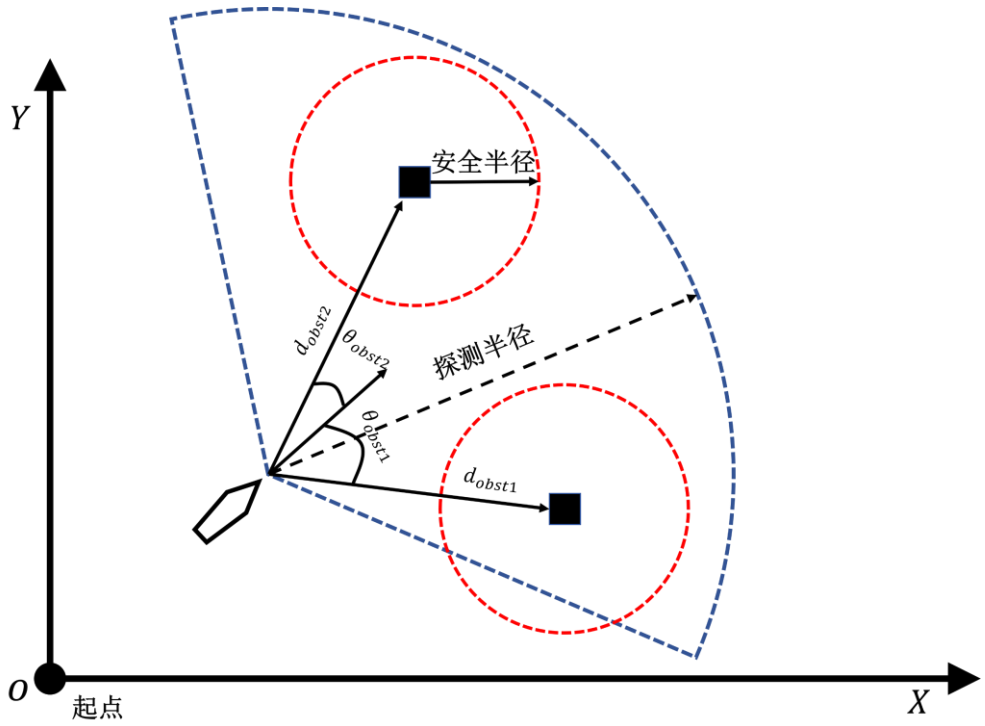


图 5.1 静态障碍物探测示意图。

Fig.5.1 Schematic diagram of static obstacle detection.

本章以障碍物中心周围 40 m 区域作为安全域。当船体与任一障碍物的中心距离小于 40 m 时，判定为安全域侵入并终止回合。该判定使用环境内全部障碍物位置；观测构造则仍按上述已观测集合与两槽位规则进行。

5.2.2 注意力时序融合网络

第四章通过 LSTM 对历史观测—动作信息进行编码，并利用最终隐藏状态形成历史特征。在静态避障任务中，障碍物进入观测、接近安全域及绕行后恢复目标推进等过程，对帆舵调节提出了不同需求。历史序列中各时刻的运动状态与控制响应，对当前决策的参考作用也随航行情境发生变化。

为使历史特征的融合与当前决策需求相联系，本章在原有双分支结构中引入时间注意力。当前观测经特征提取后构成查询信息，最近若干历史隐藏状态分别提供键和值，由查询与各历史表示的匹配结果确定时间权重，再形成加权历史上下文。该结构保留 LSTM 的时序编码能力，同时为当前决策提供对多个历史表示进行选择性融合的通路。

本文采用缩放点积注意力实现上述历史信息融合。设最近 K 个历史观测—动作对经 LSTM 编码得到隐藏状态序列

$$H_t = \{h_{t-K+1}, \ldots, h_t\}. \tag{5-3}$$

以 Actor 为例，记当前观测经全连接层提取的特征为e_t，由其构造查询向量：

$$q_t = W_q e_t + b_q \tag{5-4}$$

历史分支仍按照第四章的方式，将同一时间步的观测与动作配对后输入 LSTM。在线控制过程中，上一时刻的观测—动作对用于更新循环状态，并得到当前决策时已经获得的历史隐藏状态。注意力窗口保存最近 K个历史隐藏状态，并按照时间顺序记为 $h_t^{(1)}, h_t^{(2)}, \dots, h_t^{(K)}$，其中 $h_t^{(K)}$对应距离当前决策最近的历史表示。

对各历史隐藏状态分别进行线性映射，得到键向量和值向量：

$$k_t^{(i)} = W_k h_t^{(i)} + b_k,\ v_t^{(i)} = W_v h_t^{(i)} + b_v. \tag{5-5}$$

查询与各键之间的缩放点积经归一化后，得到历史权重：

$$\alpha_{t,i} = \frac{exp\left(\boldsymbol{q}_t^T k_t^{(i)} / \sqrt{d_k}\right)}{\sum_{j=1}^{K} exp\left(\boldsymbol{q}_t^T k_t^{(j)} / \sqrt{d_k}\right)}. \tag{5-6}$$

式中，d_k为查询和键的特征维度，W_q、W_k和W_v为可学习参数；$\alpha_{t,i}$为第i个历史隐藏状态的注意力系数，满足$\alpha_{t,i} \geq 0$且$\sum_{i=1}^{K} \alpha_{t,i} = 1$。随后对值向量加权求和，形成历史上下文，并与当前特征进行拼接：

$$\boldsymbol{g}_t = \sum_{i=1}^{K} \alpha_{t,i}\, v_t^{(i)}, \boldsymbol{\xi}_t = f_{fuse}([\boldsymbol{e}_t; \boldsymbol{g}_t]). \tag{5-7}$$

其中，$\boldsymbol{g}_t$为加权历史上下文，f_{fuse}为后续全连接融合映射。Actor 根据融合特征输出帆舵动作分布；Critic 采用相应的历史融合结构，并结合待评价动作估计 Q 值。Actor 与两个 Critic 分别维护独立的网络参数，策略优化、价值更新及目标网络更新继续采用 SAC 框架。网络整体连接关系以一个 Critic 为例示于图 5.2。

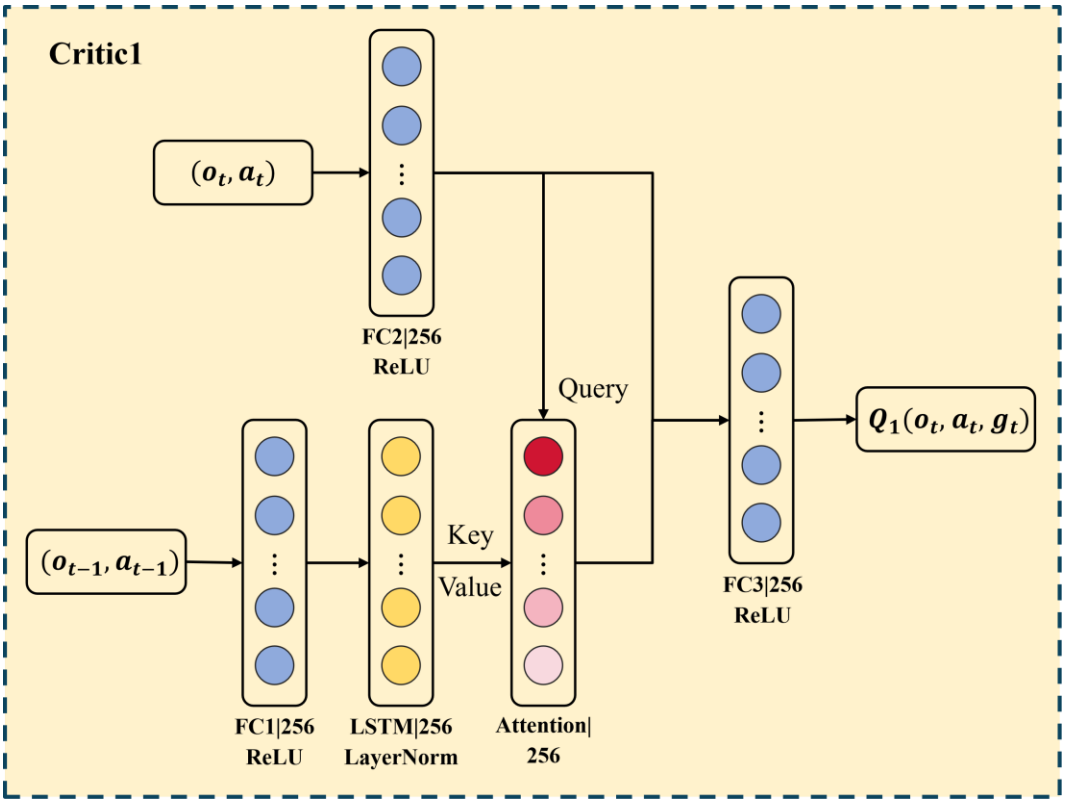


图 5.2 引入时间注意力的 Critic 网络结构

Fig.5.2 Critic network architecture with temporal attention.

本章将经验中的历史序列长度、训练展开长度和注意力窗口长度统一设置为K。训练时，历史编码与注意力汇聚按同一窗口配置完成；在线控制时，LSTM随交互持续更新，注意力读取最近K个历史隐藏状态。当前观测通过独立分支参与当步决策，在执行动作后与该动作配对，进入下一步的历史编码。

与仅使用最终隐藏状态的融合方式相比，该结构为当前决策提供了多个历史表示之间的加权通路。障碍物进入观测后，其距离和方位信息能够立即改变当前查询，进而调整历史上下文；后续绕行过程中的观测和控制响应继续进入历史分支，共同参与后续帆舵决策。

5.2.3 避障奖励设计

静态避障任务同时需要持续接近目标和绕开障碍物。本章保留第四章基础奖励中的航行进度、帆舵调节、阶段到达、目标到达及时间反馈，在其基础上增加障碍物相关项。将基础航行奖励整体记为R_t^{base}，则总奖励表示为

$$R_t = R_t^{\text{base}} - R_{\text{obst},t}. \tag{5-8}$$

避障项使用当前观测槽位中的两个有效障碍距离。为表示接近障碍物时的距

离作用强度，记单个障碍的惩罚幅值函数为$\rho(d)$：

$$\rho(d)=\begin{cases}\exp\left[-\dfrac{d-D_c}{b_d}\right], & 0<d<D_{\mathrm{det}},\leftarrow\\ 0, & \text{其他.}\end{cases} \tag{5-9}$$

其中，$D_{\mathrm{det}}=150\,\mathrm{m}$为距离作用范围，$D_c=40\,\mathrm{m}$为安全域半径，$b_d=20\,\mathrm{m}$为距离衰减尺度。有效槽位满足$d>0$，空槽位不产生距离惩罚。两个槽位的幅值相加得到

$$R_{\mathrm{obst},t}=\rho\left(d_{t,1}\right)+\rho\left(d_{t,2}\right). \tag{5-10}$$

距离函数在障碍较远时取较小值，随着船体接近安全域边界逐渐增大，使奖励反馈在实际侵入之前就体现近障程度。基础进度奖励继续引导船体驶向目标，距离惩罚则促使策略在接近障碍时调整航向及帆舵组合；绕开障碍后，其幅值随距离增大而减小，目标推进重新成为主要的航行反馈。

各对照模型使用相同的障碍观测规则和奖励配置。这样，模型比较围绕历史特征融合展开，窗口比较则考察统一序列配置下的控制差异。

5.3 实验结果与分析

本节从历史融合方式、窗口配置、任务条件变化及注意力作用四个方面开展实验。首先比较不同历史融合模型的任务完成率、航行效率与帆舵调节表现，随后分析统一窗口配置对控制性能的影响；在此基础上，通过任务条件变化和代表性航迹考察模型的适应性，并通过固定模型下的权重干预，进一步分析动态历史加权对控制过程的实际贡献。

下文所提及的各类模型均选择一个训练检查点进行相关的任务测试。

5.3.1 不同历史信息融合方式对比实验

为验证时间注意力机制对静态障碍物环境下历史信息利用的作用，本文设置三种采用不同历史信息融合方式的 SAC-LSTM 控制模型进行比较。三种模型采用相同的观测空间、动作空间、奖励函数、训练环境及 SAC 主要训练参数，并通过调整网络结构使总体参数规模保持在相近范围。实验的主要区别集中于 LSTM 产生的历史时序特征如何参与当前决策。

主模型采用 5.2 节所述的时间注意力结构，以下记为 Attention 模型。该模型以当前状态经全连接层提取的特征作为 Query，并根据 Query 与历史 LSTM 隐

藏状态之间的相关关系计算不同时刻的权重，再将加权后的历史特征与当前特征融合。因此，同一段历史信息在不同当前状态下可以产生不同的融合结果。

为进一步区分模型性能提升与网络规模增加、历史特征变换等因素的关系，设置两种对照模型。Deep-LSTM 模型移除注意力层，通过增加后续全连接结构使参数规模与主模型保持相近，并直接使用 LSTM 历史编码结果参与当前决策。该模型保留历史信息编码能力，但不再对不同历史时刻进行显式加权选择。MeanPool 模型则保留对历史隐藏状态的特征映射，并对各时刻特征进行平均融合，使历史序列中的各位置以相同权重参与决策。由此，三种模型分别对应“动态加权融合”“LSTM 历史编码直接融合”和“历史特征等权融合”三种处理方式，其比较用于分析历史信息融合方式对避障控制性能的影响。

（1）任务完成结果

在此基础上，使用训练好的模型进行了 1000 次测试并通过不同失败情况的归类得到表 5.1。

表 5.1 不同历史融合模型的任务完成情况

Table.5.1 Task outcomes of different history-fusion models.

指标	Attention	Deep-LSTM	MeanPool
任务成功率（%）	95.5	84.8	71.8
安全域侵入 / 次	44	127	254
超时 / 次	0	25	27
越界 / 次	1	0	1

注：任务成功指在规定时间内到达目标且全程未侵入 40 m 障碍安全域，各失败类型按回合结局统计。

从任务完成结果可以看出，Attention 模型在 1000 个测试场景中完成 955 次任务，成功率达到 95.5%；Deep-LSTM 和 MeanPool 的成功率分别为 84.8%和 71.8%。Attention 相较两种对照模型分别提高 10.7 和 23.7 个百分点，表明在相同任务设置下，引入基于当前状态的历史信息动态加权后，模型能够完成更多随机障碍场景。配对结果中，Attention 相较 Deep-LSTM 和 MeanPool 分别存在 142 和 261 个“仅 Attention 成功”的场景，而反方向分别为 35 和 24 个场景，也体现出总体任务完成能力上的差异。

进一步观察失败类型，三种模型的主要失败原因均为进入 40 m 障碍物安全

域。其中 Attention 模型出现 44 次安全域侵入，而 Deep-LSTM 和 MeanPool 分别增加至 127 次和 254 次；后两种模型还分别出现 25 次和 27 次超时。由于三种模型使用相同的障碍物观测和避障奖励，上述差异主要反映了不同历史融合方式形成的控制策略在目标推进和障碍规避之间的协调能力不同。Attention 模型在当前测试中减少了安全域侵入，同时基本消除了长时间未能到达目标的情况。

（2）成功航行回合的效率与控制表现

任务成功率反映模型能否完成整个避障航行任务，但仅比较成功与失败还不能说明成功回合中的实际航行过程。因此，在成功到达目标的回合中，进一步统计平均航行时间、航行距离以及帆角和舵角变化率，结果如表 5.2 所示。

表 5.2 不同历史融合模型的航行效率与控制表现

Table.5.2 Navigation efficiency and control performance of history-fusion models.

指标	Attention	Deep-LSTM	MeanPool
平均航行时间 (s)	193.15 ± 62.63	239.14 ± 136.55	272.51 ± 152.85
平均航行距离(m)	607.93 ± 114.02	635.26 ± 151.54	779.41 ± 292.61
帆角变化率(°/s)	0.91 ± 0.38	0.99 ± 0.43	2.09 ± 0.41
舵角变化率(°/s)	0.93 ± 0.34	0.89 ± 0.25	1.06 ± 0.29

注：指标分别基于各模型成功到达目标的回合统计，Attention、Deep-LSTM 和 MeanPool 对应样本数分别为 955、848 和 718；数据表示为均值±标准差

表 5.2 表明，在各模型成功完成的回合中，Attention 的平均航行时间和航行距离均低于两种对照模型。其中，Attention 的平均航行时间为 193.15 s，Deep-LSTM 和 MeanPool 分别为 239.14 s 和 272.51 s。结合表 5.1 的任务完成结果，Attention 不仅能够完成更多随机障碍场景，其成功航行过程也具有较低的时间和航程开销。

控制调节指标进一步说明了这种差异。Attention 与 Deep-LSTM 的帆舵角变化率总体接近，其中 Attention 的舵角变化率为 0.93°/s，略高于 Deep-LSTM 的 0.89°/s，但其任务成功率和成功航行效率更高。这表明，Attention 的主要优势是在相近的控制调节强度下，更好地协调了目标推进与障碍规避。相比之下，MeanPool 的帆角变化率达到 2.09°/s，同时伴随更长的航行时间和航程，表现出较大的控制调节与航行开销。

三种模型采用相同的障碍观测和奖励设置，并保持相近的参数规模，其结果

体现了历史融合结构对所学习控制策略的影响。在本组实验中，由当前观测驱动的历史选择性融合取得了较好的综合表现，说明在获得时序表示之后，进一步调整不同历史位置参与当前决策的方式，有助于改善静态避障控制。

5.3.2 历史窗口长度对控制性能的影响

在采用时间注意力后，窗口配置决定了训练时历史序列的展开范围，以及在线决策时直接参与注意力汇聚的历史表示数量。本节进一步比较不同窗口配置，分析时序信息组织方式对静态避障控制性能的影响。

沿用 5.2.2 节的设置，将经验中的历史序列长度、训练展开长度和注意力窗口长度统一记为K，分别取 5、10 和 20，并按各自配置训练模型。其中，$K=10$为上一节 Attention 模型采用的配置。控制周期为 1 s，因此三个注意力窗口分别读取最近 5、10 和 20 个控制步对应的隐藏状态；在线 LSTM 循环状态则继续随回合内交互更新。除窗口配置外，各模型的网络结构、观测与动作空间、奖励函数及训练环境保持一致。

测试仍采用 5.3 节所述的 1000 个随机场景，使三个模型面对相同的初始状态、风场及障碍物布局。三种窗口配置的任务结局分别为：$K=5$成功 913 次，$K=10$成功 955 次，$K=20$成功 714 次；对应的安全域侵入次数分别为 87、44 和 285 次。 为进一步比较模型完成任务后的航行过程，统计各自成功回合中的航行时间、航行距离以及帆舵角变化率，结果如表 5.3 所示。

表 5.3 不同历史窗口长度模型的航行性能

Table.5.3 The navigation performance of models with different historical window lengths

	K=5	K=10	K=20
任务成功率(%)	91.3	95.5	71.4
平均航行时间(s)	198.99 ± 64.75	193.15 ± 62.63	276.27 ± 126.08
平均航行距离(m)	635.52 ± 136.61	607.93 ± 114.02	755.64 ± 225.36
帆角变化率(°/s)	0.77 ± 0.32	0.91 ± 0.38	1.25 ± 0.34
舵角变化率(°/s)	0.87 ± 0.37	0.93 ± 0.34	1.31 ± 0.36

注：任务成功率基于各模型全部 1000 个测试回合；其余指标分别基于对应模型成功到达目标的回合统计。相关成功回合统计分别包含 913、955 和 714 个回合。

从任务完成结果来看，三种窗口设置并未表现出随历史长度增加而持续提高的趋势。$K=5$时任务成功率为 91.3%，模型已经能够完成大部分随机避障任务；

历史窗口增加至$K=10$后，成功率进一步提高至 95.5%，安全域侵入次数由 87 次减少至 44 次。继续将窗口扩大至$K=20$后，成功率反而下降至 71.4%，安全域侵入次数增加至 285 次。因此，在本文所测试的三种时间范围中，$K=10$取得了更高的整体任务完成率，说明增加历史信息只有在适当范围内能够带来性能改善。

成功回合中的航行指标进一步反映了这种差异。与$K=5$相比，$K=10$的平均航行时间由 198.99 s 缩短至 193.15 s，平均航行距离由 635.52 m 减小至 607.93 m，表明增加一定范围的历史信息后，模型不仅能够完成更多任务，在成功回合中也形成了更直接的目标推进与绕障过程。与此同时，$K=5$的帆角和舵角变化率分别为 0.77°/s 和 0.87°/s，略低于$K=10$的 0.91°/s 和 0.93°/s。这说明较短窗口下的动作调节强度较低，但这种较小的帆舵变化并没有同时带来更高的任务成功率和航行效率。对于本文任务而言，$K=10$在适当增加控制调节的同时，获得了更高的任务完成率和更短的航行时间、航行距离。

当窗口增加至$K=20$时，任务成功率下降至 71.4%，成功回合的平均航行时间和航行距离分别增加至 276.27 s 和 755.64 m，帆角与舵角变化率也分别上升至 1.25°/s 和 1.31°/s。较长窗口下的性能下降由此同时体现在安全完成能力、航行效率和控制调节开销上。

仅比较全部随机场景的总体结果，还难以判断窗口长度的影响主要体现在哪一类避障任务中。为此，进一步根据场景的障碍几何关系对测试结果进行分组。具体而言，若起点与目标点的直线路径与任一障碍物 40 m 安全域相交，则记为“直线遮挡”场景，此时无人帆船必须主动改变原有目标方向完成绕行；其余场景记为“直线未遮挡”。该划分仅由测试开始前的障碍物布局确定，与模型实际产生的航迹无关。正式测试的 1000 个场景中，共包含 282 个直线未遮挡场景和 718 个直线遮挡场景。如图 5.3 所示。

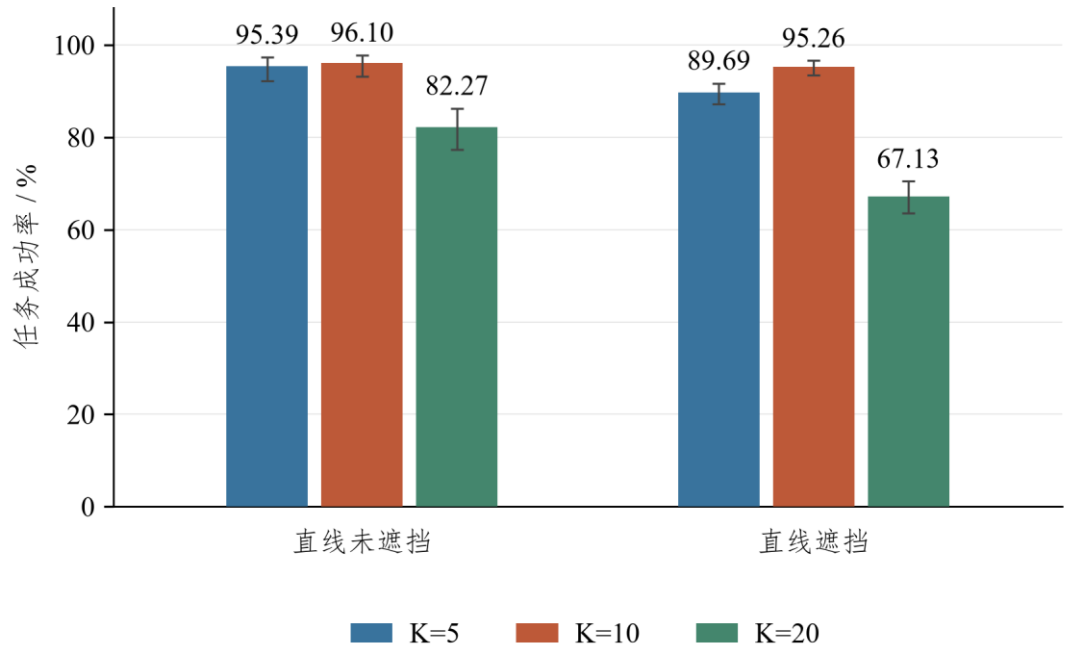


图 5.3 不同历史窗口模型在障碍几何分组下的任务成功率

Fig.5.3 The task success rate of different historical window models under obstacle geometric grouping

在直线未遮挡场景中，$K=5$与$K=10$的任务成功率分别为 95.39%和96.10%，相差 0.71 个百分点；在直线遮挡场景中，两者成功率分别为 89.69%和95.26%，差距扩大至 5.57 个百分点。这表明，$K=10$相对于较短窗口的改善，更集中地体现在起终点直连区域受到障碍安全域阻挡的场景中。此时，模型需要在保持目标推进的同时形成有效绕行，适当的窗口配置有助于协调这一过程。

该分组描述的是障碍布局与起终点之间的几何关系，实际航迹仍由风况、船体运动状态及局部障碍共同决定。$K=20$在直线未遮挡和直线遮挡场景中的成功率分别为 82.27%和 67.13%，均低于另外两种配置，说明其性能下降存在于两类场景中，并在直线受阻场景中更加突出。

从障碍物数量的分组结果也可以观察到类似趋势。随着单个场景中的障碍物数量由 5 个增加到 8 个，$K=10$的成功率由 96.7%下降至 93.8%，仍保持在较高水平；$K=5$则由 93.3%下降至 87.1%，而$K=20$由 78.8%进一步下降至 64.1%。这说明随着局部航行约束增多，不同历史窗口之间的性能差异逐渐更加明显，也进一步体现了历史信息范围对复杂避障决策的影响。

综合比较可见，三种统一窗口配置的控制性能并未随窗口扩大而持续提高。其中，$K=10$在任务成功率、成功航行时间和航程方面取得了较好的综合表现，

后续实验据此采用该配置。本实验中的窗口参数同时影响经验历史序列、训练展开过程和注意力直接读取的历史表示数量，而在线 LSTM 状态仍随回合内交互持续更新。因此，实验结果反映的是不同序列组织配置对学习与控制表现的共同影响，说明窗口设置需要与任务及训练方式相适应。

这一结果与第四章的历史截断分析回答不同问题：第四章在固定策略下比较不同历史构造与完整历史的动作一致性，本节则比较不同窗口配置重新训练后的任务表现。前者反映既有策略对历史的依赖，后者反映模型配置对闭环控制结果的影响。

5.3.3 任务条件变化下的适应性与航行行为分析

前两节分别比较了历史信息融合方式及历史窗口长度对静态避障控制性能的影响，并确定 Attention 模型及$K = 10$窗口作为本章的主要控制配置。上述结果主要来自与训练阶段一致的随机障碍生成与探测条件，反映了模型在既定任务分布中的控制性能。本节进一步改变测试任务条件，从无障碍基础航行和障碍探测距离变化两个方面考察模型的任务适应性，并结合递增障碍布局下的代表性航迹，对模型的航行行为及性能边界进行分析。

（1）无障碍条件下的基础航行保持

第五章在第四章基础点到点航行任务上增加了静态障碍物观测和避障奖励，使控制策略除目标推进外，还需要学习障碍规避行为。为考察这种任务扩展对原有基础航行能力的影响，本组实验完全移除测试环境中的障碍物，并在相同初始状态、随机风向和简化 Dryden 模型风场条件下分别测试第四章 SAC-LSTM 和第五章 Attention 模型。两模型各测试 1000 个回合，其中 SAC-LSTM 成功 992 次，Attention 成功 999 次，任务成功率分别为 99.2%和 99.9%。因此，第五章模型在经过静态避障任务训练后仍保持了较高的基础点到点任务完成能力。

进一步选取两模型均成功的 991 个相同场景，对其航行过程进行比较，结果见表 5.4。

表 5.4 无障碍条件下的基础航行表现

Table.5.4 The basic navigation performance under barrier-free conditions

指标	第四章 SAC-LSTM	第五章 Attention	变化差异
任务成功率（%）	99.2	99.9	+0.7%

指标	第四章 SAC-LSTM	第五章 Attention	变化差异
平均航行时间（s）	181.5	196.3	+8.2%
平均航行距离（m）	595.0	603.6	+1.5%
有效航速（m/s）	3.387	3.224	−4.82%
舵角变化率（°/s）	0.659	0.763	+15.7%

注：任务成功率基于两模型各 1000 个测试回合；其余指标基于两模型共同成功的 991 个配对场景。除任务成功率采用百分点差外，其余差异均为第五章 Attention 模型相对第四章 SAC-LSTM 模型的相对变化率。

在两模型共同成功的991个场景中，Attention的平均航行距离较第四章SAC-LSTM增加1.5%，平均航行时间增加8.2%，舵角变化率由0.659°/s上升至0.763°/s。航时增幅高于航程增幅，且伴随更多舵角调节，说明两模型的差异更多体现为航行过程中的推进效率与局部控制修正，而不是绕行距离的大幅增加。结合前述任务成功率，Attention在避障任务训练后保持了基础目标航行能力，同时呈现出与第四章模型不同的控制调节特征。

这种差异在逆风条件下更加明显。逆风共同成功场景中，两模型平均航程分别为 747.7 m 和 751.2 m，差异仅 3.5 m，而 Attention 平均航时由 253.2 s 增加至 284.0 s，对应有效航速降低约 10.87%；舵角变化率也由 0.891°/s 增加至 1.185°/s。

图 5.5 给出了一个无障碍条件下的代表性同场景航迹。两种模型均能够完成逆风条件下的目标航行，并形成必要的横向迂回；相比之下，第四章 SAC-LSTM 在主要换舷点之间形成的航段较为直接，而第五章 Attention 模型在相邻主要转向之间仍包含多次局部方向调整，与前述航时和舵角变化结果相对应。该现象表明，避障任务训练后的策略在维持较高基础任务完成率的同时，航行行为具有更明显的持续修正特征。

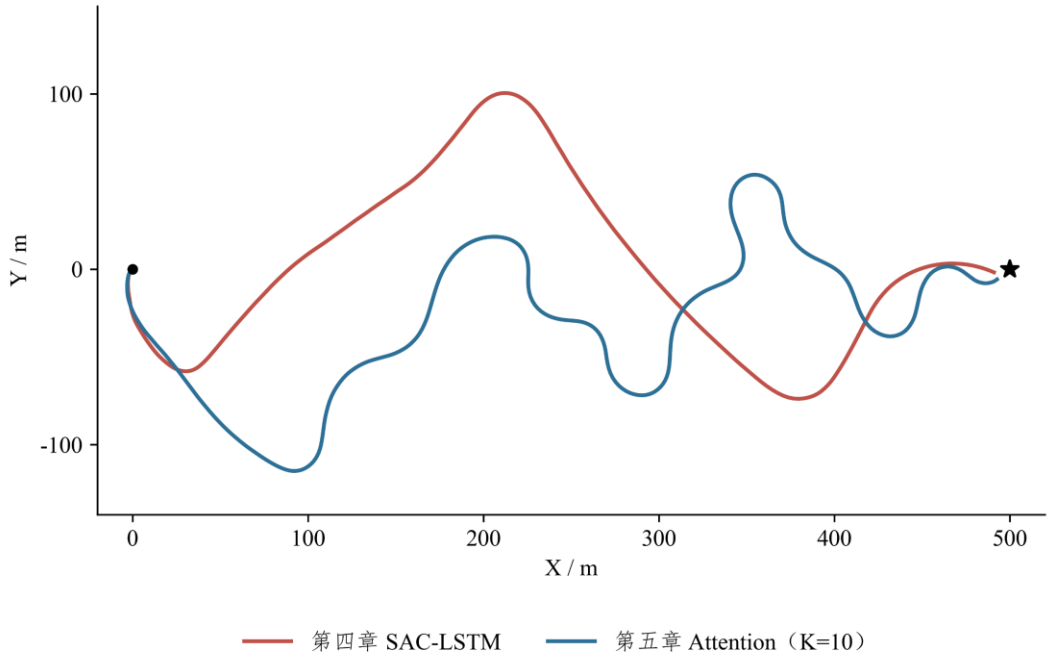


图 5.5 无障碍条件下的代表性同场景航迹

Fig.5.5 Representative cross-scenario flight tracks under barrier-free conditions

（2）障碍探测条件变化下的适应性

标准静态障碍实验中，未知障碍物在进入船艏前方 120°视场且距离小于 150 m 后首次进入已观测障碍集合。为考察控制策略对障碍信息获取条件变化的适应能力，本组实验保持物理障碍布局、初始状态、风场及其他环境设置不变，仅将未知障碍物的首次探测距离由 150 m 依次缩短至 120 m、100 m 和 80 m；障碍被发现后仍按原有 150 m 范围参与后续观测。Deep-LSTM 和 Attention 在每种条件下分别使用相同的 500 个测试场景。

实验结果见表 5.5 及图 5.6。

表 5.5 探测距离变化下的任务结果

Table.5.5 Task results under varying detection distances

首次探测距离/m	Deep-LSTM 成功率/%	Attention 成功率/%	仅 Attention 成功	仅 Deep-LSTM 成功	安全域侵入 Deep/Attention
150（B1）	88.4	96.2	54	15	53 / 19
120（B2）	89.2	96.6	51	14	50 / 17
100（B3）	88.8	79.8	41	86	50 / 101
80（B4）	60.6	43.0	70	158	190 / 285

注：每种首次探测距离均采用两模型相同的 500 个配对测试场景；“仅 Attention 成功”和“仅 Deep-LSTM 成功”为逐场景配对结局计数；安全域侵入次数按 Deep-LSTM/Attention 顺序给出。

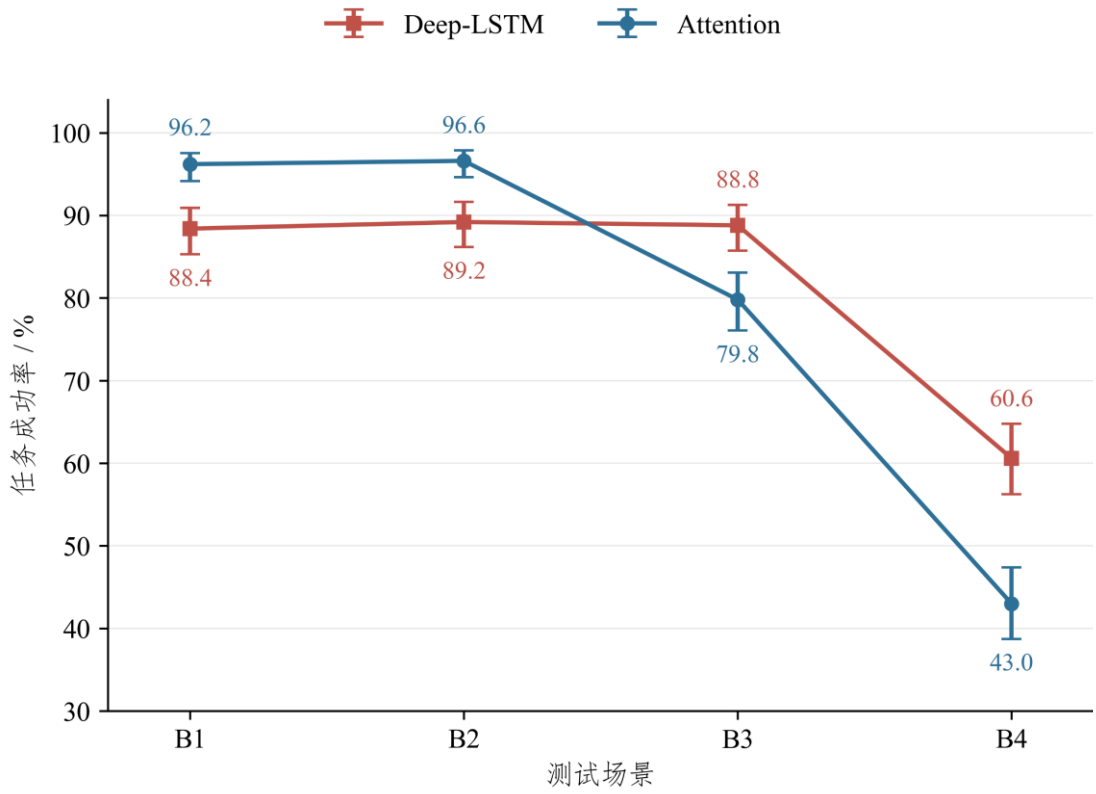


图 5.6 不同障碍首次探测距离下两种模型的任务成功率

Fig.5.6 The task success rates of the two models under different initial detection distances for various obstacles

当首次探测距离由 150 m 缩短至 120 m 时，两模型的任务成功率均基本保持不变。Attention 分别取得 96.2%和 96.6%的成功率，仍明显高于 Deep-LSTM 的 88.4%和 89.2%。进一步结合逐场景结果可以发现，Attention 在 120 m 条件下有 12 个原基准成功场景转为失败，同时有 14 个原失败场景转为成功，因此 0.4 个百分点的增加主要来自少量边界场景之间的结果互换，而不是整体性能进一步提升。

当首次探测距离缩短至 100 m 后，两种模型的变化趋势开始出现明显差异。Deep-LSTM 仍保持 88.8%的成功率，而 Attention 下降至 79.8%；相同 500 个测试场景中，仅 Deep-LSTM 成功的场景达到 86 个，而仅 Attention 成功的场景为 41 个。首次探测距离进一步缩短至 80 m 后，两模型性能均明显下降，Deep-LSTM 和 Attention 成功率分别降低至 60.6%和 43.0%，仅 Deep-LSTM 成功的场景进一

步增加至 158 个。

失败类型表明，上述性能下降主要表现为安全域侵入。Attention 在 100 m 和 80 m 条件下分别产生 101 次和 285 次安全域侵入，而对应条件下均未发生超时；Deep-LSTM 同样以安全域侵入作为主要失败形式。这说明当障碍物更晚进入观测时，模型性能变化主要由有限剩余航行空间内能否完成有效绕行所决定，而非目标推进能力不足。

需要强调的是，Attention 在较短探测距离下的成功率下降并不意味着其所有成功航行过程同时恶化。在两模型共同成功的场景中，Attention 在 150、120 和 100 m 条件下的平均航时分别比 Deep-LSTM 短 46.54 s、48.55 s 和 55.91 s，平均航程分别减少 32.59 m、32.68 m 和 36.76 m；即使在 80 m 条件下，其平均航时仍缩短 37.14 s。因此，探测距离缩短后 Attention 的主要问题表现为能够稳定完成的场景范围缩小，而在两种模型都能够成功处理的场景中，其航行效率仍具有一定优势。

对 100 m 和 80 m 条件下“Deep-LSTM 成功而 Attention 失败”的配对场景进一步分析发现，两模型首次获得最终危险障碍信息时的距离基本一致，但随后 10 s 内 Attention 的累计舵角和累计艏向变化整体较小。例如 100 m 条件下，两模型 10 s 累计舵角变化分别为 10.92°和 5.79°，累计艏向变化分别为 19.12°和 13.83°；80 m 条件下也表现出类似趋势。这一现象说明，在障碍较晚进入观测的部分失败场景中，Attention 表现出了较弱的局部航向调整幅度。不过，这一比较来自经过任务结局筛选的场景，只能用于描述已观察到的控制行为差异，不能据此单独确定性能下降的内部原因。

综合来看，Attention 在 150 m 和 120 m 首次探测距离下保持了较高的任务成功率，优于 Deep-LSTM；当首次探测距离缩短至 100 m 和 80 m 时，其成功率分别下降至 79.8%和 43.0%，低于 Deep-LSTM 对应的 88.8%和 60.6%。这一变化表明，当前 Attention 策略对障碍信息提前量的变化更为敏感，较晚获得障碍信息时，安全域侵入成为任务失败的主要表现。与此同时，Attention 在两模型共同成功的场景中仍保持较短的平均航时，说明其航行效率优势与安全完成场景数量的下降可以同时存在。本组实验由此明确了模型在不同探测条件下的表现：标准条件下的综合性能改善，并未同样延伸至所测试的近距离探测工况。

（3）递增障碍布局下的航迹调整与失效分析

在前述随机场景测试基础上，进一步采用递增障碍布局观察模型面对局部航行约束持续变化时的实际控制过程。具体而言，以无障碍或上一级成功航迹为参考，在其附近依次加入新的静态障碍，并从相同起始条件重新执行完整航行任务。新增障碍在回合开始时即已存在，模型仍按照既定探测机制获取障碍信息并直接生成帆舵动作。该组实验主要用于分析控制策略在原有航行路径受到阻挡后如何调整后续航迹，以及局部空间约束持续增强时可能出现的失效形式。

首先考察顺风条件下的递增障碍过程，结果如图 5.7 所示。无障碍时，模型整体沿较为直接的路径向目标推进；当障碍物布置在原有航迹附近后，实际航迹随之向安全域外侧偏移，并在绕过障碍后重新趋近目标。随着障碍继续增加，模型并未简单重复上一阶段的绕行轨迹，而是根据新的局部空间约束重新调整后续航行路径。

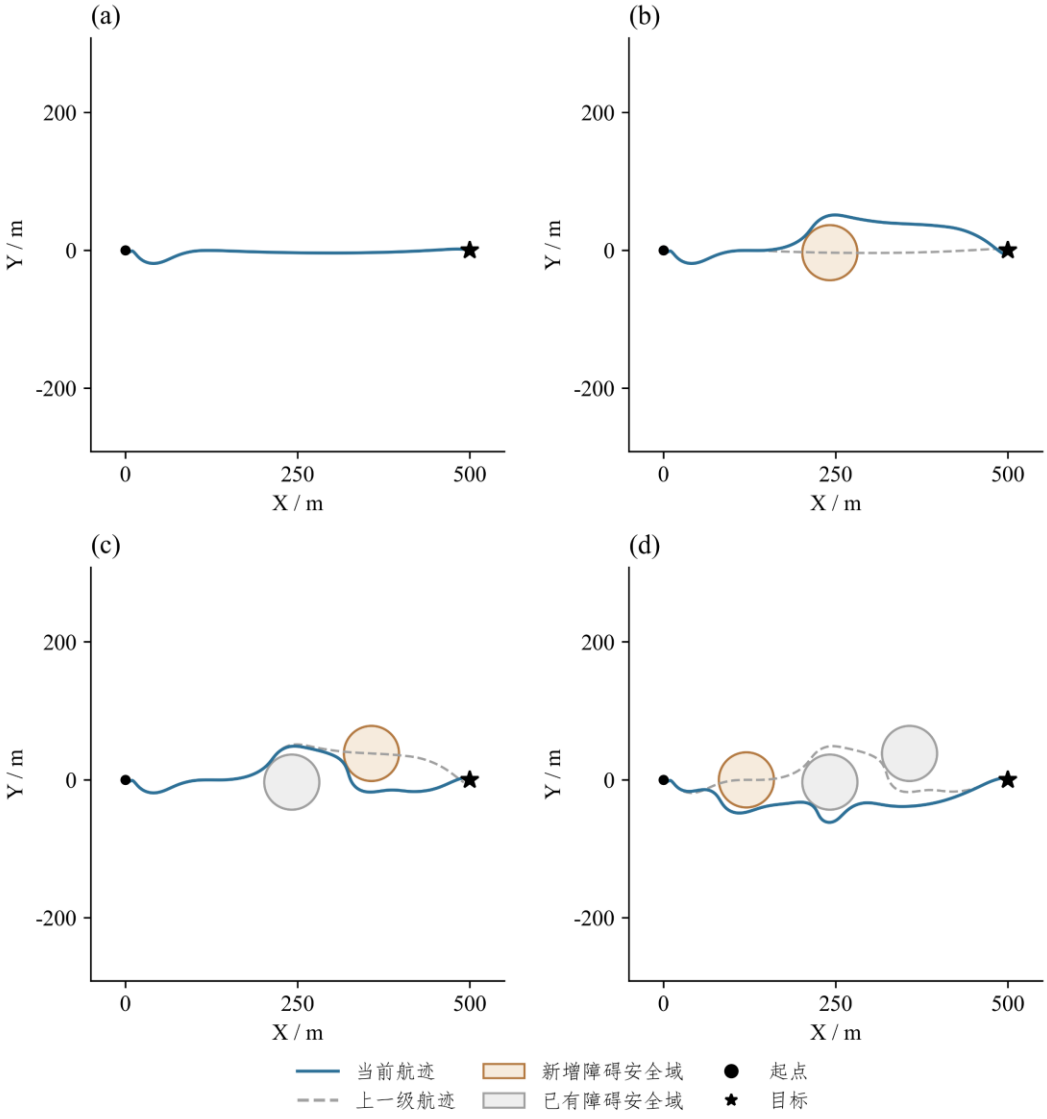


图 5.7 顺风递增障碍成功过程

Fig.5.7 The process of success in increasing obstacles under tailwind conditions

逆风条件下的结果如图 5.8 所示。与顺风相比，无人帆船本身需要通过较大范围的横向运动和换舷维持有效推进，因此新增障碍不仅引起局部绕行，还会改变后续较长航段的走向。随着障碍逐级加入，模型能够在原有逆风航行行为基础上继续调整航迹，并保持向目标推进。该结果表明，障碍规避并非独立于原有航行过程，而是与逆风推进和航向调节共同体现在连续帆舵决策中。

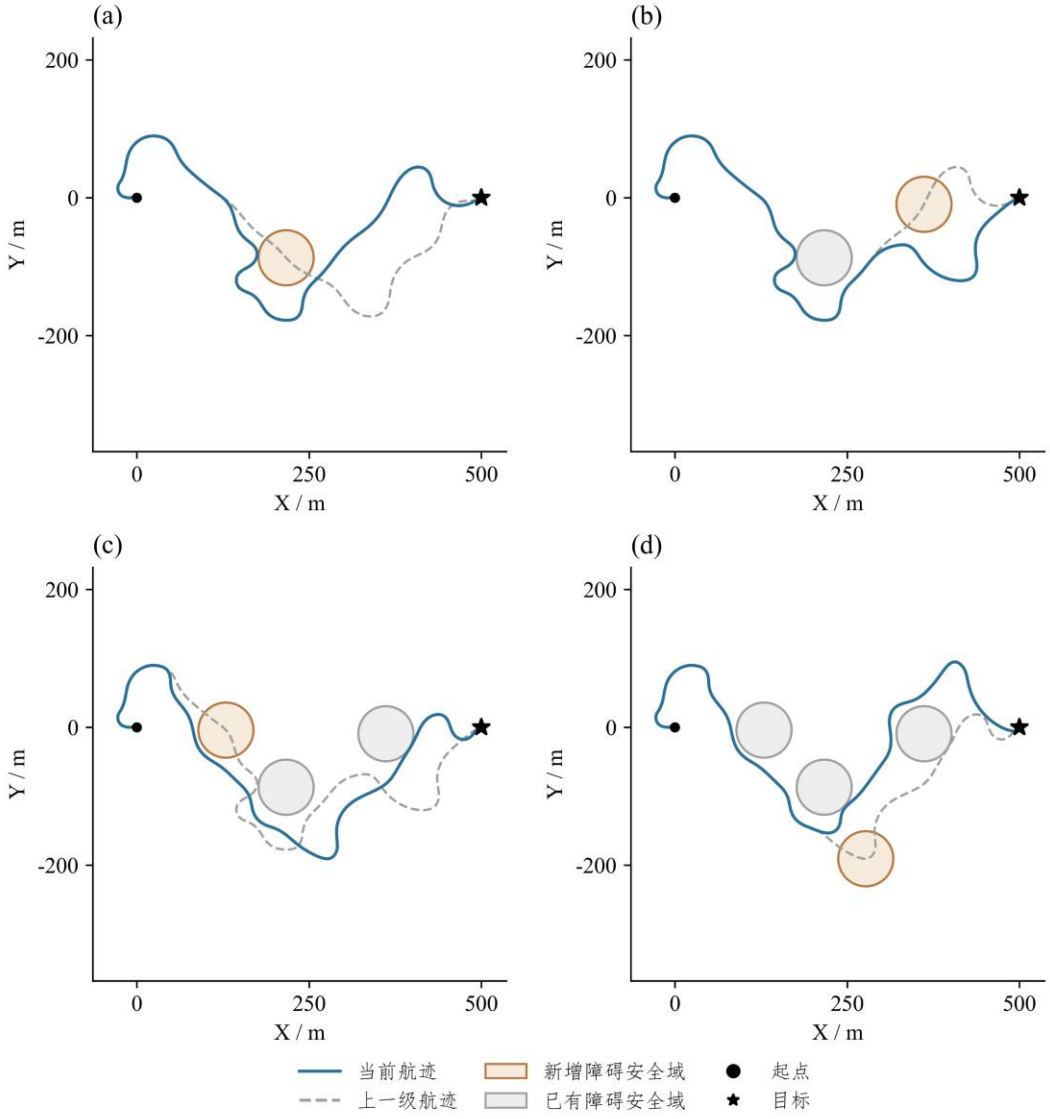


图 5.8 逆风递增障碍成功过程

Fig.5.8 The process of success in increasing obstacles under headwind conditions

进一步增加局部障碍约束后，模型也会出现安全域侵入。顺风与逆风条件下的代表性失效过程分别如图 5.9 和图 5.10 所示。新增障碍位于上一阶段成功航迹附近后，模型虽然对原有航迹进行了调整，但未能始终保持 40 m 安全距离，最终进入障碍安全域并按照正式任务规则提前终止。例如顺风失败案例中的最小障碍中心距离为 39.91 m，已经越过本文设定的 40 m 安全判据，因此该回合判定为失败。

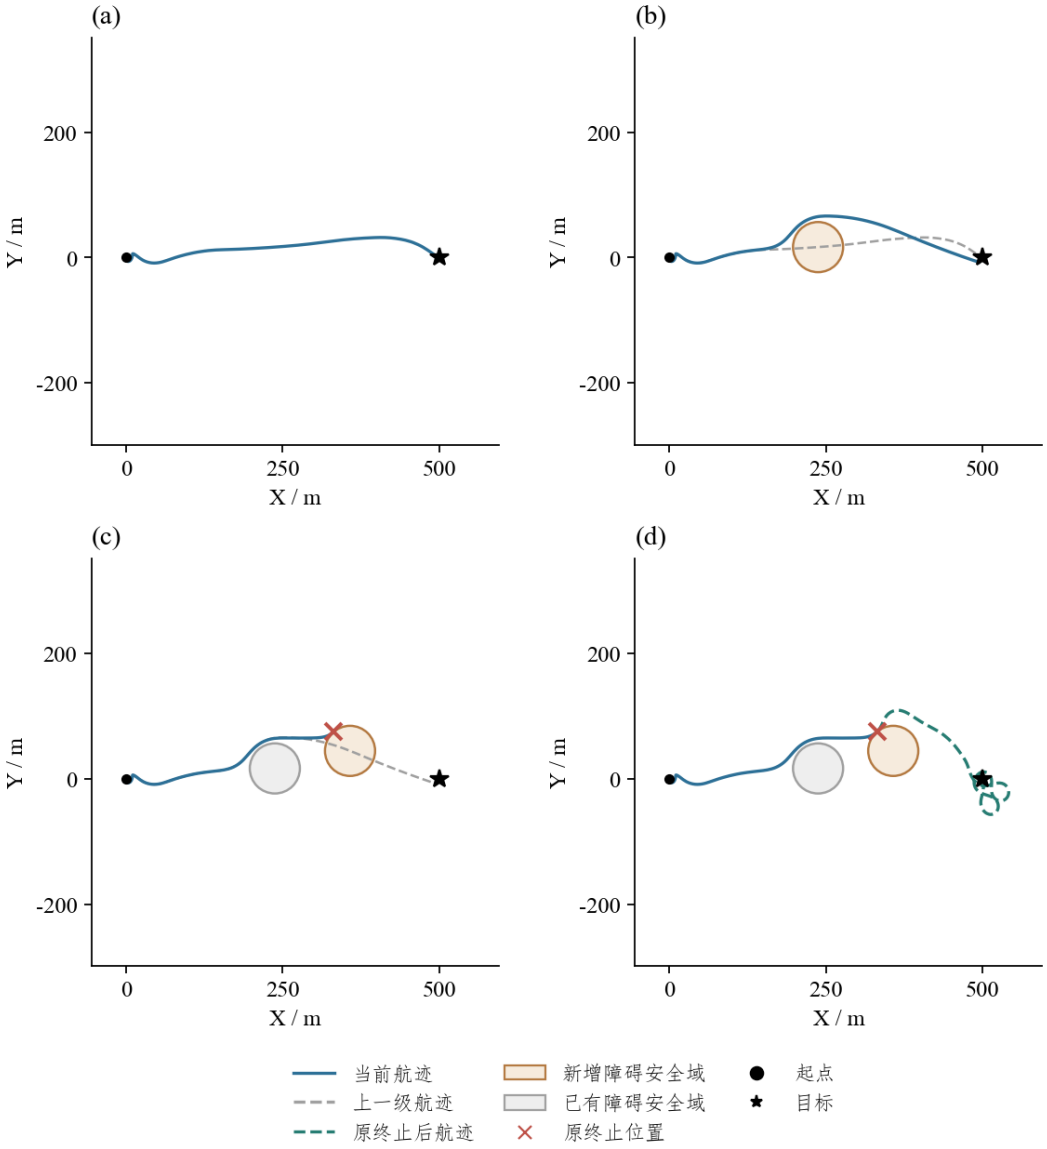


图 5.9 顺风递增障碍失败过程

Fig.5.9 The process of failure in increasing obstacles under tailwind conditions

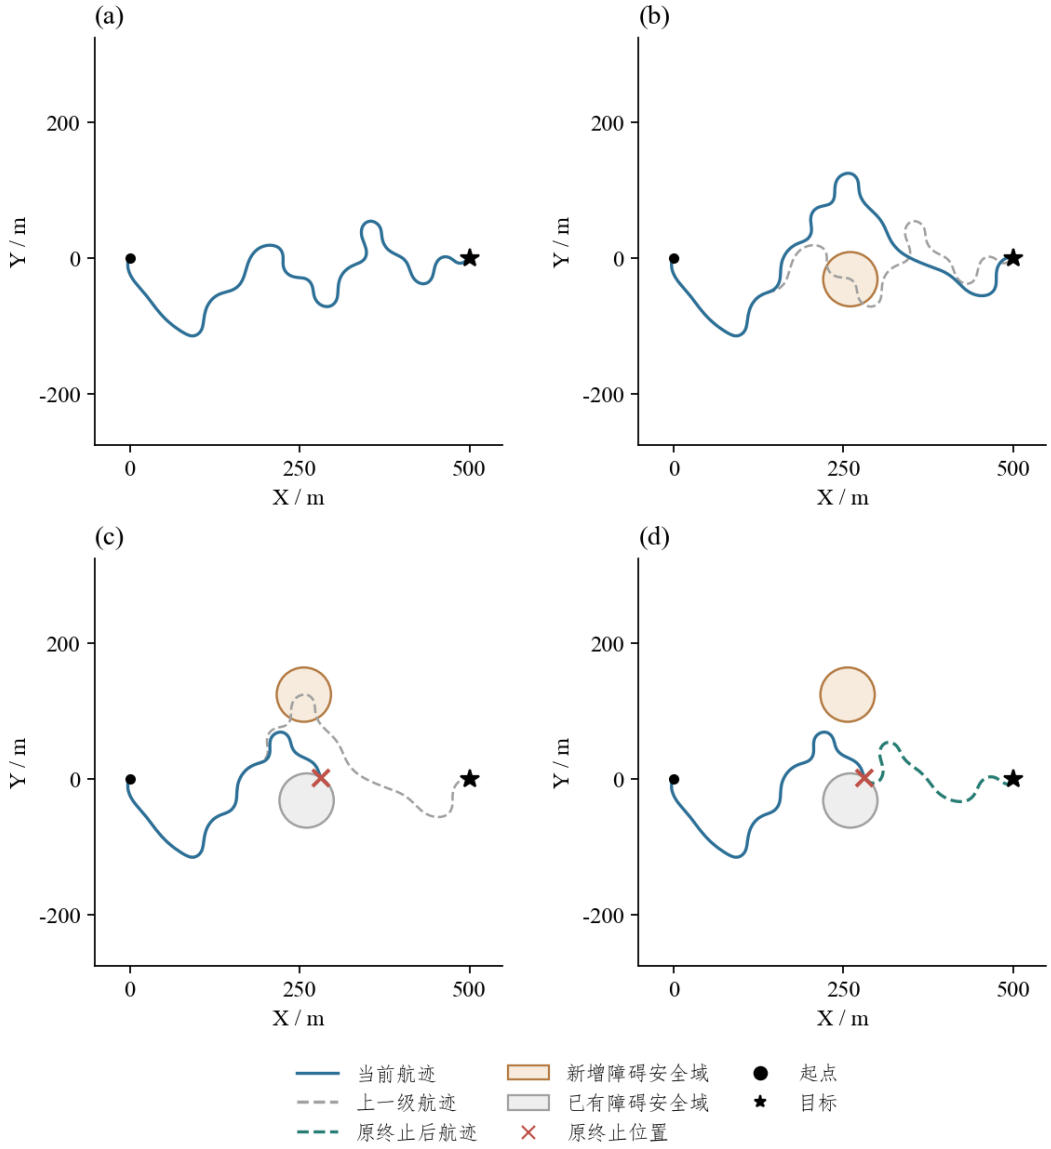


图 5.10 逆风递增障碍失败过程

Fig.5.10 The process of failure in increasing obstacles under headwind conditions

为进一步观察安全域侵入后的控制趋势，图 5.9(d)和图 5.10(d)在正式终止位置之后取消安全域终止条件，使原策略继续运行。需要说明的是，该部分延伸轨迹仅用于行为分析，不计入正式任务结果。从图中可以看出，部分回合在突破安全边界后，模型仍能够继续调整航迹并逐渐离开局部障碍区域，随后恢复向目标方向的航行。这说明部分正式失败主要体现为局部安全约束被突破，而非策略完全失去后续目标趋近能力。

综合上述案例可以看出，Attention 模型能够在原有航迹受到新增静态障碍约束后调整后续航行过程，并在顺风和逆风条件下形成相应的绕障行为；但当局部航行空间进一步受限时，这种调整能力仍存在明确边界。递增障碍实验由此从具

体航迹层面补充了前述统计结果，既展示了模型对局部障碍布局变化的适应过程，也反映了当前控制策略在安全约束较强场景中的失效特征。

5.3.4 时间注意力的作用分析

前述实验表明，基于时间注意力的历史信息融合方式能够改善静态障碍物任务中的综合控制性能，并且不同历史窗口长度会进一步影响模型的任务完成率和航行行为。然而，模型间的性能差异只能说明不同网络结构经过训练后形成的控制策略存在差异，并不能直接说明训练完成后的动态注意力权重是否实际参与了当前帆舵决策。为此，本节进一步针对最终采用的 Attention（K=10）模型，从障碍信息进入前后的权重变化、固定状态下的权重干预以及闭环航行干预三个层次分析时间注意力在控制过程中的作用。

（1）障碍信息输入前后的注意力变化

Attention 模型根据当前状态特征生成 Query，并对历史窗口中的 LSTM 隐藏状态进行动态加权。当新的障碍物首次进入策略观测后，当前决策所面对的局部环境发生变化，因此首先考察这一事件前后模型对不同时间位置历史信息的权重分配是否发生相应变化。

本文将障碍物观测字段首次由全零变为非零的决策时刻定义为 $t=0$。在该时刻，新获得的障碍信息立即参与当前状态编码和注意力 Query 计算；执行当前动作后，对应的观测—动作信息从下一决策步开始进入 LSTM 历史序列。为避免不同时间位置由不同航行回合组成，本节选取能够完整覆盖事件前 20 步至事件后 40 步的 585 个测试回合进行统计。

为描述时间注意力分布的变化，采用归一化熵、加权滞后和近期权重偏移三个指标。归一化熵反映各历史位置权重分布的集中程度，数值降低表示权重进一步向部分历史位置集中；加权滞后表示注意力权重对应历史信息距离当前决策时刻的平均时间距离，数值降低表示整体更加偏向近期历史；近期权重偏移则定义为最近 3 个历史位置的权重和减去均匀分配情况下的基准值 $3/K$。对于 $K=10$，均匀权重下该基准值为 0.3，因此近期权重偏移为正表示模型对最近 3 个历史位置给予了高于均匀分配的权重。

障碍首次进入观测前后的权重变化如图 5.11 所示，对事件前后各 10 个决策步的平均结果进一步汇总于表 5.6。

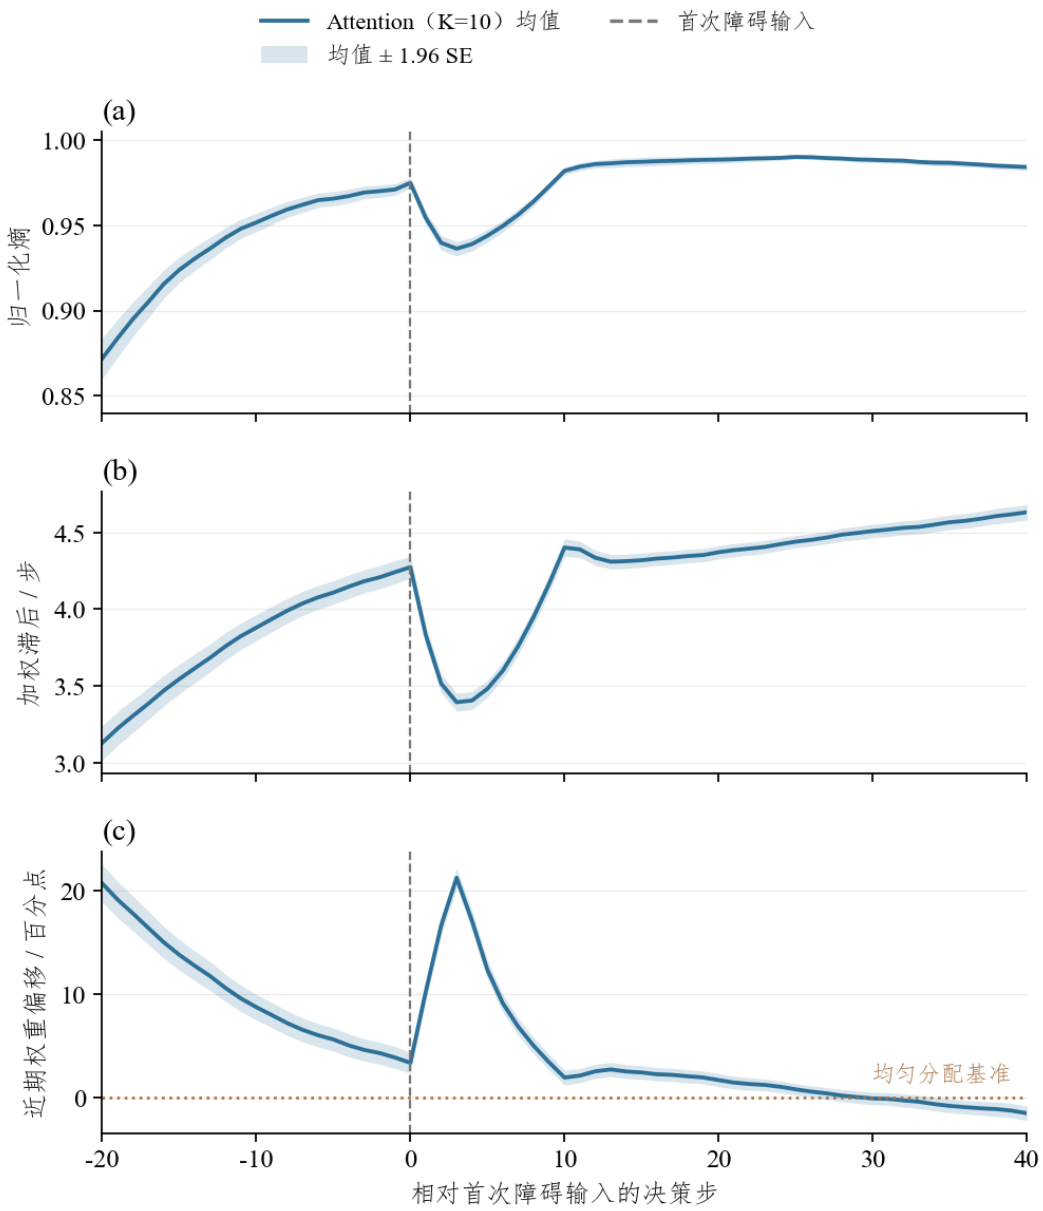


图 5.11 障碍物首次进入观测前后的注意力变化

Fig.5.11 The change in attention before and after the first appearance of the obstacle in the observation

表 5.6 障碍物首次进入观测前后注意力指标的平均变化

Table.5.6 The average change in attention indicators before and after the first appearance of the obstacle in the observation

指标	事件后 10 步相对事件前 10 步的平均变化
归一化熵	-0.0106
加权滞后 / 步	-0.3427
近期权重偏移	+0.0453

注：统计采用 K=10 Attention 模型的 585 个完整事件窗口，变化量均为事件后 10 步均

值减去事件前 10 步均值。

图 5.11 显示，障碍信息首次进入观测后，时间注意力在前几个控制步内出现了较明显的调整：归一化熵降低，加权滞后缩短，近期权重偏移上升，表明权重短时向较新的历史表示集中。随后，归一化熵和加权滞后逐渐回升，近期权重偏移回落，权重分布重新趋于分散。因此，这一变化体现为障碍信息进入前后的阶段性调整，而不是持续增加对近期历史的关注。

表 5.6 进一步给出了事件前后各 10 步的平均变化。事件后归一化熵降低 0.0106，加权滞后减少 0.3427 步，近期权重偏移增加 0.0453，与图中短时向近期历史偏移的趋势一致。上述结果表明，模型会伴随局部观测条件变化调整历史表示的相对权重，使不同时间位置的信息以不同方式参与当前决策。

（2）注意力权重离线干预

仅观察权重分布随事件发生变化，还不能判断这些差异是否真正影响 Actor 输出。为进一步检验动态时间权重是否参与帆舵动作生成，本节在保持网络参数、当前状态编码以及历史隐藏状态不变的条件下，对 Attention 权重进行离线干预。由于输入状态和历史表示均保持不变，此时动作输出的变化直接来源于历史信息汇聚方式的改变。

设置两种权重干预方式。第一种为均匀替换，即将原始动态权重全部替换为 $1/K$，使 10 个历史位置以相同权重参与上下文计算；第二种为权重置换，保留原始权重数值集合，但随机打乱权重与历史位置之间的对应关系。前者取消不同时间位置之间的动态权重差异，后者进一步改变各权重所对应的具体历史位置。离线分析不推进环境，仅比较同一输入条件下干预前后的 Actor 输出。

$K = 10$模型的离线干预结果如表 5.7 所示。

表 5.7 注意力权重离线干预下的归一化动作变化

Table.5.7 Normalized movement changes under offline intervention with attention weight adjustment

干预方式	归一化动作向量变化	帆指令绝对变化	舵指令绝对变化
均匀替换	0.0432	0.0222	0.0303
权重置换	0.0456	0.0241	0.0314

注：统计采用 K=10 Attention 模型；帆角和舵角指令均为 Actor 输出的归一化动作，动作向量变化采用干预前后二维动作的 L2 距离。

由表 5.7 可见，均匀替换和权重置换后的归一化动作向量平均变化分别为 0.0432 和 0.0456，两种干预均影响帆、舵两个动作分量。均匀替换改变了不同历史位置之间的相对权重，权重置换则改变了权重与历史表示的对应关系。两种情况下动作输出均发生变化，说明时间注意力的加权结果实际参与了历史上下文构造，并进一步影响当前帆舵动作的生成。

这一结果表明，时间注意力并非仅产生一个用于可视化的中间权重分布，其计算结果实际参与了历史上下文构造，并进一步影响 Actor 生成的帆舵动作。同时，权重置换同样引起动作变化，说明策略不仅利用不同历史信息的总体加权强度，权重与具体时间位置之间的对应关系也会影响当前控制输出。

（3）注意力权重闭环干预

离线干预能够检验权重变化是否影响瞬时动作，但单个时间步的动作变化并不能直接反映对完整航行过程的影响。因此，在离线分析基础上进一步开展闭环权重干预实验。采用固定的 $K = 10$ Attention 模型，在相同的 1000 个测试场景中分别执行原始动态权重和均匀权重两条控制分支。两条分支采用相同的初始状态、障碍物布局、风场序列及按时间索引的外部随机扰动；当历史窗口填满后，均匀权重分支持续以$1/K$替换原始 Attention 权重，并重新计算历史上下文和后续帆舵动作。

两种权重方式下的闭环结果汇总于表 5.8。

表 5.8 动态权重与均匀权重下的闭环航行表现

Table.5.8 The closed-loop navigation performance under dynamic weighting and uniform weighting conditions

指标	原始动态权重	均匀权重	变化差值
任务成功率 /%	95.1	94.8	-0.3
航行时间 / s	193.08	200.40	+7.31
航行距离 / m	607.66	615.47	+7.80
最小安全余量 / m	11.42	10.67	-0.74
帆角累计变化量 /°	186.01	212.10	+26.10
舵角累计变化量 /°	194.97	219.95	+24.99

注：任务成功率基于 1000 个配对测试场景；其余连续指标采用两种权重方式均成功的

916 个相同场景。差值均为均匀权重减去原始动态权重。

表 5.8 显示，原始动态权重与均匀权重的任务成功率分别为 95.1%和 94.8%，整体完成比例接近。结合两种权重方式共同成功的 916 个场景，可以得到 35 个场景仅原始动态权重成功、32 个场景仅均匀权重成功，其余 17 个场景均未成功。因此，改变历史权重分配会影响部分场景的任务结局，但两类相反变化使总体成功率差异保持较小。

在两种权重方式共同成功的场景中，采用均匀权重后，平均航行时间增加 7.31 s，航行距离增加 7.80 m，最小安全余量减少 0.74 m；帆角和舵角累计变化量分别增加 26.10°和 24.99°。这些结果表明，学习到的动态权重对成功航行过程具有实际作用，主要体现为较低的航行开销、较少的累计帆舵调节和略大的安全余量。

本组干预与 5.3.1 节的模型对比所考察的对象不同。Attention、Deep-LSTM 和 MeanPool 分别经过训练，其差异体现了不同历史融合结构参与学习后形成的整体策略表现；本组实验则固定同一 Attention 模型的网络参数，仅对在线注意力权重施加干预。两条控制分支在相同初始条件和外部扰动下分别闭环运行，各自的观测、历史隐藏状态与航迹随控制动作继续演化。因此，本组实验用于分析已训练策略中动态权重分配对后续航行过程的影响。

结合权重统计和离线干预结果，时间注意力在当前模型中形成了实际的历史选择性融合：障碍信息进入后，历史权重出现短时调整；改变权重及其与历史位置的对应关系会影响动作输出；在闭环航行中，动态加权的收益主要体现为更短的航时和航程、较少的累计调节及略大的安全余量。

5.4 本章小结

本章研究了无显式风场输入条件下无人帆船在静态障碍物环境中的局部帆舵控制问题。在第四章 SAC-LSTM 模型的基础上，扩展局部障碍物观测和距离惩罚，并引入由当前观测驱动的时间注意力，对历史隐藏状态进行选择性融合，使策略能够结合当前障碍几何关系与历史运动响应，协调目标推进和局部绕行。

对比实验表明，Attention 模型在 1000 个随机障碍场景中的任务成功率达到 95.5%，较 Deep-LSTM 和 MeanPool 分别提高 10.7 和 23.7 个百分点，安全域侵入次数相应减少。在各模型成功完成的回合中，Attention 同时具有较短的平均航

行时间和航程。窗口配置实验进一步表明，扩大历史范围并不必然改善控制表现；在所测试的三种统一窗口配置中，$K = 10$取得了较好的任务完成率与成功航行效率。

任务条件变化实验显示，Attention 在避障任务训练后保持了较高的无障碍任务完成率，但其航行时间和舵角调节较第四章模型有所增加。在 150 m 和 120 m 首次探测距离下，模型保持了较高的静态避障任务成功率；当探测距离缩短至 100 m 和 80 m 时，成功率明显下降，表明其控制表现受到障碍信息提前量的影响。递增障碍案例进一步展示了模型在顺风和逆风条件下调整航迹的过程，以及局部空间约束增强时的安全域侵入行为。

注意力作用分析表明，障碍信息首次进入观测后，历史权重出现短时向近期表示偏移的变化；固定输入下的权重替换和置换会改变帆舵动作输出。闭环干预进一步显示，动态权重对已训练策略的作用主要体现为改善成功航行过程中的效率、安全余量和累计调节表现。上述结果从整体任务性能和模型内部信息利用两个层面，说明了当前观测驱动的历史选择性融合在本文静态避障控制任务中的作用。

6 结论与展望

6.1 主要结论

1、历史观测—动作编码能够支持无显式风场输入的局部帆舵控制。本文围绕风速和风向不作为策略直接输入时的无人帆船局部航行问题，构建了融合当前观测与历史观测—动作信息的 SAC-LSTM 控制模型。随机风向测试中，该模型的任务成功率达到 99.36%，高于采用相同基础观测和奖励的 SAC-nowind 模型，并能够在顺风、横风及迎风相关工况下形成相应的帆舵控制行为。风向读出结果表明，LSTM 隐藏状态包含较当前观测更易提取的风向相关信息；历史截断结果进一步表明，历史构造会影响当前动作。上述结果说明，历史运动响应能够为无显式风场输入条件下的局部控制提供有效补充。

2、当前观测驱动的历史选择性融合改善了所测试静态障碍任务的综合表现。在静态障碍物环境中，本文通过扩展局部障碍观测和距离惩罚，并引入当前观测驱动的时间注意力，对历史隐藏状态进行选择性融合。在 1000 个随机障碍场景中，Attention 模型的任务成功率为 95.5%，高于 Deep-LSTM 和 MeanPool 模型，且在各自成功回合中具有较低的平均航时和航程。固定模型的权重干预表明，动态权重参与了帆舵动作生成，并影响部分场景的任务结局；在共同成功的场景中，其收益主要体现为降低航行开销和累计控制调节、保持较大的安全余量。上述结果说明，使用时间注意力的融合方式在设定的静态障碍任务中起到了综合表现优化的作用。

3、历史信息利用的收益具有明确的任务与观测条件。不同历史信息配置和观测条件会改变控制模型的性能。第五章的窗口实验中，$K = 10$在所测试的三种统一配置下取得较好的综合表现，扩大窗口并未持续提高任务完成能力。静态避障训练后的 Attention 模型保持了较高的无障碍任务完成率，但航行时间和舵角调节有所增加；当障碍物首次探测距离缩短至 100 m 和 80 m 时，其任务成功率明显下降，并低于相应条件下的 Deep-LSTM 模型。这些结果表明，历史选择性融合的作用需要与信息获取提前量、任务约束和训练配置相匹配，标准条件下的性能改善并不自动延伸到所有变化工况。

综上，本文在所采用的四自由度动力学和局部航行任务设定下，验证了历史观测—动作编码及选择性融合用于无显式风场输入帆舵控制的可行性，并分析了

其任务表现、信息利用特征及适用条件。研究形成了从基础目标航行到静态障碍物场景的连续方法验证，为后续面向模型差异、观测变化和实际平台的研究提供了依据。

6.2 本文创新点

本文的创新性主要体现在以下三个方面：

（1）构建面向无人帆船局部自主航行的端到端强化学习帆舵控制框架

无人帆船自主航行通常采用路径规划、制导与控制相互配合的分层架构，通过风场信息、航行性能模型及控制规则生成可执行的参考航路和帆舵控制量。作为对这一成熟技术路线的补充探索，本文将端到端强化学习方法引入无人帆船航迹点之间的局部自主航行，构建由船体观测和目标信息直接生成帆角、舵角调节量的连续控制框架。该方法不预先规定局部参考航向或待跟踪轨迹，而是使实际航迹由策略输出、帆舵执行和船体动力学之间的闭环交互共同形成，从而将局部航行决策与帆舵联合控制纳入统一的策略学习过程。仿真实验表明，该框架能够在不同风向条件下形成相应的目标航行行为，并能够进一步扩展至包含静态障碍物的局部航行任务，为无人帆船端到端自主控制提供了一种可行的研究路径。

（2）提出无显式风场输入条件下基于历史观测—动作信息的无人帆船控制方法

针对风速和风向不作为策略直接观测输入时形成的部分可观测控制问题，本文在 SAC 框架中引入 LSTM 时序编码结构，将无人帆船历史运动响应与此前帆舵动作共同用于当前决策，不设置独立的风场重构模块。对比实验表明，在相同无显式风场当前观测条件下，引入历史编码后模型在随机风向及迎风相关工况中的任务完成能力得到明显改善。进一步通过隐藏状态风向读出和历史截断分析发现，循环隐藏状态中包含可提取的风向相关信息，且历史信息的变化能够影响帆舵动作输出，从任务性能和内部信息利用两个层面验证了历史运动响应对部分可观测控制的作用。

（3）提出面向静态障碍物航行任务的当前状态驱动历史选择性融合方法。

针对静态障碍环境中目标推进、障碍规避和帆船动力学响应共同影响当前控制决策的问题，本文在 LSTM 时序编码基础上引入时间注意力机制，以当前观测特征构造查询信息，对不同历史隐藏状态进行动态加权，实现历史信息与当前航行情境之间的选择性融合。通过参数规模相近的 Deep-LSTM 和 MeanPool 模型

对照、不同历史窗口配置测试，以及注意力权重统计、离线权重干预和闭环干预，分别分析了历史融合结构的整体性能和动态权重在已训练策略中的实际作用。实验进一步表明，历史信息的利用并非时间范围越长越好，其效果与任务条件和障碍信息提前量存在明显关系。

6.3 未来展望

本研究取得了预期成果，由于作者专业知识与时间有限，仍然有一些方面可以进一步完善和深入探索：

1、从单层端到端控制向分层与安全约束强化学习拓展。本文采用单层端到端策略直接完成局部目标航行和帆舵控制，减少了显式制导与控制模块之间的中间接口，但策略内部决策过程缺少明确的任务层次和安全约束保证。第五章进一步表明，当障碍信息提前量不足时，模型仍可能发生安全域侵入。后续可在当前低层帆舵控制策略基础上，引入分层强化学习结构，由高层策略处理航迹点选择、换舷意图或局部避障模式，低层策略完成连续帆舵调节，从而将长时间尺度任务决策与短时间尺度运动控制适当分离。对于障碍距离、横摇角及执行器工作范围等安全要求，可进一步研究约束强化学习、安全过滤器或模型预测安全层，将安全约束从奖励塑形中独立出来，在保留学习策略适应能力的同时提高约束满足能力。

2、从统一数值模型走向系统化 Sim-to-Real 验证。本文当前训练与测试均建立在统一的四自由度无人帆船模型上，主要考察控制方法在受控动力学条件下的有效性。实际平台中仍存在船体参数偏差、气水动力模型误差、风浪流耦合、执行器迟滞与死区，以及传感器偏置、时延和数据缺失等 Sim-to-Real 差异。后续研究可首先结合实船航行数据开展关键动力学参数与执行器特性的辨识，并在仿真训练阶段对质量、惯量、气水动力系数、风场参数、传感器噪声和执行延迟等因素进行合理范围的域随机化；随后按照数值仿真、硬件在环和受控水域实船试验逐级验证策略性能。在获得少量真实航行数据后，还可进一步研究域适应、残差修正或安全约束下的策略微调，以缩小统一仿真模型与真实平台之间的性能差异。

3、从固定历史编码与局部任务走向长期部分可观测决策。第四、第五章主要采用 LSTM 及固定长度时间注意力进行历史信息建模。实验表明，历史信息能够

支持无显式风场输入控制，但不同窗口配置并未呈现随历史范围增加而持续改善的趋势，同时当前窗口参数还同时影响训练展开长度和注意力读取范围。后续可分别研究训练展开、在线记忆和注意力时间范围的作用，并根据风场变化速度、障碍信息出现及换舷过程动态调整历史信息的保留与读取方式。在此基础上，可进一步比较循环记忆、显式隐状态估计以及基于预测模型的状态表征方式，研究策略是否能够形成对隐藏环境状态及未来运动趋势更加稳定的内部表示。

在任务层面，后续还应由单航迹点和静态障碍逐步扩展至动态障碍、多航迹点及更长时间尺度的连续任务，并采用多组独立训练、跨船体参数和未见环境分布开展验证，以区分特定训练策略的表现与方法本身的可重复性和泛化能力。

参考文献

[1] 冷疏影, 朱晟君, 李薇, 等. 从“空间”视角看海洋科学综合发展新趋势[J]. 科学通报, 2018, 63(31): 3167-3183.

[2] 卢晓亭, 俞建成, 孙朝阳, 等. 基于海洋机器人的科学观测与实验系统研究现状与展望[J]. 海洋技术学报, 2023, 42(4): 107-120.

[3] MOGIAS A, BOUBONARI T, KEVREKIDIS T. Examining the presence o f ocean literacy principles in Greek primary school textbooks[J]. Internation al Research in Geographical and Environmental Education, 2021, 30(4): 31 4-331.

[4] 俞建成, 孙朝阳, 张艾群. 无人帆船研究现状与展望[J]. 机械工程学报, 201 8, 54(24): 98-110.

[5] CHAI F, JOHNSON K S, CLAUSTRE H, et al. Monitoring ocean biogeoc hemistry with autonomous platforms[J]. Nature Reviews Earth & Environm ent, 2020, 1(6): 315-326.

[6] VERFUSS U K, ANICETO A S, HARRIS D V, et al. A review of unma nned vehicles for the detection and monitoring of marine fauna[J]. Marine Pollution Bulletin, 2019, 140: 17-29.

[7] SILVA A, MATOS A, SOARES C, et al. Measuring underwater noise with high endurance surface and underwater autonomous vehicles[C]//OCEANS 2013 MTS/IEEE San Diego. Piscataway, NJ: IEEE, 2013: 1-6.

[8] ABRIL J, SALOM J, CALVO O. Fuzzy control of a sailboat[J]. Internatio nal Journal of Approximate Reasoning, 1997, 16(3-4): 359-375.

[9] SAILDRONE. Saildrone completes first autonomous circumnavigation of A ntarctica[EB/OL]. (2019-08-05)[2026-09-21]. https://www.saildrone.com/news/unmanned-vehicle-completes-antarctica-circumnavigation.

[10] RICCIARDULLI L, FOLTZ G R, MANASTER A, et al. Assessment of S aildrone extreme wind measurements in Hurricane Sam using MW satellite sensors[J]. Remote Sensing, 2022, 14(12): 2726.

[11] OCEAN AERO. Revolutionary reef restoration[EB/OL]. [2026-09-21]. https://www.oceanaero.com/thoughts/reefrestoration.

[12] “海鸥”号海洋观测无人帆船完成首次海上试验[J]. 军民两用技术与产品, 2019(11): 66.

[13] SUN Z, FENG A, YU J, et al. Development of autonomous sailboat sails and future perspectives: A review[J]. Renewable and Sustainable Energy Reviews, 2025, 207: 114918.

[14] 安洋. 面向航速最优的无人帆船设计与优化方法研究[D]. 沈阳: 中国科学院大学(中国科学院沈阳自动化研究所), 2023.

[15] 浙江大学. 海洋气象史首次！浙大“信天翁”穿越台风眼[EB/OL]. (2025-07-30)[2026-09-21]. https://www.zju.edu.cn/2025/0730/c76700a3072228/page.htm.

[16] YASUKAWA H, YOSHIMURA Y. Introduction of MMG standard method for ship maneuvering predictions[J]. Journal of Marine Science and Technology, 2015, 20(1): 37-52.

[17] JAULIN L. Modélisation et commande d’un bateau à voile[C]//CIFA 2004: Conférence Internationale Francophone d’Automatique. Douz, Tunisia, 2004.

[18] SLOOFF J W. The aero- and hydromechanics of keel yachts[M]. Cham: Springer, 2015.

[19] XIAO L, JOUFFROY J. Modeling and nonlinear heading control of sailing yachts[J]. IEEE Journal of Oceanic Engineering, 2014, 39(2): 256-268.

[20] FOSSEN T I. Guidance and control of ocean vehicles[M]. Chichester: John Wiley & Sons, 1994.

[21] FOSSEN T I. Marine control systems: Guidance, navigation and control of ships, rigs and underwater vehicles[M]. Trondheim: Marine Cybernetics, 2002.

[22] FOSSEN T I. Handbook of marine craft hydrodynamics and motion control[M]. Chichester: John Wiley & Sons, 2011.

[23] 荆纬, 李浩, 咸琳涛, 等. 基于强化学习的自动帆船路径规划算法研究[J]. 中国海洋大学学报(自然科学版), 2021, 51(8): 79-87.

[24] KERWIN J E. A velocity prediction program for ocean racing yachts: Rep ort No. 78-11[R]. Cambridge, MA: Massachusetts Institute of Technology, Department of Ocean Engineering, 1978.

[25] ROUX Y, HUBERSON S, HAUVILLE F, et al. Yacht performance predicti on: Towards a numerical VPP[C]//Proceedings of the 1st High Performance Yacht Design Conference. Auckland, New Zealand, 2002: 213-220.

[26] ROUX Y, DURAND M, LEROYER A, et al. Strongly coupled VPP and CFD RANSE code for sailing yacht performance prediction[C]//Proceedings of the 3rd High Performance Yacht Design Conference. Auckland, New Ze aland, 2008.

[27] AN Y, YU J, HU F, et al. Towards a general design evaluation tool: The development and validation of a VPP for autonomous sailing monohulls[J]. Applied Ocean Research, 2022, 120: 103053.

[28] BINGHAM B, AGÜERO C, MCCARRIN M, et al. Toward maritime robot ic simulation in Gazebo[C]//OCEANS 2019 MTS/IEEE Seattle. Piscataway, NJ: IEEE, 2019: 1-10.

[29] PARAVISI M, SANTOS D H, JORGE V, et al. Unmanned surface vehicle simulator with realistic environmental disturbances[J]. Sensors, 2019, 19(5): 1068.

[30] TIPSUWAN Y, SANPOSH P, TECHAJAROONJIT N. Overview and contro l strategies of autonomous sailboats—a survey[J]. Ocean Engineering, 2023, 281: 114879.

[31] SANTOS D H, SILVA JUNIOR A G, NEGREIROS A P F, et al. Design and implementation of a control system for a sailboat robot[J]. Robotics, 2 016, 5(1): 5.

[32] SILVA JUNIOR A G, SANTOS D H, NEGREIROS A P F, et al. High-lev el path planning for an autonomous sailboat robot using Q-learning[J]. Sen sors, 2020, 20(6): 1550.

[33] LANGBEIN J, STELZER R, FRÜHWIRTH T. A rule-based approach to lo ng-term routing for autonomous sailboats[C]//Robotic Sailing: Proceedings o

f the 4th International Robotic Sailing Conference. Berlin, Heidelberg: Spri nger, 2011: 195-204.

[34] YUAN S, ZHU Z, XUE Y, et al. Path planning for unmanned sailboats us ing improved potential field and A* algorithm[C]//OCEANS 2024—Singapo re. Piscataway, NJ: IEEE, 2024: 1-7.

[35] SAOUD H, HUA M D, PLUMET F, et al. Routing and course control of an autonomous sailboat[C]//2015 European Conference on Mobile Robots. Piscataway, NJ: IEEE, 2015: 1-6.

[36] SIDOTI D, PATTIPATI K R, BAR-SHALOM Y. Minimum-time sailing boa t path algorithm[J]. IEEE Journal of Oceanic Engineering, 2023, 48(2): 307 -322.

[37] 邓英杰, 王博, 徐艺菲, 等. 基于改进 RRT*算法的无人帆船自适应路径规划 [J]. 大连海事大学学报, 2025, 51(4): 22-30.

[38] NIAN R, SHEN Z, DING W. Research on global path planning of unman ned sailboat based on improved ant colony optimization[C]//2021 6th Intern ational Conference on Automation, Control and Robotics Engineering. Pisca taway, NJ: IEEE, 2021: 428-432.

[39] SHEN Z, DING W, LIU Y, et al. Path planning optimization for unmanne d sailboat in complex marine environment[J]. Ocean Engineering, 2023, 26 9: 113475.

[40] GONG Y, LUO M, WANG C, et al. A path planning method based on im proved particle swarm optimization algorithm[C]//2020 7th International Co nference on Information Science and Control Engineering. Piscataway, NJ: IEEE, 2020: 106-110.

[41] LIU L, WANG C, GAO H, et al. High-level path planning of unmanned s ailboat for sailing championship and innovative education[C]//2022 IEEE In ternational Conference on Unmanned Systems. Piscataway, NJ: IEEE, 2022: 1557-1562.

[42] SUDA T, NIKOVSKI D. Deep reinforcement learning for optimal sailing upwind[C]//2022 International Joint Conference on Neural Networks. Piscataway, NJ: IEEE, 2022: 1-8.

[43] PÊTRÈS C, ROMERO-RAMIREZ M A, PLUMET F. A potential field approach for reactive navigation of autonomous sailboats[J]. Robotics and Autonomous Systems, 2012, 60(12): 1520-1527.

[44] PLUMET F, SAOUD H, HUA M D. Line following for an autonomous sailboat using potential fields method[C]//2013 MTS/IEEE OCEANS—Bergen. Piscataway, NJ: IEEE, 2013: 1-6.

[45] 康梦萁, 许劲松, 徐建云, 等. 无人帆船短途路径规划研究[J]. 船舶工程, 2016, 38(9): 1-5.

[46] 项天远, 张延伟, 谭华, 等. 基于概率势场的无人帆船实时路径规划研究[J]. 国外电子测量技术, 2020, 39(5): 17-22.

[47] 袁鹏, 徐泓燊, 张雪飞, 等. 基于速度选择切换型视线法的无人帆船循迹航行[J]. 中国舰船研究, 2020, 15(1): 31-37.

[48] 刘方成, 邓英杰, 徐艺菲, 等. 基于 DDPG 制导的无人帆船路径跟踪控制[J]. 燕山大学学报, 2026, 50(3): 231-240.

[49] AN Y, YU J, ZHANG J. Autonomous sailboat design: A review from the performance perspective[J]. Ocean Engineering, 2021, 238: 109753.

[50] JAULIN L, LE BARS F. A simple controller for line following of sailboats[C]//Robotic Sailing 2012: Proceedings of the 5th International Robotic Sailing Conference. Berlin, Heidelberg: Springer, 2013: 117-129.

[51] PLUMET F, PÊTRÈS C, ROMERO-RAMIREZ M A, et al. Toward an autonomous sailing boat[J]. IEEE Journal of Oceanic Engineering, 2015, 40(2): 397-407.

[52] 张雪飞, 袁鹏, 谭俊哲, 等. 基于模糊 PID 的无人帆船航向控制方法[J]. 中国舰船研究, 2019, 14(6): 15-21.

[53] HERRERO P, JAULIN L, VEHÍ J, et al. Guaranteed set-point computation with application to the control of a sailboat[J]. International Journal of Control, Automation and Systems, 2010, 8(1): 1-7.

[54] WILLE K L, HASSANI V, SPRENGER F. Modeling and course control o f sailboats[J]. IFAC-PapersOnLine, 2016, 49(23): 532-539.

[55] ZHANG G, LI J, LI B, et al. Improved integral LOS guidance and path-f ollowing control for an unmanned robot sailboat via the robust neural dam ping technique[J]. The Journal of Navigation, 2019, 72(6): 1378-1398.

[56] DONG Y, WU N, QI J, et al. Predictive course control and guidance of a utonomous unmanned sailboat based on efficient sampled Gaussian process [J]. Journal of Marine Science and Engineering, 2021, 9(12): 1420.

[57] ABROUGUI H, NEJIM S, DALLAGI H. Modeling and autopilot design fo r an autonomous catamaran sailboat based on feedback linearization[C]//201 9 International Conference on Advanced Systems and Emergent Technologi es. Piscataway, NJ: IEEE, 2019: 130-135.

[58] 邵康健, 刘道发. 基于漂角观测的无人帆船反步自适应控制[J]. 现代电子技术, 2025, 48(3): 129-134.

[59] PÊTRÈS C, ROMERO-RAMIREZ M A, PLUMET F, et al. Modeling and reactive navigation of an autonomous sailboat[C]//2011 IEEE/RSJ Internatio nal Conference on Intelligent Robots and Systems. Piscataway, NJ: IEEE, 2011: 3571-3576.

[60] SHEN Z, WANG S, YU H, et al. Online speed optimization with feedfor ward of unmanned sailboat via extremum seeking without steady-state oscil lation[J]. Ocean Engineering, 2019, 189: 106393.

[61] LIU K, SUN Z, QU Y, et al. Research on key methods of autonomous sa ilboat's position-keeping control[C]//OCEANS 2022—Chennai. Piscataway, NJ: IEEE, 2022: 1-6.

[62] DENG Y J, ZHANG X K, ZHANG G Q. Fuzzy logic based speed optimi zation and path-following control for sail-assisted ships[J]. Ocean Engineeri ng, 2019, 171: 300-310.

[63] WIRZ J, TRANZATTO M, LINIGER A, et al. AEOLUS, the ETH autono mous model sailboat[C]//Robotic Sailing 2015: Proceedings of the 8th Inter national Robotic Sailing Conference. Cham: Springer, 2016: 103-112.

[64] SUN Q, QIAO Z, STRÖMBECK C, et al. Tacking control of an autonomous sailboat based on force polar diagram[C]//2018 13th World Congress on Intelligent Control and Automation. Piscataway, NJ: IEEE, 2018: 467-473.

[65] LIU S, YU Z, WANG T, et al. MPC-based collaborative control of sail and rudder for unmanned sailboat[J]. Journal of Marine Science and Engineering, 2023, 11(2): 460.

[66] 贾金恒, 黄琰, 赵文涛, 等. 基于模型预测控制的无人帆船轨迹跟踪方法[J]. 中国舰船研究, 2024, 19(1): 145-157.

[67] CHEN Y, LIU S, WANG T, et al. Sail-rudder collaborative control of unmanned sailboat based on reinforcement learning[C]//OCEANS 2024—Singapore. Piscataway, NJ: IEEE, 2024: 1-6.

[68] 谢天, 王博, 邓英杰, 等. 基于深度学习的无人帆船帆-舵联合航路点跟踪控制[J]. 中国舰船研究, 2026, 21(3): 245-254.

[69] LAURI M, HSU D, PAJARINEN J. Partially observable Markov decision processes in robotics: A survey[J]. IEEE Transactions on Robotics, 2023, 39(1): 21-40.

[70] HEESS N, HUNT J J, LILLICRAP T P, et al. Memory-based control with recurrent neural networks[EB/OL]. (2015)[2026-09-21]. https://arxiv.org/abs/1512.04455.

[71] NI T, EYSENBACH B, SALAKHUTDINOV R. Recurrent model-free RL can be a strong baseline for many POMDPs[C]//Proceedings of the 39th International Conference on Machine Learning. PMLR, 2022, 162: 16691-16723.

[72] SLIWKA J, NICOLA J, COQUELIN R, et al. Sailing without wind sensor and other hardware and software innovations[C]//Robotic Sailing: Proceedings of the 4th International Robotic Sailing Conference. Berlin, Heidelberg: Springer, 2011: 27-38.

[73] XIAO K, SLIWKA J, JAULIN L. A wind-independent control strategy for autonomous sailboats based on Voronoi diagram[C]//Field Robotics: Proceed

ings of the 14th International Conference on Climbing and Walking Robots and the Support Technologies for Mobile Machines. Singapore: World Scientific, 2011: 110-124.

[74] CABRERA-GÁMEZ J, DOMÍNGUEZ-BRITO A C, HERNÁNDEZ-SOSA J D, et al. A virtual wind sensor based on a particle filter[C]//Robotic Sailing 2016: Proceedings of the 9th International Robotic Sailing Conference. Cham: Springer, 2016: 69-78.

[75] 何成龙, 迟书凯, 宇文国朴, 等. 基于数据融合的无人帆船真风计算方法[J]. 水下无人系统学报, 2024, 32(1): 66-78.

[76] SUN Q, QI W, QIAN H. MoWe: Motion observation for wind estimation of sailing robots[J]. Journal of Field Robotics, 2025, 42(5): 2355-2374.

[77] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[78] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems. 2017, 30: 5998-6008.

[79] SUTTON R S, BARTO A G. Reinforcement learning: An introduction[M]. Cambridge, MA: MIT Press, 1998.

[80] WATKINS C J C H, DAYAN P. Q-learning[J]. Machine Learning, 1992, 8 (3-4): 279-292.

[81] RUMMERY G A, NIRANJAN M. On-line Q-learning using connectionist systems: Technical Report CUED/F-INFENG/TR 166[R]. Cambridge: University of Cambridge, Department of Engineering, 1994.

[82] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[83] SUTTON R S, MCALLESTER D, SINGH S, et al. Policy gradient methods for reinforcement learning with function approximation[C]//Advances in Neural Information Processing Systems. 1999, 12: 1057-1063.

[84] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[EB/OL]. (2015)[2026-09-21]. https://arxiv.org/abs/1509.02971.

[85] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[EB/OL]. (2017)[2026-09-21]. https://arxiv.org/abs/1707.06347.

[86] FUJIMOTO S, VAN HOOF H, MEGER D. Addressing function approximation error in actor-critic methods[C]//Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018, 80: 1587-1596.

[87] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018, 80: 1861-1870.

[88] HAARNOJA T, ZHOU A, HARTIKAINEN K, et al. Soft actor-critic algorithms and applications[EB/OL]. (2018)[2026-09-21]. https://arxiv.org/abs/1812.05905.

[89] LIN L J. Self-improving reactive agents based on reinforcement learning, planning and teaching[J]. Machine Learning, 1992, 8(3-4): 293-321.

[90] VAN HASSELT H. Double Q-learning[C]//Advances in Neural Information Processing Systems. 2010, 23: 2613-2621.

[91] DORMAND J R, PRINCE P J. A family of embedded Runge-Kutta formulae[J]. Journal of Computational and Applied Mathematics, 1980, 6(1): 19-26.

作者简历

1 教育经历

2018.09-2022.06	浙江大学	本科
2023.09-2026.12	浙江大学	硕士

2 科研成果

（1）期刊论文

Learning to sail without wind information: reinforcement learning-based control for unmanned sailing vessels under partial observability, Applied Ocean Research（已发表，第一作者）

（2）发明专利

一种基于深度强化学习算法的无人帆船避障航行控制方法（实质审查，第二发明人）

3 项目经历

4 在校荣誉